

# Series de Tiempo


VI Semestre

Grupo: B

Mtr. Alcides Ramos Calcina  
FINESI

**MODELOS ARMA**  
Modelos Autorregresivo (AR)  
y Medias Móviles (MA)

# 5. Modelo Lineal General



- La metodología de la **modelización univariante** es sencilla. Dado que el objetivo es explicar el valor que toma en el momento  $t$  una variable de interés que presenta **dependencia temporal**, una forma de trabajar es recoger información sobre el pasado de la variable, observar su evolución en el tiempo y explotar el patrón de regularidad que muestran los datos.
- Este procedimiento se hará operativo mediante los modelos **ARMA** que son una aproximación a la estructura teórica general.
- El modelo de series temporales univariante se descompone:

$$Y_t = \underbrace{PS}_t + \underbrace{a}_t \quad t = 1, 2, 3, \dots$$

Parte que recoge el patrón de regularidad, o parte sistemática

Parte puramente aleatoria  
(Ruido blanco)

# 5. Modelo Lineal General



- El modelo teórico:


$$Y_t = f(Y_{t-1}, Y_{t-2}, Y_{t-3}, \dots) + a_t \quad t = 1, 2, 3, \dots$$

donde se exige que el comportamiento de  $Y_t$  sea función de sus valores pasados, posiblemente infinitos.

- Dentro de los **procesos estocásticos estacionarios** se considerará únicamente la clase de procesos lineales que se caracterizan porque se pueden representar como una combinación lineal de variables aleatorias.
- En el caso de los procesos estacionarios con distribución normal y media cero, bajo condiciones muy generales,  $Y_t$  se puede expresar como:

$$Y_t = \pi_1 Y_{t-1} + \pi_2 Y_{t-2} + \pi_3 Y_{t-3} + \dots + a_t \quad t = 1, 2, 3, \dots \quad (I)$$

# 5. Modelo Lineal General



- Las condiciones generales que ha de cumplir el proceso son:

a) El proceso sea **no anticipante**.

El presente no venga determinado por el futuro, luego el valor de  $Y$  en el momento  $t$  no puede depender de valores futuros de  $Y$  o de las innovaciones  $a$ .

b) El proceso sea **invertible**.

El presente dependa de forma convergente de su propio pasado lo que implica que la influencia de  $Y_{t-k}$  en  $Y_t$  ha de ir disminuyendo conforme nos alejemos en el pasado. Si y solo si se cumple:

$$\sum_{i=1}^{\infty} \pi_i^2 < \infty$$

- El modelo (I) se puede escribir de forma más compacta en términos del operador de retardos:


$$Y_t = \pi_1 L Y_t + \pi_2 L^2 Y_t + \pi_3 L^3 Y_t + \dots + a_t$$

$$Y_t = (\pi_1 L + \pi_2 L^2 + \pi_3 L^3 + \dots) Y_t + a_t$$

$$Y_t - (\pi_1 L + \pi_2 L^2 + \pi_3 L^3 + \dots) Y_t = a_t$$

$$(1 - \pi_1 L - \pi_2 L^2 - \pi_3 L^3 - \dots) Y_t = a_t \quad \Rightarrow \quad \boxed{\Pi_{\infty}(L) Y_t = a_t}$$

# 5. Modelo Lineal General



- Otra forma alternativa de escribir el modelo (I) es:

$$Y_t = \frac{1}{\Pi_{\infty}(L)} a_t = \Psi_{\infty}(L) a_t = (1 + \psi_1 L + \psi_2 L^2 + \psi_3 L^3 + \dots) a_t$$


$$Y_t = a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \psi_3 a_{t-3} + \dots \quad t = 1, 2, 3, \dots \quad (\text{II})$$

- Es decir, el valor  $Y_t$  se puede representar como la combinación lineal del ruido blanco  $a_t$  y su pasado infinito.
- El modelo (II) cumple la **condición de estacionariedad** si los parámetros del modelo satisfacen la siguiente restricción:

$$\sum_{i=1}^{\infty} \psi_i^2 < \infty$$

- Tanto la representación (I) como la (II) son igualmente válidas para los procesos estocásticos estacionarios  $\Leftrightarrow$  cumplen las dos condiciones antes mencionadas, o sea que el modelo sea **no anticipante** e **invertible**.

# 5. Modelo Lineal General



- Será necesario simplificar las formulaciones del modelo general (I) y/o (II) de forma que tengan un número finito de parámetros.

$$\Pi_{\infty}(L) \simeq \frac{\phi_p(L)}{\theta_q(L)}$$

donde  $\phi_p(L)$  y  $\theta_q(L)$  son polinomios en el operador de retardos finitos de orden  $p$  y  $q$ , respectivamente:


$$\phi_p(L) = 1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p$$

$$\theta_q(L) = 1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_q L^q$$

- Sustituyendo en el modelo (I), se obtiene:

$$\Pi_{\infty}(L) Y_t \simeq \frac{\phi_p(L)}{\theta_q(L)} Y_t = a_t \quad \Rightarrow \quad \boxed{\phi_p(L) Y_t = \theta_q(L) a_t}$$

# 5. Modelo Lineal General



- Por lo tanto, el modelo lineal general admite tres representaciones, todas igualmente válidas bajo los supuestos señalados:

$$\phi_p(L)Y_t = \theta_q(L)a_t$$

$$(1 - \phi_1 L - \phi_2 L^2 - \dots - \phi_p L^p)Y_t = (1 - \theta_1 L - \theta_2 L^2 - \dots - \theta_q L^q)a_t$$

$$Y_t = \underbrace{\phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \dots + \phi_p Y_{t-p}}_{\text{parte autorregresiva}} + \underbrace{a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \dots - \theta_q a_{t-q}}_{\text{parte medias móviles}}$$


$AR(p)$

$MA(q)$

$\underbrace{\hspace{15em}}_{\text{Representación finita}}$ 
 $ARMA(p, q)$

- Esta formulación finita es una representación más restringida que las representaciones generales (I)-(II).

# 5. Modelo Lineal General



- Dos casos particulares del modelo  $ARMA(p, q)$  de gran interés son:
  - **$AR(p)$** . Modelo que sólo presenta parte autorregresiva, es decir, el polinomio de medias móviles es de orden 0:

$$Y_t = AR(p)$$



$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + a_t$$

- **$MA(q)$** . Modelo que sólo presenta parte medias móviles, es decir, el polinomio autorregresivo es de orden 0:

$$Y_t = MA(q)$$



$$Y_t = a_t - \theta_1 a_{t-1} + \theta_2 a_{t-2} + \cdots + \theta_q a_{t-q}$$

- Los modelos  $ARMA(p, q)$ ,  $AR(p)$  y  $MA(q)$  son aproximaciones al modelo lineal general. Comenzaremos por caracterizar sus **funciones de autocorrelación** para conocer sus propiedades y posteriormente utilizarlos para **modelar series** y **predecir**.





## 6. Modelo Autorregresivo (AR)

- Un modelo autorregresivo de orden  $p$ , o abreviadamente un modelo  $AR(p)$ , se define de la siguiente forma:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + a_t$$

Donde:

$\phi_1, \phi_2, \dots, \phi_p$  son los parámetros constantes del modelo  
 $a_t$ , es una variable “ruido blanco”  
 $\phi_1(L)$ , polinomio autorregresivo

- A continuación se van analizar las características de los modelos  $AR(1)$  y  $AR(2)$ .

### Modelo $AR(1)$

- Un modelo  $AR(1)$  viene definido por:

$$Y_t = \phi_1 Y_{t-1} + a_t$$


- En términos de operador de retardos,

$$(1 - \phi L) Y_t = a_t \quad \longrightarrow \quad \phi(L) Y_t = a_t$$


# Modelo $AR(1)$



- La estructura de correlación temporal representada por el modelo  $AR(1)$  es como sigue:



- Es importante mencionar con respecto a la constante  $\phi_1$  la cual debe estar comprendida en el rango  $[-1, 1]$ , indicando:
  - ❖ Si  $\phi_1 > 0$ , la variable  $Y_t$  depende de su retardo anterior de forma **proporcional**.
  - ❖ Si  $\phi_1 < 0$ , la variable  $Y_t$  depende de su retardo anterior de forma **inversamente proporcional**.
  - ❖ Si  $\phi_1 = 0$ , la variable  $Y_t$  **no depende** de su retardo anterior.



# Modelo $AR(1)$

## Condiciones de estacionariedad

a) **Media:**  $E(Y_t) = \frac{0}{1 - \phi} = 0$  con parámetro  $\phi \neq 1$

Si en el modelo se incluye una constante (intercepto), se obtendrá que:  $Y_t = \delta + \phi_1 Y_{t-1} + a_t$

entonces,  $E(Y_t) = E(Y_{t-1}) = \mu$  se verifica que  $\mu = \frac{\delta}{1 - \phi}$

b) **Varianza:**  $\gamma_0 = \frac{\sigma^2}{1 - \phi^2}$

Para que el proceso sea estacionario, varianza constante y finita, es necesario que  $|\phi| < 1$ .

# Modelo $AR(1)$



La función de **autocovarianzas** de un proceso  $AR(1)$  estacionario es:


$$\gamma_k = \begin{cases} \sigma^2 & k = 0 \\ 1 - \phi^2 & k > 0 \\ \phi \gamma_{k-1} & k > 0 \end{cases}$$

c) Los coeficientes de autocorrelación:

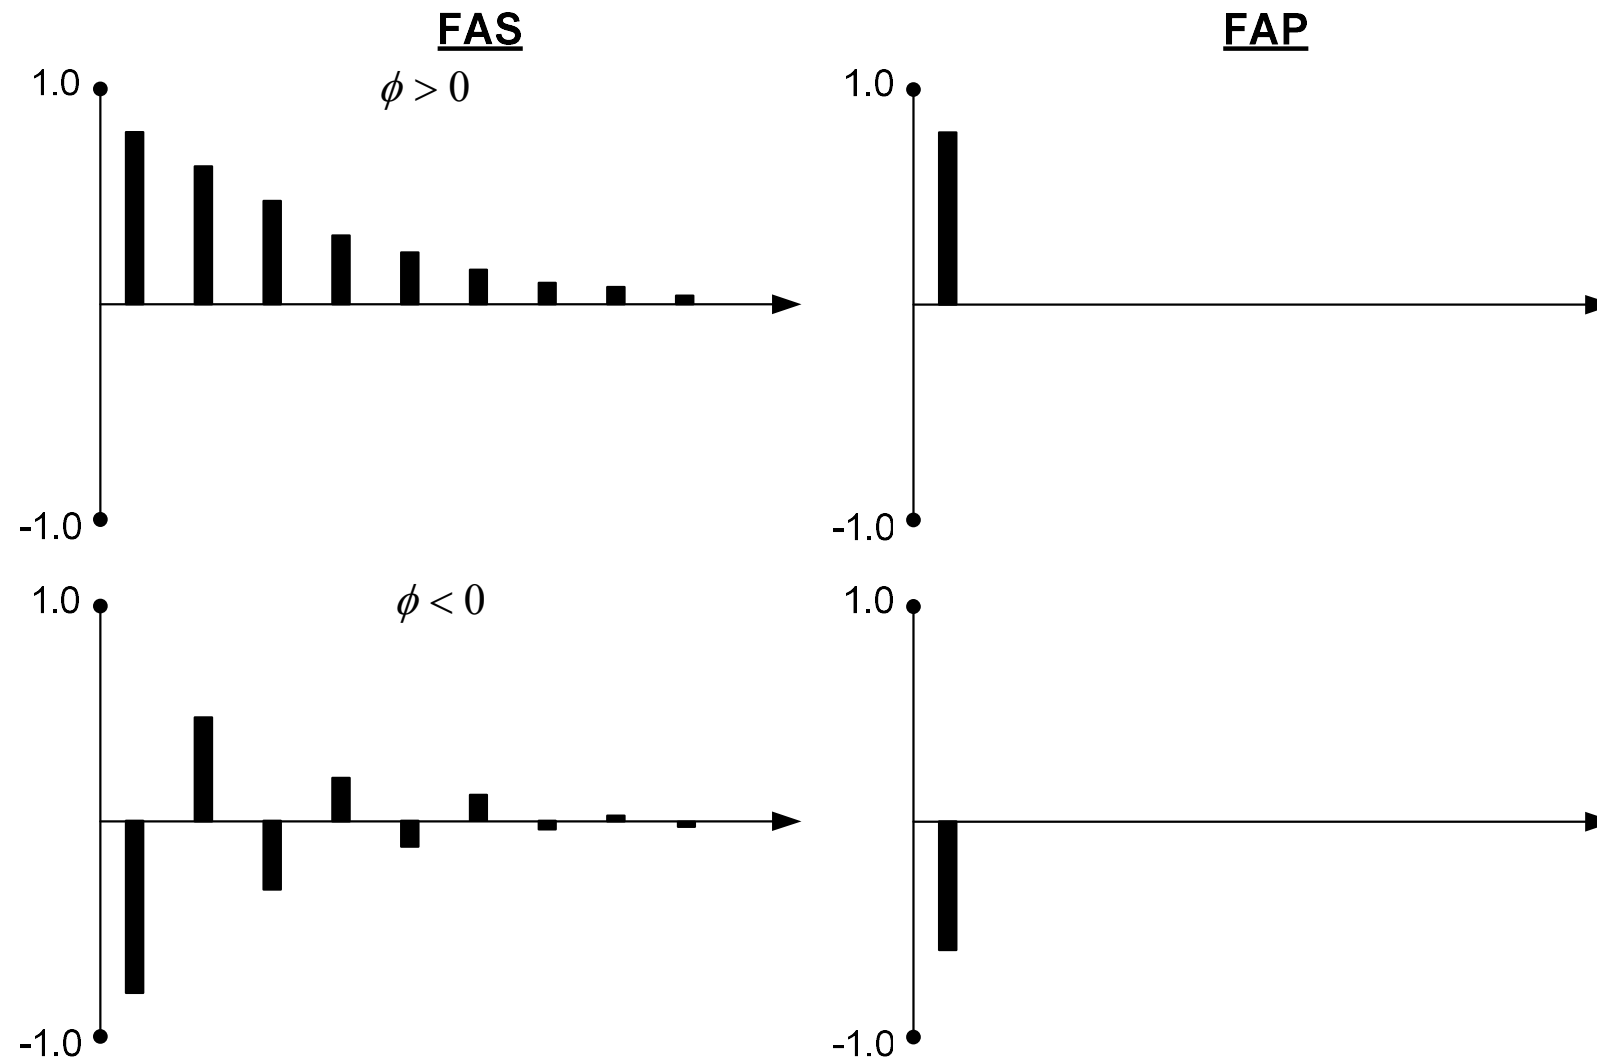
$$\rho_k = \begin{cases} 1 & k = 0 \\ \phi \rho_{k-1} & k > 0 \end{cases}$$


Para distinguir si un proceso es autorregresivo o no, así como su orden, se recurre a las **funciones de autocorrelación simple (FAS) y parcial (FAP)**, como se muestra en la siguiente figura.

# Modelo $AR(1)$



Funciones de autocorrelación simple y parcial para procesos  $AR(1)$ .





## 6. Modelo Autorregresivo (AR)

### Modelo AR(2)

- Un modelo AR(2) viene definido por:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + a_t$$

- En términos de operador de retardos,  $(1 - \phi_1 L - \phi_2 L^2) Y_t = a_t$   $\longrightarrow$   $\phi_2 (L) Y_t = a_t$
- La constante  $\phi_1$  y  $\phi_2$  deben estar comprendida en el rango  $[-1, 1]$


### Condiciones de estacionariedad

a) **Media:**  $(1 - \phi_1 + \phi_2) E(Y_t) = 0 \quad \rightarrow \quad E(Y_t) = 0$

b) **Varianza:**  $\gamma_1 = \frac{\phi_1 \gamma_0}{1 - \phi_2}$

La función de autocovarianzas de un modelo AR(2) es, por lo tanto:  $\gamma_k = \begin{cases} \gamma_0 & k = 0 \\ \gamma_1 & k = 1 \\ \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} & k > 1 \end{cases}$

# Modelo $AR(2)$



c) Los coeficientes de autocorrelación:


$$\rho_k = \begin{cases} 1 & k = 0 \\ \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} & k > 0 \end{cases}$$

- Para distinguir si un proceso es autorregresivo o no así como su orden, se recurre a las funciones de autocorrelación simple (FAS) y parcial (FAP), como se muestra en la siguiente figura.
- Los procesos  $AR(2)$  se reconocen por una **FAS infinita** y una **FAP que se anula** a partir del tercer retardo.


# Modelo $AR(2)$



Funciones de autocorrelación simple y parcial para procesos  $AR(2)$ .







## 6. Modelo Autorregresivo (AR)

### Modelo $AR(p)$

- Un modelo  $AR(p)$  viene definido por:

$$Y_t = \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + a_t$$

- En términos de operador de retardos,  $(1 - \phi_1 L - \phi_2 L^2 - \phi_3 L^3 - \cdots - \phi_p L^p) Y_t = a_t \longrightarrow \phi_p(L) Y_t = a_t$

### Condiciones de estacionariedad

a) **Media:**  $(1 - \phi_1 + \phi_2 + \cdots + \phi_p) E(Y_t) = 0 \rightarrow E(Y_t) = 0$


Este modelo se puede generalizar para representar series con media distinta de cero. El siguiente modelo  $AR(p)$ :

$$Y_t = \delta + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + a_t$$

Tiene media:

$$(1 - \phi_1 + \phi_2 + \cdots + \phi_p) E(Y_t) = \delta \rightarrow E(Y_t) = \frac{\delta}{1 - \phi_1 + \phi_2 + \cdots + \phi_p}$$

# Modelo $AR(p)$



## b) Los coeficientes de autocorrelación:

La función de autocorrelación,  $\rho_k$ ,  $k = 0, 1, 2, \dots$  de un proceso  $AR(p)$  tiene la misma estructura que la de un proceso  $AR(1)$ ,

Resumiendo:

- Muchos coeficientes de autocorrelación simple no nulos que decrecen con el retardo como mezcla de exponenciales y senoidales.
- Los  $p$  primeros coeficientes de autocorrelación parcial son distintos de cero.

## REGLA DE IDENTIFICACIÓN DEL ORDEN DE UN PROCESO AUTORREGRESIVO:

*El número de coeficientes de la FAP distintos de cero indica el orden del proceso AR*

# Ejemplo 4

Simular 500 observaciones de un proceso autorregresivos AR(1) y represente su FAS y FAP , con:

- a)  $\phi = 0.8$
- b)  $\phi = 0.1$
- c)  $\phi = -0.9$


En el siguiente script utiliza el comando **arima.sim()** para simular 500 observaciones de un proceso AR(1) para diferentes valores de  $\phi$ .

```
set.seed(123)
AR1_m1 <- arima.sim(model = list(ar = 0.8), n = 500)
plot(AR1_m1, ylab = "Yt", main = "Proceso AR(1) con phi = 0.8")
cpar(mfrow = c(2,1))
acf(AR1_m1,main="FAS")
pacf(AR1_m1,main="FAP")
```


# Ejemplo 4 – Simulación AR(1)

a) Modelo:  $Y_t = 0.8Y_{t-1} + a_t$


Proceso AR(1) con  $\phi = 0.8$



FAS




FAP




# Ejemplo 4 – Simulación AR(1)

b) Modelo:  $Y_t = 0.1Y_{t-1} + a_t$


Proceso AR(1) con  $\phi = 0.1$



FAS



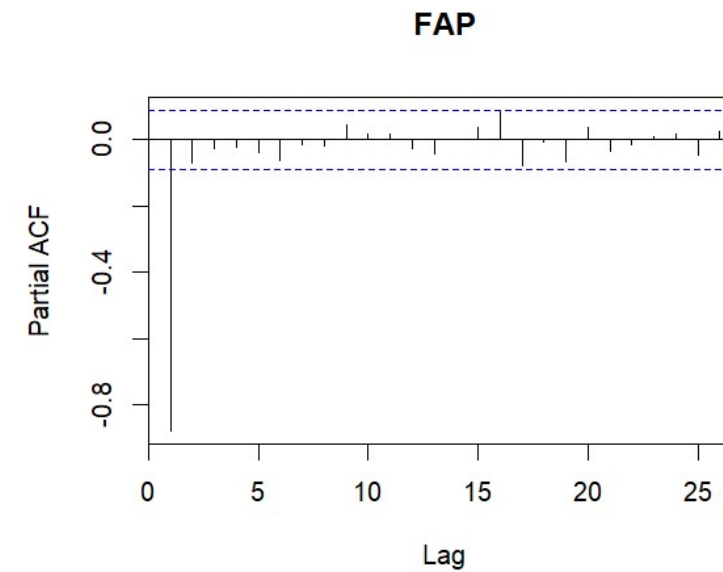


FAP



# Ejemplo 4 – Simulación AR(1)

c) Modelo:  $Y_t = -0.9Y_{t-1} + a_t$

Proceso AR(1) con  $\phi = -0.9$



# Ejemplo 5

Simular 500 observaciones de un proceso autorregresivos AR(2) y represente su FAS y FAP , con:

a)  $\phi_1 = 0.1$  y  $\phi_2 = 0.5$

b)  $\phi_1 = -0.7$  y  $\phi_2 = 0.1$

Al igual que el Ejemplo 4.4, seguimos utilizando el comando **arima.sim()** para simular 500 observaciones de un proceso AR(2) para diferentes valores de  $\phi_1$  y  $\phi_2$ .


```
set.seed(123)
AR2_m1 <- arima.sim(model = list(ar = c(0.1, 0.5)), n = 500)
plot(AR2_m1, ylab = "Yt", main = "Proceso AR(2) con phi_1 = 0.1 y phi_2 = 0.5")
par(mfrow = c(1,2))
acf(AR2_m1, main="FAS")
pacf(AR2_m1, main="FAP")
```




# Ejemplo 5 – Simulación AR(2)

a) Modelo:  $Y_t = 0.1Y_{t-1} + 0.5Y_{t-2} + a_t$


Proceso AR(2) con  $\phi_1 = 0.1$  y  $\phi_2 = 0.5$



FAS



FAP







# Ejemplo 5 – Simulación AR(2)

b) Modelo:  $Y_t = -0.7Y_{t-1} + 0.1Y_{t-2} + a_t$


Proceso AR(2) con  $\phi_1 = -0.7$  y  $\phi_2 = 0.1$




FAS



FAP





## 7. Modelo de Media Móvil (*MA*)

- Un proceso MA se caracteriza por un reajuste de la estimación, en cada instante de tiempo, a partir de los errores pasados de estimación.
- Un modelo de media móvil de orden  $q$ , o abreviadamente un modelo MA( $q$ ), se define de la siguiente forma:


$$Y_t = a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \cdots + \theta_q a_{t-q}$$

- A continuación se van analizar las características de los modelos MA(1) y MA(2).

### Modelo *MA*(1)


- Un modelo MA(1) viene definido por:

$$Y_t = a_t + \theta a_{t-1}$$


- Utilizando el operador polinomial de retardos,  $Y_t = (1 - \theta L) a_t$    $Y_t = \theta(L) a_t$

La constante  $\theta$  debe estar comprendida en el rango **[-1, 1]**

# Modelo $MA(1)$




- La estructura de correlación temporal representada por el modelo  $MA(1)$  es como sigue:



- Vamos a comprobar si el modelo  $MA(1)$  cumple las condiciones de estacionariedad para cualquier valor del parámetro  $\theta$ .

# Modelo $MA(1)$



## Condiciones de estacionariedad


a) **Media:**  $E(Y_t) = E(a_t - \theta a_{t-1}) = 0$

b) **Varianza:**  $\gamma_0 = (1 + \theta^2) \sigma^2$

La función de autocovarianzas de un  $MA(1)$  es:

$$\gamma_k \begin{cases} \gamma_0 = (1 + \theta^2) \sigma^2 & k = 0 \\ \gamma_1 = -\theta \sigma^2 & k = 1 \\ \gamma_k = 0 & k > 1 \end{cases}$$

# Modelo $MA(1)$



c) Los coeficientes de autocorrelación:


$$\rho_k = \begin{cases} 1 & k = 0 \\ \frac{-\theta}{1 + \theta^2} & k = 1 \\ 0 & k > 1 \end{cases}$$

La **función de autocorrelación simple FAS** de un proceso  $MA(1)$  tiene propiedades similares a la función de autocorrelación parcial FAP de un proceso  $AR(1)$ , es decir, sólo existe **un coeficiente distinto de cero**.


Por tanto, un **proceso  $MA(1)$**  se caracteriza por:


- ✓ El primer coeficiente de autocorrelación simple es distinto de cero.
- ✓ Muchos coeficientes de autocorrelación parcial no nulos que decrecen con el retardo como mezcla de exponenciales y senoidales.

# Modelo $MA(1)$



Funciones de autocorrelación simple y parcial para procesos  $MA(1)$ .






# 7. Modelo de Media Móvil (MA)

## Modelo MA(2)

- Un modelo MA(2) viene definido por:

$$Y_t = a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2}$$

- En términos de operador de retardos,  $Y_t = a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2}$    $Y_t = \theta_2 (L) a_t$
- La constante  $\theta_1$  y  $\theta_2$  deben estar comprendida en el rango  $[-1, 1]$

## Condiciones de estacionariedad


a) Media:  $E(Y_t) = E(a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2}) = 0$

b) Varianza:

La función de autocovarianzas de un modelo AR(2) es, por lo tanto:

$$\gamma_k \begin{cases} \gamma_0 = (1 + \theta_1^2 + \theta_2^2) \sigma^2 & k = 0 \\ \gamma_1 = (-\theta_1 + \theta_1 \theta_2) \sigma^2 & k = 1 \\ \gamma_2 = -\theta_2 \sigma^2 & k = 2 \\ \gamma_k = 0 & k > 2 \end{cases}$$

# Modelo $MA(2)$



c) Los coeficientes de autocorrelación:

$$\rho_k = \begin{cases} \rho_1 = \frac{-\theta_1 + \theta_1\theta_2}{1 + \theta_1^2 + \theta_2^2} & k = 1 \\ \rho_2 = \frac{-\theta_2}{1 + \theta_1^2 + \theta_2^2} & k = 2 \\ \rho_k = 0 & k = 3 \end{cases}$$

La FAS de un proceso  $MA(2)$  es una función truncada en el retardo 2. Los coeficientes de autocorrelación,  $\rho_1$ ,  $\rho_2$ , pueden ser positivos, negativos, o de distinto signo dependiendo de los valores de los parámetros autorregresivos..


- Los procesos  $MA(2)$  se reconocen por una FAP infinita y una FAS que se anula a partir del tercer retardo.




# Modelo $MA(2)$



Funciones de autocorrelación simple y parcial para procesos  $MA(2)$ .






# 7. Modelo de Media Móvil (*MA*)

## Modelo $MA(q)$


- Un modelo  $MA(q)$  viene definido por:

$$Y_t = a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2} + \cdots + \theta_q a_{t-q}$$

- En términos de operador de retardos,  $Y_t = (1 - \theta_1 L - \theta_2 L^2 - \theta_3 L^3 - \cdots - \theta_q L^q) a_t$    $Y_t = \theta_q(L) a_t$
- El modelo de  $MA(q)$  tiene media constante y cero, varianza constante y finita y su función de autocovarianzas está truncada a partir del retardo  $q$ , es decir,

$$\rho_k = \begin{cases} \rho_k \neq 0 & k = 1, 2, 3, \dots, q \\ \rho_k = 0 & k > q \end{cases}$$

# Modelo $MA(q)$



Respecto a las funciones de autocorrelación, un proceso  $MA(q)$  se caracteriza por:

- Los  $q$  primeros coeficientes de autocorrelación simple son distintos de cero.
- Muchos coeficientes de autocorrelación parcial no nulos que decrecen con el retardo como mezcla de exponenciales y senoidales.

## REGLA DE IDENTIFICACIÓN DEL ORDEN DE UN PROCESO DE MEDIA MÓVIL:

*El número de coeficientes de la FAS distintos de cero indica el orden del proceso  $MA$*

# Ejemplo 6

Simular 500 observaciones de un proceso de media móvil MA(1) y MA(2), además represente su FAS y FAP, con los siguientes parámetros:

- a)  $\theta = 0.7$
- b)  $\theta = -0.9$
- c)  $\theta_1 = -0.8$  y  $\theta_2 = 0.5$


Continuamos utilizando el comando **arima.sim()** para simular 500 observaciones de un proceso MA(1) y MA(2) para diferentes valores de  $\theta$ .

```
set.seed(123)
MA1_m1 <- arima.sim(model = list(ma = 0.7), n = 500)
plot(MA1_m1, ylab = "Yt", main = "Proceso MA(1) con zeta = 0.7")
par(mfrow = c(1,2))
acf(MA1_m1, main="FAS")
pacf(MA1_m1, main="FAP")
```


# Ejemplo 6 – Simulación MA(1)

a) Modelo:  $Y_t = a_t + 0.7a_{t-1}$


Proceso MA(1) con zeta = 0.7



FAS




FAP




# Ejemplo 6 – Simulación MA(1)

b) Modelo:  $Y_t = a_t - 0.9a_{t-1}$


Proceso MA(1) con zeta = -0.9



FAS



FAP




# Ejemplo 4 – Simulación MA(2)



c) Modelo:  $Y_t = a_t - 0.8_1 a_{t-1} + 0.5 a_{t-2}$

Proceso MA(2) con zeta\_1 = -0.8 y zeta\_2 = 0.5



```
set.seed(123)
```



```
MA2_m1 <- arima.sim(model = list(ma = c(-0.8,  
0.5)), n = 500)
```

```
plot(MA2_m1, ylab = "Yt", main = "Proceso  
MA(2) con zeta_1 = -0.8 y zeta_2 = 0.5")
```

```
par(mfrow = c(1,2))
```

```
acf(MA2_m1, main="FAS")
```

```
pacf(MA2_m1, main="FAP")
```







GRACIAS

<https://aulavirtual2.unap.edu.pe/>