

# PRACTICA.R

VICTOR RAUL MAYE MAMANI

2024-05-20

```
library(TTR) # Método de Media móvil

## Warning: package 'TTR' was built under R version 4.3.3

library(ggplot2)

## Warning: package 'ggplot2' was built under R version 4.3.1

library(forecast)

## Warning: package 'forecast' was built under R version 4.3.3

## Registered S3 method overwritten by 'quantmod':
##   method      from
##   as.zoo.data.frame zoo

library(fastDummies)

## Warning: package 'fastDummies' was built under R version 4.3.3

## Thank you for using fastDummies!

## To acknowledge our work, please cite the package:

## Kaplan, J. & Schlegel, B. (2023). fastDummies: Fast Creation of Dummy
## (Binary) Columns and Rows from Categorical Variables. Version 1.7.1. URL:
## https://github.com/jacobkap/fastDummies, https://jacobkap.github.io/fastD
## ummies/.

library(mFilter)

## Warning: package 'mFilter' was built under R version 4.3.3


ruta_archivo = 'C:\\Users\\LENOVO\\Downloads\\horastrabajadas.txt'
datos <- read.table(ruta_archivo, header = TRUE, sep = " ")

yts <- ts(datos$horastrabajadas, start = c(1976, 3), frequency = 4)

# a) Represente la serie e identifica las componentes de variación presen
# tes en la misma.

plot(yts, main = "Serie Temporal de Horas Trabajadas", xlab = "Trimestres
", ylab = "Horas Trabajadas")
```


## Serie Temporal de Horas Trabajadas




**# LOS COMPONENTES DE VARIACION SE PUEDEN OBSERVAR EN LA PREGUNTA B INDIVIDUALMENTE**

*# b) Realice la descomposición de serie y represente de manera individual cada componente.*


```
decomp = decompose(yts)  
plot(decomp$x)
```




```
# TENDENCIA  
plot(decomp$trend)
```



```
# ESTACIONALIDAD  
plot(decomp$seasonal)
```




```
# ALEATORIO  
plot(decomp$random)
```




# c) Estima la tendencia a través del ajuste de una función cuadrática, p  
 romedio móvil doble, el  
 # método de Holt-Winters y filtro de Hodrick - Prescott. ¿Qué método ajusta  
 ta mejor la  
 # tendencia?, justifique su respuesta.

```
# Ajuste funcion cuadratica
t <- time(yts)
Y2 <- lm(yts ~ t + I(t^2))
pron = ts(predict(Y2, t), c(1976,3), frequency = 4)
plot(yts, xlab="Trimestres", ylab="Horas")
lines(pron, type = "l", col = "red")
legend(x = "bottomright", legend = c("Yts", "Y2"), col = c('black', 'red'),
lty = c(1, 1))
```



*# Observamos que la línea de ajuste de la función cuadrática se ajusta bien a la serie original*

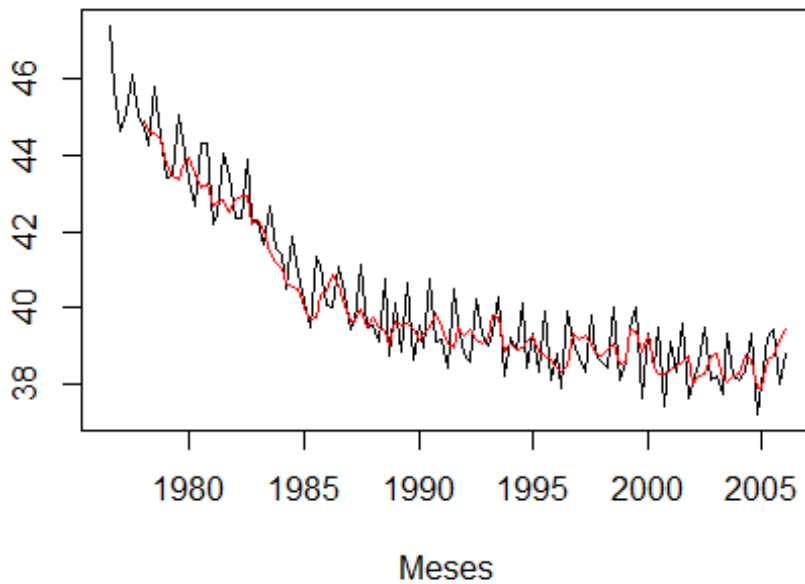
```
# Promedio móvil doble
k<-4 #Periodo
Yts_ma <- SMA(yts, k)
plot(yts)
lines(Yts_ma, type="l", col="red")
legend(x = "bottomright", legend = c("Yts", "Yts_ma"), col = c("black", "red"), lty=c(1,1))
```



```

Yts_ma2 <- SMA(Yts_ma, k) # Media móvil de media móvil
a <- 2*Yts_ma - Yts_ma2
b <- (2/(k-1))*(Yts_ma - Yts_ma2)
p <- 2
Yma2 <- a + b*p
plot(yts, type='l', xlab="Meses", ylab=" ")
lines(Yma2, type='l', col = 'red')

```




*# El promedio movil doble tambien se ajusta, pero no podemos apreciar claramente la tendencia como en el funcion cuadratica*

*# Holt-Winters*

```
HORhw_m <- HoltWinters(yts, seasonal = "multiplicative")
plot(HORhw_m)
legend(x = "bottomright", legend = c("HORAS", "HORhw_m"), col = c('black', 'red'), lty = c(1, 1))
```



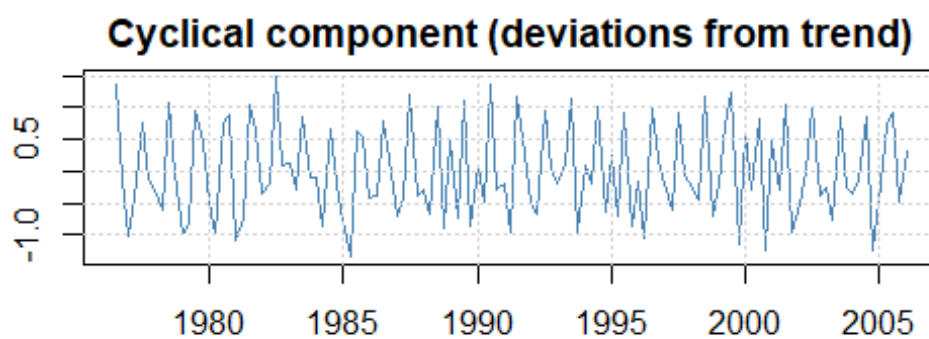

## Holt-Winters filtering



*# En este caso se observa que se ajusta demasiado a la serie original lo que dificulta la estimación de la tendencia*

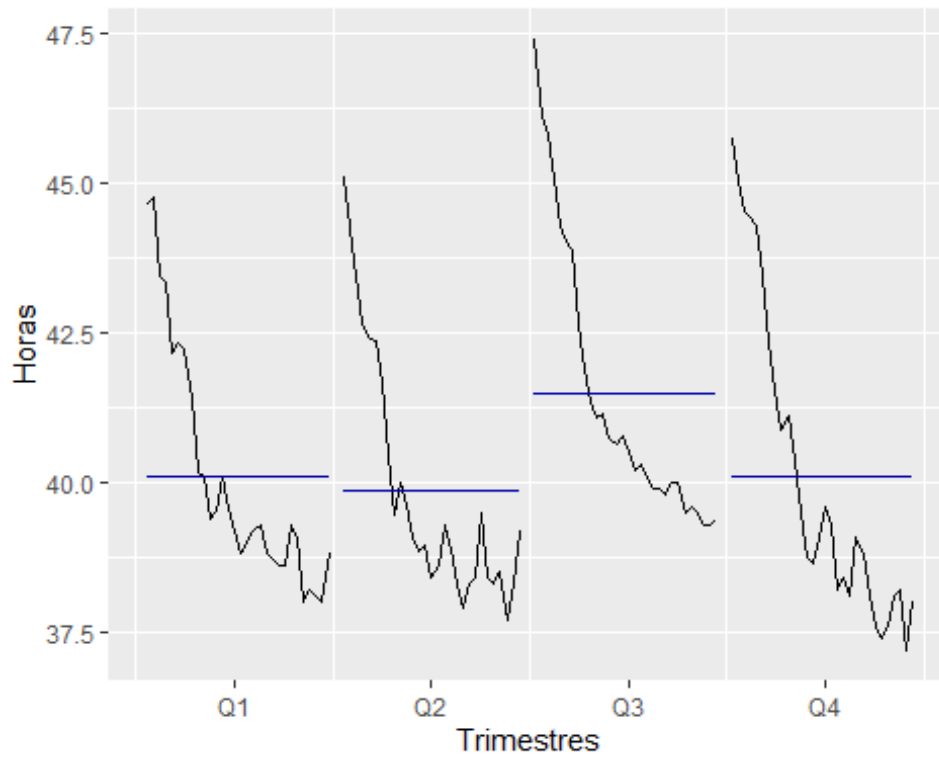
*# Filtro de Hodrick*

```
lambda_hp <- 1600  
Yhp <- hpfilter(yts, type="lambda", freq=lambda_hp)  
plot(Yhp)  
abline(h=0, col="green")
```




# d) Detecte el componente estacional haciendo uso de los métodos gráficos. Para usted, ¿qué método gráfico es más efectivo?

```
ggsubseriesplot(yts, xlab = "Trimestres", ylab = "Horas")
```

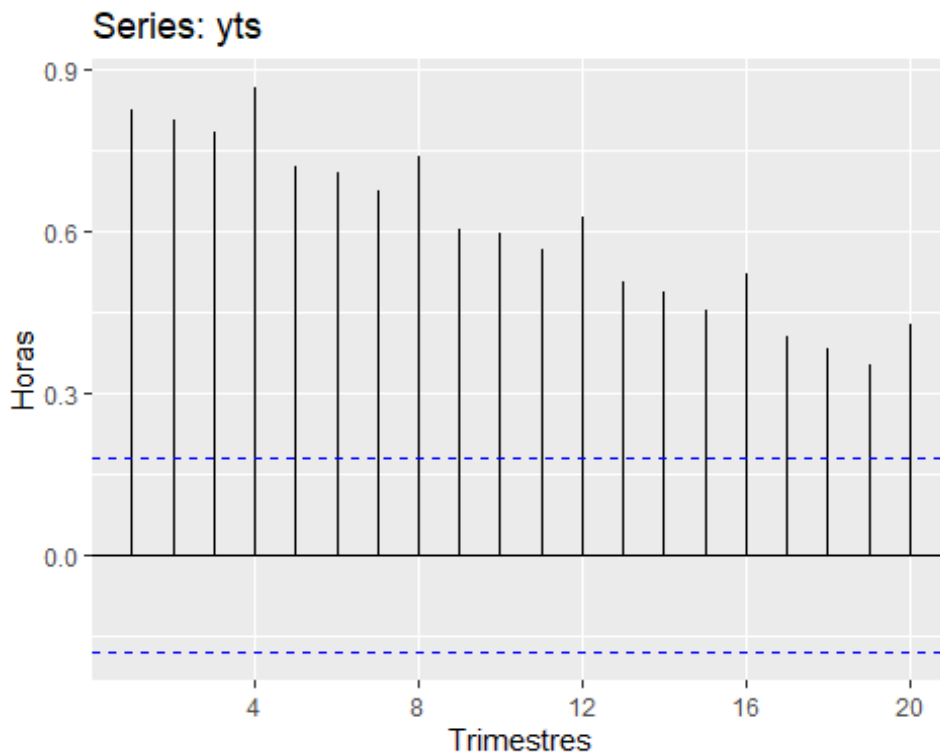


```
ggseasonplot(yts, xlab = "Trimestres", ylab = "Horas")
```



```
ggAcf(yts, xlab = "Trimestres", ylab = "Horas")
```

```
## Warning in ggplot2::geom_segment(lineend = "butt", ...): Ignoring unknown
## parameters: `xlab` and `ylab`
```



*#Podemos observar que en los tres metodos no hay estacionalidad*

*# Siendo el mas efectivo el grafico de lineas ggseasonplot*

*# e) En caso de haber detectado el componente estacional, ratifique a través de la regresión de*

*# variables Dummy.*

```
datos$trimestre = rep(1:4, length.out = 119)
```

```
datos$horas_1 <- lag(datos$horastrabajadas)
```

*# Construcción de Las Dummy*

```
datos$dummy <- datos$trimestre
```

```
tabla_dummy <- dummy_columns(datos, select_columns = "dummy", remove_first_dummy = TRUE)
```

```
head(tabla_dummy)
```

```
##  horastrabajadas trimestre horas_1 dummy dummy_2 dummy_3 dummy_4
## 1          47.395         1  47.395     1         0         0         0
## 2          45.730         2  45.730     2         1         0         0
## 3          44.647         3  44.647     3         0         1         0
## 4          45.087         4  45.087     4         0         0         1
```

```
## 5          46.100          1 46.100          1          0          0          0
## 6          45.045          2 45.045          2          1          0          0

# Dataframe para la regresion con Dummies
tabla_reg <- tabla_dummy[, c("horastrabajadas", "horas_1", "dummy_2", "dummy_3", "dummy_4")]
# Regresion con Dummies
reg_1 <- lm(datos$horastrabajadas ~ ., data = tabla_reg)
summary(reg_1)


## Warning in summary.lm(reg_1): essentially perfect fit: summary may be
## unreliable

##
## Call:
## lm(formula = datos$horastrabajadas ~ ., data = tabla_reg)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -7.611e-16 -1.307e-16 -9.800e-18  6.070e-17  4.125e-15
##
## Coefficients:
##              Estimate Std. Error    t value Pr(>|t|)
## (Intercept) -1.042e-14  7.419e-16 -1.405e+01  <2e-16 ***
## horas_1      1.000e+00  1.779e-17  5.621e+16  <2e-16 ***
## dummy_2      2.697e-16  1.133e-16  2.381e+00   0.0189 *
## dummy_3      5.721e-17  1.134e-16  5.050e-01   0.6147
## dummy_4      6.170e-17  1.152e-16  5.360e-01   0.5933
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 4.286e-16 on 114 degrees of freedom
## Multiple R-squared:  1, Adjusted R-squared:  1
## F-statistic: 8.549e+32 on 4 and 114 DF, p-value: < 2.2e-16

# Podemos observar que no todas las variables son significativas


# f) Desestacionalice la serie con el método de media móvil central.

Yv_ma <- SMA(yts, 4) # media móvil simple
Yv_mc <- ma(yts, 4) # media móvil centrada
plot(yts, xlab="Años/Trimestres", ylab="Horas")
lines(Yv_ma, type = "l", col = "red")
lines(Yv_mc, type = "l", col = "blue")
legend(x = "bottomright", legend = c("Yv", "Yv_ma", "Yv_mc"), col = c('black', 'red', 'blue'), lty=c(1,1,1))
```



# g) Evalúe la existencia de las variaciones cíclicas mediante el ajuste regresión:

```
datos$t <- seq(1:NROW(datos))
# Construir series
cosP <- cos(2*pi/119*34*datos$t)
senP <- sin(2*pi/119*34*datos$t)
# Ajuste del modelo
ciclo <- lm(yts ~ cosP + senP)
plot(ciclo$residuals, type = "l", xlab="t", ylab="Residuos", col = "red")
```



*# Podemos apreciar que si hay un componente ciclico con una amplitud de a proximadamente 5 trimestres*