

Actividad-02.r

VICTOR RAUL MAYE MAMANI

2024-05-20


LAS INTERPRETACIONES Y RESPUESTAS ESTAN DE COLOR ROJO

```
#####  
# ACTIVIDAD 2 #  
#####  
  
# EJERCICIO 1  
#LIBRERIAS  
library(ggplot2)  
library(forecast)  
  
## Warning: package 'forecast' was built under R version 4.3.3  
  
## Registered S3 method overwritten by 'quantmod':  
##   method           from  
##   as.zoo.data.frame zoo  
  
library(readxl)  
library(seasonal)  
  
## Warning: package 'seasonal' was built under R version 4.3.3  
  
library(fastDummies)#creacion de variables dummies  
  
## Warning: package 'fastDummies' was built under R version 4.3.3  
  
## Thank you for using fastDummies!  
  
## To acknowledge our work, please cite the package:  
  
## Kaplan, J. & Schlegel, B. (2023). fastDummies: Fast Creation of Dummy  
(Binary) Columns and Rows from Categorical Variables. Version 1.7.1. URL:  
https://github.com/jacobkap/fastDummies,  
https://jacobkap.github.io/fastDummies/.  
  
library(scales) # formtato de fechas en el eje x  
library(dplyr) #generar tablas de resumen  
  
##  
## Attaching package: 'dplyr'  
  
## The following objects are masked from 'package:stats':  
##  
##   filter, lag
```

```
## The following objects are masked from 'package:base':
##
## intersect, setdiff, setequal, union


# A.1) tendencia:  $T = 2*t + 1$ 

t <- 1:150
tendencia <- 2*t + 1
plot(tendencia, type = "l", xlab="t")
```




```
# A.2) estacional:  $E_t = 30*\sin((2*\pi/12)*(t+1))+100$ 


estacional <- 30*sin((2*pi/12)*(t+1))+100
plot(estacional, type = "l", xlab="t")
```




```
# A.3) irregular  
irregular = rnorm(length(t), 0,5)  
plot(irregular, type = "l", xlab="t")
```




```
# simular los modelos:  
#modelo aditivo :  
ya <- tendencia + estacional + irregular  
plot(ya,type="l", xlab="t")
```



```
# modelo mixto:  
# calcular irregular  
irregular = rnorm(length(t),0,500)  
  
ym <- tendencia*estacional + irregular  
plot(ym,type="l", xlab="t")
```

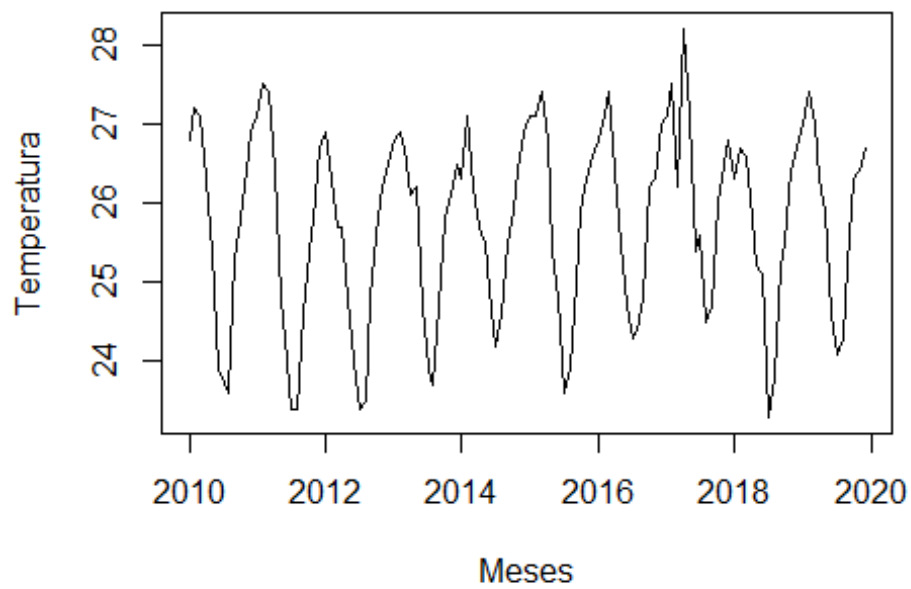


```
# b) tendencia exponencial  
# tendencia:  $Tt = e^{2t}$   
  
t <- seq(0,2, length= length(t))  
tendencia_e <- exp(2*t)  
plot(tendencia_e, type = "l", xlab="t")
```



Ejercicio 2


```
datos = read_excel("F:/777--Programacion repos/Una/r/TASK-  
2/data/data.xlsx")  
View(datos)  
yts <- ts(datos$temperatura, start = c(2010,1), frequency = 12)  
plot(yts, type = "l", xlab = "Meses", ylab = "Temperatura")
```



(a) Realice la descomposición de los componentes de la serie de temperaturas.

```
decomp = decompose(yts,type = "additive")  
plot(decomp, xlab = "Meses", ylab = "Temperatura")
```

Decomposition of additive time series



(b) ¿Cree que podría haber un componente cíclico en las temperaturas? Explique su respuesta.

generacion de t

```
datos$t = seq(1:NROW(datos))
```

Construir series


```
cosP <- cos(2*pi/120*12*datos$t)
```

```
senP <- sin(2 * pi / 120 * 12 * datos$t)
```

Ajuste del modelo

```
ciclo <- lm(yts ~ cosP + senP)
```

```
plot(ciclo$residuals, type = "l", xlab="t", ylab="Residuos", col = "red")
```





Se observa que el grafico de los residuos tiene un parecido a la función seno, por lo que se puede decir que hay un componente cíclico en las temperaturas.

(c) ¿Utilizaría los componentes de tendencia o estacionalidad, o ambos para realizar el pronóstico en la previsión de las temperaturas de la década siguiente?


```
plot(decomp, xlab = "Meses", ylab = "Temperatura")
```

Decomposition of additive time series




Analisis de la estacionalidad


```
ggsubseriesplot(yts, xlab = "Meses", ylab = "Temperatura")
```




```
ggseasonplot(yts, xlab = "Meses", ylab = "Temperatura")
```



```
ggAcf(yts, xlab = "Meses", ylab = "Temperatura")  
## Warning in ggplot2::geom_segment(lineend = "butt", ...): Ignoring  
unknown  
## parameters: `xlab` and `ylab`
```



```
# Analisis de la tendencia
t <- time(yts)
Ylm <- lm(yts ~ t) # Modelo Lineal simple  $Y = a + b*t$ 
pron = ts(predict(Ylm, t), c(2010,1), frequency = 12)
plot(yts, xlab="Años", ylab=" ")
lines(pron, type = "l", col = "red")
legend(x = "bottomright", legend = c("Yts", "Ylm"), col = c('black',
'red'), lty = c(1,1))
```




*# No se considera la tendencia, ya que se observa una tendencia muy pequeña en los datos.
Practicamente es constante.*

En cambio se considera la estacionalidad porque podemos detectarla gracias a los graficos usados.


EJERCICIO 3

```
datos = read_excel("F:/777--Programacion repos/Una/r/TASK-2/data/data.xlsx", sheet = 2)
View(datos)
Yts <- ts(datos$Ventas, start = c(2019, 1), frequency = 4)
plot(Yts, type = "l", xlab = "Trimestre", ylab = "Ventas")
```



(a) Grafique las observaciones contra el tiempo, ¿qué clase de tendencia parece haber?

```
t <- time(Yts)
Ylm <- lm(Yts ~ t) # Modelo Lineal simple  $Y = a + b*t$ 
pron = ts(predict(Ylm, t), c(2019, 1), frequency = 4)
plot(Yts, xlab = "Años", ylab = " ")
lines(pron, type = "l", col = "red")
legend(x = "bottomright", legend = c("Yts", "Ylm"), col = c("black",
"red"), lty = c(1, 1))
```



Se observa una tendencia creciente en las ventas.

b) Si se supone que una tendencia lineal $VENT_t = \beta_0 + \beta_1 t$, describe las observaciones, determine las estimaciones puntuales de mínimos cuadrados de β_0 y β_1 .

```
print(Ylm)
```

```
##
## Call:
## lm(formula = Yts ~ t)
##
## Coefficients:
## (Intercept)          t
##   -6038.337         3.007
```

Revisando el modelo lineal simple, se tiene que la ecuación de la recta es:

$Y = -45.14621 + 0.03519 \cdot t$

Donde:

$Y = \text{Ventas}$

$t = \text{Trimestre}$

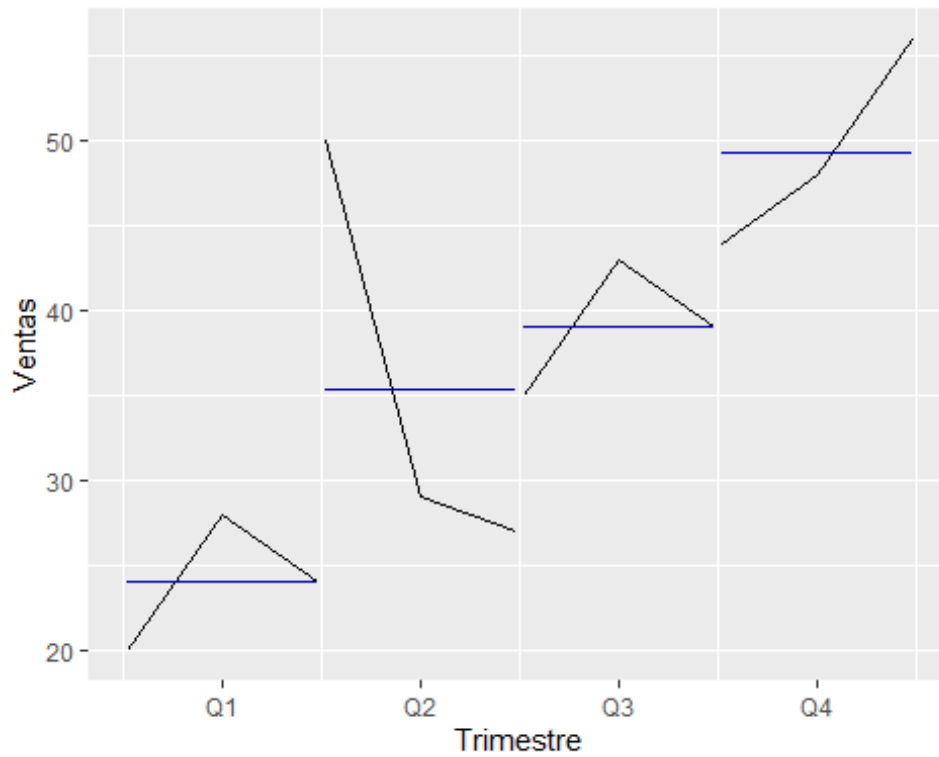
$\beta_0 = -45.14621$

$\beta_1 = 0.03519$


(d) Determine a través de Los métodos gráficos y estadísticos la existencia de Los componentes de
estacionalidad y ciclicidad.

Comprobar La estacionalidad


```
ggsubseriesplot(Yts, xlab = "Trimestre", ylab = "Ventas")
```



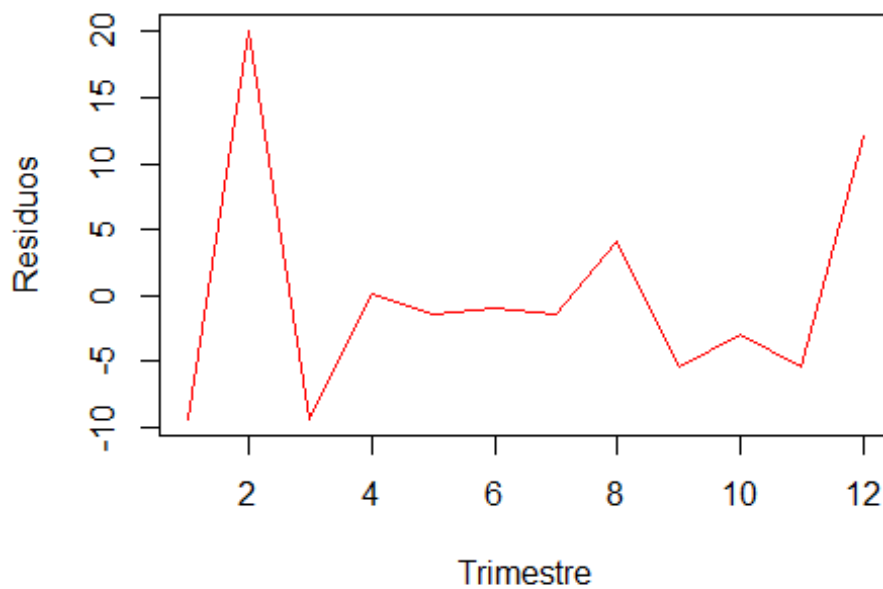
```
ggseasonplot(Yts, xlab = "Trimestre", ylab = "Ventas")
```

```
ggAcf(Yts, xlab = "Trimestre", ylab = "Ventas")  
## Warning in ggplot2::geom_segment(lineend = "butt", ...): Ignoring  
unknown  
## parameters: `xlab` and `ylab`
```



```
# Comprobar la ciclicidad
datos$t = seq(1:NROW(datos))
cosP <- cos(2 * pi / 4 * datos$t)
senP <- sin(2 * pi / 4 * datos$t)
ciclo <- lm(Yts ~ cosP + senP)
plot(ciclo$residuals, type = "l", xlab = "Trimestre", ylab = "Residuos",
col = "red")
```




Se observa que hay un componente estacional en las ventas, ya que se observan picos y valles en la serie temporal.

No se observa un componente cíclico en las ventas, ya que los residuos no tienen un comportamiento cíclico.

#####

EJERCICIO 4


```
datos = read_excel("F:/777--Programacion repos/Una/r/TASK-
2/data/data.xlsx", sheet = 3)
View(datos)
Yts <- ts(datos$ventas, start = c(2010, 1), frequency = 4)
plot(Yts, type = "l", xlab = "Trimestre", ylab = "Ventas")
```



¿Parece que hay algún efecto estacional significativo de estos niveles de venta?


Comprobar la estacionalidad

```
ggsubseriesplot(Yts, xlab = "Trimestre", ylab = "Ventas")
```




```
ggseasonplot(Yts, xlab = "Trimestre", ylab = "Ventas")
```

Seasonal plot: Yts



```
ggAcf(Yts, xlab = "Trimestre", ylab = "Ventas")
```

```
## Warning in ggplot2::geom_segment(lineend = "butt", ...): Ignoring
unknown
## parameters: `xlab` and `ylab`
```



Se observa que Los 3 gráficos muestran un comportamiento NO estacional en las ventas.

```
datos$ven_1 = lag(datos$ventas)
```

```
datos$dummy = datos$trimestre
tabla_dummy = dummy_columns(datos, select_columns = c("dummy"),
remove_first_dummy = TRUE)
head(tabla_dummy)
```

```
## # A tibble: 6 × 8
```

```
##   año trimestre ventas ven_1 dummy dummy_2 dummy_3 dummy_4
##   <dbl>     <dbl> <dbl> <dbl> <dbl>   <int>   <int>   <int>
## 1  2010         1  2292   NA     1         0         0         0
## 2  2010         2  2450  2292     2         1         0         0
## 3  2010         3  2363  2450     3         0         1         0
## 4  2010         4  2477  2363     4         0         0         1
## 5  2011         1  2063  2477     1         0         0         0
## 6  2011         2  2358  2063     2         1         0         0
```

```
tabla_reg = tabla_dummy[, c("ventas", "ven_1", "dummy_2", "dummy_3",
"dummy_4")]
```

```

reg = lm(datos$ventas ~ ., data = tabla_reg)
summary(reg)

##
## Call:
## lm(formula = datos$ventas ~ ., data = tabla_reg)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -335.31  -52.74    0.35   77.11  180.23
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)   35.32566   142.81519    0.247   0.8058
## ven_1          0.95397    0.04957   19.243 < 2e-16 ***
## dummy_2       278.30603    45.33960    6.138 2.51e-07 ***
## dummy_3        72.57093    44.99153    1.613   0.1142
## dummy_4        99.21237    44.92627    2.208   0.0327 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 107.5 on 42 degrees of freedom
## (1 observation deleted due to missingness)
## Multiple R-squared:  0.9017, Adjusted R-squared:  0.8923
## F-statistic: 96.27 on 4 and 42 DF, p-value: < 2.2e-16

# 4 Indices estacionales
mean_ventas = mean(datos$ventas)
mean_trim1 = mean(datos$ventas[datos$trimestre == 1])
mean_trim2 = mean(datos$ventas[datos$trimestre == 2])
mean_trim3 = mean(datos$ventas[datos$trimestre == 3])
mean_trim4 = mean(datos$ventas[datos$trimestre == 4])

indices = c(mean_trim1, mean_trim2, mean_trim3, mean_trim4) / mean_ventas
indices

## [1] 0.9531114 1.0209111 1.0123360 1.0136415

# Los indices son: 0.9531114 1.0209111 1.0123360
# 1.0136415


# La magnitud del efecto estacional es relativamente
# pequeña, ya que los valores de los índices estacionales
# están cerca de 1. Esto significa que aunque hay un
# efecto estacional en las ventas, no es muy pronunciado.
# La empresa experimenta variaciones estacionales en las
# ventas, pero estas no son significativamente grandes
# en comparación con el nivel medio de ventas.

```

```

datos$t <- seq(1:NROW(datos))
cosP <- cos(2 * pi / 15 * datos$t)
senP <- sin(2 * pi / 15 * datos$t)
ciclo <- lm(Yts ~ cosP + senP)
plot(ciclo$residuals, type = "l", xlab = "Trimestre", ylab = "Residuos",
col = "red")

```



No se logra apreciar un componente cíclico en las ventas, ya que los residuos no tienen un comportamiento cíclico. En cambio se observa una tendencia creciente en las ventas.