Actividad 4

Estudiante: Maye Mamani Victor Raul

Tabla de contenido

Alumno: Maye Mamani Victor Raul

LAS INTERPRETACIONES Y CONCLUSIONES DE CADA PASO SE ENCUENTRAN EN ESTE FORMATO

Ejemplo: Según el grafico anterior no hay tendencia

CASO 1: VENTAS DE UN RESTAURANTE

```
# Librerias necesaria
library(forecast) # Modelo ARIMA
library(tseries) # Para series de tiempo
library(TSA) # Para series de tiempo
library(urca) # Raiz Unitaria
library(ggplot2) # Para hacer gráficos
library(gridExtra)
library(dplyr) # Para la manipulación de datos
library(lmtest) # Inferencia para coeficientes estimados
library(MASS) # Transformacion de Box-Cox
library(nortest) # Pruebas de normalidad
library(strucchange) # Cambio estructural - Test de Chow
library(mFilter)
library(readxl)
library(fitdistrplus)
data <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-04.xlsx",sheet = "datos1")
View(data)
# Gráfica de la serie
data_ts <- ts(data$Ventas, start = 1981, frequency = 1)
plot(data_ts, xlab="Semanas", ylab="Ventas")
```

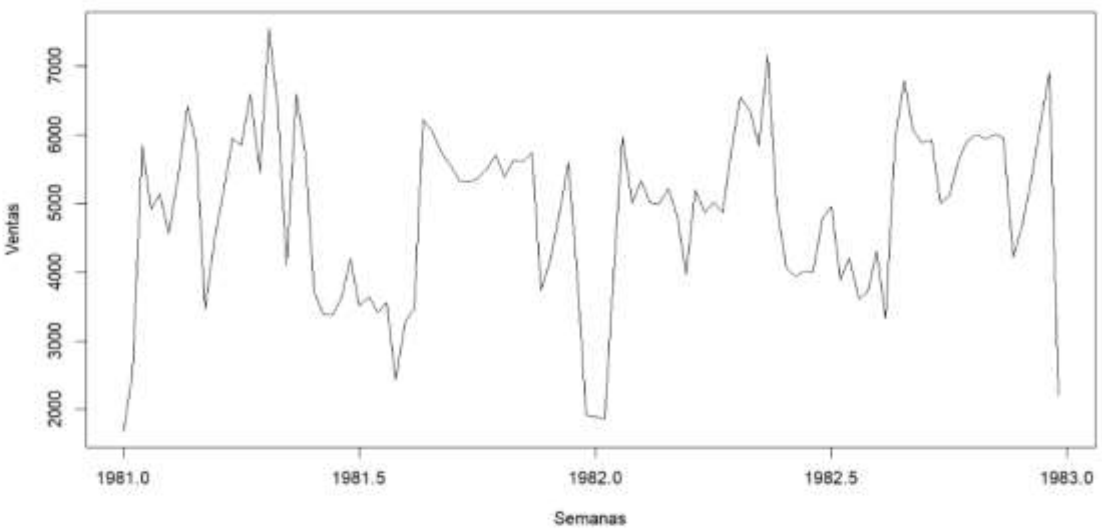

1. IDENTIFICACIÓN

Análisis de la tendencia y la estacionalidad

```
#Descomposición de la serie
data_des <- decompose(data_ts, type = "additive")
```

```r
plot(data_des,type="l")
```

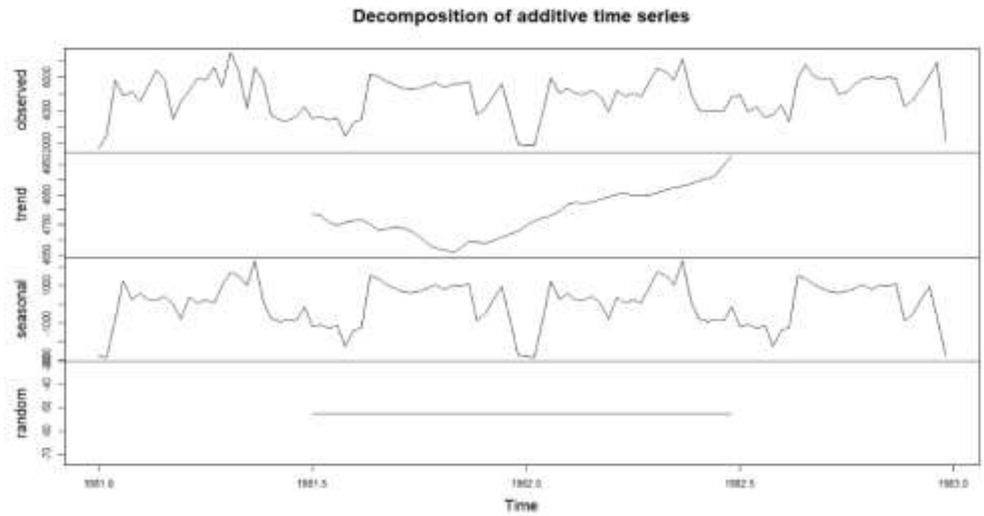


```r
#Graficos de la serie para identificar estacionalidad
plot1 <- ggsubseriesplot(data_ts, xlab = "Semanas", ylab = "Ventas")
plot2 <- ggseasonplot(data_ts, xlab = "Semanas", ylab = "Ventas")
plot3 <- ggAcf(data_ts, xlab = "Semanas", ylab = "Ventas")

grid.arrange(plot1, plot2, plot3, ncol = 1)
```

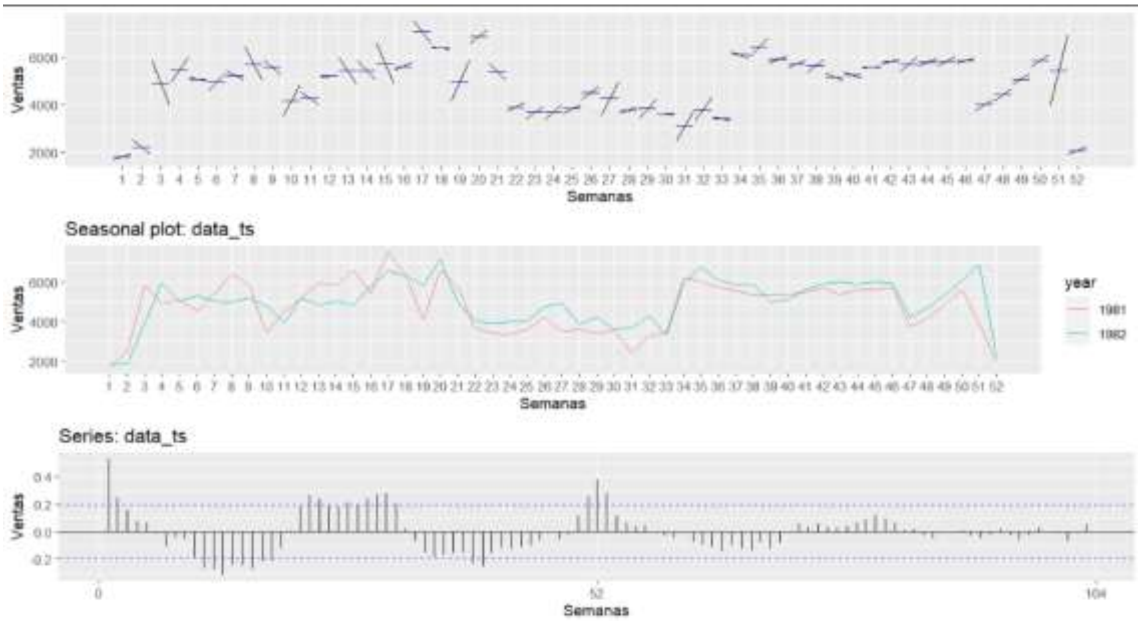


```r
#Análisis de tendencia
lambda_hp <- 129600
data_hp <- hpfilter(data_ts, type="lambda", freq=lambda_hp)
plot(data_hp)
```

Alumno: Maye Mamani Victor Raul

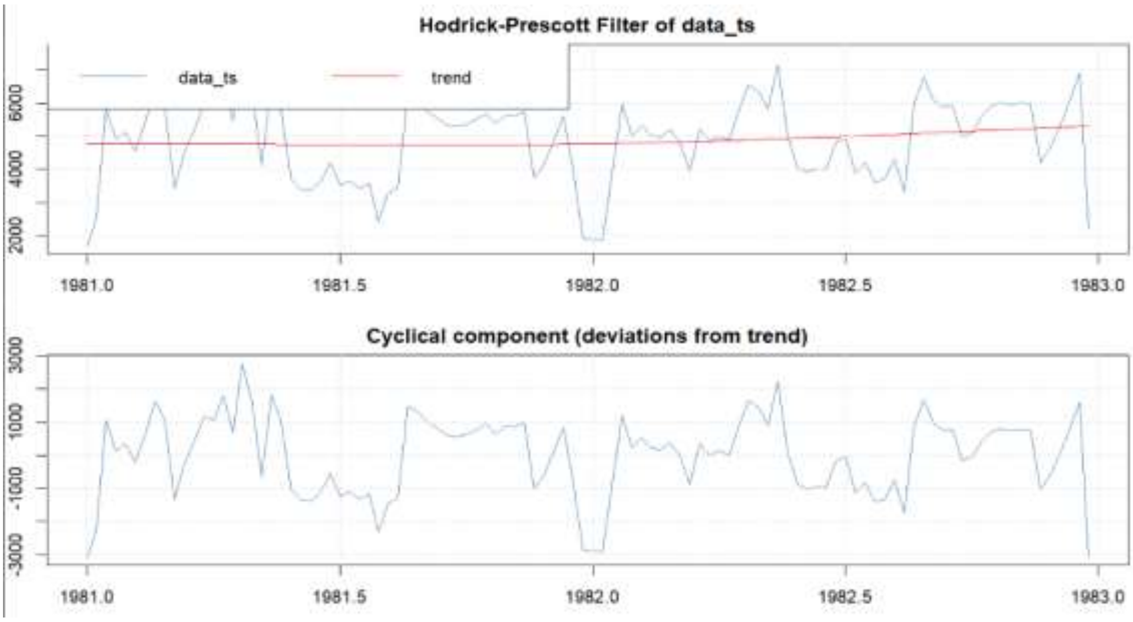

Conclusión: estacionalidad y tendencia

INTERPRETACION:

Según los gráficos anteriores NO parece haber una tendencia clara, pero sí hay estacionalidad y parece haber un patrón cíclico que se repite anualmente

Análisis de Estacionariedad

Estacionariedad en Varianza

```
#Estacionaridad en varianza
Grupo <- rep(1:13, each = 8)
boxplot(data$Ventas ~ Grupo, xlab = "Grupo", ylab="Yt")
```

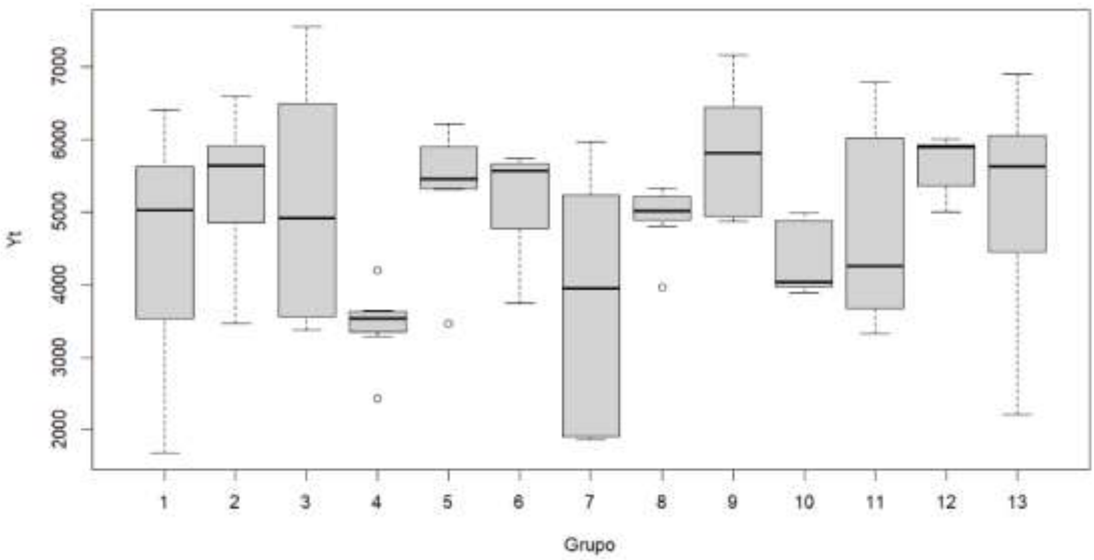

Vemos que la variación no parece ser constante, por lo que probablemente necesitemos transformar la serie.

Alumno: Maye Mamani Victor Raul

ŘȟȘ ħļŝðļŝɢŀŋɪȘ ðrŝħŀɢǭȘ ŧļȘ ĸɢŀãçɕȘ ɢçðæŧɢçŋȘ ļŋɪȘ çɢõɪȘ ŧļȘ ĸɢŀãçɕȘ çǭȘ ếȘ
ŋrðɕȘ øŧǭȘ rðõɪȘ ĸɕȘ rðõħǭȘ ņõħəħļɢĸ

```
qqnorm(data_ts, main = "Lambda = 1") # Yt: Original
qqline(data_ts)
```

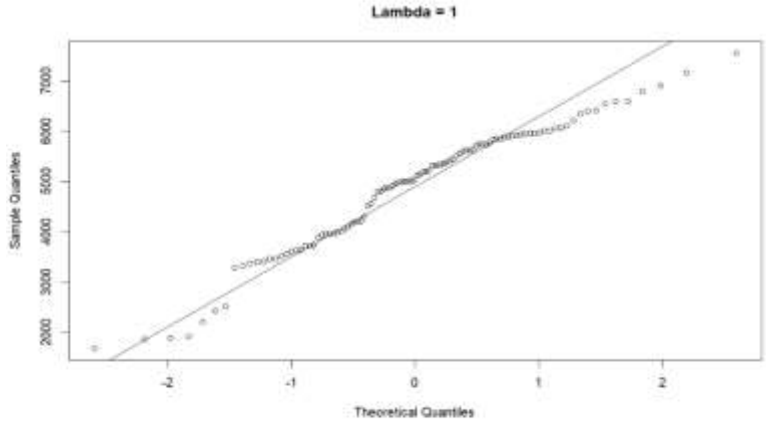

Estacionariedad en Media

```
FAS <- acf(data_ts, lag.max = 15, main="FAS – Yt", level = 0.95)
FAP <- pacf(data_ts, lag.max = 15, main="FAP – Yt", level = 0.95)
```

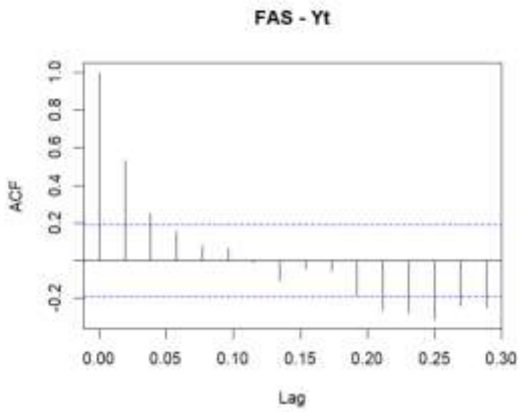

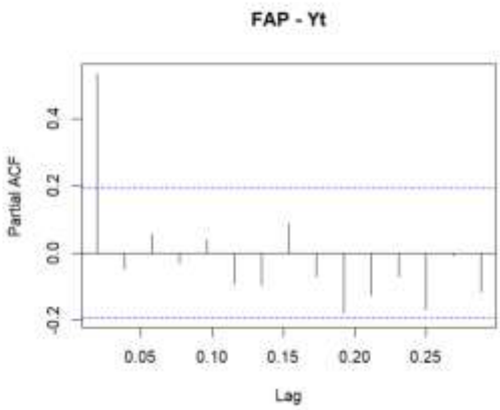

INTERPRETACION:

Los coeficientes de autocorrelación simple (FAS) decrecen hacia cero rápidamente de forma oscilatoria, además, el primer coeficiente de autocorrelación parcial (FAP) es menor a 0.9; por tanto, esta serie de ventas presenta altos indicios de ser estacionaria.

Alumno: Maye Mamani Victor Raul

```
Residual standard error: 1006 on 99 degrees of freedom
Multiple R-squared:  0.2322,    Adjusted R-squared:  0.2167
F-statistic: 14.97 on 2 and 99 DF,  p-value: 2.093e-06


Value of test-statistic is: -5.2981 14.0355

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.46 -2.88 -2.57
phi1  6.52  4.63  3.81
```

Conclusión: Estacionariedad

INTERPRETACION:

De los resultados, el valor de T calculado =-5.29 8 1, T critico =-2.888 8 por lo tanto, aceptamos la hipótesis nula (Ho) de la existencia de raíz unitaria, es decir que la serie es estacionaria en media y varianza

Identificación del modelo estacionario

a) Identificación de las órdenes p y q

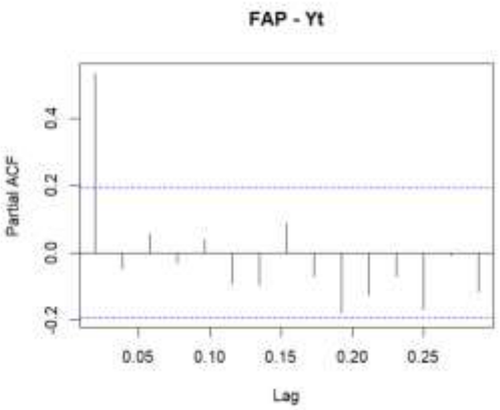

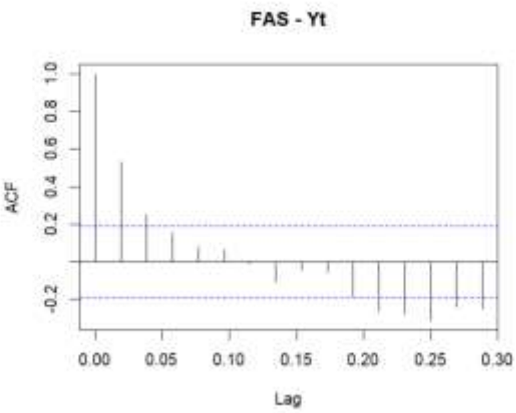

La FAS estimada muestra una estructura infinita decreciendo en forma de onda seno-coseno amortiguada que sugiere un modelo ARMA(p, q) con parte autorregresiva de orden = 1.

Los tres primeros coeficientes del FAS son significativamente distintos de cero y el resto no. Según esta interpretación el modelo adecuado sería un AR(1) y MA(3).

b) Inclusión del termino independiente (δ) o intercepto

```
#incluir el intercepto
Z <- mean(data_ts)
Co <- var(data_ts)
Tn <- length(data_ts)
Ta <- Tn - 1
Sigma <- Co/Ta
t <- Z/Sigma
```

```
tt <- qt(1-0.05/2,Ta-1)
pruebaT <- c(t, tt)
names(pruebaT) <- c("t-calculado","t-critico")
pruebaT
```

```
> pruebaT
t-calculado   t-critico
  0.3256219   1.9834953
```

INTERPRETACION:

Vemos que Tcalculado < Tcritico.Entonces se acepta la hipótesis nula, por lo cual no incluiremos el intercepto

Conclusión: Identificación de los modelos

Resumiendo, se proponen los siguientes modelos para la serie estacionaria:

$$AR(1) = ARIMA(1,0,0) = \ Z_t = \phi_1 Z_{t-1} + a_t$$

$$MA(2) = ARIMA(0,0,2) = \ Z_t = a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2}$$

$$ARMA(1,2) = ARIMA(1,0,2) = \ Z_t = \phi_1 Z_{t-1} + a_t + \theta_1 a_{t-1} + \theta_2 a_{t-2}$$

2. ESTIMACION

```
mod1 <- Arima(data_ts, order = c(1, 0, 0), include.constant = FALSE)
coeftest(mod1)
```

```
z test of coefficients:

    Estimate Std. Error z value  Pr(>|z|)
ar1  0.96900    0.01951  49.668 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

$$Z_t = 0.96900 Z_{t-1} + a_t$$

```
mod2 <- Arima(data_ts, order = c(0, 0, 2), include.constant = FALSE)
coeftest(mod2)
```

```
z test of coefficients:

    Estimate Std. Error z value  Pr(>|z|)
ma1 1.330084   0.066399  20.032 < 2.2e-16 ***
ma2 0.713893   0.069037  10.341 < 2.2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

$$Z_t = a_t + 1.330084 a_{t-1} + 0.713893 a_{t-2}$$

```
mod3 <- Arima(data_ts, order = c(1, 0, 2), include.constant = FALSE)
```

```
coeftest(mod3)
```

```
z test of coefficients:

     Estimate Std. Error  z value Pr(>|z|)
ar1  0.9942959  0.0077216 128.7683  < 2e-16 ***
ma1 -0.2474759  0.1077573  -2.2966  0.02164 *
ma2 -0.3200939  0.1223653  -2.6159  0.00890 **
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

$$Z_t = 0.9942959Z_{t-1} + a_t - 0.2474759a_{t-1} - 0.3200939a_{t-2}$$

3. VALIDACIÓN

3.1. Análisis de los coeficientes estimados

a. Significación de los coeficientes

 # De las imágenes anteriores analizamos su significancia

Modelo 1: AR(1)

$$\phi_1 = 0.96900 \rightarrow 0.00000 < 0.01, altamente\ significativo$$

Modelo 2: MA(2)

$$\theta_1 = 1.330084 \rightarrow 0.00000 < 0.01, altamente\ significativo$$

$$\theta_2 = 0.713893 \rightarrow 0.00000 < 0.01, altamente\ significativo$$

Modelo 3: ARMA(1,2)

$$\phi_1 = 0.9942959 \rightarrow 0.00000 < 0.01, altamente\ significativo$$

$$\theta_1 = -0.2474759 \rightarrow 0.02164 < 0.05, significativo$$

$$\theta_2 = -0.3200939 \rightarrow 0.1223653 > 0.05, NO\ es\ significativo$$

b. Examen de la matriz de correlaciones entre los coeficientes

```
vcov(mod1)
vcov(mod2)
vcov(mod3)
```

```
> vcov(mod1)
            ar1
ar1 0.0003806271
> vcov(mod2)
            ma1         ma2
ma1 0.004408807 0.002869561
ma2 0.002869561 0.004766068
> vcov(mod3)
              ar1           ma1           ma2
ar1  5.962296e-05 -0.0003349812 -0.0004350626
ma1 -3.349812e-04  0.0116116320  0.0004372848
ma2 -4.350626e-04  0.0004372848  0.0149732564
> 
```

INTERPRETACION:

Se observa claramente que ningún coeficiente esta próximo ni cercano a 0.9, por tanto, podemos indicar que no hay problema de multicolinealidad en los modelos propuestos.

c. Condición de Convergencia e Invertibilidad

```
autoplot(mod1)
autoplot(mod2)
autoplot(mod3)
```

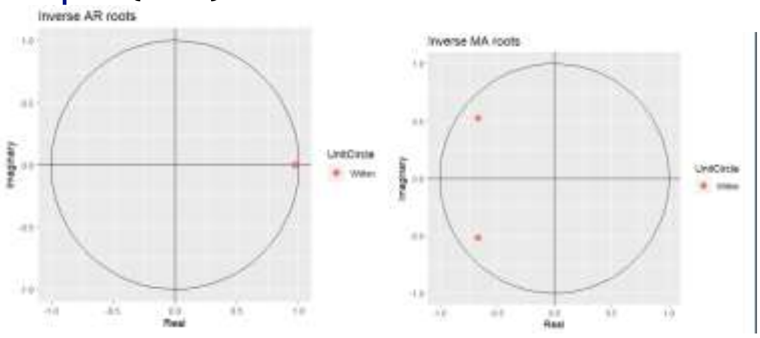

INTERPRETACION:

En la figura de raíces inversas de AR, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de estacionariedad para la parte autorregresiva.

En la figura de raíces inversas de MA, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de invertibilidad para la parte de media movíl.

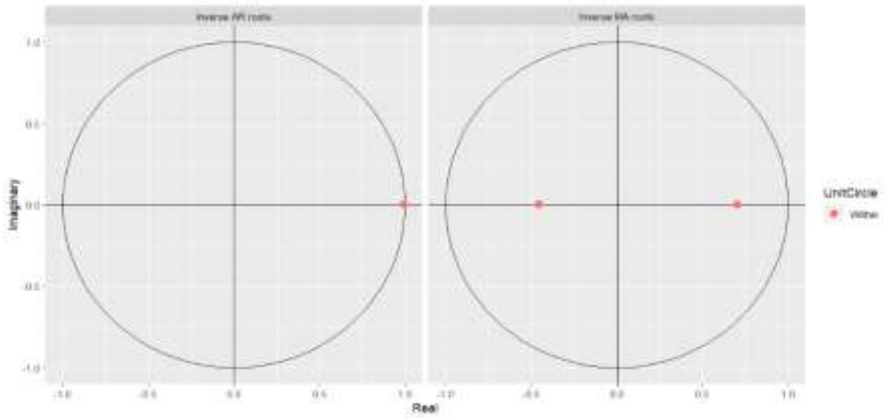

INTERPRETACION:

En la última figura al estar los valores dentro de la circunferencia unitaria es un indicativo de que el modelo se ajusta correctamente. Tanto en su parte AR, como en su parte MA.

d. Análisis de la estabilidad

```
Chow_mod1 <- Fstats(mod1$fitted ~ 1, from = 0.43)
```

```
sctest(Chow_mod1)
Chow_mod2 <- Fstats(mod2$fitted ~ 1, from = 0.43)
sctest(Chow_mod2)
Chow_mod3 <- Fstats(mod3$fitted ~ 1, from = 0.43)
sctest(Chow_mod3)
```

```
> Chow_mod1 <- Fstats(mod1$fitted ~ 1, from = 0.49)
> sctest(Chow_mod1)

        supF test

data:  Chow_mod1
sup.F = 3.0989, p-value = 0.1308

> Chow_mod2 <- Fstats(mod2$fitted ~ 1, from = 0.49)
> sctest(Chow_mod2)

        supF test

data:  Chow_mod2
sup.F = 1.4148, p-value = 0.353

> Chow_mod3 <- Fstats(mod3$fitted ~ 1, from = 0.49)
> sctest(Chow_mod3)

        supF test

data:  Chow_mod3
sup.F = 3.7762, p-value = 0.08956
```

INTERPRETACION:

En las tres pruebas se acepta la hipótesis nula ($p > \alpha = 0.05$), es decir, existe estabilidad de coeficientes.

3.2. Análisis de los residuos

a) Media es igual a cero

```
plot(mod1$residuals)
abline(h = 0, col = "red")
```

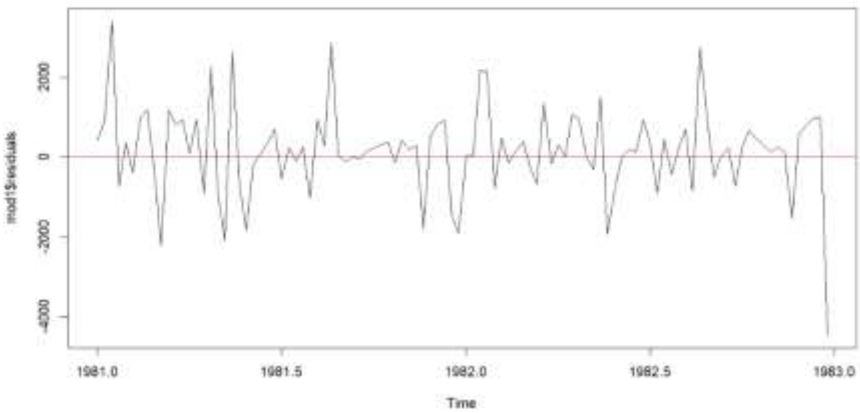


```
t.test(mod1$residuals, mu = 0)
```

```
        One Sample t-test

data:  mod1$residuals
t = 1.4658, df = 103, p-value = 0.1457
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -56.39116 375.88182
sample estimates:
mean of x
 159.7453
```

INTERPRETACION:

Segun el grafico vemos que un buen numero de residuales están en torno a la media igual a cero.

Y confirmando lo anterior p=0.1457 > 0.05, se acepta Ho, es decir la media es igual a cero

```
plot(mod2$residuals)
abline(h = 0, col = "red")
```

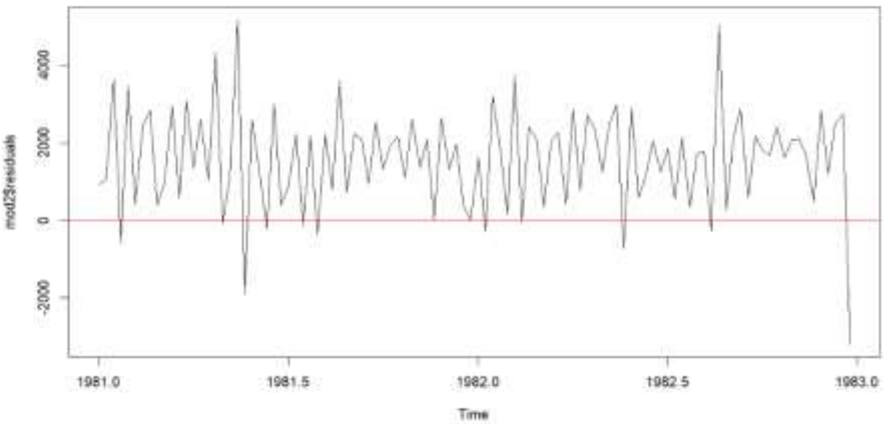


```
t.test(mod2$residuals, mu = 0)
```

```
        One Sample t-test

data:  mod2$residuals
t = 12.134, df = 103, p-value < 2.2e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 1327.265 1845.911
sample estimates:
mean of x
 1586.588
```

INTERPRETACION:

Segun el grafico vemos que los residuales NO están en torno a la media igual a cero.

Y confirmando lo anterior p=0.00000 < 0.05, se rechaza Ho, es decir la media no es igual a cero.

```
plot(mod3$residuals)
```

```
abline(h = 0, col = "red")
```

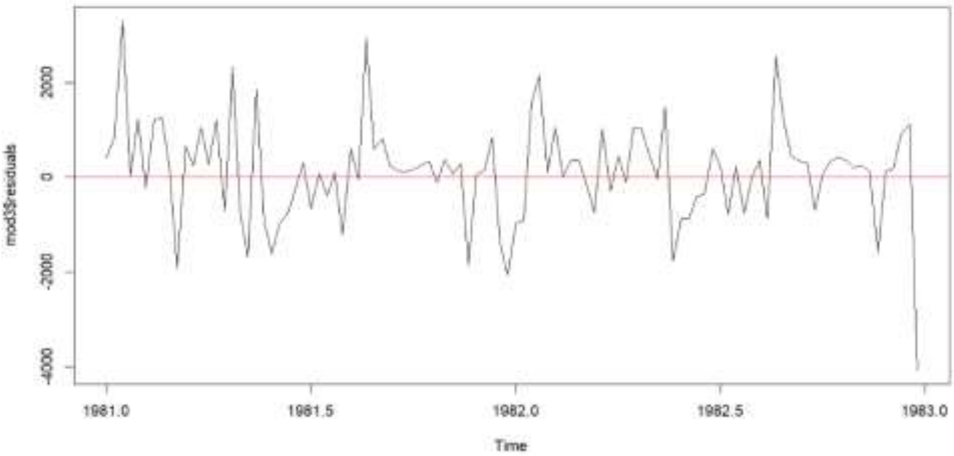


```
t.test(mod3$residuals, mu = 0)
```

```
data:  mod3$residuals
t = 1.0655, df = 103, p-value = 0.2892
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -96.2819 319.8295
sample estimates:
mean of x
 111.7738
```

INTERPRETACION:

Segun el grafico vemos que un buen número de residuales están en torno a la media igual a cero.

Y confirmando lo anterior p=0.2892 > 0.05, se acepta Ho, es decir la media es igual a cero

b) Homocedasticidad o varianza constante

```
par(mfrow = c(3,1))
scatter.smooth(sqrt(abs(mod1$residuals)), lpars=list(col=2), main =
"Modelo 1")
scatter.smooth(sqrt(abs(mod2$residuals)), lpars=list(col=2), main =
"Modelo 2")
scatter.smooth(sqrt(abs(mod3$residuals)), lpars=list(col=2), main =
"Modelo 3")
```

Alumno: Maye Mamani Victor Raul

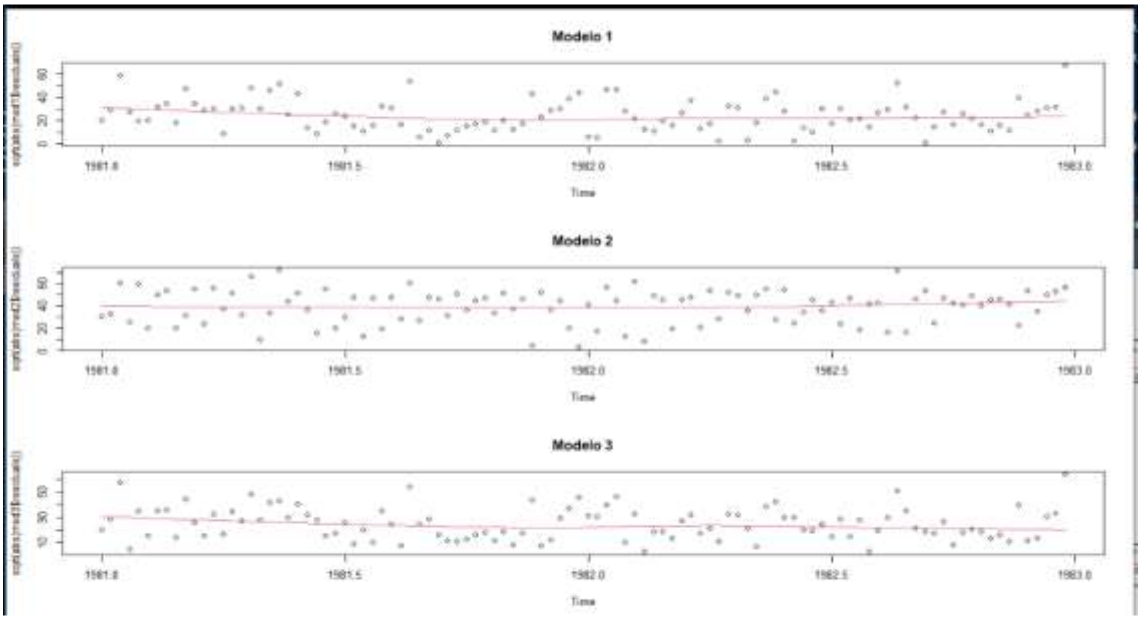

INTERPRETACION:

Se observa que los datos parecen no presentan una variabilidad considerable, por tanto, será necesario realizar la prueba de Breusch-Pagan para determinar finalmente si las varianzas constantes para los modelos.

```
obs=get(mod1$series)
bptest(resid(mod1)~I(obs-resid(mod1)))

obs=get(mod2$series)
bptest(resid(mod2)~I(obs-resid(mod2)))

obs=get(mod3$series)
bptest(resid(mod3)~I(obs-resid(mod3)))
```

```
        studentized Breusch-Pagan test

data:  resid(mod1) ~ I(obs - resid(mod1))
BP = 0.010868, df = 1, p-value = 0.917

        studentized Breusch-Pagan test

data:  resid(mod2) ~ I(obs - resid(mod2))
BP = 0.82445, df = 1, p-value = 0.3639

        studentized Breusch-Pagan test

data:  resid(mod3) ~ I(obs - resid(mod3))
BP = 0.22171, df = 1, p-value = 0.6377
```

INTERPRETACION:

El valor de probabilidad (p-valor) asociado al estadístico BP asume un valor de 0.917 para el modelo 1, 0.3639 para el modelo 2 y 0.6377 para el modelo 3. Entonces el p-value de los 3 modelos es mayor a 0.05, con esto podemos decir que los residuales de los 3 modelos son constantes

c. Ausencia de correlación serial

```
resid_m1 <- as.vector(mod1$residuals)
```

Alumno: Maye Mamani Victor Raul

```r
resid_m2 <- as.vector(mod2$residuals)
resid_m3 <- as.vector(mod3$residuals)
par(mfrow = c(1,1))
FAS_e.m1 <- acf(resid_m1, lag.max = 25,
                main="FAS Modelo 1", level = 0.95)
FAS_e.m2 <- acf(resid_m2, lag.max = 25,
                main="FAS Modelo 2", level = 0.95)
FAS_e.m3 <- acf(resid_m3, lag.max = 25,
                main="FAS Modelo 3", level = 0.95)
```

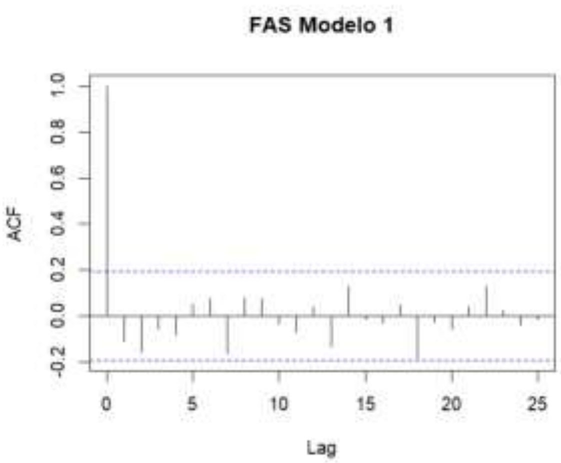

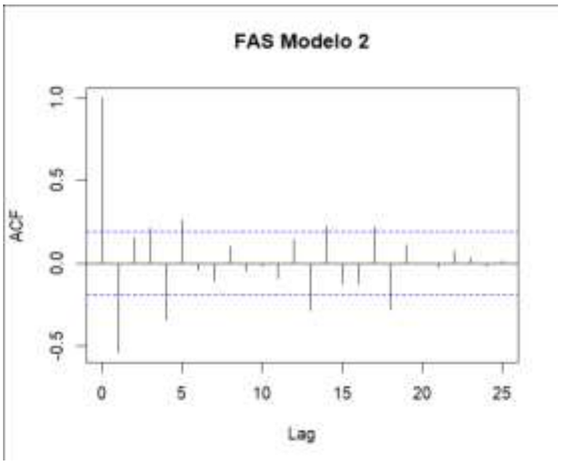

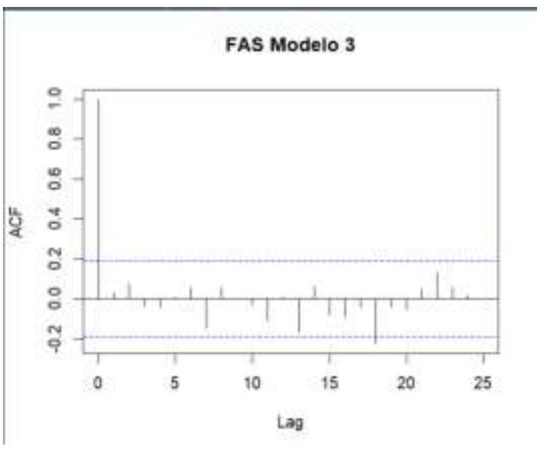

INTERPRETACION:

Se observa que solo un coeficiente del FAS para los modelos 1 y 3 son significativos. Por el contrario el modelo 2 presenta muchos coeficientes que superan los limites de confianza indicando problemas de autocorrelación entre residuales

ØGõGܻæŋḽẽħõľGõ̤ kŋ̤ Gḽŝðõħŋ̤ õ̤ ŧɾGõðľŋɪ̤ kG̤ Prueba de Ljung - Box

```r
Box.test(resid_m1,type = "Ljung-Box")
Box-Ljung test

data:  resid_m1
X-squared = 1.3104, df = 1, p-value = 0.2523
```

```
Box.test(resid_m2,type = "Ljung-Box")
Box-Ljung test

data:  resid_m2
X-squared = 31.421, df = 1, p-value = 2.077e-08
```

```
Box.test(resid_m3,type = "Ljung-Box")
Box-Ljung test

data:  resid_m3
X-squared = 0.080731, df = 1, p-value = 0.7763
```

INTERPRETACION:

Confirmamos lo mencionado en los correlogramas, en los modelos 1 y 3 se acepta la hipótesis nula(p-valor > 0.05) de que los coeficientes de autocorrelación son cero; es decir, los residuos son independientes o están incorrelacionados. Y en el modelo 2 se rechaza la hipótesis nula (pvalor < 0.05) indicándonos que los residuos están correlacionados.

d) Contraste de normalidad

```
ajuste_m1<-fitdist(data = resid_m1, distr="norm")
plot(ajuste_m1)
JB_m1 <- jarque.bera.test(resid_m1)
JB_m1
```

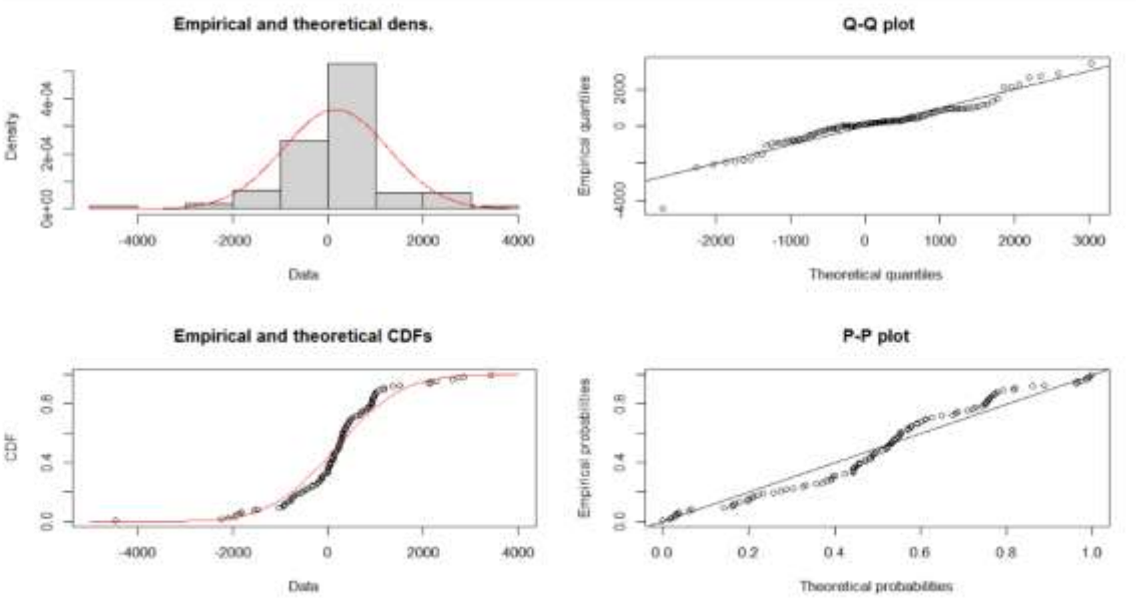


```
        Jarque Bera Test

data:  resid_m1
X-squared = 40.1, df = 2, p-value = 1.96e-09
```

INTERPRETACION:

Alumno: Maye Mamani Victor Raul

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal.

En la prueba JB, como p = 0.000000 < 0.05, se rechaza Ho, es decir, los residuos NO se aproximan a una distribucion normal.

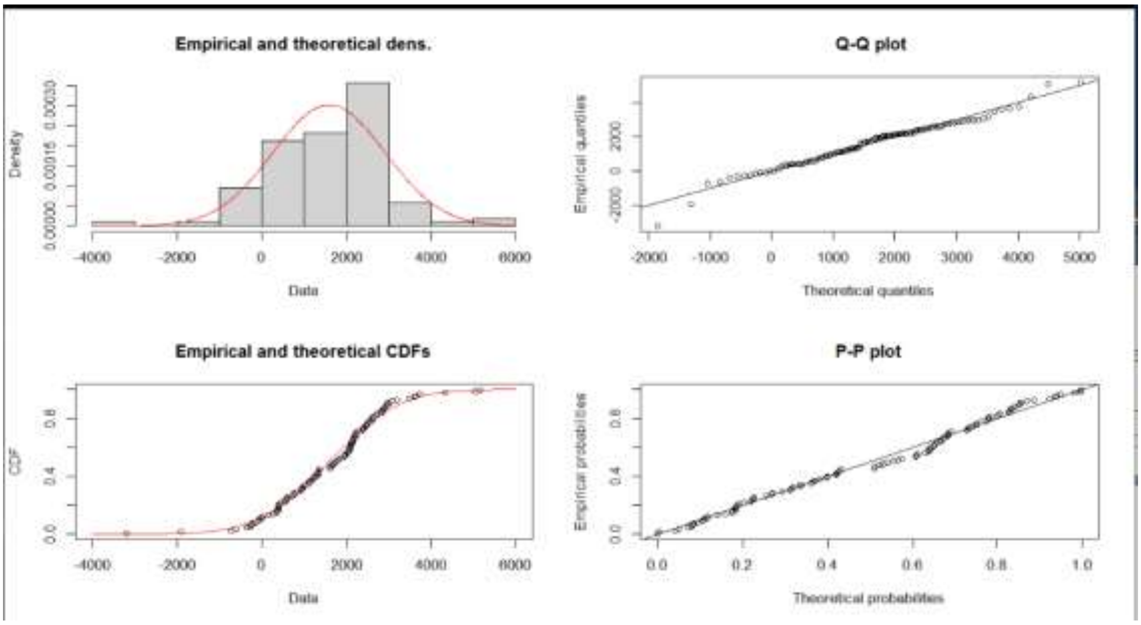


```
        Jarque Bera Test

data:  resid_m2
X-squared = 6.7366, df = 2, p-value = 0.03445
```

INTERPRETACION:

las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal.

En la prueba JB, como p = 0.03445 < 0.05, se rechaza Ho, es decir, los residuos NO se aproximan a una distribucion normal.

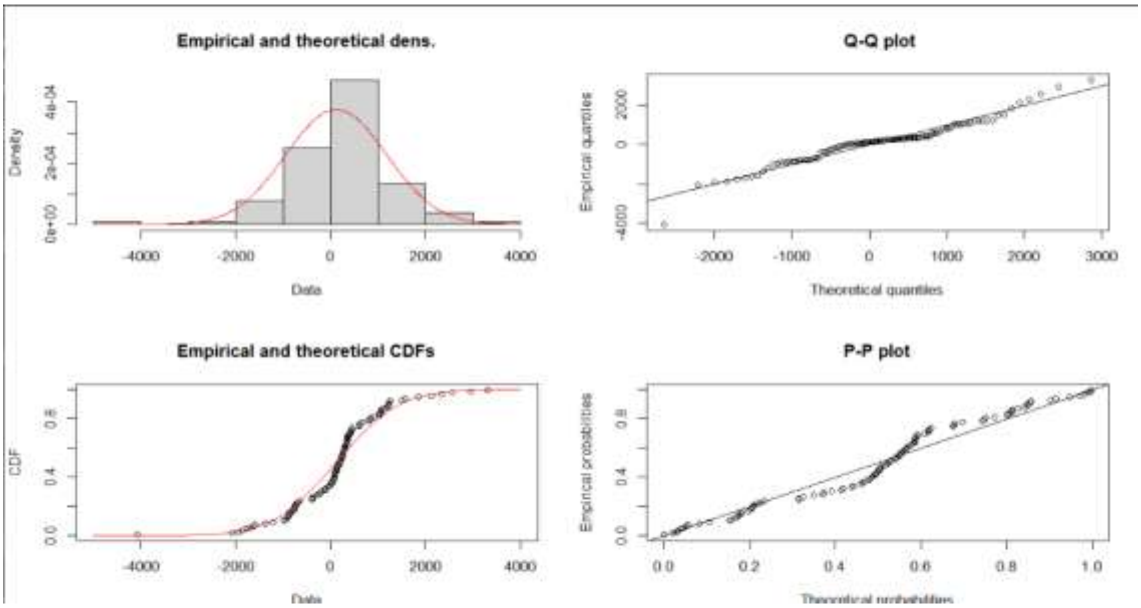

```
        Jarque Bera Test

data:  resid_m3
X-squared = 22.824, df = 2, p-value = 1.106e-05
```

INTERPRETACION:

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal.

En la prueba JB, como p = 0.000001 < 0.05, se rechaza Ho, es decir, los residuos NO se aproximan a una distribución normal.

CONCLUSION: ELECCION DEL MEJOR MODELO

CONCLUIMOS QUE EL MEJOR MODELO ES EL AR(1) POR LO SIGUIENTE:

- **SUS COEFICIENTES SON SIGNIFICATIVOS**
- **LA MEDIA DE LOS RESIDUALES TIENDE A CERO**
- **CUMPLE CON LA CONDICION DE ESTACIONALIDAD**
- **NO TIENE MULTICOLINEALIDAD**
- **LOS RESIDUALES SON CONSTANTES**

CASO 2: PRODUCCIÓN DE MAIZ

```
data <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-04.xlsx",sheet = "datos2")
View(data)
# Gráfica de la serie
data_ts <- ts(data$Produccion, start = c(1961,1), frequency = 1)
plot(data_ts, xlab="Años", ylab="Produccion")
```

Alumno: Maye Mamani Victor Raul

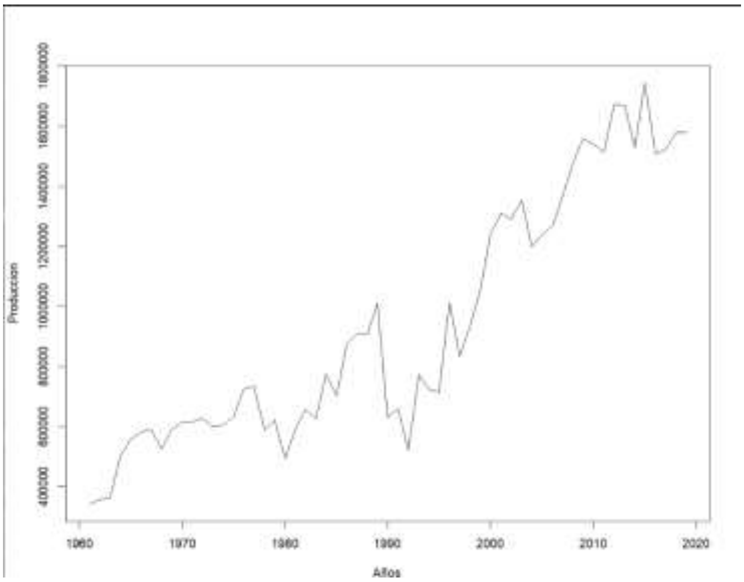

1.IDENTIFICACION

Análisis de la tendencia y estacionalidad

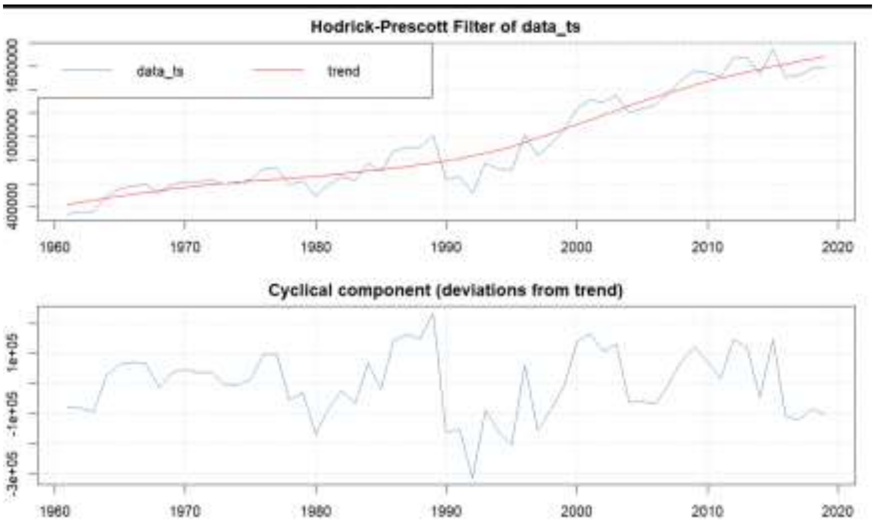

Conclusión estacionalidad y tendencia:

INTERPRETACION:

Se observa que la serie si presenta una tendencia creciente, y no tiene estacionalidad dado que la serie es anual y tiene periodicidad menor a un año

Análisis de la estacionariedad

Estacionariedad en varianza

```
Grupo <- rep(1:9, each = 6)
Grupo <- c(Grupo, rep(x = 10,5))
boxplot(data$Produccion ~ Grupo, xlab = "Año", ylab = "Producción",
main = "Distribución de Producción por Año")
```

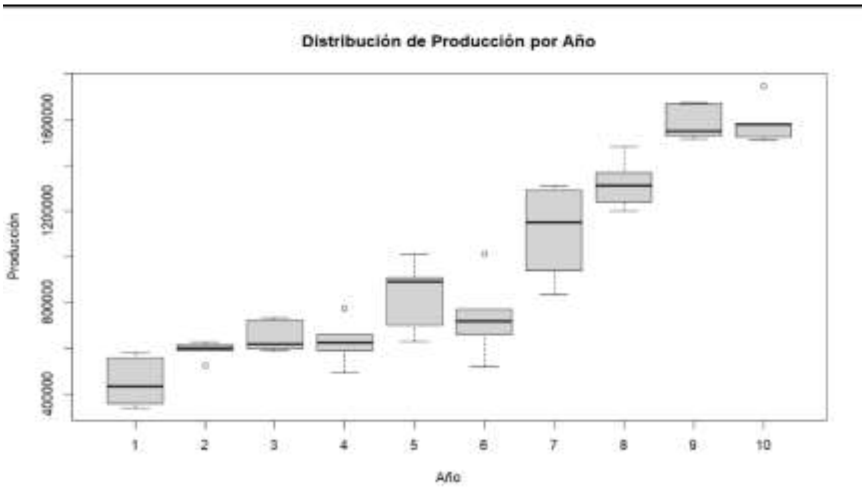

INTERPRETACION:

Dado el grafico podemos identificar que la serie no parece tener una varianza constante, en otras palabras no aparenta ser estacionaria en varianza.

VALOR OPTIMO PARA LAMDA

```
b = BoxCox.ar(data_ts)
```

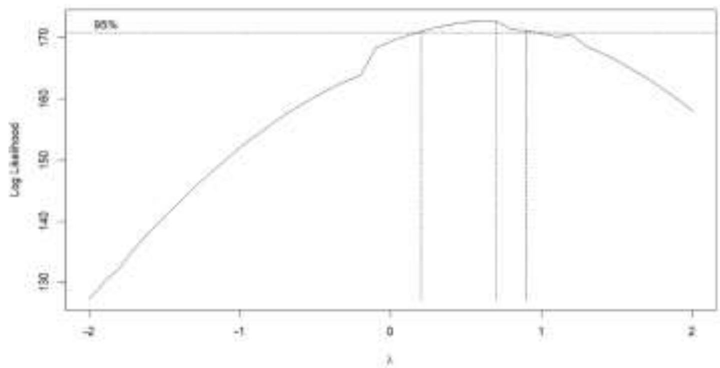


```
lambda <- b$mle
round(lambda,0)
```

Observamos que el valor optimo para lamda es 0.7 que se acerca mas a 1, por lo que lambda seria 1. Entonces no hacemos una transformación, ya que sigue siendo la serie original.

```
qqnorm(data_ts, main = "Lambda = 1") # Yt: Original
qqline(data_ts)
```

Alumno: Maye Mamani Victor Raul

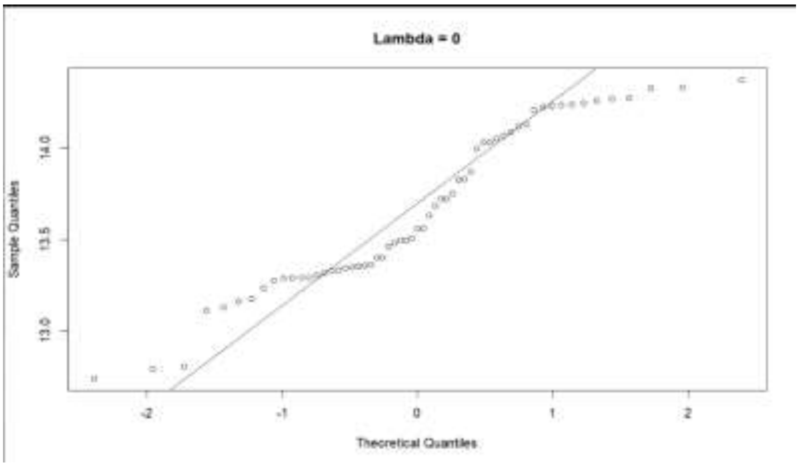

Estacionariedad en media

```
FAS <- acf(data_ts, lag.max = 15, main="FAS - Yt", level = 0.95)
```

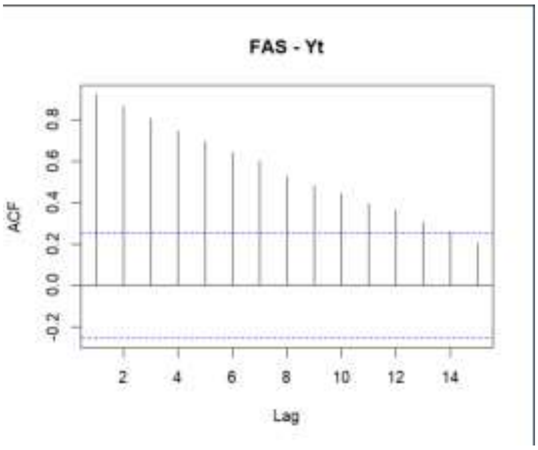


```
FAP <- pacf(data_ts, lag.max = 15, main="FAP - Yt", level = 0.95)
```

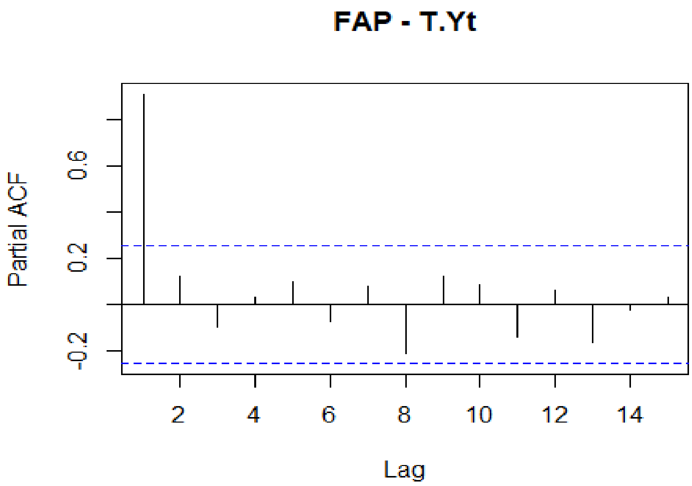


```
FAP[1]
```

```
##
## Partial autocorrelations of series 'T.Yt', by lag
##
##     1
## 0.921
```

INTERPRETACION:

Observamos que el comportamiento de las FAS es decreciente lentamente lo que nos indica que no hay estacionariedad de la serie. Y vemos que el primer coeficiente del FAP es significativo siendo 0.921 mayor a 0.9. Por lo que la serie no es estacionaria.

```
# Verificación con la prueba de Raíz unitaria de Dickey-Fuller Aumentada.
data_adf <- ur.df(data_ts, type="trend", lags = 1)
summary(data_adf)
```

```
###############################################
# Augmented Dickey-Fuller Test Unit Root Test #
###############################################

Test regression trend


Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min      1Q  Median      3Q     Max
-360220  -53502    8013   77557  200586

Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  7.821e+04  3.917e+04   1.997   0.0510 .
z.lag.1     -2.019e-01  9.739e-02  -2.074   0.0430 *
tt           4.604e+03  2.333e+03   1.974   0.0536 .
z.diff.lag  -2.523e-01  1.328e-01  -1.899   0.0630 .
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 108100 on 53 degrees of freedom
Multiple R-squared:  0.1903,   Adjusted R-squared:  0.1445
F-statistic: 4.153 on 3 and 53 DF,  p-value: 0.01024


Value of test-statistic is: -2.0737 2.7715 2.1589

Critical values for test statistics:
      1pct  5pct 10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

INTERPRETACION:

Con un T calculado de -2.0737 > T critico de -3.45. Concluimos que se rechaza la hipótesis nula de la existencia de raíz unitaria, es decir la serie NO es estacionaria en media y varianza

Conclusión de estacionariedad en media y varianza

Dado lo anterior concluimos que según los métodos graficos y la prueba de raíz unitaria de dickey Fuller que NO HAY ESTACIONARIEDAD EN VARIANZA Y MEDIA

Diferenciación

```
data_diff <- diff(data_ts)
plot(data_diff, xlab = "Años", ylab="Produccion")
```

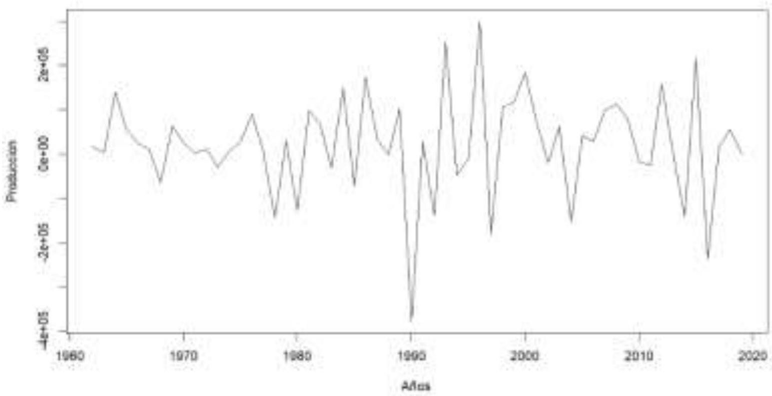

Después de realizar la primera diferencia la serie aparenta ser estacionaria

```
#Correlograma de la 1ra diferencia
par(mfrow =c(1,2))
FAS <- acf(data_diff, lag.max=15, main="Fas", level = 0.95)
FAP <- pacf(data_diff, lag.max=15, main="Fap", level =0.95)
```

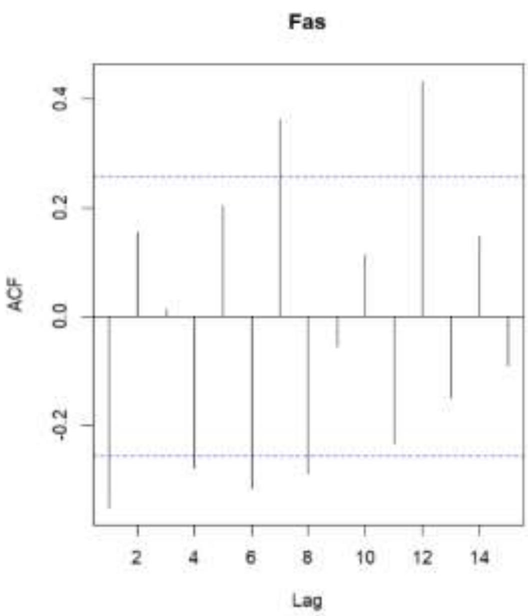

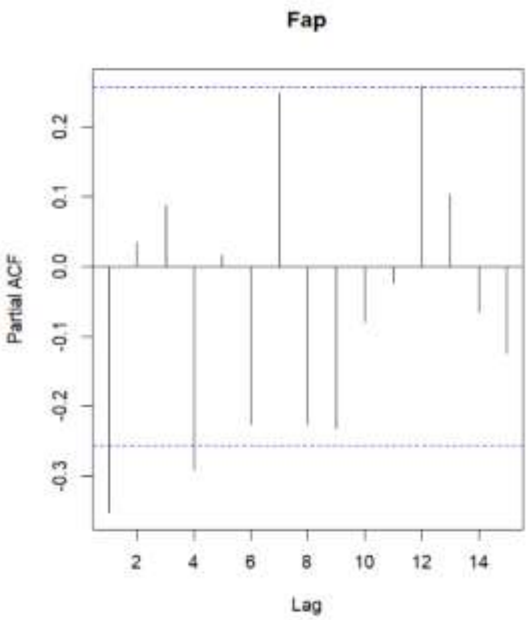

INTERPRETACION:

Según el FAS se observa que disminuye rápidamente a 0, y en el FAP vemos que el primer coeficiente es menor a 0.9. Esto nos da a entender que la serie es ESTACIONARIA

```
#Dickey fuller

data_adf <- ur.df(data_diff, type="drift", lags = 1)
summary(data_adf)

Value of test-statistic is: -5.7842 16.7287

Critical values for test statistics:
      1pct  5pct 10pct
tau2 -3.51 -2.89 -2.58
phi1  6.70  4.71  3.86
```

Vemos que T calculado -5.7842 < T critico -2.89. Por lo que haceptamos Ho, ósea que si hay raíz unitaria. Lo que nos indica que si hay ESTACIONARIEDAD EN MEDIA Y VARIANZA.

Conclusión de la diferenciación

Dado el análisis anterior usando las autocorrelaciones y la prueba de raíz unitaria se observa que la serie es estacionaria después de aplicar la primera diferencia.

a. Identificación de las órdenes p y q

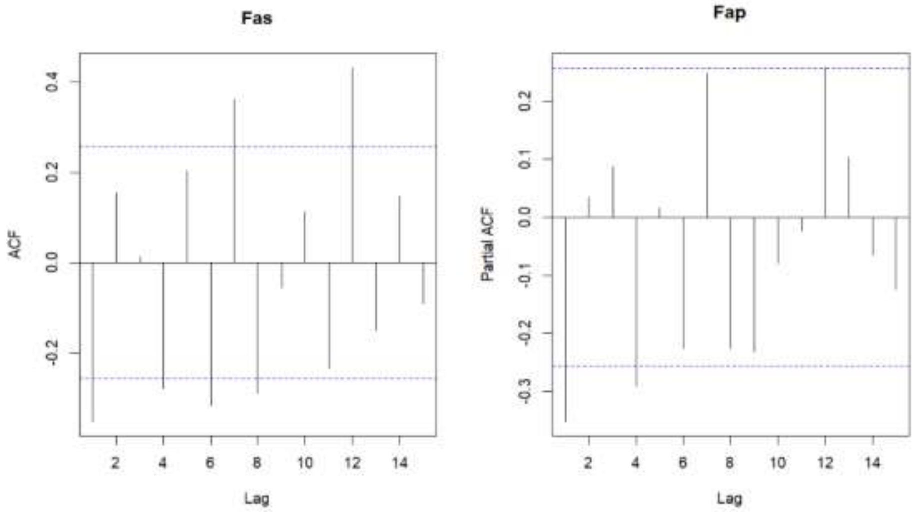

INTERPRETACION:

Según las FAS y FAP podemos ver que el comportamiento de estas podrían sugerirnos un modelo ARMA(1,2) ya que no muestran un patrón fijo y van seguidos de una mezcla oscilaciones sinusoidales.

b. Inclusión del término independiente o intercepto

```
plot(data_diff, xlab="Años", ylab="Produccion")
abline(h = mean(data_diff), col = "red")
```

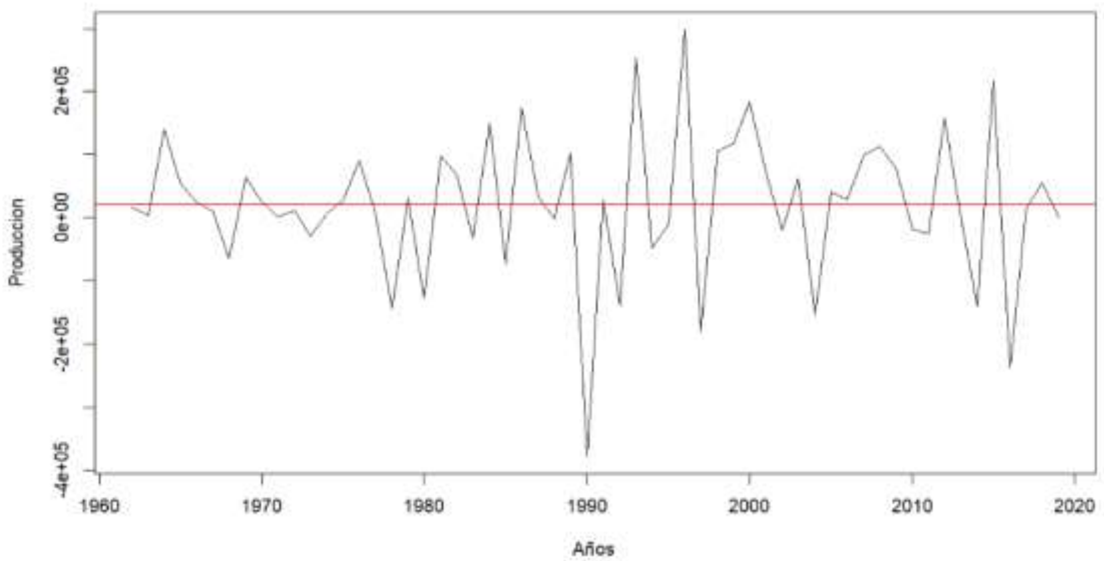


```
Z <- mean(data_diff)
Co <- var(data_diff)
Tn <- length(data_ts)
Ta <- Tn - 1
Sigma <- Co/Ta
```

Alumno: Maye Mamani Victor Raul

```
t <- Z/Sigma
tt <- qt(1-0.05/2,Ta-1)
pruebaT <- c(t, tt)
names(pruebaT) <- c("t-calculado","t-critico")
pruebaT
```

```
 t-calculado    t-critico
9.242922e-05 2.002465e+00
```

Conclusión de la inclusión del intercepto

El primer grafico nos muestra que la serie estacionaria parece oscilar en torno a una media de 0. Para verificar esto se hizo la prueba estadistica donde el T calculado < T crítico, entonces aceptamos la hipótesis nula. Finalmente concluimos que el intercepto no debe ser incluido en el modelo.

Conclusión: Identificación de los modelos

Resumiendo, se proponen los siguientes modelos para la serie estacionaria:

$$AR(1) = ARIMA(2,1,0) = \ Z_t = \phi_1\, Z_{t-1} + a\_t$$

$$MA(1) = ARIMA(0,1,2) = \ Z_t = a_t + \theta_1 a_{t-1} + \theta_2\, a_{t-2}$$

$$ARMA(1,1) = ARIMA(1,1,1) =$$

$$Z_t = \phi\_1\ \ Z\_(t-1) + a\_t + \theta_1\, a_{t-1} + \theta\_2\ \ a\_(t-2)$$

2.ESTIMACION

```
#ARIMA(1,1,0)

mod1 <- Arima(data_ts, order = c(1,1,0))
coeftest(mod1)
```

```

z test of coefficients:

    Estimate Std. Error z value Pr(>|z|)
ar1 -0.30209    0.12375  -2.441  0.01464 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

$$Z_t = -0.30209_{t-1} + a_t$$

Dado la significancia de los coeficientes del modelo AR(1) podemos ver que es significativo para el modelo.

```
#ARIMA(0,1,2)
mod2 <- Arima(data_ts, order = c(0,1,2))
coeftest(mod2)
```

```
z test of coefficients:
```

```
    Estimate Std. Error z value Pr(>|z|)
ma1 -0.24076    0.11944 -2.0158  0.04382 *
ma2  0.27947    0.17537  1.5936  0.11102
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1
```

$$z_t = -0.24076_{t-1} + 0.27497_{t-2} + a_t$$

```
#ARIMA(1,1,2)
mod3 <- Arima(data_ts, order = c(1,1,2))
coeftest(mod3)
```

Dado la significancia de los coeficientes del modelo MA(2) podemos ver que solo MA1 es significativo para el modelo.

```
z test of coefficients:

    Estimate Std. Error z value Pr(>|z|)
ar1 -0.13998    0.32033 -0.4370   0.6621
ma1 -0.12513    0.29434 -0.4251   0.6708
ma2  0.25508    0.18971  1.3446   0.1788
```

$$z_t = -0.13998Z_{t-1} + \mathrm{a_t} + 0.12513a_{t-1} + 0.25508a_{t-2}$$

INTERPRETACION:

Dado la significancia de los coeficientes del modelo ARMA(1,2) podemos ver que ningún coeficiente es significativo para el modelo.

3. VALIDACION

3.1. Análisis de los coeficientes estimados

a. Significación de los coeficientes

De los coeficientes anteriores analizamos su significancia

Modelo 1: AR(1)

$$\phi_1 = 0.30209 \rightarrow 0.01464 < 0.05, es\ significativo$$

Modelo 2: MA(2)

$$\theta_1 = -0.24076 \rightarrow 0.04382 < 0.05, es\ significativo$$

$$\theta_2 = -0.27497 \rightarrow 0.11102 > 0.05, NO\ es\ significativo$$

Modelo 3: ARMA(1,2)

$$\phi_1 = 0.13998 \rightarrow 0.6621 > 0.05, NO\ es\ significativo$$

$$\theta_1 = 0.-0.12513 \rightarrow 0.6708 > 0.05, NO\ es\ significativo$$

$$\theta_2 = 0.25508 \rightarrow 0.1788 > 0.05, NO\ es\ significativo$$

b. Examen de la matriz de correlaciones entre los coeficientes

```
vcov(mod1)
```

```
            ar1
ar1 0.01531465
```

```
vcov(mod2)
```

```
              ma1          ma2
ma1 0.014264983 0.002097739
ma2 0.002097739 0.030752962
```

```
vcov(mod3)
```

```
             ar1          ma1          ma2
ar1  0.10261333 -0.08610588  0.02921369
ma1 -0.08610588  0.08663420 -0.02540416
ma2  0.02921369 -0.02540416  0.03598994
```

Se observa claramente que ningún coeficiente esta próximo ni cercano a 0.9, por tanto, podemos indicar que no hay problema de multicolinealidad en los modelos propuestos.

c. Condición de Convergencia e Invertibilidad

```
autoplot(mod1)
autoplot(mod2)
autoplot(mod3)
```

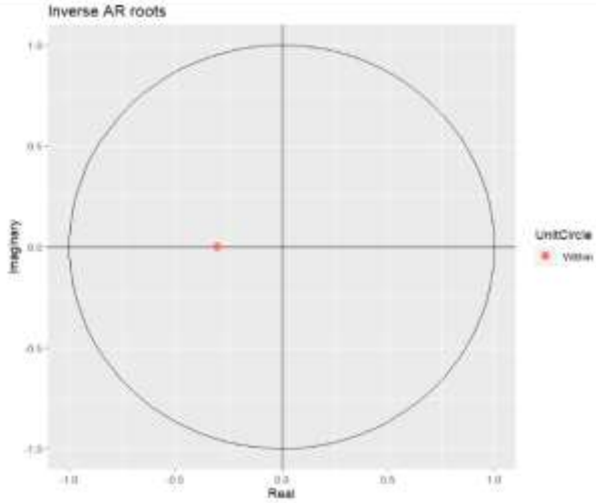

INTERPRETACION:

En la figura de raíces inversas de AR, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de estacionariedad para la parte autorregresiva.

Alumno: Maye Mamani Victor Raul

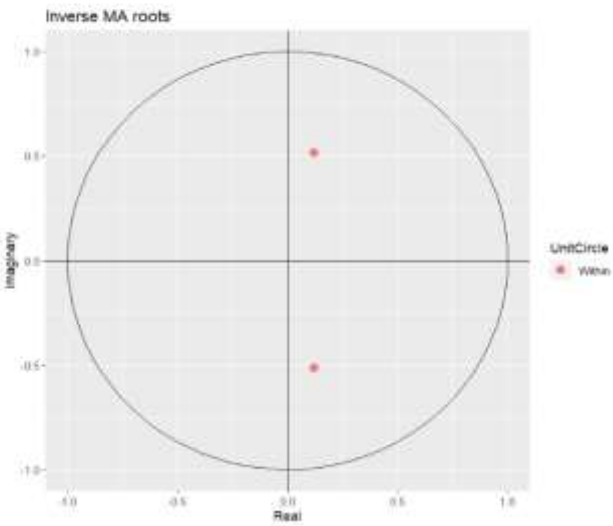

INTERPRETACION:

En la figura de raíces inversas de MA, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de invertibilidad para la parte de media movíl.

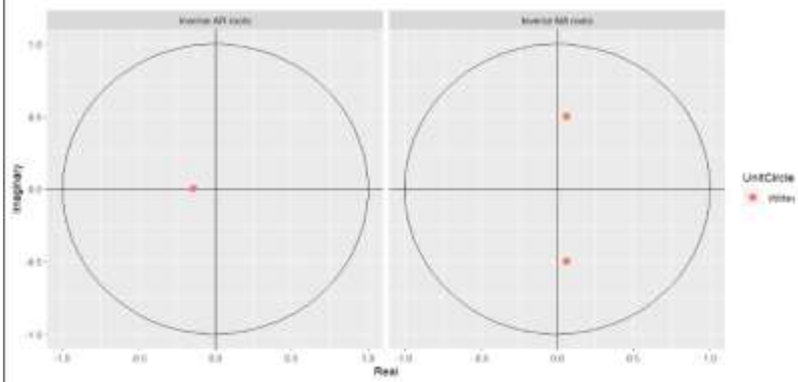

INTERPRETACION:

En la última figura al estar los valores dentro de la circunferencia unitaria es un indicativo de que el modelo se ajusta correctamente. Tanto en su parte AR, como en su parte MA.

d. Análisis de la estabilidad

```
Chow_mod1 <- Fstats(mod1$fitted ~ 1, from = 0.40)
sctest(Chow_mod1)

Chow_mod2 <- Fstats(mod2$fitted ~ 1, from = 0.40)
sctest(Chow_mod2)

Chow_mod3 <- Fstats(mod3$fitted ~ 1, from = 0.40)
sctest(Chow_mod3)
```

```
        supF test
```

```
data:  Chow_mod1
sup.F = 2.2185, p-value = 0.3873

        supF test

data:  Chow_mod2
sup.F = 3.8142, p-value = 0.1754

        supF test

data:  Chow_mod3
sup.F = 1.7002, p-value = 0.5028
```

En las tres pruebas se acepta la hipótesis nula (p > 0.05), es decir,SI existe estabilidad de coeficientes.

3.2 Análisis de residuos

```
Ho: E(at) = 0
Hi: E(at) != 0
#si el p value es mayor que la significancia aceptamos ho


plot(mod1$residuals)
abline(h = 0, col = "red")
t.test(mod1$residuals, mu = 0)
```

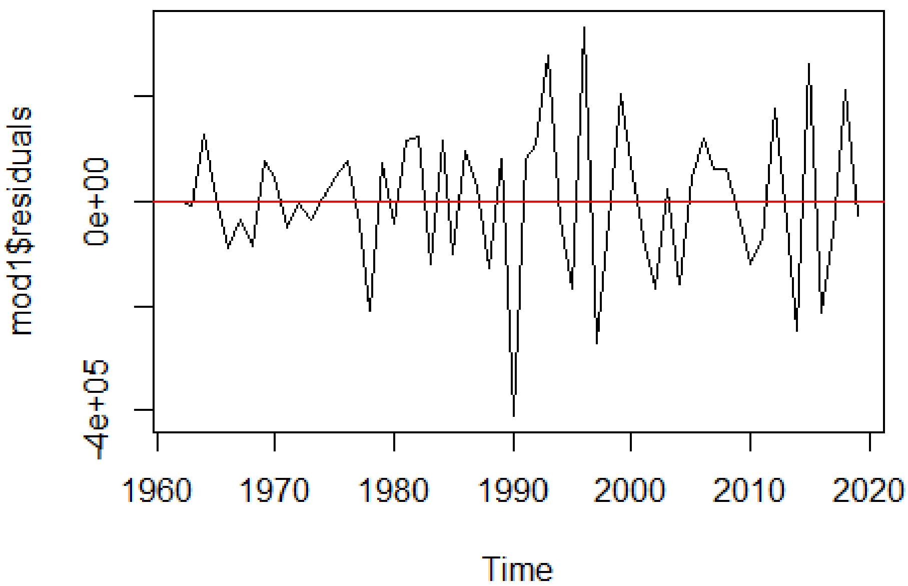


```
        One Sample t-test

data:  mod1$residuals
t = 1.9513, df = 58, p-value = 0.05586
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
```

```
  -707.3088 55405.9293
sample estimates:
mean of x
 27349.31
```

INTERPRETACION:

Según el grafico vemos que un buen numero de residuales están en torno a la media igual a cero.
Y confirmando lo anterior p=0.005586 > 0.05, se acepta Ho, es decir la media es igual a cero

```
plot(mod2$residuals)
abline(h = 0, col = "red")
t.test(mod2$residuals, mu = 0)
```

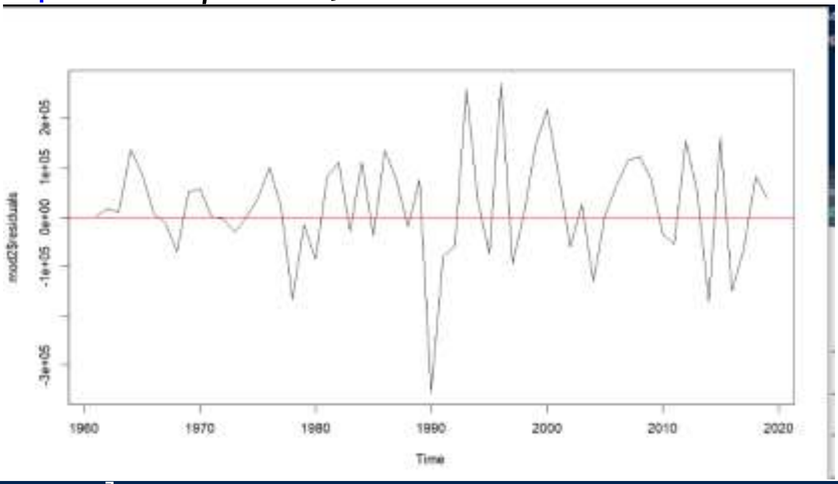


```
        One Sample t-test

data:  mod2$residuals
t = 1.4724, df = 58, p-value = 0.1463
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -7411.469 48648.560
sample estimates:
mean of x
 20618.55
```

INTERPRETACION:

Segun el grafico vemos que un buen numero de residuales están en torno a la media igual a cero.
Y confirmando lo anterior p=0.1463 > 0.05, se acepta Ho, es decir la media es igual a cero

```
plot(mod3$residuals)
abline(h = 0, col = "red")
t.test(mod3$residuals, mu = 0)
```

Alumno: Maye Mamani Victor Raul

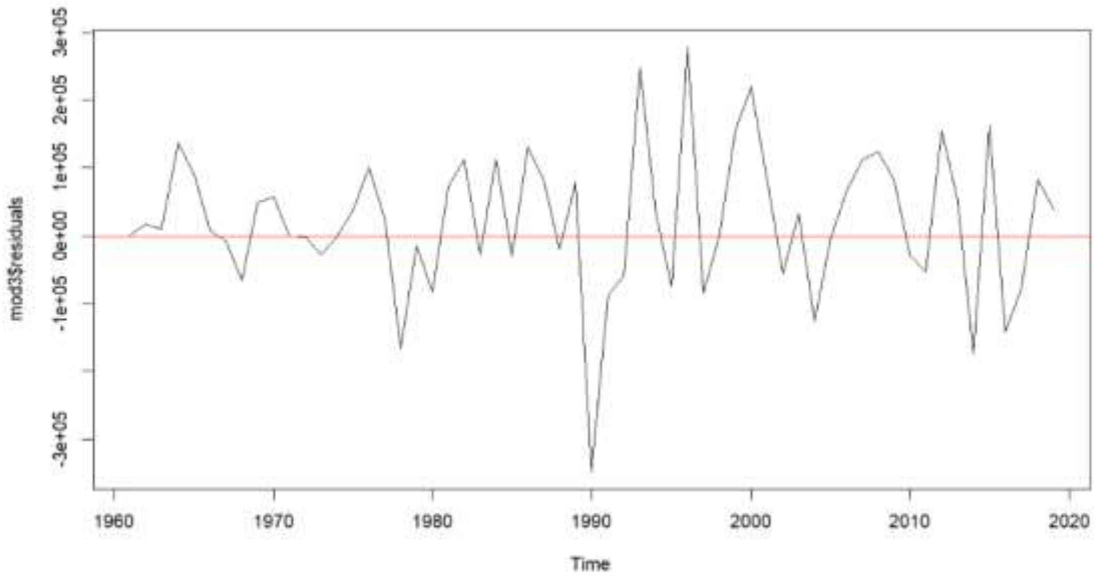


```
        One Sample t-test

data:  mod3$residuals
t = 1.5475, df = 58, p-value = 0.1272
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -6336.359 49516.763
sample estimates:
mean of x
  21590.2
```

INTERPRETACION:

Segun el grafico vemos que un buen numero de residuales están en torno a la media igual a cero.
Y confirmando lo anterior p=0.1272 > 0.05, se acepta Ho, es decir la media es igual a cero

Alumno: Maye Mamani Victor Raul

Homocedasticidad de los residuos

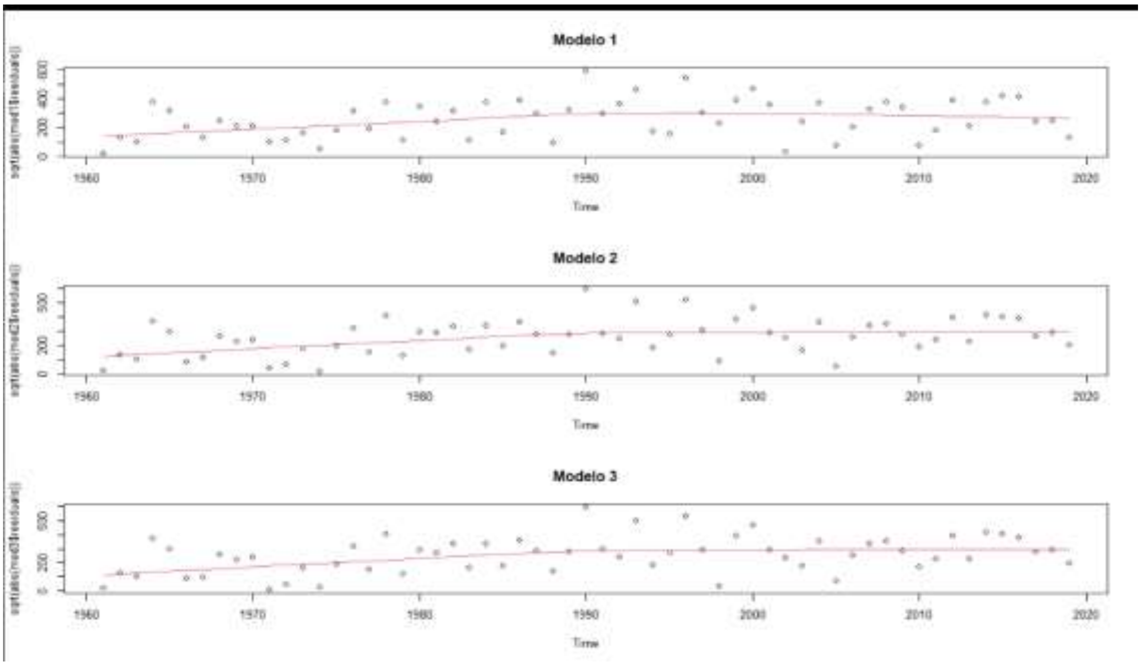

INTERPRETACION:

Se observa que los datos parecen no presentan una variabilidad considerable, por tanto, será necesario realizar la prueba de Breusch-Pagan para determinar finalmente si las varianzas constantes para los modelos.

Prueba de Breusch – Pagan

```
obs=get(mod1$series)
bptest(resid(mod1)~I(obs-resid(mod1)))
```

```
studentized Breusch-Pagan test

data:  resid(mod1) ~ I(obs - resid(mod1))
BP = 0.57678, df = 1, p-value = 0.4476
```

```
obs=get(mod2$series)
bptest(resid(mod2)~I(obs-resid(mod2)))
```

```
	studentized Breusch-Pagan test

data:  resid(mod2) ~ I(obs - resid(mod2))
BP = 0.52042, df = 1, p-value = 0.4707
```

```
obs=get(mod3$series)
bptest(resid(mod3)~I(obs-resid(mod3)))
```

```
	studentized Breusch-Pagan test
```

```
data:  resid(mod3) ~ I(obs - resid(mod3))
BP = 0.57112, df = 1, p-value = 0.4498
```

INTERPRETACION:

El valor de probabilidad (p-valor) asociado al estadístico BP asume un valor de 0.4476 para el modelo 1, 0.4707 para el modelo 2 y 0.4498 para el modelo 3. Entonces el p-value de los 3 modelos es mayor a 0.05, con esto podemos decir que los residuales de los 3 modelos son constantes

Correlograma de los residuos

```
resid_m1 <- as.vector(mod1$residuals)
resid_m2 <- as.vector(mod2$residuals)
resid_m3 <- as.vector(mod3$residuals)
par(mfrow = c(1,3))
FAS_e.m1 <- acf(resid_m1, lag.max = 25,
                main="FAS Modelo 1", level = 0.95)
FAS_e.m2 <- acf(resid_m2, lag.max = 25,
                main="FAS Modelo 2", level = 0.95)
FAS_e.m3 <- acf(resid_m3, lag.max = 25,
                main="FAS Modelo 3", level = 0.95)
```

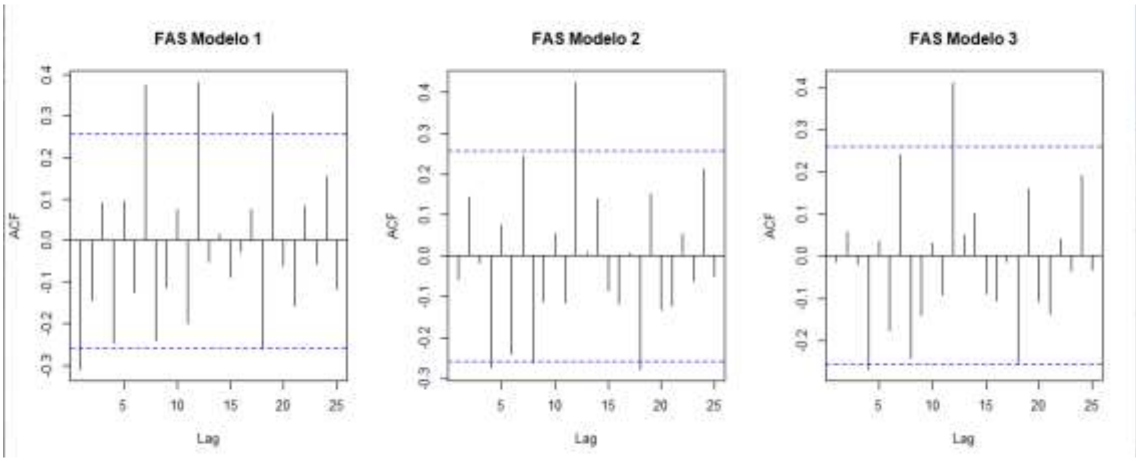

INTERPRETACION:

Se observa que casi la totalidad de los coeficientes del FAS para los modelos 1 y 3 se encuentran dentro de las bandas de no significación, sobre todo los de los primeros retardos. Pero en el modelo 1 se ve varios coeficientes significativos indicando problemas de autocorrelación.

Prueba de Ljung – Box

```
Box.test(resid_m1,type = "Ljung-Box")
Box.test(resid_m2,type = "Ljung-Box")
```

```
Box.test(resid_m3,type = "Ljung-Box")
```

```
        Box-Ljung test

data:  resid_m1
X-squared = 5.8325, df = 1, p-value = 0.01573

        Box-Ljung test

data:  resid_m2
X-squared = 0.20182, df = 1, p-value = 0.6533

        Box-Ljung test

data:  resid_m3
X-squared = 0.012917, df = 1, p-value = 0.9095
```

INTERPRETACION:

Confirmamos lo mencionado en los correlogramas, en los modelos 1 y 3 se acepta la hipótesis nula(p-valor > 0.05) de que los coeficientes de autocorrelación son cero; es decir, los residuos son independientes o están incorrelacionados.

Y en el modelo 1 se rechaza la hipótesis nula indicando que los residuos están correlacionados

d. Contraste de normalidad

```
ajuste_m1<-fitdist(data = resid_m1, distr="norm")
plot(ajuste_m1)
JB_m1 <- jarque.bera.test(resid_m1)
JB_m1
```

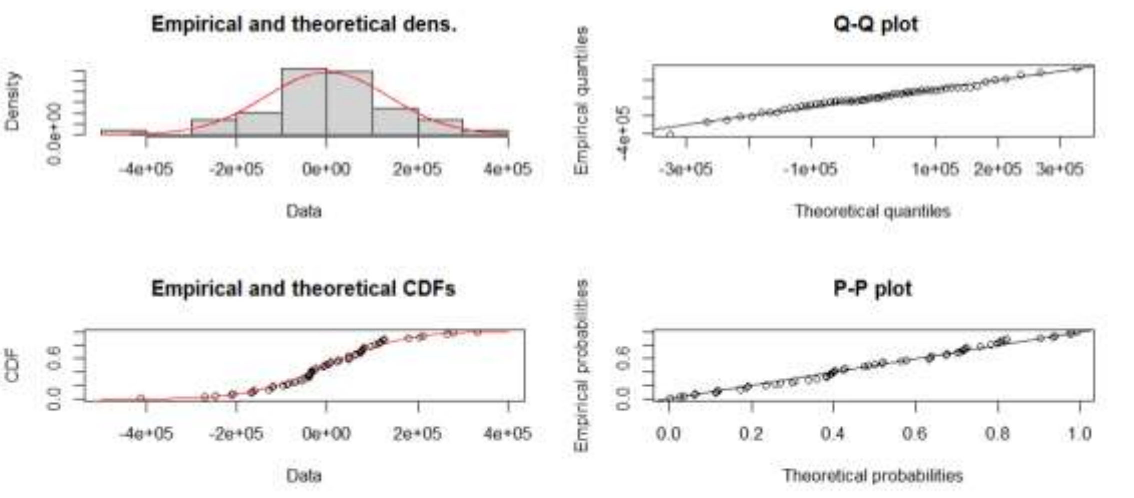


```
        Jarque Bera Test

data:  resid_m1
X-squared = 1.2796, df = 2, p-value = 0.5274
```

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal.

En la prueba JB, como p = 0.5274 > 0.05, se acepta Ho, es decir, los residuos se aproximan a una distribución normal.

```
ajuste_m2<-fitdist(data = resid_m2, distr="norm")
plot(ajuste_m2)
JB_m2 <- jarque.bera.test(resid_m2)
JB_m2
```

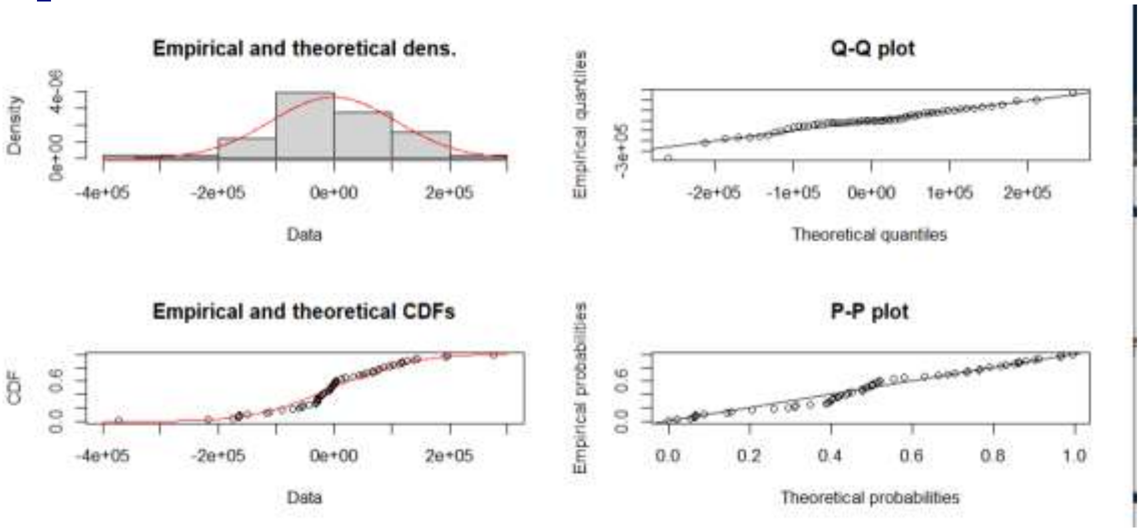


```
        Jarque Bera Test

data:  resid_m2
X-squared = 7.3252, df = 2, p-value = 0.02567
```

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal.

En la prueba JB, como p = 0.0257 < 0.05, se rechaza Ho, es decir, los residuos NO se aproximan a una distribución normal.

```
ajuste_m3<-fitdist(data = resid_m3, distr="norm")
plot(ajuste_m3)
JB_m3 <- jarque.bera.test(resid_m3)
JB_m3
```

Alumno: Maye Mamani Victor Raul

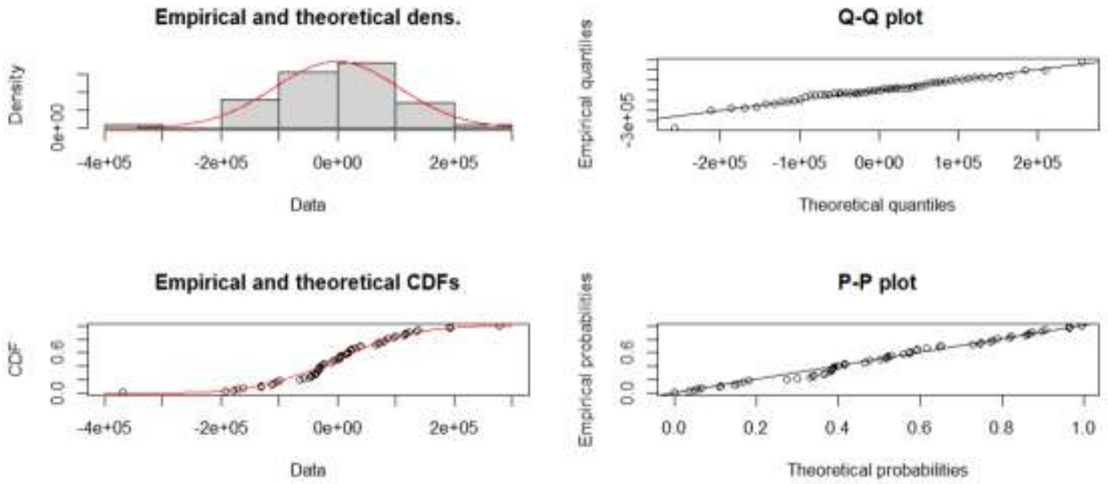

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal.

En la prueba JB, como p = 0.4199 < 0.05, se rechaza Ho, es decir, los residuos NO se aproximan a una distribución normal.

CONCLUSION:

El modelo con mejores métricas fue el fue el AR(1) por las siguientes razones:

- **Los residuos se aproximan a una distribución normal**
- **Los residuos son independientes**
- **Cumple con la condición de estacionalidad**
- **No tiene multicolinealidad**
- **Los coeficientes son estables**