

Tabla de contenido

| | |
|---|-----------|
| Caso 1 | 3 |
| 1 Identificación | 3 |
| 1. 1 Análisis de la tendencia y la estacionalidad | 4 |
| 1.1.1 Estacionalidad | 4 |
| 1.1.2 Análisis de tendencia | 4 |
| 1.2 Análisis de estacionariedad | 5 |
| 1.2.1 Estacionariedad en varianza | 5 |
| 1.2.2 Estacionariedad en media | 6 |
| 1.3 Identificación del modelo estacionario | 11 |
| 1.3.1 Identificación de las órdenes p y q | 11 |
| 1.3.2 Inclusión del término independiente (δ) o intercepto | 11 |
| 2 Estimación | 12 |
| 3 Validación | 12 |
| 3.1 Análisis de los coeficientes estimados | 12 |
| 3.1.1 Significación de los coeficientes | 12 |
| 3.1.2 Examen de la matriz de correlaciones entre los coeficientes | 13 |
| 3.1.3 Condición de convergencia e invertibilidad | 13 |
| 3.1.4 Análisis de la estabilidad | 14 |
| 3.2 Análisis de los residuos | 15 |
| 3.2.1 Media es igual a cero | 15 |
| 3.2.2 Homocedasticidad o varianza constante | 17 |
| 3.2.3 Ausencia de correlación serial | 18 |
| 3.2.4 Contraste de normalidad | 20 |
| 4 Pronostico | 22 |
| 4.1Pronosticos de cada modelo | 22 |
| Modelo 1: ARIMA(3,2,0) | 22 |
| Modelo 2: ARIMA(0,2,1) | 24 |
| Modelo 3: ARIMA(1,2,2) | 26 |
| Métricas basadas en el error | 28 |
| Conclusión | 28 |
| CASO 2: INTERESES PAGADOS AL EXTERIOR (IPE) | 30 |
| 1 Identificación | 30 |
| 1. 1 Análisis de la tendencia y la estacionalidad | 31 |
| 1.1.1 Estacionalidad | 31 |
| 1.1.2 Análisis de tendencia | 32 |
| 1.2 Análisis de estacionariedad | 32 |

| | |
|---|----|
| 1.2.1 Estacionariedad en varianza..... | 32 |
| 1.2.2 Estacionariedad en media..... | 35 |
| 1.3 Identificación del modelo estacionario | 36 |
| 1.3.1 Identificación de las órdenes p y q | 36 |
| 1.3.2 Inclusión del término independiente (δ) o intercepto | 37 |
| 2 Estimación | 37 |
| 3 Validación | 38 |
| 3.1 Análisis de los coeficientes estimados | 38 |
| 3.1.1 Significación de los coeficientes | 38 |
| 3.1.2 Examen de la matriz de correlaciones entre los coeficientes | 39 |
| 3.1.3 Condición de convergencia e invertibilidad..... | 39 |
| 3.1.4 Análisis de la estabilidad | 41 |
| 3.2 Análisis de los residuos | 41 |
| 3.2.1 Media es igual a cero..... | 41 |
| 3.2.2 Homocedasticidad o varianza constante | 43 |
| 3.2.3 Ausencia de correlación serial | 45 |
| 3.2.4 Contraste de normalidad..... | 46 |
| 4 Pronóstico | 48 |
| 4.1Pronosticos de cada modelo..... | 48 |
| Modelo 1: ARIMA (1,1,0) | 48 |
| Modelo 2: ARIMA (0,1,5) | 50 |
| Modelo 3: ARIMA (1,1,2) | 53 |
| Métricas basadas en el error | 54 |
| Conclusión..... | 55 |
| ARIMA (1,1,0) | 55 |
| ARIMA (0,1,5) | 55 |
| ARIMA (1,1,2) | 55 |

Actividad 5


```
# Librerias necesaria
library(forecast) # Modelo ARIMA
library(tseries) # Para series de tiempo
library(TSA) # Para series de tiempo
library(urca) # Raiz Unitaria
library(ggplot2) # Para hacer gráficos
library(gridExtra)
library(dplyr) # Para la manipulación de datos
library(lmtest) # Inferencia para coeficientes estimados
library(MASS) # Transformacion de Box-Cox
library(nortest) # Pruebas de normalidad
library(strucchange) # Cambio estructural - Test de Chow
library(mFilter)
library(readxl)
library(fitdistrplus)
```

Caso 1

1 Identificación

Grafica inicial de la serie:

```
data <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-05.xlsx", sheet = "1")
View(data)
# Gráfica de la serie
data_ts <- ts(data$interes, start = c(1999,1), frequency = 12)
plot(data_ts, xlab="Meses", ylab="IPC")
```

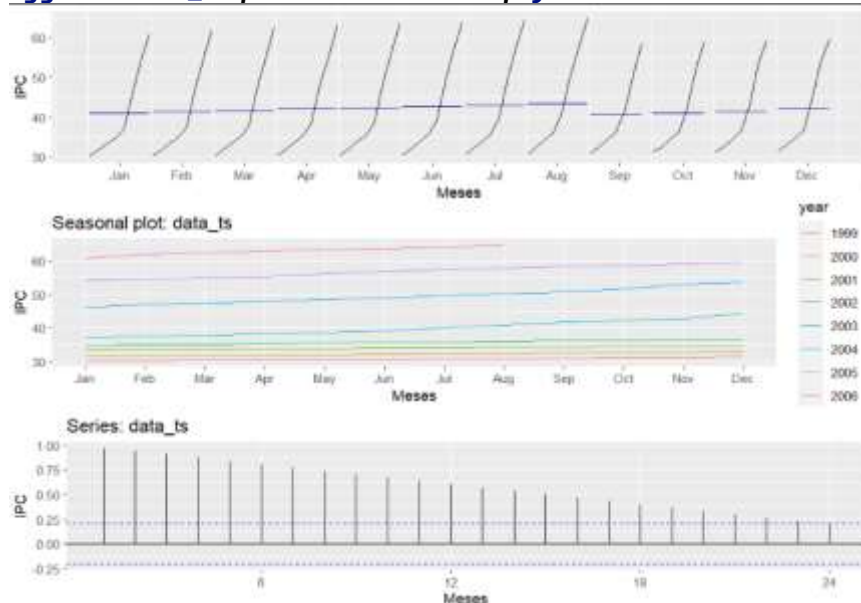


En primera instancia podemos visualizar una clara TENDENCIA creciente, la varianza no parece variar y no es estacionaria en media. Y tendremos que realizar un análisis de estacionalidad dado que la serie es trimestral

1. 1 Análisis de la tendencia y la estacionalidad

1.1.1 Estacionalidad

```
plot1 <- ggsubseriesplot(data_ts, xlab = "Meses", ylab = "IPC")  
plot2 <- ggseasonplot(data_ts, xlab = "Meses", ylab = "IPC")  
plot3 <- ggAcf(data_ts, xlab = "Meses", ylab = "IPC")
```



Vemos que la serie no presenta estacionalidad, dado que el primer grafico nos muestra se muestra a un mismo nivel, el segundo nos muestra que no hay un patrón claro y finalmente el correlograma decrece constantemente.


1.1.2 Análisis de tendencia

#Análisis de tendencia

```
lambda_hp <- 1600
```

```
data_hp <- hpfilter(data_ts, type="lambda", freq=lambda_hp)
```

```
plot(data_hp)
```

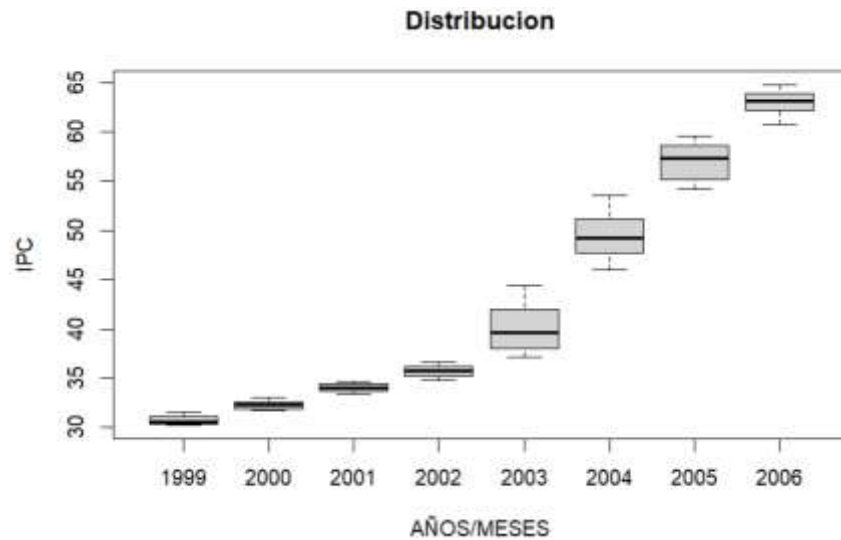


Hay una tendencia creciente y no parece haber algún patrón que se repita cíclicamente

1.2 Análisis de estacionariedad

1.2.1 Estacionariedad en varianza

```
boxplot(data$IPC ~ data$Año, xlab = "AÑOS/MESES", ylab="IPC",  
main="Distribucion" )
```

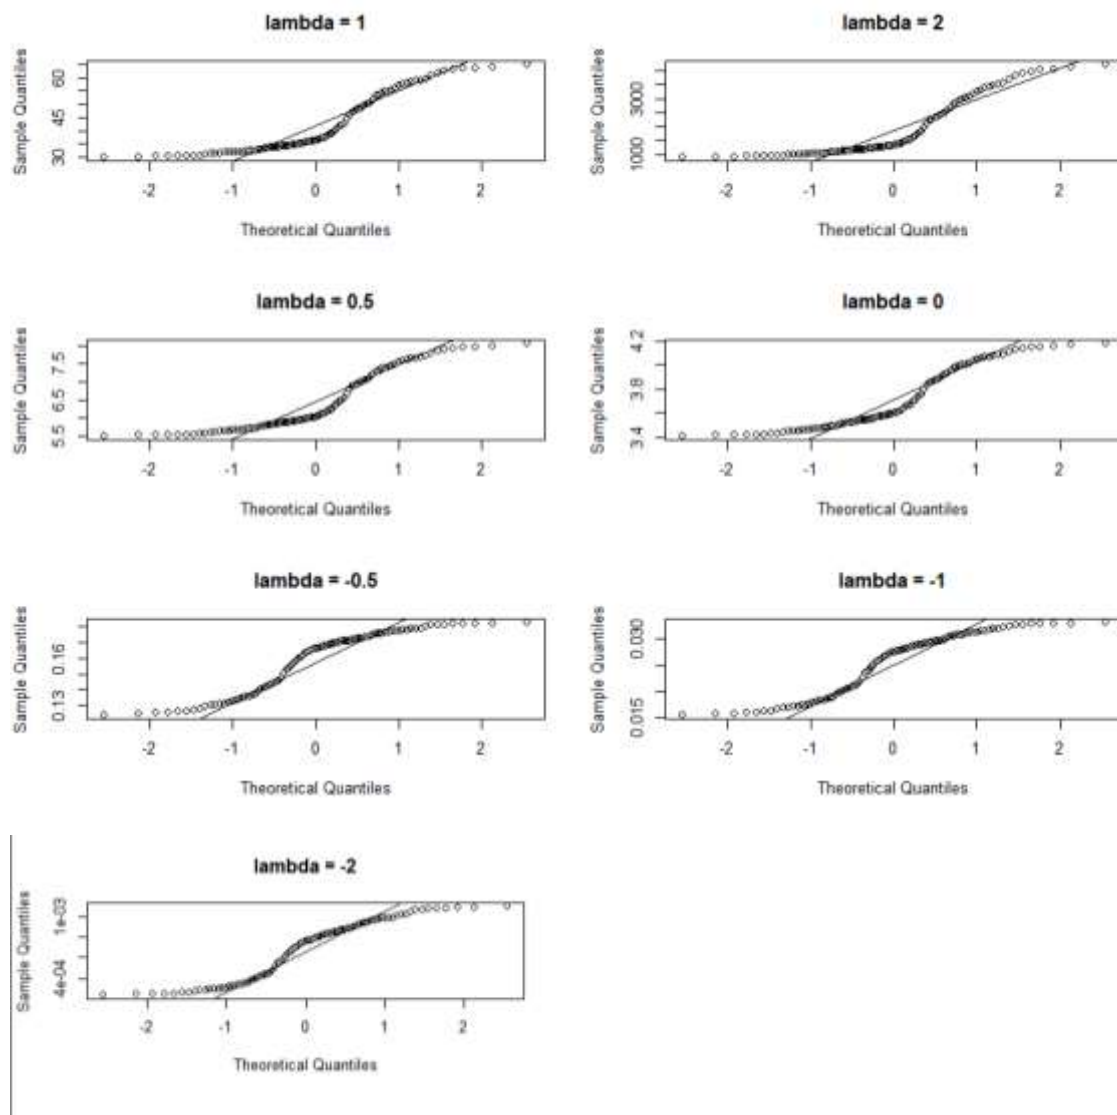


Tenemos ciertos indicios de estacionariedad en varianza, sin embargo a partir del año 2003 este presenta un cambio significativo en la serie lo que nos sugiere que no existe estacionariedad en varianza.

```
qqnorm(data_ts, main="lambda = 1")  
qqline(data_ts)  
  
t1.yt <- data_ts^2  
qqnorm(t1.yt, main="lambda = 2")  
qqline(t1.yt)  
  
t3.yt <- sqrt(data_ts)  
qqnorm(t3.yt, main="lambda = 0.5")  
qqline(t3.yt)  
  
t4.yt <- log(data_ts)  
qqnorm(t4.yt, main="lambda = 0")  
qqline(t4.yt)  
  
t5.yt <- 1/sqrt(data_ts)  
qqnorm(t5.yt, main="lambda = -0.5")  
qqline(t5.yt)  
  
t6.yt <- 1/data_ts  
qqnorm(t6.yt, main="lambda = -1")  
qqline(t6.yt)
```

Alumno: Maye Mamani Victor Raul

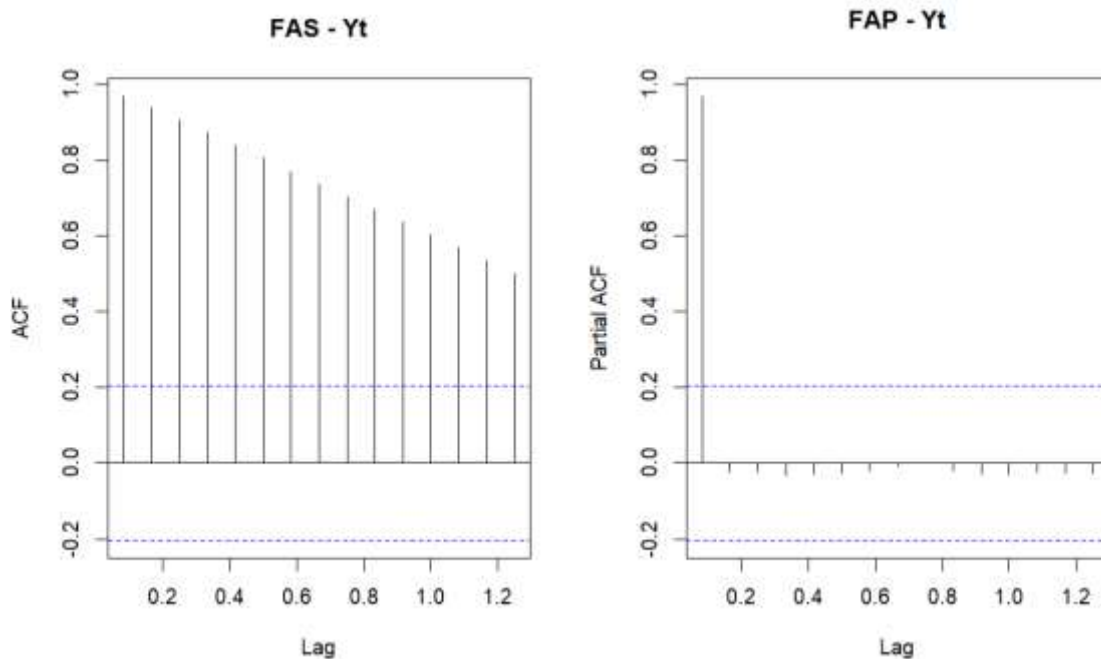
```
t7.yt <- 1/(Yt^2)
qqnorm(t7.yt, main="lambda = -2")
qqline(t7.yt)
```



Se observa el ajuste a la distribución normal de la serie original y en las demás figuras se tiene todas las demás transformaciones, las cuales no son sensibles al valor que vaya a tomar lambda (λ)

1.2.2 Estacionariedad en media

```
par(mfrow = c(1,2))
FAS <- acf(data_ts, lag.max = 15, main="FAS - Yt")
FAP <- pacf(data_ts, lag.max = 15, main="FAP - Yt")
FAP$acf[1]
```



[1] 0.9689437

El FAS decrece lentamente y el primer FAP es significativo siendo mayor a 0.9, por lo que podríamos decir que la serie NO ES ESTACIONARIA

Coefficients:

| | Estimate | Std. Error | t value | Pr(> t) |
|-------------|-----------|------------|---------|-------------|
| (Intercept) | 0.194058 | 0.185783 | 1.045 | 0.2992 |
| z.lag.1 | -0.008109 | 0.007524 | -1.078 | 0.2842 |
| tt | 0.007407 | 0.003211 | 2.306 | 0.0235 * |
| z.diff.lag | 0.485739 | 0.093634 | 5.188 | 1.4e-06 *** |

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2499 on 86 degrees of freedom
Multiple R-squared: 0.5241, Adjusted R-squared: 0.5075
F-statistic: 31.57 on 3 and 86 DF, p-value: 7.424e-14

Value of test-statistic is: -1.0777 7.7405 6.0705


Critical values for test statistics:

| | 1pct | 5pct | 10pct |
|------|-------|-------|-------|
| tau3 | -4.04 | -3.45 | -3.15 |
| phi2 | 6.50 | 4.88 | 4.16 |
| phi3 | 8.73 | 6.49 | 5.47 |

Observamos que el T calculado (-1.0777) es MAYOR que el T critico (-3.45) por tanto se rechaza la hipótesis nula de la existencia de raíz unitaria, es decir que la serie NO ES ESTACIONARIA


Diferenciamos la serie

```
data_diff = diff(data_mod)
plot(data_diff, xlab="Meses", ylab="IPC")
abline(h = mean(data_diff), col = "red")
```



Volvemos a analizar el correlograma

```
par(mfrow = c(1,2))
FAS <- acf(data_diff, lag.max = 15, main="FAS - diff Yt")
FAP <- pacf(data_diff, lag.max = 15, main="FAP - diff Yt")
FAP$acf[1]
```



Hay un decrecimiento lento en el FAS, sin embargo el valor del primer coeficiente de las FAP es menor a 0.9, por lo que existen indicios de que la serie NO es estacionaria en media. Es por que recurriremos a una confirmatoria para la evaluación de la estacionariedad del modelo.

```
data_adf <- ur.df(data_diff, type="trend", lags = 1)
summary(data_adf)
```

| Residuals: | | | | |
|------------|----------|----------|---------|---------|
| Min | 1Q | Median | 3Q | Max |
| -0.58622 | -0.14484 | -0.02920 | 0.07888 | 1.15691 |


```
Coefficients:
(Intercept)  Estimate Std. Error t value Pr(>|t|)
z.lag.1      -0.530904  0.110180 -4.819 6.25e-06 ***
tt           0.004355  0.001396  3.120 0.00247 **
z.diff.lag    0.035425  0.108660  0.326 0.74521
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2529 on 85 degrees of freedom
Multiple R-squared:  0.2566, Adjusted R-squared:  0.2304
F-statistic: 9.782 on 3 and 85 DF, p-value: 1.303e-05

Value of test-statistic is: -4.8185 7.7709 11.6148


Critical values for test statistics:
      1pct  5pct 10pct
tau3  -4.04 -3.45 -3.15
phi2   6.50  4.88  4.16
phi3   8.73  6.49  5.47
```

Observamos que el T calculado (-4.8185) es MENOR que el T critico (-3.45) por tanto se acepta la hipótesis nula de la existencia de raíz unitaria, es decir que la serie ES ESTACIONARIA

Teniendo en cuenta que el grafico de la serie y el correlograma nos indica que NO es estacionaria, pero la prueba de raíz unitaria indica que es estacionaria. Tomamos la decisión de volver a hacer una diferenciación mas para una mejor estabilización de la serie

Segunda Diferenciación


```
par(mfrow = c(1,1))
data_diff2 = diff(data_diff)
plot(data_diff2, xlab="Meses", ylab="IPC")
abline(h = mean(data_diff2), col = "red")
```



Análisis de estacionariedad

```
par(mfrow = c(1,2))
FAS <- acf(data_diff2, lag.max = 15, main="FAS - 2da diff Yt")
FAP <- pacf(data_diff2, lag.max = 15, main="FAP - 2da diff Yt")
```

FAP\$acf[1]



El FAS decrece rápidamente a cero, y el primer coeficiente del FAP es menor a 0.9, por lo que la serie es estacionaria, pero de igual forma haremos la prueba de raíz unitaria.

```
data_adf <- ur.df(data_diff2, type="drift", lags = 1)
summary(data_adf)
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.008139   0.029542   0.276   0.784
z.lag.1      -1.527289   0.166203  -9.189 2.23e-14 ***
z.diff.lag    0.240127   0.105992   2.266   0.026 *
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.2771 on 85 degrees of freedom
Multiple R-squared:  0.6372, Adjusted R-squared:  0.6287
F-statistic: 74.66 on 2 and 85 DF, p-value: < 2.2e-16

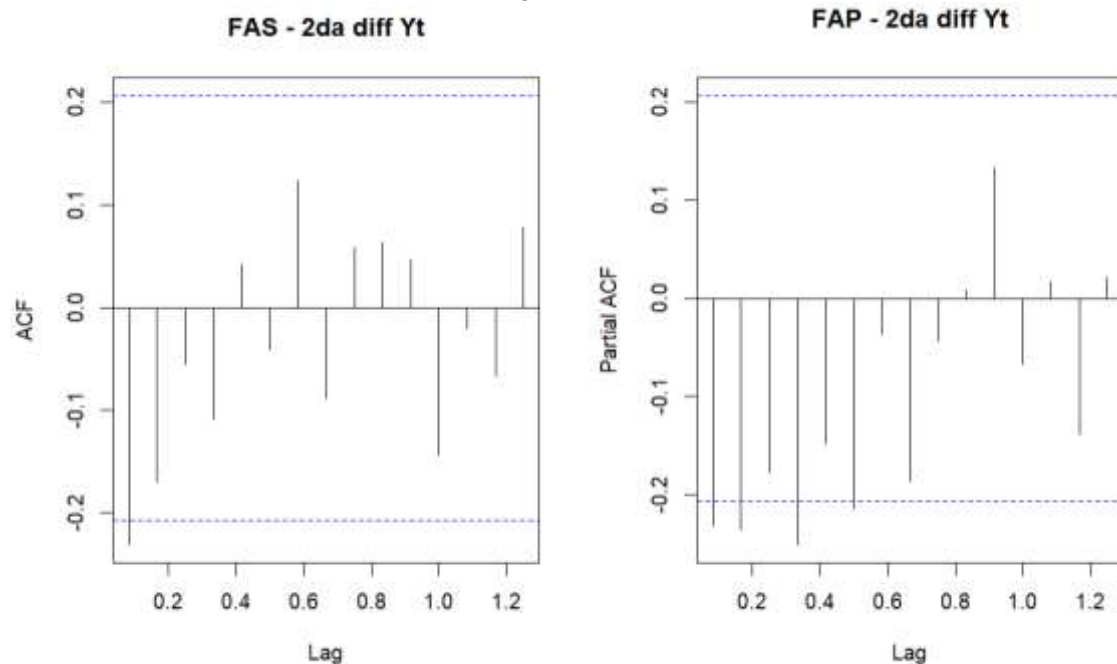
Value of test-statistic is: -9.1893 42.2251

Critical values for test statistics:
      1pct  5pct 10pct
tau2  -3.51 -2.89 -2.58
phi1   6.70  4.71  3.86
```

Observamos que el T calculado (-9.1893) es MENOR que el T crítico (-2.89) por tanto se acepta la hipótesis nula de la existencia de raíz unitaria, es decir que la serie ES ESTACIONARIA

1.3 Identificación del modelo estacionario

1.3.1 Identificación de las órdenes p y q



Observando el FAS vemos que decrece rápidamente y tiene un coeficiente significativo MA(1). Y el FAP decrece rápidamente a cero mostrando un patrón sinusoidal y tiene 2 coeficientes diferentes de cero por lo que también planteamos un AR(3). Adicionalmente planteamos un ARIMA(1,2).

1.3.2 Inclusión del término independiente (δ) o intercepto

```
Z <- mean(data_diff2)
Co <- var(data_diff2)
Tn <- length(data_diff2)
Ta <- Tn - 1
Sigma <- Co/Ta
t <- Z/Sigma
tt <- qt(1-0.05/2,Ta-1)
pruebaT <- c(t, tt)
names(pruebaT) <- c("t-calculado", "t-critico")
pruebaT
```

| t-calculado | t-critico |
|-------------|-----------|
| 6.085177 | 1.987290 |

Se rechaza la hipótesis nula y se incluye la constante.

Resumiendo, se proponen los siguientes modelos

ARIMA(3,2,0)

ARIMA(0,2,1)

ARIMA(1,2,2)

2 Estimación

```
mod1 <- Arima(data_mod, order = c(3, 2, 0), include.constant = T)
coeftest(mod1)
```

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) | |
|-----|----------|------------|---------|----------|----|
| ar1 | -0.32564 | 0.10357 | -3.1441 | 0.001666 | ** |
| ar2 | -0.28464 | 0.10452 | -2.7232 | 0.006466 | ** |
| ar3 | -0.17365 | 0.10283 | -1.6887 | 0.091283 | . |

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\Delta^2 Y_t = -0.3256 Y_{t-1} - 0.28464 \Delta^2 Y_{t-2} - 0.1736 \Delta^2 Y_{t-3} + a_t$$

```
mod2 <- Arima(data_mod, order = c(0, 2, 1), include.constant = T)
coeftest(mod2)
```

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) | |
|-----|----------|------------|---------|-----------|-----|
| ma1 | -0.67612 | 0.13061 | -5.1767 | 2.259e-07 | *** |

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\Delta^2 Y_t = a_t - 0.6761 a_{t-1}$$

```
mod3 <- Arima(data_mod, order = c(1, 2, 2), include.constant = T)
coeftest(mod3)
```

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) | |
|-----|----------|------------|---------|----------|---|
| ar1 | 0.15321 | 0.32614 | 0.4698 | 0.63852 | |
| ma1 | -0.60038 | 0.32139 | -1.8681 | 0.06175 | . |
| ma2 | -0.20687 | 0.23711 | -0.8725 | 0.38294 | |

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\Delta^2 Y_t = 0.1532 \Delta^2 Y_{t-1} + a_t - 0.6003 a_{t-1} - 0.2068 a_{t-2}$$

3 Validación

3.1 Análisis de los coeficientes estimados

3.1.1 Significación de los coeficientes

Para el modelo 1

AR(1): $\phi_1 = -0.3256 \rightarrow p = 0.0000 < 0.01$, altamente significativo

AR(2): $\phi_2 = -0.28464 \rightarrow p = 0.0000 < 0.01$, altamente significativo

AR(3): $\phi_3 = -0.1736 \rightarrow p = 0.0912 > 0.01$, NO es significativo

Para el modelo 2

MA(1): $\theta_1 = -0.6761 \rightarrow p = 0.0000 < 0.01$, altamente significativo

Para el modelo 3

AR(1): $\phi_1 = 0.1532 \rightarrow p = 0.6385 > 0.01$, altamente significativo

MA(1): $\theta_1 = -0.6003 \rightarrow p = 0.0617 > 0.05$, No es significativo

$MA(2): \phi_1 = -0.2068 \rightarrow p = 0.3829 > 0.01$, NO es significativo

3.1.2 Examen de la matriz de correlaciones entre los coeficientes

vcov(mod1)

| | ar1 | ar2 | ar3 |
|-----|-------------|-------------|-------------|
| ar1 | 0.010726879 | 0.003143925 | 0.002536229 |
| ar2 | 0.003143925 | 0.010925282 | 0.003018367 |
| ar3 | 0.002536229 | 0.003018367 | 0.010574821 |

vcov(mod2)

| | ma1 |
|-----|------------|
| ma1 | 0.01705901 |

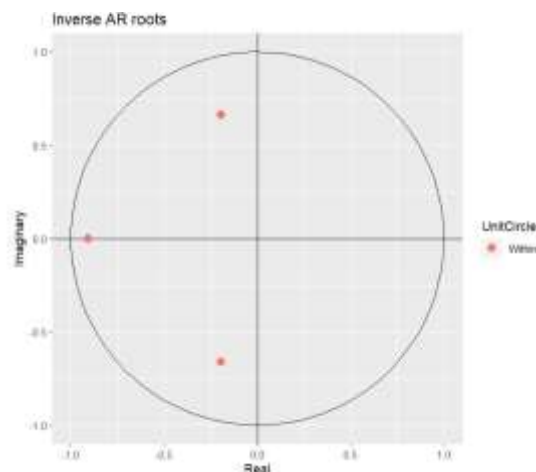
vcov(mod3)

| | ar1 | ma1 | ma2 |
|-----|-------------|-------------|-------------|
| ar1 | 0.10636603 | -0.09928611 | 0.07010027 |
| ma1 | -0.09928611 | 0.10329013 | -0.07344415 |
| ma2 | 0.07010027 | -0.07344415 | 0.05621914 |

Se observa claramente que ningún coeficiente está próximo ni cercano a 0.9, por tanto, podemos indicar que no hay problema de multicolinealidad en los modelos propuestos.

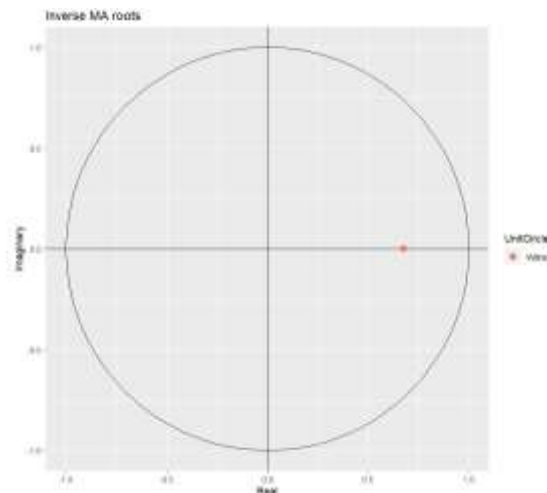
3.1.3 Condición de convergencia e invertibilidad

autoplot(mod1)




En la figura de raíces inversas de AR, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de estacionariedad para la parte autorregresiva.

autoplot(mod2)



En la figura de raíces inversas de MA, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de invertibilidad para la parte de media móvil.

`autoplot(mod3)`



Al estar los valores dentro de la circunferencia unitaria es un indicativo de que el modelo se ajusta correctamente. Tanto en su parte AR, como en su parte MA.

3.1.4 Análisis de la estabilidad

#Análisis de estabilidad

```
Chow_mod1 <- Fstats(mod1$fitted ~ 1, from = 0.60,to=0.70)
```

```
sctest(Chow_mod1)
```

```
supF test
```

```
data: Chow_mod1
```

```
sup.F = 506.59, p-value < 2.2e-16
```

```
Chow_mod2 <- Fstats(mod2$fitted ~ 1, from = 0.60,to=0.70)
```

```
sctest(Chow_mod2)
```

```
supF test
```

```
data: Chow_mod2
```

```
sup.F = 507.6, p-value < 2.2e-16
```

```
Chow_mod3 <- Fstats(mod3$fitted ~ 1, from = 0.60,to=0.70)
sctest(Chow_mod3)
supF test
data: Chow_mod3
sup.F = 507.35, p-value < 2.2e-16
```


En las tres pruebas se rechaza la hipótesis nula ($p < \alpha = 0.05$), es decir, NO existe estabilidad de coeficientes

3.2 Análisis de los residuos

3.2.1 Media es igual a cero

Modelo 1

```
plot(mod1$residuals)
abline(h = 0, col = "red")
t.test(mod1$residuals, mu = 0)
```




```
One Sample t-test
data: mod1$residuals
t = 0.289, df = 91, p-value = 0.7732
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.04666254  0.06255243
sample estimates:
mean of x
0.007944943
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.7732 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

Modelo 2

```
plot(mod2$residuals)
abline(h = 0, col = "red")
t.test(mod2$residuals, mu = 0)
```




One Sample t-test

```
data: mod2$residuals
t = 0.53477, df = 91, p-value = 0.5941
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.03987526  0.06925532
sample estimates:
mean of x
0.01469003
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t. Como $p = 0.5941 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

Modelo 3

```
plot(mod3$residuals)
abline(h = 0, col = "red")
t.test(mod3$residuals, mu = 0)
```



One Sample t-test

```
data: mod3$residuals
t = 0.85858, df = 91, p-value = 0.3928
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
```




```
-0.02927068  0.07383793
sample estimates:
mean of x
0.02228363
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.3928 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

3.2.2 Homocedasticidad o varianza constante

```
par(mfrow = c(3,1))
scatter.smooth(sqrt(abs(mod1$residuals)), lpars=list(col=2), main =
"Modelo 1")
scatter.smooth(sqrt(abs(mod2$residuals)), lpars=list(col=2), main =
"Modelo 2")
scatter.smooth(sqrt(abs(mod3$residuals)), lpars=list(col=2), main =
"Modelo 3")
```



Se observa que los datos parecen no presentar una variabilidad considerable, por tanto, será necesario realizar la prueba de Breusch-Pagan para determinar finalmente si las varianzas constantes para los modelos

```
obs=get(mod1$series)
bptest(resid(mod1)~I(obs-resid(mod1)))
studentized Breusch-Pagan test

data:  resid(mod1) ~ I(obs - resid(mod1))
BP = 5.7253, df = 1, p-value = 0.01672
```

```
obs=get(mod2$series)
```

```
bptest(resid(mod2)~I(obs-resid(mod2)))  
studentized Breusch-Pagan test  
  
data: resid(mod2) ~ I(obs - resid(mod2))  
BP = 6.3088, df = 1, p-value = 0.01201
```


```
obs=get(mod3$series)  
bptest(resid(mod3)~I(obs-resid(mod3)))  
studentized Breusch-Pagan test  
  
data: resid(mod3) ~ I(obs - resid(mod3))  
BP = 3.3616, df = 1, p-value = 0.06673
```

El valor de probabilidad (p-valor) asociado al estadístico BP asume un valor de 0.06673 para el MODELO 3, que es mayor a $\alpha=0.05$. Por tanto, los residuales de estos modelos son constantes.

En cambio en el MODELO 1 y MODELO 2 tiene el valor de probabilidad de 0.1039 y 0.6629 respectivamente, que son menores a $\alpha=0.05$, por lo cual podemos afirmar que los residuales de estos modelos no tiene varianza constante.

3.2.3 Ausencia de correlación serial

```
resid_m1 <- as.vector(mod1$residuals)  
resid_m2 <- as.vector(mod2$residuals)  
resid_m3 <- as.vector(mod3$residuals)  
par(mfrow = c(1,1))  
FAS_e.m1 <- acf(resid_m1, lag.max = 25,  
                main="FAS Modelo 1")  
FAS_e.m2 <- acf(resid_m2, lag.max = 25,  
                main="FAS Modelo 2")  
FAS_e.m3 <- acf(resid_m3, lag.max = 25,  
                main="FAS Modelo 3")
```



Se observa que casi la totalidad de los coeficientes del FAS para los modelos 1 y 3 se encuentran dentro de las bandas de no significación. Por el contrario, el modelo 2 presenta 3 coeficientes al borde de los límites de confianza indicando problemas de autocorrelación entre residuales. Por tanto, tenemos altos indicios de que los residuos de los modelos 1 y 3 sean ruido blanco

```
Box.test(resid_m1,type = "Ljung-Box")
```

Box-Ljung test

data: resid_m1

X-squared = 0.21148, df = 1, p-value = 0.6456

```
Box.test(resid_m2,type = "Ljung-Box")
```

Box-Ljung test

data: resid_m2

X-squared = 4.6216, df = 1, p-value = 0.03157

```
Box.test(resid_m3,type = "Ljung-Box")
```

Box-Ljung test

data: resid_m3

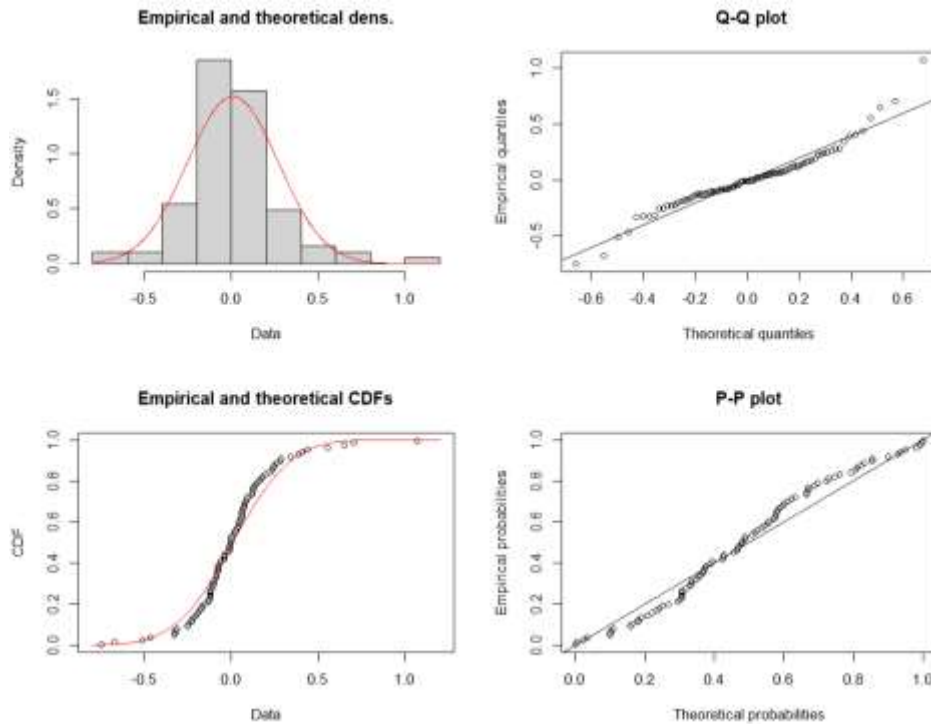
X-squared = 0.012379, df = 1, p-value = 0.9114

Con los valores 0.6456 y 0.9114 en los MODELOS 1 Y 3 son mayores a $\alpha=0.05$, por lo que se acepta la hipótesis nula de que los coeficientes de autocorrelación son cero; es decir, los residuos son independientes o están incorrelacionados. Pero el MODELO 2 con el valor de $0.03157 < 0.05$

rechazamos la hipótesis nula indicándonos que los residuos están correlacionados.

3.2.4 Contraste de normalidad

```
ajuste_m1<-fitdist(data = resid_m1, distr="norm")  
plot(ajuste_m1)  
JB_m1 <- jarque.bera.test(resid_m1)  
JB_m1
```

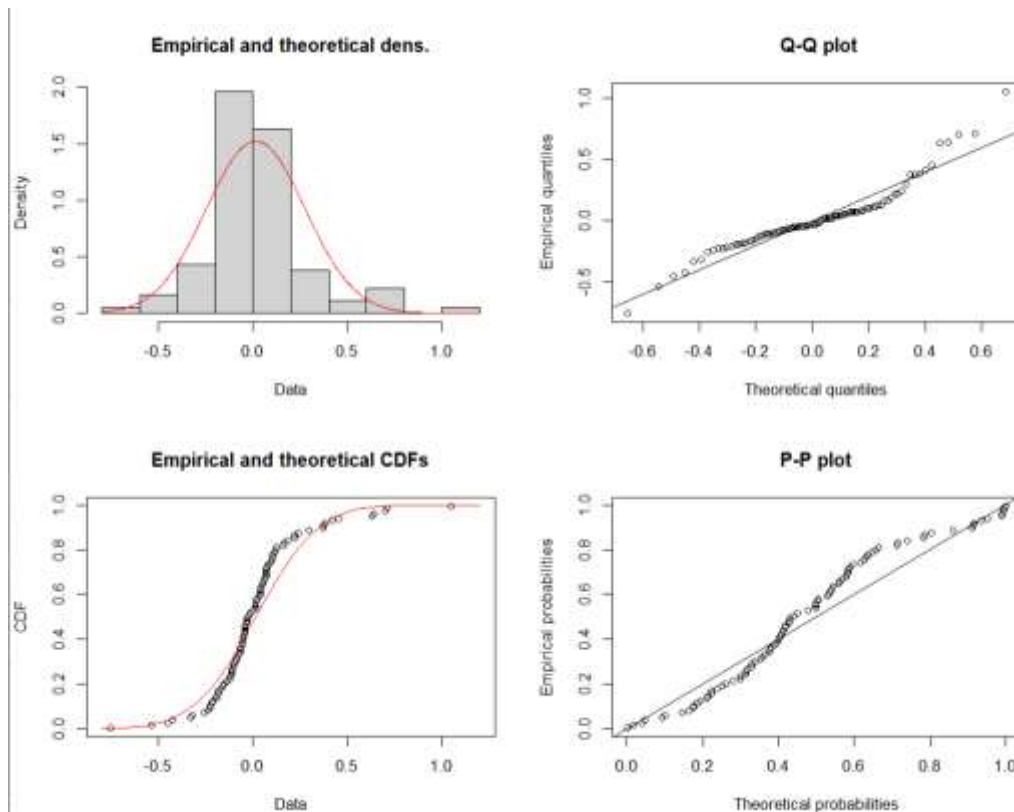


Jarque Bera Test

```
data: resid_m1  
X-squared = 41.778, df = 2, p-value = 8.471e-10
```

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.0000 < 0.05$, se rechaza la H_0 , es decir, los residuos NO se aproximan a una distribución normal.

```
ajuste_m2<-fitdist(data = resid_m2, distr="norm")  
plot(ajuste_m2)  
JB_m2 <- jarque.bera.test(resid_m2)  
JB_m2
```

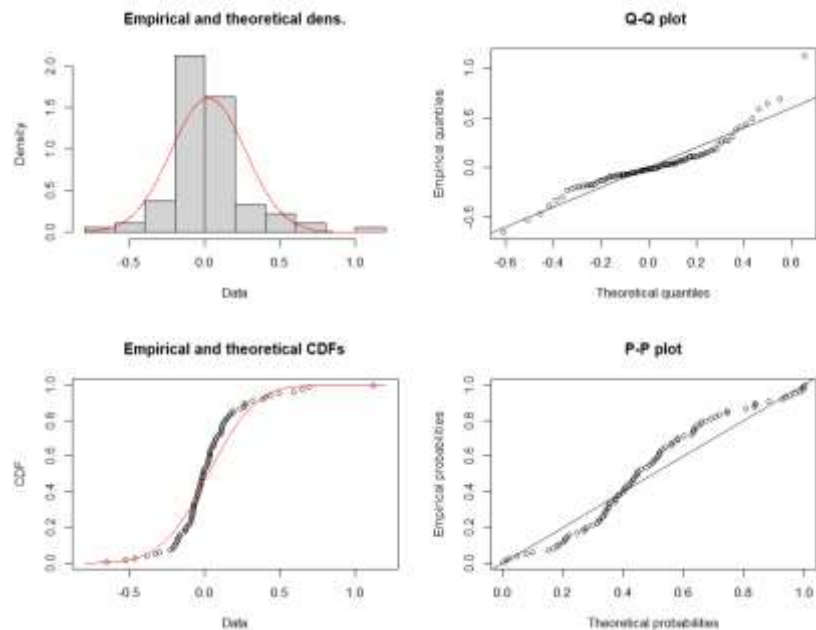


Jarque Bera Test

```
data: resid_m2  
X-squared = 47.925, df = 2, p-value = 3.919e-11
```

En las figuras se observa que los residuales del modelo 2 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.00000 < 0.05$, se rechaza la H_0 , es decir, los residuos NO se aproximan a una distribución normal.

```
ajuste_m3<-fitdist(data = resid_m3, distr="norm")  
plot(ajuste_m3)  
JB_m3 <- jarque.bera.test(resid_m3)  
JB_m3
```



Jarque Bera Test

data: resid_m3
X-squared = 87.238, df = 2, p-value < 2.2e-16

En las figuras se observa que los residuales del modelo 3 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.00000 < 0.05$, se acepta H_0 , es decir, los residuos NO se aproximan a una distribución normal.

4 Pronostico

4.1 Pronosticos de cada modelo

Modelo 1: ARIMA(3,2,0)

```
Pron1 <- forecast(mod1, level=c(95), h=10)
```

```
plot(Pron1)
```

```
summary(Pron1)
```

Forecast method: ARIMA(3,2,0)

Model Information:

Series: data_ts

ARIMA(3,2,0)

Coefficients:

| | ar1 | ar2 | ar3 |
|------|---------|---------|---------|
| | -0.3256 | -0.2846 | -0.1737 |
| s.e. | 0.1036 | 0.1045 | 0.1028 |

sigma^2 = 0.07279: log likelihood = -8.39

AIC=24.78 AICC=25.25 BIC=34.78

Error measures:


| | ME | RMSE | MAE | MPE | MAPE |
|--------------|-------------|-----------|----------|------------|-----------|
| MASE | | | | | |
| ACF1 | | | | | |
| Training set | 0.007944943 | 0.2623677 | 0.183105 | 0.02477163 | 0.4173242 |
| 46547 | -0.04717314 | | | | 0.039 |

Forecasts:

| | Point Forecast | Lo 95 | Hi 95 |
|----------|----------------|----------|----------|
| Sep 2006 | 65.32976 | 64.80096 | 65.85856 |
| Oct 2006 | 65.82460 | 64.79331 | 66.85590 |
| Nov 2006 | 66.34229 | 64.79941 | 67.88517 |


Alumno: Maye Mamani Victor Raul

| | | | |
|----------|----------|----------|----------|
| Dec 2006 | 66.87907 | 64.79726 | 68.96089 |
| Jan 2007 | 67.41145 | 64.71834 | 70.10456 |
| Feb 2007 | 67.93587 | 64.56976 | 71.30197 |
| Mar 2007 | 68.46081 | 64.37547 | 72.54615 |
| Apr 2007 | 68.98861 | 64.14337 | 73.83386 |
| May 2007 | 69.51672 | 63.86925 | 75.16419 |
| Jun 2007 | 70.04382 | 63.55289 | 76.53475 |



PRONÓSTICO DE SERIE ORIGINAL Y VALORES ESTIMADOS

```
data_modelo1 <- (mod1$fitted)
grafico_comparativo <- cbind(data_ts,data_modelo1)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt","yest"),lty = c(1,1), lwd = 2,col=c("black",
"red"))
```

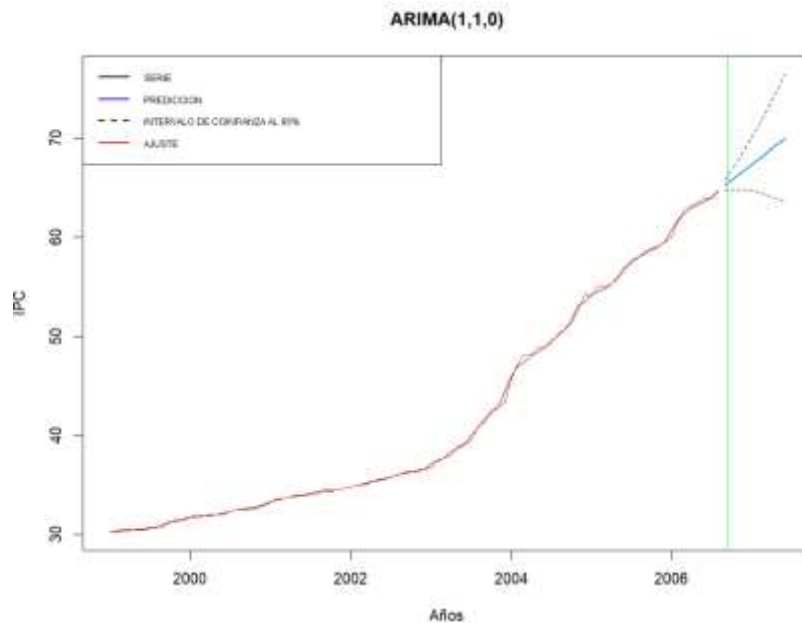


GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```
plot(Pron1, shaded = FALSE, xlab = "Años", ylab = "IPC",main =
"ARIMA(1,1,0)")
lines(Pron1$fitted, col = "red")
```


Alumno: Maye Mamani Victor Raul

```
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE  
COINFIANZA AL 95%", "AJUSTE"),col=c("black", "blue", "black", "red"),  
lty=c(1,1,2,1), lwd = 2,cex = 0.6)  
abline(v=2006.7, lwd = 1, col="green")
```



Modelo 2: ARIMA(0,2,1)

```
Pron2 <- forecast(mod2, level=c(95), h=10)  
plot(Pron2)  
summary(Pron2)
```



Forecast method: ARIMA(0,2,1)

Model Information:
Series: data_ts
ARIMA(0,2,1)

Coefficients:
ma1


```

-0.6761
s.e.    0.1306

sigma^2 = 0.07121: log likelihood = -8.6
AIC=21.19 AICC=21.33 BIC=26.19

Error measures:
MASE      ACF1      ME      RMSE      MAE      MPE      MAPE
Training set 0.01469003 0.2624562 0.1774635 0.04408597 0.4000181 0.038
24954 0.2205244

Forecasts:
Point Forecast    Lo 95    Hi 95
Sep 2006      65.32250 64.79950 65.84551
Oct 2006      65.85801 64.99029 66.72573
Nov 2006      66.39351 65.17057 67.61646
Dec 2006      66.92902 65.32936 68.52868
Jan 2007      67.46452 65.46446 69.46458
Feb 2007      68.00003 65.57578 70.42428
Mar 2007      68.53553 65.66385 71.40721
Apr 2007      69.07104 65.72944 72.41263
May 2007      69.60654 65.77332 73.43976
Jun 2007      70.14204 65.79627 74.48782


```

PRONÓSTICO DE SERIE ORIGINAL Y VALORES ESTIMADOS

```

data_modelo2 <- (mod2$fitted)
grafico_comparativo <- cbind(data_ts,data_modelo2)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt", "yest"),lty = c(1,1), lwd = 2,col=c("black",
"red"))

```




GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```

plot(Pron2, shaded = FALSE, xlab = "Meses", ylab = "",main =
"ARIMA(0,1,5)")
lines(Pron2$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"),col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2,cex = 0.6)
abline(v=2006.7, lwd = 1, col="green")

```

Alumno: Maye Mamani Victor Raul

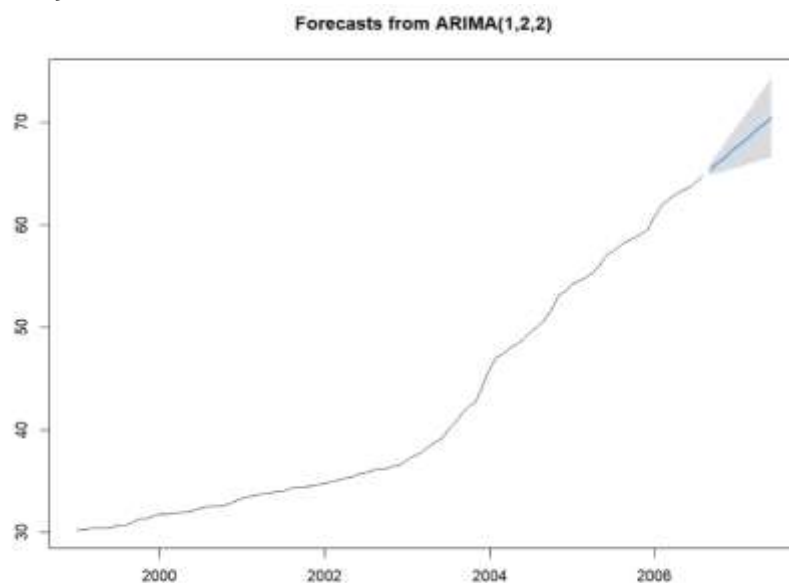


Modelo 3: ARIMA(1,2,2)

```
Pron3 <- forecast(mod3, level=c(95), h=10)
```

```
plot(Pron3)
```

```
summary(Pron3)
```



Forecast method: ARIMA(1,2,2)

Model Information:

Series: data_ts

ARIMA(1,2,2)

Coefficients:

| | ar1 | ma1 | ma2 |
|------|--------|---------|---------|
| | 0.1532 | -0.6004 | -0.2069 |
| s.e. | 0.3261 | 0.3214 | 0.2371 |

sigma² = 0.06535: log likelihood = -3.78

AIC=15.56 AICC=16.03 BIC=25.56


Error measures:

| | ME | RMSE | MAE | MPE | MAPE |
|--------------|-------------|-----------|-----------|------------|-----------|
| MASE | | | | | |
| ACF1 | | | | | |
| Training set | 0.02228363 | 0.2485855 | 0.1641209 | 0.06164755 | 0.3777026 |
| 37375 | -0.01141304 | | | | 0.035 |

| Forecasts: | | | | |
|------------|-------|----------|----------|----------|
| | Point | Forecast | Lo 95 | Hi 95 |
| Sep 2006 | | 65.36983 | 64.86881 | 65.87086 |
| Oct 2006 | | 65.93916 | 65.01379 | 66.86454 |
| Nov 2006 | | 66.50643 | 65.20365 | 67.80921 |
| Dec 2006 | | 67.07338 | 65.40958 | 68.73717 |
| Jan 2007 | | 67.64028 | 65.61801 | 69.66255 |
| Feb 2007 | | 68.20717 | 65.82256 | 70.59178 |
| Mar 2007 | | 68.77406 | 66.02007 | 71.52805 |
| Apr 2007 | | 69.34095 | 66.20890 | 72.47300 |
| May 2007 | | 69.90784 | 66.38814 | 73.42755 |
| Jun 2007 | | 70.47473 | 66.55732 | 74.39215 |

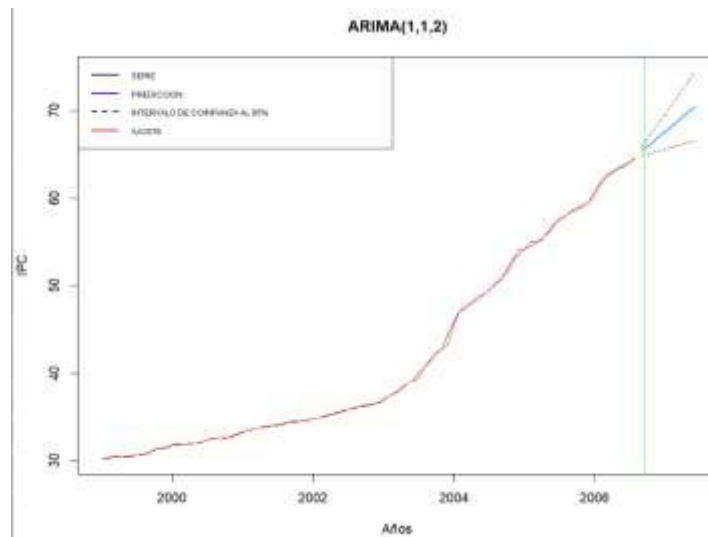
PRONÓSTICO DE SERIE ORIGINAL Y VALORES ESTIMADOS

```
data_modelo3 <- (mod3$fitted)
grafico_comparativo <- cbind(data_ts,data_modelo3)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt","yest"),lty = c(1,1), lwd = 2,col=c("black",
"red"))
```



GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```
plot(Pron3, shaded = FALSE, xlab = "Años", ylab = "IPC",main =
"ARIMA(1,1,2)")
lines(Pron3$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"),col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2,cex = 0.6)
abline(v=2006.7, lwd = 1, col="green")
```



Métricas basadas en el error

accuracy(Pron1)

| ME | RMSE | MAE | MPE | MAPE | MASE | ACF1 |
|--------------|-------------|-----------|----------|------------|-----------|-------|
| Training set | 0.007944943 | 0.2623677 | 0.183105 | 0.02477163 | 0.4173242 | 0.039 |
| 46547 | -0.04717314 | | | | | |

accuracy(Pron2)

| ME | RMSE | MAE | MPE | MAPE | MASE | ACF1 |
|--------------|------------|-----------|-----------|------------|-----------|-------|
| Training set | 0.01469003 | 0.2624562 | 0.1774635 | 0.04408597 | 0.4000181 | 0.038 |
| 24954 | 0.2205244 | | | | | |

accuracy(Pron3)

| ME | RMSE | MAE | MPE | MAPE | MASE | ACF1 |
|--------------|-------------|-----------|-----------|------------|-----------|-------|
| Training set | 0.02228363 | 0.2485855 | 0.1641209 | 0.06164755 | 0.3777026 | 0.035 |
| 37375 | -0.01141304 | | | | | |

Basado en las métricas MAE y RMSE, el modelo Pron3 es el mejor entre los tres, ya que tiene los valores más bajos (MAE = 0.1641 Y RMSE=0.2485) en ambas métricas. Esto indica que sus predicciones son más precisas y con menos variabilidad en los errores grandes.

Conclusión

Modelo ARIMA(3,2,0)

1. Estimación y Validación:

- Los coeficientes estimados para AR(1) y AR(2) fueron significativos, lo que indica que estos términos contribuyen de manera significativa al modelo, pero AR(3) no fue significativo.
- La prueba de estabilidad de coeficientes (Chow test) indicó inestabilidad, lo que podría sugerir que el modelo podría no ser robusto en el tiempo.

2. Análisis de Residuos:

- Los residuos mostraron una media cercana a cero y no presentaron homocedasticidad, como indicado por la prueba de Breusch-Pagan.

- No se observaron problemas significativos de autocorrelación en los residuos, como se confirmó mediante el análisis del correlograma de los residuos.

Modelo ARIMA(0,2,1)

1. Estimación y Validación:

- El coeficiente estimado para MA(1) fue significativo, lo que indica que este término es importante para modelar la serie.
- La prueba de estabilidad de coeficientes mostró inestabilidad, similar al primer modelo.

2. Análisis de Residuos:

- Los residuos mostraron una media cercana a cero y no presentaron homocedasticidad, según la prueba de Breusch-Pagan.
- Se observaron problemas de autocorrelación en los residuos, sugiriendo que el modelo podría no capturar completamente la estructura de la serie.

Modelo ARIMA(1,2,2)

1. Estimación y Validación:

- El coeficiente AR(1) , MA(1) y MA(2) no fueron significativos , lo que indica que estos términos pueden no ser necesarios para el modelo.
- La prueba de estabilidad de coeficientes mostró inestabilidad, similar a los otros modelos.

2. Análisis de Residuos:

- Los residuos mostraron una media cercana a cero y no presentaron homocedasticidad, según la prueba de Breusch-Pagan.
- Se observaron problemas de autocorrelación en los residuos, lo que indica que el modelo puede no ser adecuado para capturar toda la variabilidad de la serie.

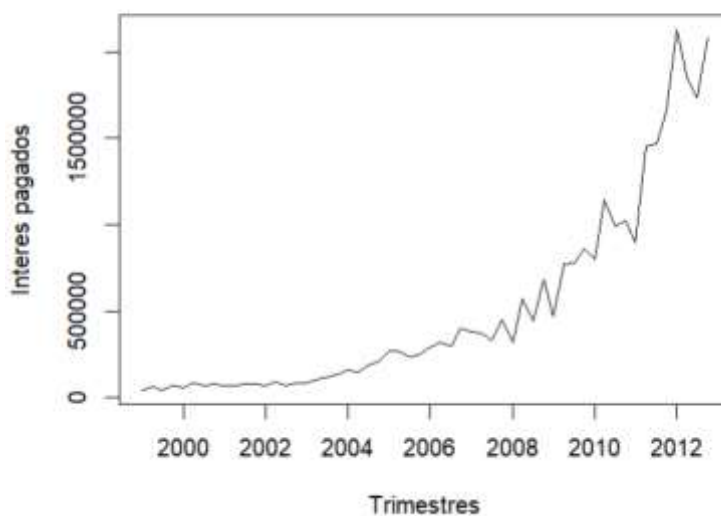
Considerando la significancia de los coeficientes, la ausencia de autocorrelación en los residuos y la estabilidad de los coeficientes, el ARIMA(0,2,1) emerge como el modelo preferido.

Pero basado en las métricas MAE (Error Absoluto Medio) y RMSE (Error Cuadrático Medio), se puede concluir que el modelo 3 ARIMA(1,2,2) se destaca como el mejor entre los tres evaluados. Con un MAE de 0.1641 y un RMSE de 0.2486, el modelo 3 exhibe los errores más bajos en sus predicciones, indicando una mayor precisión y menor variabilidad en comparación con los modelos 1 y 2. Estas métricas sugieren que el modelo 3 produce predicciones más cercanas a los valores reales y con una consistencia superior, haciendo de este modelo la opción preferida para este análisis.

En este caso eligiremos el modelo 3 ya que sus predicciones son mejores

CASO 2: INTERESES PAGADOS AL EXTERIOR (IPE)


```
data <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-05.xlsx", sheet = "2")
View(data)
# Gráfica de la serie
data_ts <- ts(data$interes, start = c(1999,1), frequency = 4)
plot(data_ts, xlab="Trimestres", ylab="Interes pagados")
```



En primera instancia podemos visualizar una clara TENDENCIA creciente, la varianza no parece variar mucho, y no es estacionaria en media. Por lo que tendremos que realizar un análisis de estacionalidad dado que la serie es trimestral

1 Identificación

```
#Descomposición de la serie
data_des <- decompose(data_ts, type = "multiplicative")
plot(data_des, type="l")
```



Se aprecia una tendencia creciente

1. 1 Análisis de la tendencia y la estacionalidad

1.1.1 Estacionalidad


#Graficos de la serie para identificar estacionalidad

```
plot1 <- ggsubseriesplot(data_ts, xlab = "Trimestres", ylab =  
"Interes pagados")
```

```
plot2 <- ggseasonplot(data_ts, xlab = "Trimestres", ylab = "Interes  
pagados")
```

```
plot3 <- ggAcf(data_ts, xlab = "Trimestres", ylab = "Interes  
pagados")
```

```
grid.arrange(plot1, plot2, plot3, ncol = 1)
```



Vemos que la serie no presenta estacionalidad, dado que el primer grafico nos muestra se muestra a un mismo nivel, el segundo nos muestra que

no hay un patrón claro y finalmente el correlograma decrece constantemente.


1.1.2 Análisis de tendencia

#Análisis de tendencia

```
lambda_hp <- 1600
```

```
data_hp <- hpfilter(data_ts, type="lambda", freq=lambda_hp)
```

```
plot(data_hp)
```



Hay una tendencia creciente y no parece haber algún patrón que se repita cíclicamente


1.2 Análisis de estacionariedad

1.2.1 Estacionariedad en varianza

#Estacionariedad en varianza

```
Grupo <- rep(1:7, each = 8)
```

```
boxplot(data$interes ~ Grupo, xlab = "Grupo", ylab="Yt")
```




La varianza va creciendo, por lo que diremos que no es constante


Transformación de la serie para que sea estacionaria

Alumno: Maye Mamani Victor Raul

```
b <- BoxCox.ar(data_ts)
lambda <- b$mle
round(lambda, 1)
[1] -0.1
```




```
qqnorm(data_ts, main = "Lambda = 1") # Yt: Original
qqline(data_ts)
```




```
data_mod = log(data_ts)
qqnorm(data_mod, main = "Lambda = 0")
qqline(data_mod)
```


Alumno: Maye Mamani Victor Raul



```
boxplot(data_mod ~ Grupo, xlab = "Grupo", ylab="log(Yt)")
```




```
plot(data_mod, xlab="Trimestres", ylab="log(Yt)")
```



Después de haber transformado la serie podemos notar que la varianza se ha estabilizado y aparenta ser constante

1.2.2 Estacionariedad en media

```
par(mfrow = c(1,2))  
FAS <- acf(data_ts, lag.max = 15, main="FAS - log(Yt)")  
FAP <- pacf(data_ts, lag.max = 15, main="FAP - log(Yt)")
```



El FAS decrece lentamente y el primer FAP es significativo siendo casi 0.9, por lo que podríamos decir que la serie NO ES ESTACIONARIA

Verificación con la prueba de Raíz unitaria de Dickey-Fuller Aumentada.

```
data_adf <- ur.df(data_mod, type="trend", lags = 1)  
summary(data_adf)
```

```
Residual standard error: 0.148 on 50 degrees of freedom  
Multiple R-squared: 0.5748, Adjusted R-squared: 0.5493  
F-statistic: 22.53 on 3 and 50 DF, p-value: 2.279e-09
```

```
Value of test-statistic is: -2.4952 12.0028 3.5166
```

```
Critical values for test statistics:
```


| | 1pct | 5pct | 10pct |
|------|-------|-------|-------|
| tau3 | -4.04 | -3.45 | -3.15 |
| phi2 | 6.50 | 4.88 | 4.16 |
| phi3 | 8.73 | 6.49 | 5.47 |

Observamos que el T calculado (-2.4952) es MAYOR que el T critico (-3.45) por tanto se acepta la hipótesis nula de la existencia de raíz unitaria, es decir que la serie NO ES ESTACIONARIA

Diferenciamos debido a que la serie no es estacionaria

```
data_diff = diff(data_mod)  
plot(data_diff, xlab="Trimestres", ylab="Interes pagados")  
abline(h = mean(data_diff), col = "red")
```

```
data_adf <- ur.df(data_diff, type="drift", lags = 1)
summary(data_adf)
```



Y volvemos a aplicar el test de Dickey Fuller

Residual standard error: 0.1564 on 50 degrees of freedom
Multiple R-squared: 0.8575, Adjusted R-squared: 0.8518
F-statistic: 150.5 on 2 and 50 DF, p-value: < 2.2e-16

Value of test-statistic is: -6.2316 19.4227


Critical values for test statistics:

| | 1pct | 5pct | 10pct |
|------|-------|-------|-------|
| tau2 | -3.51 | -2.89 | -2.58 |
| phi1 | 6.70 | 4.71 | 3.86 |

Ahora vemos que el T calculado (-6.23)16 es MENOR que el T crítico (-2.89) por tanto se RECHAZA la hipótesis nula de la existencia de raíz unitaria, es decir que la serie ES ESTACIONARIA

1.3 Identificación del modelo estacionario

1.3.1 Identificación de las órdenes p y q



Observando el FAS vemos que decrece en forma sinusoidal y tiene 5 coeficientes significativos por lo que proponemos un MA(5). Y el FAP decrece rápidamente a cero mostrando un patrón sinusoidal y tiene el primer coeficiente diferente de cero por lo que también planteamos un AR(1) aunque no esta muy claro. Adicionalmente planteamos un ARMA(1,2).

1.3.2 Inclusión del término independiente (δ) o intercepto

#incluir el intercepto

```
Z <- mean(data_diff)
Co <- var(data_diff)
Tn <- length(data_diff)
Ta <- Tn - 1
Sigma <- Co/Ta
t <- Z/Sigma
tt <- qt(1-0.05/2, Ta-1)
pruebaT <- c(t, tt)
names(pruebaT) <- c("t-calculado", "t-critico")
pruebaT
```

| t-calculado | t-critico |
|-------------|-----------|
| 77.157356 | 2.00574 |

Al tener un T calculado (77.157356) MAYOR al T crítico (2.00574) se acepta la hipótesis alterna por lo que incluimos la constante en el modelo

2 Estimación

```
mod1 <- Arima(data_mod, order = c(1, 1, 0), include.constant = T)
coeftest(mod1)
```

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) | |
|----------------|-----------|------------|----------|-----------|-----------|
| ar1 | -0.715918 | 0.092892 | -7.7070 | 1.288e-14 | *** |
| drift | 0.067188 | 0.012105 | 5.5505 | 2.849e-08 | *** |
| --- | | | | | |
| Signif. codes: | 0 '***' | 0.001 '**' | 0.01 '*' | 0.05 '.' | 0.1 ' ' 1 |

Con los parámetros estimados del modelo tenemos lo siguiente

$$\Delta Y_t = 0.0671 - 0.7159\Delta Y_{t-1} + a_t$$

```
mod2 <- Arima(data_mod, order = c(0, 1, 5), include.constant = T)
coeftest(mod2)
```

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) | |
|-------|------------|------------|---------|-----------|-----|
| ma1 | -0.4485415 | 0.1576038 | -2.8460 | 0.004427 | ** |
| ma2 | 0.2633784 | 0.2748540 | 0.9582 | 0.337938 | |
| ma3 | -0.6407278 | 0.1198853 | -5.3445 | 9.066e-08 | *** |
| ma4 | 0.5254175 | 0.2013839 | 2.6090 | 0.009080 | ** |
| ma5 | -0.6995139 | 0.2720900 | -2.5709 | 0.010144 | * |
| drift | 0.0694389 | 0.0033106 | 20.9749 | < 2.2e-16 | *** |

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Con los parámetros estimados del modelo tenemos lo siguiente

$$\Delta Y_t = 0.6994 + a_t - 0.4485 + 0.2633a_{t-2} - 0.6407a_{t-3} + 0.5254a_{t-4} - 0.6995a_{t-5}$$

Modelo ARIMA (1,1,2)

```
mod3 <- Arima(data_mod, order = c(1, 1, 2), include.constant = T)
coeftest(mod3)
```

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) | |
|-------|-----------|------------|---------|-----------|-----|
| ar1 | -0.906507 | 0.093423 | -9.7032 | < 2.2e-16 | *** |
| ma1 | 0.243719 | 0.171342 | 1.4224 | 0.1549 | |
| ma2 | -0.239670 | 0.163010 | -1.4703 | 0.1415 | |
| drift | 0.067546 | 0.010765 | 6.2745 | 3.508e-10 | *** |

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Con los parámetros estimados del modelo tenemos lo siguiente

$$\Delta Y_t = 0.0675 - 0.9065\Delta Y_{t-1} + a_t + 0.2437a_{t-1} - 0.2396a_{t-2}$$

3 Validación

3.1 Análisis de los coeficientes estimados

3.1.1 Significación de los coeficientes

Para el modelo AR(1)

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) | |
|-------|-----------|------------|---------|-----------|-----|
| ar1 | -0.715918 | 0.092892 | -7.7070 | 1.288e-14 | *** |
| drift | 0.067188 | 0.012105 | 5.5505 | 2.849e-08 | *** |

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

AR(1): $\phi_1 = -0.7159 \rightarrow p = 0.00000 < 0.01$, altamente significativo

Para el modelo MA(5)

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) | |
|-------|------------|------------|---------|-----------|-----|
| ma1 | -0.4485415 | 0.1576038 | -2.8460 | 0.004427 | ** |
| ma2 | 0.2633784 | 0.2748540 | 0.9582 | 0.337938 | |
| ma3 | -0.6407278 | 0.1198853 | -5.3445 | 9.066e-08 | *** |
| ma4 | 0.5254175 | 0.2013839 | 2.6090 | 0.009080 | ** |
| ma5 | -0.6995139 | 0.2720900 | -2.5709 | 0.010144 | * |
| drift | 0.0694389 | 0.0033106 | 20.9749 | < 2.2e-16 | *** |

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

MA(1): $\theta_1 = -0.4485 \rightarrow p = 0.0044 < 0.01$, altamente significativo

MA(2): $\theta_2 = 0.2633 \rightarrow p = 0.3379 > 0.05$, NO es significativo

MA(3): $\theta_3 = -0.6407 \rightarrow p = 0.0000 < 0.01$, altamente significativo

MA(4): $\theta_4 = 0.5254 \rightarrow p = 0.0090 < 0.01$, altamente significativo

MA(5): $\theta_5 = -0.6995 \rightarrow p = 0.0101 < 0.05$, es significativo

z test of coefficients:

| | Estimate | Std. Error | z value | Pr(> z) |
|-------|-----------|------------|---------|---------------|
| ar1 | -0.906507 | 0.093423 | -9.7032 | < 2.2e-16 *** |
| ma1 | 0.243719 | 0.171342 | 1.4224 | 0.1549 |
| ma2 | -0.239670 | 0.163010 | -1.4703 | 0.1415 |
| drift | 0.067546 | 0.010765 | 6.2745 | 3.508e-10 *** |

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

AR(1): $\phi_1 = -0.9065 \rightarrow p = 0.0000 < 0.01$, altamente significativo

MA(1): $\theta_1 = 0.2437 \rightarrow p = 0.1549 > 0.05$, NO es significativo

MA(2): $\theta_2 = -0.2396 \rightarrow p = 0.1415 > 0.05$, NO es significativo

3.1.2 Examen de la matriz de correlaciones entre los coeficientes

vcov(mod1)

| | ar1 | drift |
|-------|--------------|--------------|
| ar1 | 8.628880e-03 | 2.049485e-05 |
| drift | 2.049485e-05 | 1.465264e-04 |

vcov(mod2)

| | ma1 | ma2 | ma3 | ma4 | ma5 | drift |
|-------|---------------|---------------|---------------|---------------|---------------|---------------|
| ma1 | 2.483896e-02 | 2.580993e-02 | 3.811391e-03 | -0.0182930187 | -0.0245507250 | 1.659998e-05 |
| ma2 | 2.580993e-02 | 7.554474e-02 | 1.455536e-02 | -0.0419279506 | -0.0675689521 | -8.637586e-06 |
| ma3 | 3.811391e-03 | 1.455536e-02 | 1.437248e-02 | -0.0138970967 | -0.0093773322 | -8.930819e-06 |
| ma4 | -1.829302e-02 | -4.192795e-02 | -1.389710e-02 | 0.0405554824 | 0.0355791858 | -1.317850e-05 |
| ma5 | -2.455073e-02 | -6.756895e-02 | -9.377332e-03 | 0.0355791858 | 0.0740329643 | -2.455073e-02 |
| drift | 1.659998e-05 | -8.637586e-06 | -8.930819e-06 | -0.0000131785 | 0.0000141385 | 1.095990e-05 |


vcov(mod3)

| | ar1 | ma1 | ma2 | drift |
|-------|---------------|---------------|---------------|---------------|
| ar1 | 8.727900e-03 | -0.0103213052 | 8.607613e-03 | 1.139592e-06 |
| ma1 | -1.032131e-02 | 0.0293581486 | -3.515797e-03 | -1.031090e-05 |
| ma2 | 8.607613e-03 | -0.0035157970 | 2.657211e-02 | -4.151149e-05 |
| drift | 1.139592e-06 | -0.0000103109 | -4.151149e-05 | 1.158904e-04 |

Se observa claramente que ningún coeficiente esta próximo ni cercano a 0.9, por tanto, podemos indicar que no hay problema de multicolinealidad en los modelos propuestos.


3.1.3 Condición de convergencia e invertibilidad

autoplot(mod1)




En la figura de raíces inversas de AR, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de estacionariedad para la parte autorregresiva.

`autoplot(mod2)`



En la figura de raíces inversas de MA, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de invertibilidad para la parte de media móvil.

`autoplot(mod3)`



Al estar los valores dentro de la circunferencia unitaria es un indicativo de que el modelo se ajusta correctamente. Tanto en su parte AR, como en su parte MA.

3.1.4 Análisis de la estabilidad

```
Chow_mod1 <- Fstats(mod1$fitted ~ 1, from = 0.67)
sctest(Chow_mod1)
supF test

data: Chow_mod1
sup.F = 160.43, p-value < 2.2e-16
```

```
Chow_mod2 <- Fstats(mod2$fitted ~ 1, from = 0.67)
sctest(Chow_mod2)
supF test

data: Chow_mod2
sup.F = 156.99, p-value < 2.2e-16
```

```
Chow_mod3 <- Fstats(mod3$fitted ~ 1, from = 0.67)
sctest(Chow_mod3)
supF test


data: Chow_mod3
sup.F = 157.84, p-value < 2.2e-16
```

En las tres pruebas se rechaza la hipótesis nula ($p < \alpha = 0.05$), es decir, NO existe estabilidad de coeficientes.

3.2 Análisis de los residuos

3.2.1 Media es igual a cero

```
plot(mod1$residuals)
abline(h = 0, col = "red")
t.test(mod1$residuals, mu = 0)
```




One Sample t-test

```
data: mod1$residuals
t = 0.10559, df = 55, p-value = 0.9163
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
-0.03876991 0.04308281
sample estimates:
mean of x
```

0.002156447

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.9163 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

```
plot(mod2$residuals)
abline(h = 0, col = "red")
t.test(mod2$residuals, mu = 0)
```




One Sample t-test

```
data: mod2$residuals
t = -0.61655, df = 55, p-value = 0.5401
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.04695583  0.02486117
sample estimates:
mean of x
-0.01104733
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.5401 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

```
plot(mod3$residuals)
abline(h = 0, col = "red")
t.test(mod3$residuals, mu = 0)
```



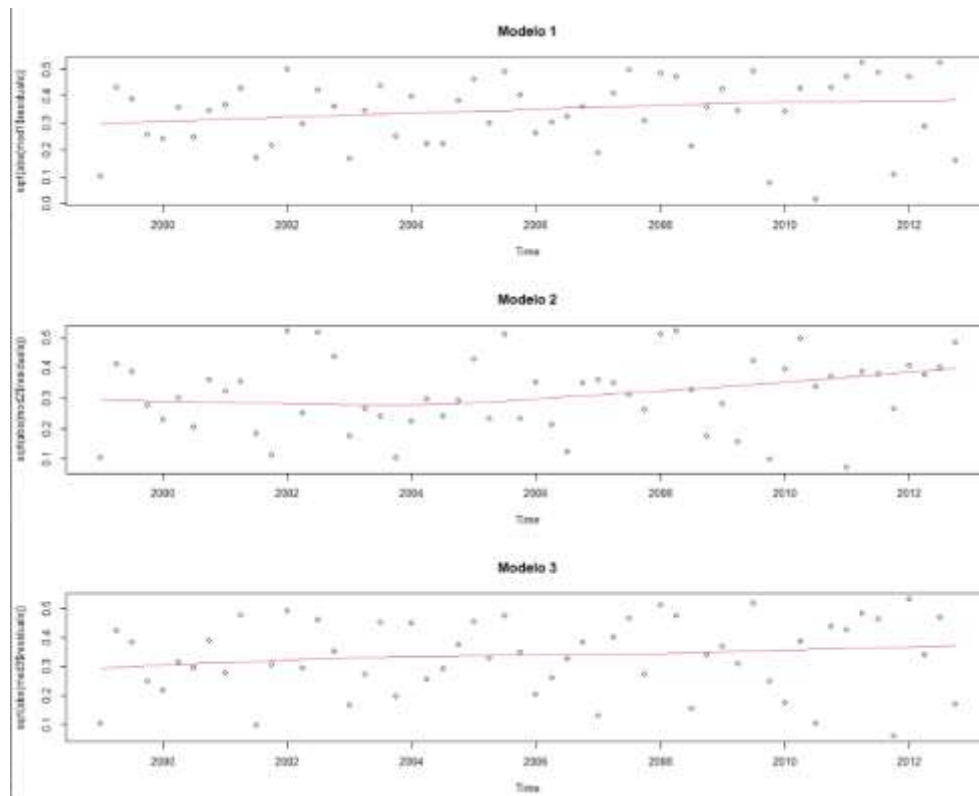
One Sample t-test

```
data: mod3$residuals
t = 0.10756, df = 55, p-value = 0.9147
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.03789693  0.04219582
sample estimates:
 mean of x
0.002149444
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.9147 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

3.2.2 Homocedasticidad o varianza constante

```
par(mfrow = c(3,1))
scatter.smooth(sqrt(abs(mod1$residuals)), lpars=list(col=2), main =
"Modelo 1")
scatter.smooth(sqrt(abs(mod2$residuals)), lpars=list(col=2), main =
"Modelo 2")
scatter.smooth(sqrt(abs(mod3$residuals)), lpars=list(col=2), main =
"Modelo 3")
```



Se observa que los datos parecen no presentar una variabilidad considerable, por tanto, será necesario realizar la prueba de Breusch-Pagan para determinar finalmente si las varianzas constantes para los modelos.

Prueba de Breusch – Pagan

```
obs=get(mod1$series)
bptest(resid(mod1)~I(obs-resid(mod1)))
```

studentized Breusch-Pagan test

```
data: resid(mod1) ~ I(obs - resid(mod1))
BP = 4.9887, df = 1, p-value = 0.02551
```

```
obs=get(mod2$series)
bptest(resid(mod2)~I(obs-resid(mod2)))
```

studentized Breusch-Pagan test

```
data: resid(mod2) ~ I(obs - resid(mod2))
BP = 1.8583, df = 1, p-value = 0.1728
```

```
obs=get(mod3$series)
bptest(resid(mod3)~I(obs-resid(mod3)))
```


studentized Breusch-Pagan test

```
data: resid(mod3) ~ I(obs - resid(mod3))
BP = 2.5607, df = 1, p-value = 0.1096
```

El valor de probabilidad (p-valor) asociado al estadístico BPasume un valor de 0.02551 para el MODELO 1, que es menor a $\alpha=0.05$. Por tanto, estos residuos no tiene varianza constante.

En cambio en el MODELO 2 y MODELO3 tiene el valor de probabilidad de 0.1728 y 0.1096 respectivamente, que son mayores a $\alpha=0.05$, por lo cual podemos afirmar que los residuales de estos modelos son constantes.

3.2.3 Ausencia de correlación serial



Se observa que casi la totalidad de los coeficientes del FAS para los modelos 1 , 2 y 3 se encuentran dentro de las bandas de no significación, sobre todo los de los primeros retardos.

Por tanto, tenemos altos indicios de que los residuos de los 3 modelos sean ruido blanco.

```
Box.test(resid_m1,type = "Ljung-Box")
Box-Ljung test

data:  resid_m1
X-squared = 0.079631, df = 1, p-value = 0.7778
```

```
Box.test(resid_m2,type = "Ljung-Box")
Box-Ljung test

data:  resid_m2
X-squared = 1.1497, df = 1, p-value = 0.2836
```

```
Box.test(resid_m3,type = "Ljung-Box")
```

```
Box-Ljung test

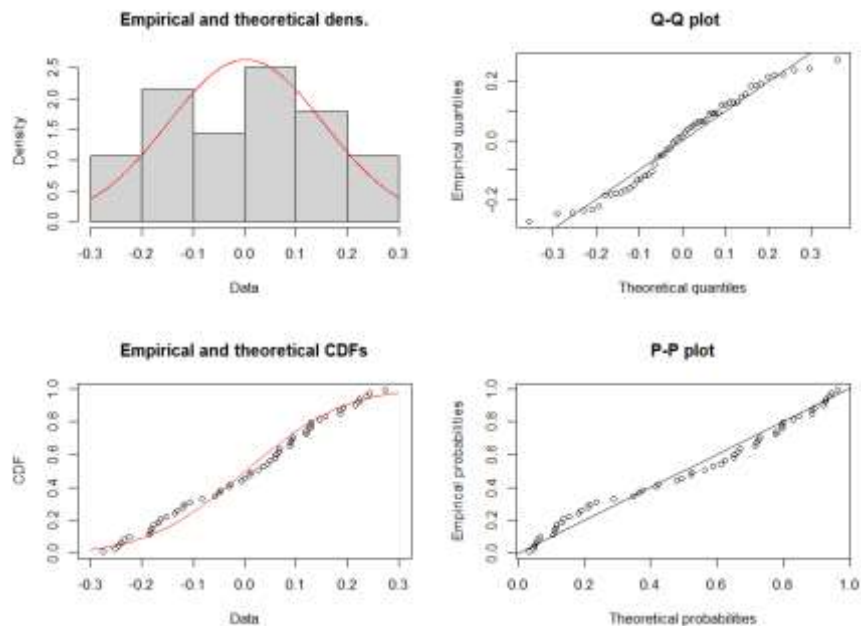
data:  resid_m3
```

```
X-squared = 0.0026241, df = 1, p-value = 0.9591
```

Con los valores 0.7778, 0.2836 y 0.9591 son mayores a $\alpha=0.05$, por lo que se acepta la hipótesis nula de que los coeficientes de autocorrelación son cero; es decir, los residuos son independientes o están incorrelacionados.

3.2.4 Contraste de normalidad

```
ajuste_m1<-fitdist(data = resid_m1, distr="norm")  
plot(ajuste_m1)  
JB_m1 <- jarque.bera.test(resid_m1)  
JB_m1
```



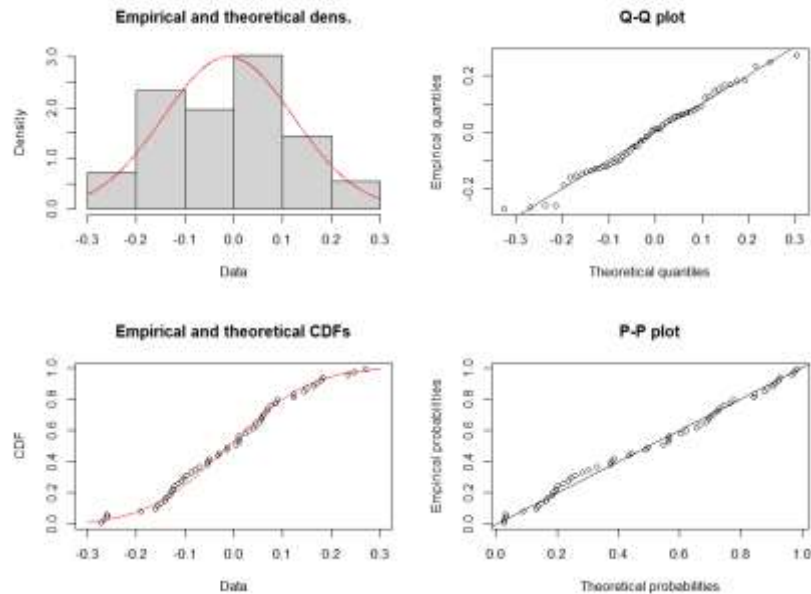
Jarque Bera Test

```
data: resid_m1  
X-squared = 3.0068, df = 2, p-value = 0.2224
```

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.2224 > 0.05$, se acepta H_0 , es decir, los residuos se aproximan a una distribución normal.

```
ajuste_m2<-fitdist(data = resid_m2, distr="norm")  
plot(ajuste_m2)  
JB_m2 <- jarque.bera.test(resid_m2)  
JB_m2
```

Alumno: Maye Mamani Victor Raul

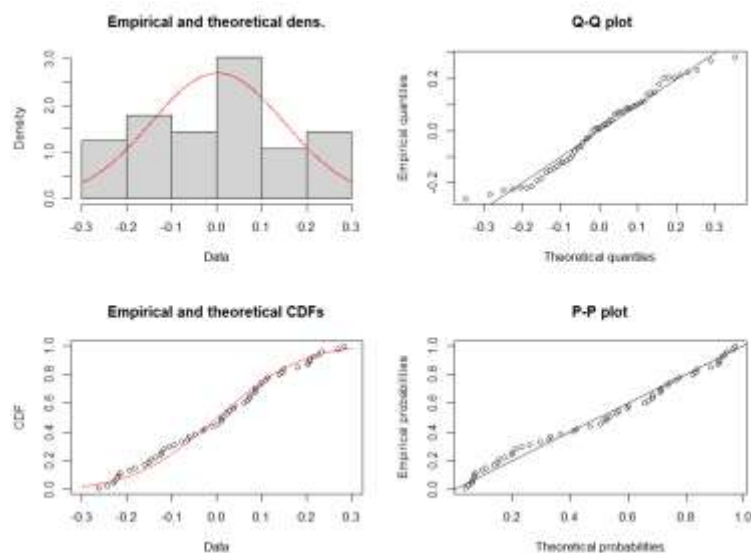


Jarque Bera Test

```
data: resid_m2  
X-squared = 0.88085, df = 2, p-value = 0.6438
```

En las figuras se observa que los residuales del modelo 2 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.6438 > 0.05$, se acepta H_0 , es decir, los residuos se aproximan a una distribución normal.

```
ajuste_m3<-fitdist(data = resid_m3, distr="norm")  
plot(ajuste_m3)  
JB_m3 <- jarque.bera.test(resid_m3)  
JB_m3
```



Jarque Bera Test

```
data: resid_m3  
X-squared = 2.4313, df = 2, p-value = 0.2965
```


En las figuras se observa que los residuales del modelo 3 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.2965 > 0.05$, se acepta H_0 , es decir, los residuos se aproximan a una distribución normal.

4 Pronostico

4.1 Pronosticos de cada modelo

Modelo 1: ARIMA (1,1,0)

```
Pron1 <- forecast(mod1, level=c(95), h=10)
plot(Pron1)
summary(Pron1)
```



En la figura se puede observar el comportamiento de la función de predicción por punto y por intervalo.

Los datos proyectados para los siguientes 10 trimestres son:

```
Forecast method: ARIMA(1,1,0) with drift

Model Information:
Series: data_mod
ARIMA(1,1,0) with drift

Coefficients:
      ar1      drift
    -0.7159  0.0672
s.e.    0.0929  0.0121

sigma^2 = 0.02424: log likelihood = 24.91
AIC=-43.82  AICC=-43.35  BIC=-37.8


Error measures:
              ME      RMSE      MAE      MPE      MAPE
MASE          ACF1
Training set 0.002156447 0.1514681 0.1302622 -0.001002706 1.037708 0.4
450654 0.03672105

Forecasts:
      Point Forecast      Lo 95      Hi 95
2013 Q1      14.53611 14.23095 14.84127
2013 Q2      14.66134 14.34410 14.97857
2013 Q3      14.68697 14.28731 15.08664
2013 Q4      14.78391 14.36328 15.20453
2014 Q1      14.82980 14.35909 15.30051
2014 Q2      14.91223 14.41701 15.40746
2014 Q3      14.96851 14.43628 15.50074
```


| | | | |
|---------|----------|----------|----------|
| 2014 Q4 | 15.04351 | 14.48612 | 15.60090 |
| 2015 Q1 | 15.10510 | 14.51730 | 15.69290 |
| 2015 Q2 | 15.17630 | 14.56397 | 15.78862 |

Es importante mencionar que, los valores pronosticados son logaritmos, por tanto, para obtener los verdaderos valores de pronóstico, se tendrán que transformar aplicando la función exp().

```
data_modelo1 <- exp(mod1$fitted)
grafico_comparativo <- cbind(data_ts, data_modelo1)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft", c("yt", "yest"), lty = c(1,1), lwd = 2, col=c("black",
"red"))
```



PRONÓSTICO DE LA SERIE ORIGINAL

Deshaciendo la transformación:

```
Pron1$mean <- exp(Pron1$mean)
Pron1$lower <- exp(Pron1$lower)
Pron1$upper <- exp(Pron1$upper)
Pron1$x <- exp(Pron1$x)
Pron1$fitted <- exp(Pron1$fitted)
Pron1$residuals <- exp(Pron1$residuals)
summary(Pron1)
```

Forecast method: ARIMA(1,1,0) with drift

Model Information:
Series: data_mod
ARIMA(1,1,0) with drift

Coefficients:
ar1 drift
-0.7159 0.0672
s.e. 0.0929 0.0121

sigma^2 = 0.02424: log likelihood = 24.91
AIC=-43.82 AICc=-43.35 BIC=-37.8

Error measures:

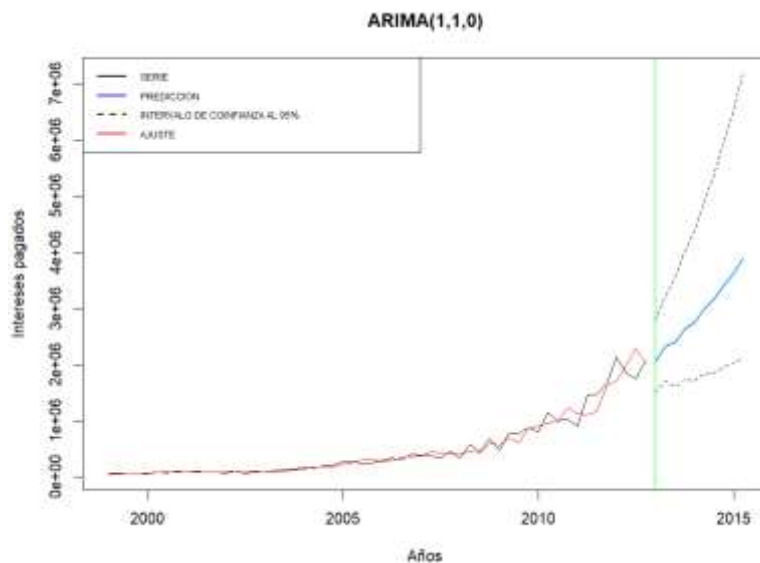
| | ME | RMSE | MAE | MPE | MAPE | MASE |
|--------------|----------------|----------|----------|------------|----------|-----------|
| ACF1 | | | | | | |
| Training set | 6211.225 | 132113.9 | 71919.14 | -0.9399903 | 13.13878 | 0.4836564 |
| 0.0547565 | | | | | | |
| Forecasts: | | | | | | |
| | Point Forecast | Lo 95 | Hi 95 | | | |
| 2013 Q1 | 2055669 | 1515042 | 2789213 | | | |
| 2013 Q2 | 2329903 | 1696545 | 3199708 | | | |
| 2013 Q3 | 2390408 | 1602876 | 3564876 | | | |
| 2013 Q4 | 2633723 | 1729399 | 4010930 | | | |
| 2014 Q1 | 2757406 | 1722164 | 4414961 | | | |
| 2014 Q2 | 2994341 | 1824848 | 4913330 | | | |
| 2014 Q3 | 3167672 | 1860355 | 5393673 | | | |
| 2014 Q4 | 3414391 | 1955433 | 5961884 | | | |
| 2015 Q1 | 3631306 | 2017363 | 6536445 | | | |
| 2015 Q2 | 3899254 | 2113747 | 7192999 | | | |

GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```

plot(Pron1, shaded = FALSE, xlab = "Años", ylab = "Intereses
pagados", main = "ARIMA(1,1,0)")
lines(Pron1$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCIÓN", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=2013, lwd = 1, col="green")

```




Modelo 2: ARIMA (0,1,5)

```

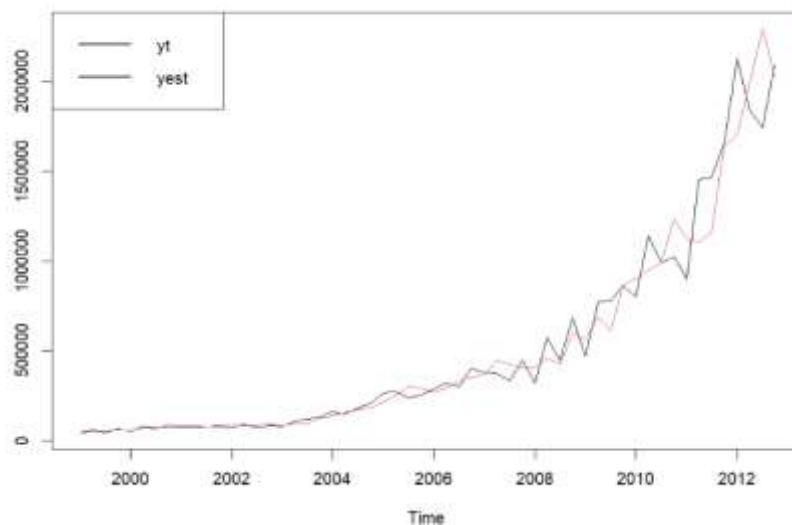
Pron2 <- forecast(mod2, level=c(95), h=10)
plot(Pron2)
summary(Pron2)

```



PRONÓSTICO DE LA SERIE ORIGINAL

```
yt_arima2 <- exp(mod2$fitted)
grafico_comparativo <- cbind(Yt,yt_arima2)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt", "yest"),lty = c(1,1), lwd = 2)
```



```
Pron2$mean <- exp(Pron2$mean)
Pron2$lower <- exp(Pron2$lower)
Pron2$upper <- exp(Pron2$upper)
Pron2$x <- exp(Pron2$x)
Pron2$fitted <- exp(Pron2$fitted)
Pron2$residuals <- exp(Pron2$residuals)
summary(Pron2)
```

Forecast method: ARIMA(0,1,5) with drift

Model Information:

```

Series: data_mod
ARIMA(0,1,5) with drift

Coefficients:
      ma1      ma2      ma3      ma4      ma5      drift
s.e.  -0.4485  0.2634 -0.6407  0.5254 -0.6995  0.0694
      0.1576  0.2749  0.1199  0.2014  0.2721  0.0033

sigma^2 = 0.02032: log likelihood = 28.17
AIC=-42.33  AICC=-39.95  BIC=-28.28

Error measures:
      ME      RMSE      MAE      MPE      MAPE      MASE
ACF1
Training set 9162.53 114974.8 64506.76 -2.005822 11.21007 0.4338081 -0.1393904

Forecasts:
      Point Forecast      Lo 95      Hi 95
2013 Q1      2165890 1626312 2884490
2013 Q2      2276487 1642389 3155400
2013 Q3      2144462 1433980 3206961
2013 Q4      2886901 1921031 4338399
2014 Q1      2638674 1672330 4163414
2014 Q2      2828412 1792581 4462791
2014 Q3      3031794 1921480 4783696
2014 Q4      3249800 2059647 5127675
2015 Q1      3483482 2207749 5496389
2015 Q2      3733968 2366501 5891615


```

GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```


plot(Pron2, shaded = FALSE, xlab = "Trimestres", ylab = "", main =
"ARIMA(0,0,2)")
lines(Pron2$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=1930, lwd = 1, col="green")

```




Modelo 3: ARIMA (1,1,2)

```
Pron3 <- forecast(modelo3, level=c(95), h=10)
plot(Pron3)
summary(Pron3)
```



PRONÓSTICO DE LA SERIE ORIGINAL

```
yt_arima3 <- exp(modelo3$fitted)
grafico_comparativo <- cbind(Yt,yt_arima3)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt", "yest"),lty = c(1,1), lwd = 2)
```



GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```
Pron3$mean <- exp(Pron3$mean)
Pron3$lower <- exp(Pron3$lower)
Pron3$upper <- exp(Pron3$upper)
Pron3$x <- exp(Pron3$x)
Pron3$fitted <- exp(Pron3$fitted)
Pron3$residuals <- exp(Pron3$residuals)
summary(Pron3)
```

Alumno: Maye Mamani Victor Raul

```
Forecast method: ARIMA(1,1,2) with drift

Model Information:
Series: data_mod
ARIMA(1,1,2) with drift


Coefficients:
          ar1      ma1      ma2      drift
s.e.    -0.9065    0.2437   -0.2397    0.0675
         0.0934    0.1713    0.1630    0.0108

sigma^2 = 0.02412: log likelihood = 26.03
AIC=-42.06  AICC=-40.84  BIC=-32.03

Error measures:
          ME      RMSE      MAE      MPE      MAPE      MASE
ACF1
Training set 8205.438 126569.1 68489 -0.8861896 12.64779 0.4605887 0.0
06992194

Forecasts:
      Point Forecast      Lo 95      Hi 95
2013 Q1          2136975 1576165 2897326
2013 Q2          2360379 1711867 3254569
2013 Q3          2453377 1669058 3606260
2013 Q4          2694501 1803620 4025422
2014 Q1          2815128 1795102 4414761
2014 Q2          3077400 1931037 4904303
2014 Q3          3228810 1947797 5352310
2014 Q4          3516103 2087372 5922749
2015 Q1          3701954 2125720 6446973
2015 Q2          4018652 2271042 7111081
```

```
plot(Pron3, shaded = FALSE, xlab = "Años", ylab = "N° DE PIELES", main = "ARIMA(1,1,2)")
lines(Pron3$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"), lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=1930, lwd = 1, col="green")
```



Métricas basadas en el error

```
accuracy(Pron1)
```

| | ME | RMSE | MAE | MPE | MAPE | MASE |
|--------------|----------|----------|----------|------------|----------|-----------|
| ACF1 | | | | | | |
| Training set | 6211.225 | 132113.9 | 71919.14 | -0.9399903 | 13.13878 | 0.4836564 |
| 0.0547565 | | | | | | |

accuracy(Pron2)

| | ME | RMSE | MAE | MPE | MAPE | MASE |
|--------------|---------|----------|----------|-----------|----------|-----------|
| ACF1 | | | | | | |
| Training set | 9162.53 | 114974.8 | 64506.76 | -2.005822 | 11.21007 | 0.4338081 |
| .1393904 | | | | | | -0 |

accuracy(Pron3)

| | ME | RMSE | MAE | MPE | MAPE | MASE |
|--------------|----------|----------|-------|------------|----------|-----------|
| ACF1 | | | | | | |
| Training set | 8205.438 | 126569.1 | 68489 | -0.8861896 | 12.64779 | 0.4605887 |
| 06992194 | | | | | | 0.0 |

Basado en las métricas MAE y RMSE, el modelo Pron2 es el mejor entre los tres, ya que tiene los valores más bajos(MAE = 64506 Y RMSE=114974) en ambas métricas. Esto indica que sus predicciones son más precisas y con menos variabilidad en los errores.

Conclusión

Sobre los modelos:

ARIMA (1,1,0)

- **Coeficientes Significativos:** Todos los coeficientes son altamente significativos.
- **Residuos:** Los residuos tienen una media cercana a cero y no presentan autocorrelación.
- **Estabilidad:** Las pruebas de Chow indicaron que no hay estabilidad de coeficientes, lo cual es un punto en contra.
- **Condición de Invertibilidad y Convergencia:** Cumple con las condiciones.

ARIMA (0,1,5)

- **Coeficientes Significativos:** Tres de los cinco coeficientes de media móvil son significativos.
- **Residuos:** Los residuos tienen una media cercana a cero y no presentan autocorrelación.
- **Estabilidad:** Al igual que el modelo anterior, no muestra estabilidad de coeficientes en las pruebas de Chow.
- **Condición de Invertibilidad y Convergencia:** Cumple con las condiciones.

ARIMA (1,1,2)

- **Coeficientes Significativos:** El coeficiente AR es significativo, pero los coeficientes MA no lo son.
- **Residuos:** Los residuos tienen una media cercana a cero y no presentan autocorrelación.
- **Estabilidad:** Similar a los otros dos modelos, no presenta estabilidad de coeficientes.
- **Condición de Invertibilidad y Convergencia:** Cumple con las condiciones.

Teniendo en cuenta todos los aspectos analizados, el modelo ARIMA (1,1,0) es el más adecuado para la serie de datos evaluada. Esto se debe a que todos sus coeficientes son altamente significativos, los residuos cumplen con los supuestos necesarios, y cumple con las condiciones de invertibilidad y convergencia. Aunque no presenta estabilidad en los coeficientes, este aspecto es una limitación compartida con los otros modelos evaluados. Pero si lo que mas nos importa es el error el modelo ARIMA(0,1,5) tiene menor error y cumple con los mismo supuestos del modelo ARIMA(1,1,0)