



## Tabla de contenido

Caso 1 .....	4
1 Identificación .....	4
1. 1 Análisis de la tendencia y la estacionalidad .....	4
1.2 Análisis de estacionariedad .....	4
1.2.1 Estacionariedad en varianza.....	4
1.2.2 Estacionariedad en media .....	4
1.3 Identificación del modelo estacionario.....	4
1.3.1 Identificación de las órdenes p y q.....	4
1.3.2 Inclusión del término independiente ( $\delta$ ) o intercepto .....	4
2 Estimación.....	4
3 Validación.....	4
3.1 Análisis de los coeficientes estimados .....	4
3.1.1 Significación de los coeficientes .....	4
3.1.2 Examen de la matriz de correlaciones entre los coeficientes .....	4
3.1.3 Condición de convergencia e invertibilidad.....	4
3.1.4 Análisis de la estabilidad.....	4
3.2 Análisis de los residuos .....	4
3.2.1 Media es igual a cero.....	4
3.2.2 Homocedasticidad o varianza constante .....	4
3.2.3 Ausencia de correlación serial .....	4
3.2.4 Contraste de normalidad.....	4
4 Pronostico .....	4
Conclusión .....	4
CASO 2.....	4
1 Identificación .....	5
1. 1 Análisis de la tendencia y la estacionalidad .....	5
1.2 Análisis de estacionariedad.....	7
1.2.1 Estacionariedad en varianza.....	7
1.2.2 Estacionariedad en media .....	9
1.3 Identificación del modelo estacionario.....	11
1.3.1 Identificación de las órdenes p y q.....	11
1.3.2 Inclusión del término independiente ( $\delta$ ) o intercepto .....	11
2 Estimación.....	11
3 Validación.....	12
3.1 Análisis de los coeficientes estimados .....	12
3.1.1 Significación de los coeficientes .....	12

3.1.2 Examen de la matriz de correlaciones entre los coeficientes .....	13
3.1.3 Condición de convergencia e invertibilidad.....	14
3.1.4 Análisis de la estabilidad.....	15
3.2 Análisis de los residuos .....	15
3.2.1 Media es igual a cero.....	15
3.2.2 Homocedasticidad o varianza constante .....	17
3.2.3 Ausencia de correlación serial .....	19
3.2.4 Contraste de normalidad.....	20
4 Pronostico .....	22

## Actividad 5

### Caso 1

#### 1 Identificación

Grafica inicial de la serie:

##### 1. 1 Análisis de la tendencia y la estacionalidad

##### 1.2 Análisis de estacionariedad

###### 1.2.1 Estacionariedad en varianza

###### 1.2.2 Estacionariedad en media

##### 1.3 Identificación del modelo estacionario

###### 1.3.1 Identificación de las órdenes p y q

###### 1.3.2 Inclusión del término independiente ( $\delta$ ) o intercepto

#### 2 Estimación

#### 3 Validación

##### 3.1 Análisis de los coeficientes estimados

###### 3.1.1 Significación de los coeficientes

###### 3.1.2 Examen de la matriz de correlaciones entre los coeficientes

###### 3.1.3 Condición de convergencia e invertibilidad

###### 3.1.4 Análisis de la estabilidad

##### 3.2 Análisis de los residuos

###### 3.2.1 Media es igual a cero

###### 3.2.2 Homocedasticidad o varianza constante

###### 3.2.3 Ausencia de correlación serial


###### 3.2.4 Contraste de normalidad

#### 4 Pronostico

#### Conclusión

### CASO 2: INTERESES PAGADOS AL EXTERIOR (IPE)

```
data <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-05.xlsx", sheet = "2")
View(data)
# Gráfica de la serie
data_ts <- ts(data$interes, start = c(1999,1), frequency = 4)
plot(data_ts, xlab="Trimestres", ylab="Interes pagados")
```

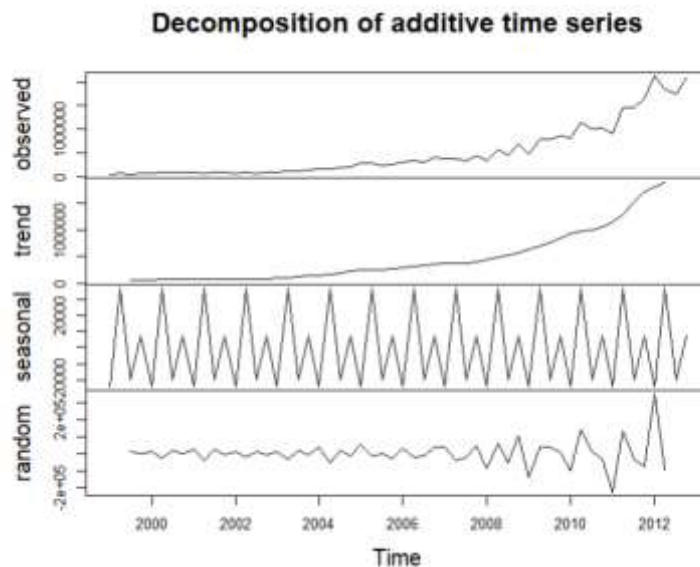


**En primera instancia podemos visualizar una clara TENDENCIA creciente y la varianza no parece variar mucho. Y tendremos que realizar una análisis de estacionalidad dado que la serie es trimestral**

## 1 Identificación

**#Descomposición de la serie**

```
data_des <- decompose(data_ts, type = "additive")
plot(data_des, type="l")
```



### 1. 1 Análisis de la tendencia y la estacionalidad

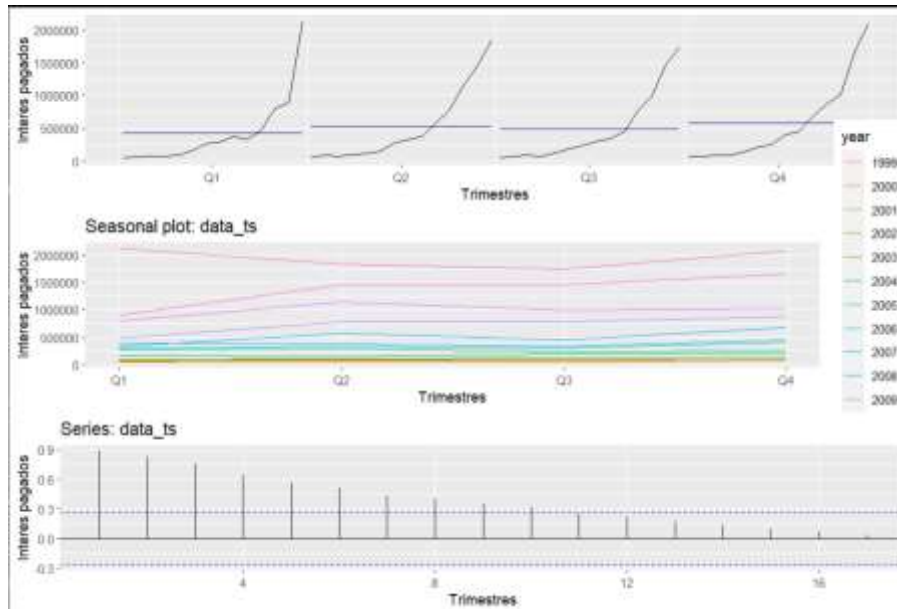
#### 1.1.1 Estacionalidad

**#Graficos de la serie para identificar estacionalidad**

```
plot1 <- ggsubseriesplot(data_ts, xlab = "Trimestres", ylab = "Interes pagados")
plot2 <- ggseasonplot(data_ts, xlab = "Trimestres", ylab = "Interes pagados")
```

```
plot3 <- ggAcf(data_ts, xlab = "Trimestres", ylab = "Interes pagados")
```

```
grid.arrange(plot1, plot2, plot3, ncol = 1)
```



**Vemos que la serie no presenta estacionalidad**


### 1.1.2 Análisis de tendencia

#Análisis de tendencia

```
lambda_hp <- 1600
```

```
data_hp <- hpfilter(data_ts, type="lambda", freq=lambda_hp)
```

```
plot(data_hp)
```



**Hay una tendencia creciente y no parece haber algún patrón que se repita cíclicamente**


## 1.2 Análisis de estacionariedad

### 1.2.1 Estacionariedad en varianza

#Estacionariedad en varianza

```
Grupo <- rep(1:7, each = 8)
```

```
boxplot(data$interes ~ Grupo, xlab = "Grupo", ylab="Yt")
```



**La varianza va creciendo, por lo que diremos que no es constante**


**Transformación de la serie para que sea estacionaria**

```
b <- BoxCox.ar(data_ts)
```

```
lambda <- b$mle
```


```
round(lambda, 1)
```

```
[1] -0.1
```




```
qqnorm(data_ts, main = "Lambda = 1") # Yt: Original
```


```
qqline(data_ts)
```



```
data_mod = log(data_ts)
qqnorm(data_mod, main = "Lambda = 0")
qqline(data_mod)
```




```
boxplot(data_mod ~ Grupo, xlab = "Grupo", ylab="log(Yt)")
```



```
plot(data_mod, xlab="Trimestres", ylab="log(Yt)")
```






**Después de haber transformado la serie podemos notar que la varianza se ha estabilizado y aparenta ser constante**

### 1.2.2 Estacionariedad en media

```
par(mfrow = c(1,2))
```

```
FAS <- acf(data_ts, lag.max = 15, main="FAS - log(Yt)")
```

```
FAP <- pacf(data_ts, lag.max = 15, main="FAP - log(Yt)")
```



**El FAS decrece lentamente y el primer FAP es significativo siendo casi 0.9, por lo que podríamos decir que la serie NO ES ESTACIONARIA**

**# Verificación con la prueba de Raíz unitaria de Dickey-Fuller Aumentada.**

```
data_adf <- ur.df(data_mod, type="trend", lags = 1)
```

```
summary(data_adf)
```

```
Residual standard error: 0.148 on 50 degrees of freedom
Multiple R-squared: 0.5748, Adjusted R-squared: 0.5493
F-statistic: 22.53 on 3 and 50 DF, p-value: 2.279e-09
```

```
value of test-statistic is: -2.4952 12.0028 3.5166
```

Critical values for test statistics:


	1pct	5pct	10pct
tau3	-4.04	-3.45	-3.15
phi2	6.50	4.88	4.16
phi3	8.73	6.49	5.47

**Observamos que el  $T$  calculado (-2.4952) es MAYOR que el  $T$  crítico (-3.45) por tanto se acepta la hipótesis nula de la existencia de raíz unitaria, es decir que la serie NO ES ESTACIONARIA**

**Diferenciamos debido a que la serie no es estacionaria**

```
data_diff = diff(data_mod)
plot(data_diff, xlab="Trimestres", ylab="Interes pagados")
abline(h = mean(data_diff), col = "red")
```

```
data_adf <- ur.df(data_diff, type="drift", lags = 1)
summary(data_adf)
```



**Y volvemos a aplicar el test de Dickey Fuller**

Residual standard error: 0.1564 on 50 degrees of freedom  
Multiple R-squared: 0.8575, Adjusted R-squared: 0.8518  
F-statistic: 150.5 on 2 and 50 DF, p-value: < 2.2e-16

Value of test-statistic is: -6.2316 19.4227

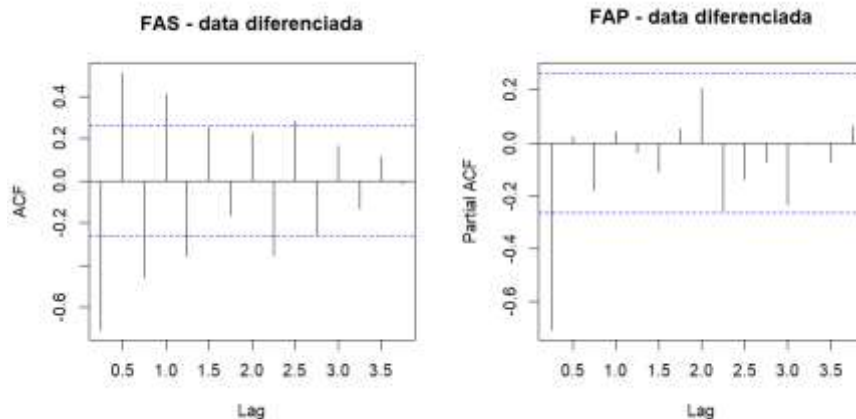
Critical values for test statistics:

	1pct	5pct	10pct
tau2	-3.51	-2.89	-2.58
phi1	6.70	4.71	3.86

**Ahora vemos que el  $T$  calculado (-6.23)16 es MENOR que el  $T$  crítico (-2.89) por tanto se RECHAZA la hipótesis nula de la existencia de raíz unitaria, es decir que la serie ES ESTACIONARIA**

## 1.3 Identificación del modelo estacionario

### 1.3.1 Identificación de las órdenes p y q



Observando el FAS vemos que decrece en forma sinusoidal y tiene 5 coeficientes significativos por lo que proponemos un MA(5). Y el FAP decrece rápidamente a cero mostrando un patrón sinusoidal y tiene el primer coeficiente diferente de cero por lo que también planteamos un AR(1) aunque no esta muy claro. Adicionalmente planteamos un ARMA(1,2).

### 1.3.2 Inclusión del término independiente ( $\delta$ ) o intercepto

#incluir el intercepto

```
Z <- mean(data_diff)
```

```
Co <- var(data_diff)
```

```
Tn <- length(data_diff)
```

```
Ta <- Tn - 1
```

```
Sigma <- Co/Ta
```

```
t <- Z/Sigma
```

```
tt <- qt(1-0.05/2, Ta-1)
```

```
pruebaT <- c(t, tt)
```

```
names(pruebaT) <- c("t-calculado", "t-critico")
```

```
pruebaT
```

```
t-calculado    t-critico
77.157356      2.00574
```

Al tener un T calculado (77.157356) MAYOR al T critico (2.00574) se acepta la hipótesis alterna por lo que incluimos la constante en el modelo

## 2 Estimación

```
mod1 <- Arima(data_mod, order = c(1, 1, 0), include.constant = T)
coeftest(mod1)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ar1    -0.715918   0.092892  -7.7070 1.288e-14 ***
drift    0.067188   0.012105   5.5505 2.849e-08 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

**Con los parámetros estimados del modelo tenemos lo siguiente**

$$\Delta Y_t = 0.0671 - 0.7159\Delta Y_{t-1} + a_t$$

```
mod2 <- Arima(data_mod, order = c(0, 1, 5), include.constant = T)
coeftest(mod2)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
ma1	-0.4485415	0.1576038	-2.8460	0.004427	**
ma2	0.2633784	0.2748540	0.9582	0.337938	
ma3	-0.6407278	0.1198853	-5.3445	9.066e-08	***
ma4	0.5254175	0.2013839	2.6090	0.009080	**
ma5	-0.6995139	0.2720900	-2.5709	0.010144	*
drift	0.0694389	0.0033106	20.9749	< 2.2e-16	***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

**Con los parámetros estimados del modelo tenemos lo siguiente**

$$\Delta Y_t = 0.6994 + a_t - 0.4485 + 0.2633a_{t-2} - 0.6407a_{t-3} + 0.5254a_{t-4} - 0.6995a_{t-5}$$

**Modelo ARIMA (1,1,2)**

```
mod3 <- Arima(data_mod, order = c(1, 1, 2), include.constant = T)
coeftest(mod3)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
ar1	-0.906507	0.093423	-9.7032	< 2.2e-16	***
ma1	0.243719	0.171342	1.4224	0.1549	
ma2	-0.239670	0.163010	-1.4703	0.1415	
drift	0.067546	0.010765	6.2745	3.508e-10	***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

**Con los parámetros estimados del modelo tenemos lo siguiente**

$$\Delta Y_t = 0.0675 - 0.9065\Delta Y_{t-1} + a_t + 0.2437a_{t-1} - 0.2396a_{t-2}$$

### 3 Validación

#### 3.1 Análisis de los coeficientes estimados

##### 3.1.1 Significación de los coeficientes

**Para el modelo AR(1)**

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
ar1	-0.715918	0.092892	-7.7070	1.288e-14	***
drift	0.067188	0.012105	5.5505	2.849e-08	***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

**AR(1):  $\phi_1 = -0.7159 \rightarrow p = 0.00000 < 0.01$ , altamente significativo**

**Para el modelo MA(5)**

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
ma1	-0.4485415	0.1576038	-2.8460	0.004427	**

```

ma2    0.2633784  0.2748540  0.9582  0.337938
ma3    -0.6407278  0.1198853 -5.3445 9.066e-08 ***
ma4     0.5254175  0.2013839  2.6090 0.009080 **
ma5    -0.6995139  0.2720900 -2.5709 0.010144 *
drift   0.0694389  0.0033106 20.9749 < 2.2e-16 ***
---

```

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

**MA(1):  $\theta_1 = -0.4485 \rightarrow p = 0.0044 < 0.01$ , altamente significativo**

**MA(2):  $\theta_2 = 0.2633 \rightarrow p = 0.3379 > 0.05$ , NO es significativo**

**MA(3):  $\theta_3 = -0.6407 \rightarrow p = 0.0000 < 0.01$ , altamente significativo**

**MA(4):  $\theta_4 = 0.5254 \rightarrow p = 0.0090 < 0.01$ , altamente significativo**

**MA(5):  $\theta_5 = -0.6995 \rightarrow p = 0.0101 < 0.05$ , es significativo**

z test of coefficients:

```

      Estimate Std. Error z value Pr(>|z|)
ar1    -0.906507   0.093423  -9.7032 < 2.2e-16 ***
ma1     0.243719   0.171342   1.4224  0.1549
ma2    -0.239670   0.163010  -1.4703  0.1415
drift   0.067546   0.010765   6.2745 3.508e-10 ***
---

```

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

**AR(1):  $\phi_1 = -0.9065 \rightarrow p = 0.0000 < 0.01$ , altamente significativo**

**MA(1):  $\theta_1 = 0.2437 \rightarrow p = 0.1549 > 0.05$ , NO es significativo**

**MA(2):  $\theta_2 = -0.2396 \rightarrow p = 0.1415 > 0.05$ , NO es significativo**

### 3.1.2 Examen de la matriz de correlaciones entre los coeficientes

**vcov(mod1)**

```

      ar1      drift
ar1  8.628880e-03 2.049485e-05
drift 2.049485e-05 1.465264e-04

```

**vcov(mod2)**

```

ma1    2.483896e-02  2.580993e-02  3.811391e-03 -0.0182930187 -0.02455
07250  1.659998e-05
ma2    2.580993e-02  7.554474e-02  1.455536e-02 -0.0419279506 -0.06756
89521 -8.637586e-06
ma3    3.811391e-03  1.455536e-02  1.437248e-02 -0.0138970967 -0.00937
73322 -8.930819e-06
ma4    -1.829302e-02 -4.192795e-02 -1.389710e-02  0.0405554824  0.03557
91858 -1.317850e-05
ma5    -2.455073e-02 -6.756895e-02 -9.377332e-03  0.0355791858  0.07403
29643  1.413850e-05
drift   1.659998e-05 -8.637586e-06 -8.930819e-06 -0.0000131785  0.00001
41385  1.095990e-05

```

**vcov(mod3)**

```


      ar1      ma1      ma2      drift
ar1  8.727900e-03 -0.0103213052  8.607613e-03  1.139592e-06
ma1 -1.032131e-02  0.0293581486 -3.515797e-03 -1.031090e-05
ma2  8.607613e-03 -0.0035157970  2.657211e-02 -4.151149e-05
drift 1.139592e-06 -0.0000103109 -4.151149e-05  1.158904e-04

```

**Se observa claramente que ningún coeficiente está próximo ni cercano a 0.9, por tanto, podemos indicar que no hay problema de multicolinealidad en los modelos propuestos.**


### 3.1.3 Condición de convergencia e invertibilidad

`autoplot(mod1)`



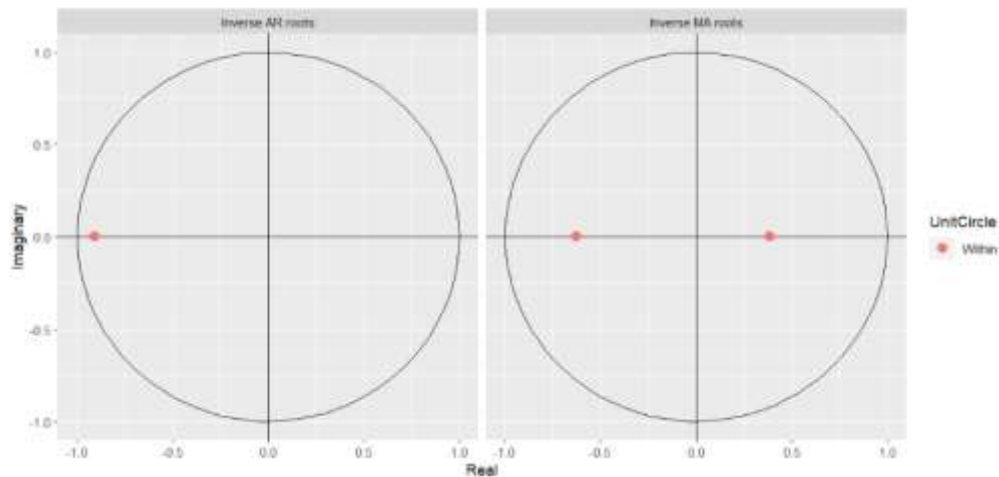
**En la figura de raíces inversas de AR, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de estacionariedad para la parte autorregresiva.**

`autoplot(mod2)`



**En la figura de raíces inversas de MA, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de invertibilidad para la parte de media móvil.**

`autoplot(mod3)`



**Al estar los valores dentro de la circunferencia unitaria es un indicativo de que el modelo se ajusta correctamente. Tanto en su parte AR, como en su parte MA.**

#### 3.1.4 Análisis de la estabilidad

```
Chow_mod1 <- Fstats(mod1$fitted ~ 1, from = 0.67)
sctest(Chow_mod1)
supF test
data: Chow_mod1
sup.F = 160.43, p-value < 2.2e-16
```

```
Chow_mod2 <- Fstats(mod2$fitted ~ 1, from = 0.67)
sctest(Chow_mod2)
supF test
data: Chow_mod2
sup.F = 156.99, p-value < 2.2e-16
```


```
Chow_mod3 <- Fstats(mod3$fitted ~ 1, from = 0.67)
sctest(Chow_mod3)
supF test
data: Chow_mod3
sup.F = 157.84, p-value < 2.2e-16
```

**En las tres pruebas se acepta la hipótesis nula ( $p < \alpha = 0.05$ ), es decir, NO existe estabilidad de coeficientes.**

#### 3.2 Análisis de los residuos

##### 3.2.1 Media es igual a cero

```
plot(mod1$residuals)
abline(h = 0, col = "red")
t.test(mod1$residuals, mu = 0)
```




One Sample t-test

```
data: mod1$residuals
t = 0.10559, df = 55, p-value = 0.9163
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.03876991  0.04308281
sample estimates:
 mean of x
0.002156447
```

**Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como  $p = 0.9163 > \alpha = 0.05$ , se acepta  $H_0$ , es decir la media es igual a cero.**

```
plot(mod2$residuals)
abline(h = 0, col = "red")
t.test(mod2$residuals, mu = 0)
```



One Sample t-test


```
data: mod2$residuals
```



```
t = -0.61655, df = 55, p-value = 0.5401
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.04695583  0.02486117
sample estimates:
 mean of x
-0.01104733
```

**Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como  $p = 0.5401 > \alpha = 0.05$ , se acepta  $H_0$ , es decir la media es igual a cero.**

```
plot(mod3$residuals)
abline(h = 0, col = "red")
t.test(mod3$residuals, mu = 0)
```




One Sample t-test

```
data: mod3$residuals
t = 0.10756, df = 55, p-value = 0.9147
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.03789693  0.04219582
sample estimates:
 mean of x
0.002149444
```

**Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como  $p = 0.9147 > \alpha = 0.05$ , se acepta  $H_0$ , es decir la media es igual a cero.**

### 3.2.2 Homocedasticidad o varianza constante

```
par(mfrow = c(3,1))
scatter.smooth(sqrt(abs(mod1$residuals)), lpars=list(col=2), main =
"Modelo 1")
scatter.smooth(sqrt(abs(mod2$residuals)), lpars=list(col=2), main =
"Modelo 2")
scatter.smooth(sqrt(abs(mod3$residuals)), lpars=list(col=2), main =
"Modelo 3")
```



Se observa que los datos parecen no presentar una variabilidad considerable, por tanto, será necesario realizar la prueba de Breusch-Pagan para determinar finalmente si las varianzas constantes para los modelos.

### Prueba de Breusch – Pagan

```
obs=get(mod1$series)
bptest(resid(mod1)~I(obs-resid(mod1)))
```

studentized Breusch-Pagan test

```
data: resid(mod1) ~ I(obs - resid(mod1))
BP = 4.9887, df = 1, p-value = 0.02551
```

```
obs=get(mod2$series)
bptest(resid(mod2)~I(obs-resid(mod2)))
```

studentized Breusch-Pagan test

```
data: resid(mod2) ~ I(obs - resid(mod2))
BP = 1.8583, df = 1, p-value = 0.1728
```

```
obs=get(mod3$series)
bptest(resid(mod3)~I(obs-resid(mod3)))
```


studentized Breusch-Pagan test

```
data: resid(mod3) ~ I(obs - resid(mod3))
BP = 2.5607, df = 1, p-value = 0.1096
```

**El valor de probabilidad (p-valor) asociado al estadístico BPasume un valor de 0.02551 para el MODELO 1, que es menor a  $\alpha=0.05$ . Por tanto, estos residuos no tiene varianza constante.**

**En cambio en el MODELO 2 y MODELO3 tiene el valor de probabilidad de 0.1728 y 0.1096 respectivamente, que son mayores a  $\alpha=0.05$ , por lo cual podemos afirmar que los residuales de estos modelos son constantes.**

### 3.2.3 Ausencia de correlación serial



**Se observa que casi la totalidad de los coeficientes del FAS para los modelos 1 , 2 y 3 se encuentran dentro de las bandas de no significación, sobre todo los de los primeros retardos.**

**Por tanto, tenemos altos indicios de que los residuos de los 3 modelos sean ruido blanco.**

```
Box.test(resid_m1,type = "Ljung-Box")
Box-Ljung test

data: resid_m1
X-squared = 0.079631, df = 1, p-value = 0.7778
```

```
Box.test(resid_m2,type = "Ljung-Box")
Box-Ljung test

data: resid_m2
X-squared = 1.1497, df = 1, p-value = 0.2836
```

```
Box.test(resid_m3,type = "Ljung-Box")
```

```
Box-Ljung test

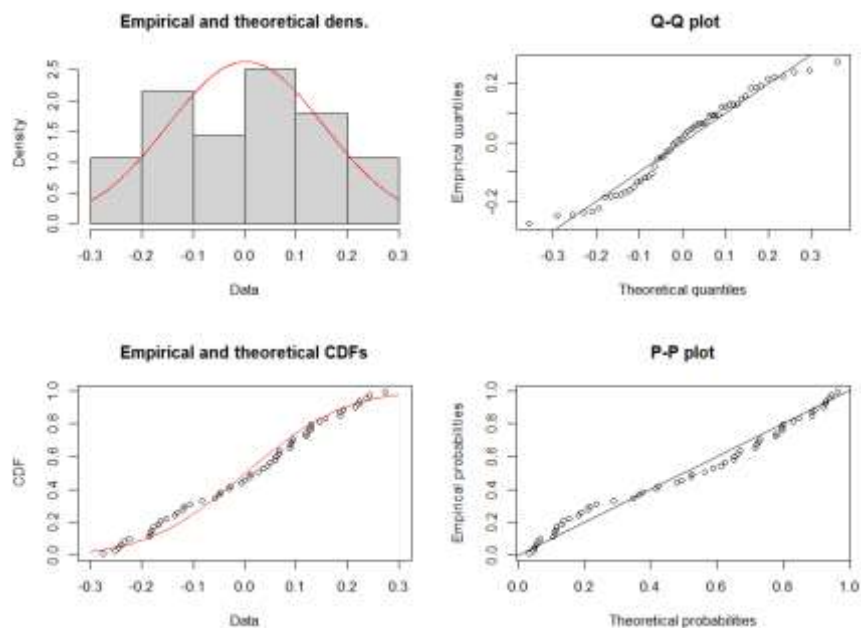
data: resid_m3
```

```
X-squared = 0.0026241, df = 1, p-value = 0.9591
```

Con los valores 0.7778, 0.2836 y 0.9591 son mayores a  $\alpha=0.05$ , por lo que se acepta la hipótesis nula de que los coeficientes de autocorrelación son cero; es decir, los residuos son independientes o están incorrelacionados.

### 3.2.4 Contraste de normalidad

```
ajuste_m1<-fitdist(data = resid_m1, distr="norm")  
plot(ajuste_m1)  
JB_m1 <- jarque.bera.test(resid_m1)  
JB_m1
```

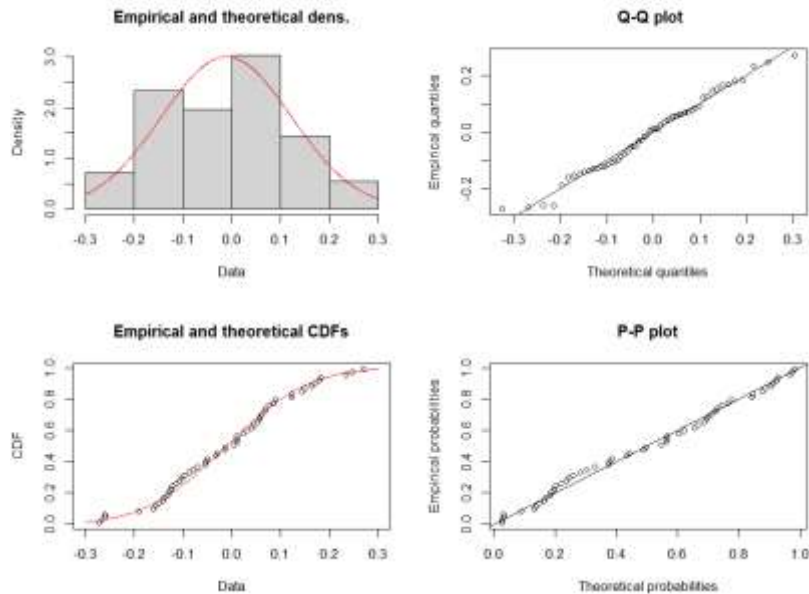


### Jarque Bera Test

```
data: resid_m1  
X-squared = 3.0068, df = 2, p-value = 0.2224
```

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como  $p = 0.2224 > 0.05$ , se acepta  $H_0$ , es decir, los residuos se aproximan a una distribución normal.

```
ajuste_m2<-fitdist(data = resid_m2, distr="norm")  
plot(ajuste_m2)  
JB_m2 <- jarque.bera.test(resid_m2)  
JB_m2
```

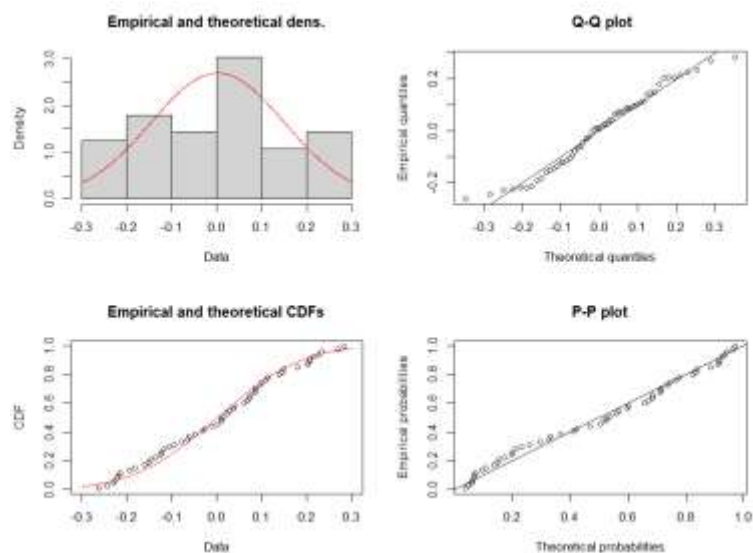


Jarque Bera Test

data: resid\_m2  
X-squared = 0.88085, df = 2, p-value = 0.6438

**En las figuras se observa que los residuales del modelo 2 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como  $p = 0.6438 > 0.05$ , se acepta  $H_0$ , es decir, los residuos se aproximan a una distribución normal.**

```
ajuste_m3<-fitdist(data = resid_m3, distr="norm")
plot(ajuste_m3)
JB_m3 <- jarque.bera.test(resid_m3)
JB_m3
```



Jarque Bera Test

data: resid\_m3  
X-squared = 2.4313, df = 2, p-value = 0.2965


En las figuras se observa que los residuales del modelo 3 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como  $p = 0.2965 > 0.05$ , se acepta  $H_0$ , es decir, los residuos se aproximan a una distribución normal.

## 4 Pronostico

### 4.1 Pronosticos de cada modelo

Modelo 1: ARIMA (1,1,0)

```
Pron1 <- forecast(mod1, level=c(95), h=10)
plot(Pron1)
summary(Pron1)
```



En la figura se puede observar el comportamiento de la función de predicción por punto y por intervalo.

Los datos proyectados para los siguientes 10 trimestres son:

```
Forecast method: ARIMA(1,1,0) with drift

Model Information:
Series: data_mod
ARIMA(1,1,0) with drift

Coefficients:
      ar1      drift
    -0.7159  0.0672
s.e.    0.0929  0.0121

sigma^2 = 0.02424:  log likelihood = 24.91
AIC=-43.82  AICC=-43.35  BIC=-37.8


Error measures:
              ME      RMSE      MAE      MPE      MAPE
MASE          ACF1
Training set 0.002156447 0.1514681 0.1302622 -0.001002706 1.037708 0.4
450654 0.03672105

Forecasts:
      Point Forecast      Lo 95      Hi 95
2013 Q1      14.53611 14.23095 14.84127
2013 Q2      14.66134 14.34410 14.97857
2013 Q3      14.68697 14.28731 15.08664
2013 Q4      14.78391 14.36328 15.20453
2014 Q1      14.82980 14.35909 15.30051
2014 Q2      14.91223 14.41701 15.40746
2014 Q3      14.96851 14.43628 15.50074
```

2014 Q4	15.04351	14.48612	15.60090
2015 Q1	15.10510	14.51730	15.69290
2015 Q2	15.17630	14.56397	15.78862

*Es importante mencionar que, los valores pronosticados son logaritmos, por tanto, para obtener los verdaderos valores de pronóstico, se tendrán que transformar aplicando la función exp().*

```
data_modelo1 <- exp(mod1$fitted)
grafico_comparativo <- cbind(data_ts, data_modelo1)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft", c("yt", "yest"), lty = c(1,1), lwd = 2, col=c("black", "red"))
```



## PRONÓSTICO DE LA SERIE ORIGINAL

Deshaciendo la transformación:

```
Pron1$mean <- exp(Pron1$mean)
Pron1$lower <- exp(Pron1$lower)
Pron1$upper <- exp(Pron1$upper)
Pron1$x <- exp(Pron1$x)
Pron1$fitted <- exp(Pron1$fitted)
Pron1$residuals <- exp(Pron1$residuals)
summary(Pron1)
```

Forecast method: ARIMA(1,1,0) with drift

Model Information:  
Series: data\_mod  
ARIMA(1,1,0) with drift

Coefficients:  
ar1 drift  
-0.7159 0.0672  
s.e. 0.0929 0.0121

sigma^2 = 0.02424: log likelihood = 24.91  
AIC=-43.82 AICc=-43.35 BIC=-37.8

Error measures:


	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	6211.225	132113.9	71919.14	-0.9399903	13.13878	0.4836564
0.0547565						

Forecasts:				
	Point Forecast	Lo 95	Hi 95	
2013 Q1	2055669	1515042	2789213	
2013 Q2	2329903	1696545	3199708	
2013 Q3	2390408	1602876	3564876	
2013 Q4	2633723	1729399	4010930	
2014 Q1	2757406	1722164	4414961	
2014 Q2	2994341	1824848	4913330	
2014 Q3	3167672	1860355	5393673	
2014 Q4	3414391	1955433	5961884	
2015 Q1	3631306	2017363	6536445	
2015 Q2	3899254	2113747	7192999	

## GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES


```
plot(Pron1, shaded = FALSE, xlab = "Años", ylab = "Intereses
pagados", main = "ARIMA(1,1,0)")
lines(Pron1$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCIÓN", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=2013, lwd = 1, col="green")
```



Modelo 2: ARIMA (0,1,5)


```
Pron2 <- forecast(mod2, level=c(95), h=10)
plot(Pron2)
summary(Pron2)
```





### PRONÓSTICO DE LA SERIE ORIGINAL

```
yt_arima2 <- exp(mod2$fitted)
grafico_comparativo <- cbind(Yt,yt_arima2)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt", "yest"),lty = c(1,1), lwd = 2)
```



```
Pron2$mean <- exp(Pron2$mean)
Pron2$lower <- exp(Pron2$lower)
Pron2$upper <- exp(Pron2$upper)
Pron2$x <- exp(Pron2$x)
Pron2$fitted <- exp(Pron2$fitted)
Pron2$residuals <- exp(Pron2$residuals)
summary(Pron2)
```

Forecast method: ARIMA(0,1,5) with drift

Model Information:

```

Series: data_mod
ARIMA(0,1,5) with drift

Coefficients:
          ma1      ma2      ma3      ma4      ma5      drift
s.e.    -0.4485    0.2634   -0.6407    0.5254   -0.6995    0.0694
          0.1576    0.2749    0.1199    0.2014    0.2721    0.0033

sigma^2 = 0.02032:  log likelihood = 28.17
AIC=-42.33  AICC=-39.95  BIC=-28.28

Error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE
ACF1
Training set 9162.53 114974.8 64506.76 -2.005822 11.21007 0.4338081 -0
.1393904

Forecasts:
      Point Forecast      Lo 95      Hi 95
2013 Q1          2165890 1626312 2884490
2013 Q2          2276487 1642389 3155400
2013 Q3          2144462 1433980 3206961
2013 Q4          2886901 1921031 4338399
2014 Q1          2638674 1672330 4163414
2014 Q2          2828412 1792581 4462791
2014 Q3          3031794 1921480 4783696
2014 Q4          3249800 2059647 5127675
2015 Q1          3483482 2207749 5496389
2015 Q2          3733968 2366501 5891615

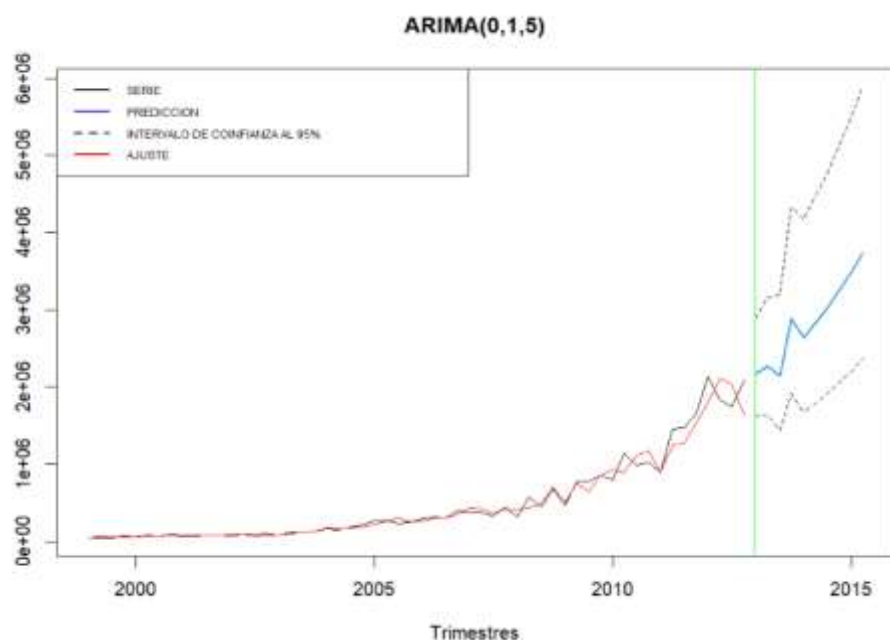
```

## GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```

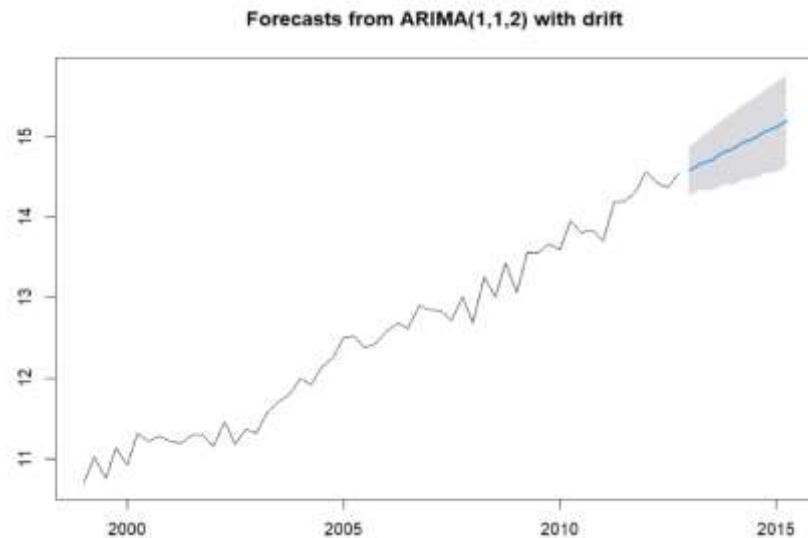
plot(Pron2, shaded = FALSE, xlab = "Trimestres", ylab = "", main =
"ARIMA(0,0,2)")
lines(Pron2$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=1930, lwd = 1, col="green")

```




### Modelo 3: ARIMA (1,1,2)

```
Pron3 <- forecast(modelo3, level=c(95), h=10)  
plot(Pron3)  
summary(Pron3)
```



### PRONÓSTICO DE LA SERIE ORIGINAL

```
yt_arima3 <- exp(modelo3$fitted)  
grafico_comparativo <- cbind(Yt, yt_arima3)  
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)  
legend("topleft", c("yt", "yest"), lty = c(1,1), lwd = 2)
```



### GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```
Pron3$mean <- exp(Pron3$mean)  
Pron3$lower <- exp(Pron3$lower)  
Pron3$upper <- exp(Pron3$upper)  
Pron3$x <- exp(Pron3$x)  
Pron3$fitted <- exp(Pron3$fitted)  
Pron3$residuals <- exp(Pron3$residuals)
```

`summary(Pron3)`

Forecast method: ARIMA(1,1,2) with drift

Model Information:

Series: data\_mod

ARIMA(1,1,2) with drift

Coefficients:

	ar1	ma1	ma2	drift
	-0.9065	0.2437	-0.2397	0.0675
s.e.	0.0934	0.1713	0.1630	0.0108

$\sigma^2 = 0.02412$ : log likelihood = 26.03

AIC=-42.06 AICC=-40.84 BIC=-32.03

Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	8205.438	126569.1	68489	-0.8861896	12.64779	0.4605887
06992194						0.0

Forecasts:


	Point	Forecast	Lo 95	Hi 95
2013 Q1		2136975	1576165	2897326
2013 Q2		2360379	1711867	3254569
2013 Q3		2453377	1669058	3606260
2013 Q4		2694501	1803620	4025422
2014 Q1		2815128	1795102	4414761
2014 Q2		3077400	1931037	4904303
2014 Q3		3228810	1947797	5352310
2014 Q4		3516103	2087372	5922749
2015 Q1		3701954	2125720	6446973
2015 Q2		4018652	2271042	7111081

`plot(Pron3, shaded = FALSE, xlab = "Años", ylab = "N° DE PIELES", main = "ARIMA(1,1,2)")`

`lines(Pron3$fitted, col = "red")`

`legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"), lty=c(1,1,2,1), lwd = 2, cex = 0.6)`

`abline(v=1930, lwd = 1, col="green")`



## Métricas basadas en el error

### accuracy(Pron1)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	6211.225	132113.9	71919.14	-0.9399903	13.13878	0.4836564
	0.0547565					

### accuracy(Pron2)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	9162.53	114974.8	64506.76	-2.005822	11.21007	0.4338081
	.1393904					

### accuracy(Pron3)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	8205.438	126569.1	68489	-0.8861896	12.64779	0.4605887
	0.06992194					

**Basado en las métricas MAE y RMSE, el modelo Pron2 es el mejor entre los tres, ya que tiene los valores más bajos(MAE = 64506 Y RMSE=114974) en ambas métricas. Esto indica que sus predicciones son más precisas y con menos variabilidad en los errores grandes.**

## Conclusión

Sobre los modelos:

### ARIMA (1,1,0)

- **Coeficientes Significativos:** Todos los coeficientes son altamente significativos.
- **Residuos:** Los residuos tienen una media cercana a cero y no presentan autocorrelación.
- **Estabilidad:** Las pruebas de Chow indicaron que no hay estabilidad de coeficientes, lo cual es un punto en contra.
- **Condición de Invertibilidad y Convergencia:** Cumple con las condiciones.

### ARIMA (0,1,5)

- **Coeficientes Significativos:** Tres de los cinco coeficientes de media móvil son significativos.
- **Residuos:** Los residuos tienen una media cercana a cero y no presentan autocorrelación.
- **Estabilidad:** Al igual que el modelo anterior, no muestra estabilidad de coeficientes en las pruebas de Chow.
- **Condición de Invertibilidad y Convergencia:** Cumple con las condiciones.

### ARIMA (1,1,2)

- **Coeficientes Significativos:** El coeficiente AR es significativo, pero los coeficientes MA no lo son.
- **Residuos:** Los residuos tienen una media cercana a cero y no presentan autocorrelación.

- **Estabilidad:** Similar a los otros dos modelos, no presenta estabilidad de coeficientes.
- **Condición de Invertibilidad y Convergencia:** Cumple con las condiciones.

*Teniendo en cuenta todos los aspectos analizados, el modelo ARIMA (1,1,0) es el más adecuado para la serie de datos evaluada. Esto se debe a que todos sus coeficientes son altamente significativos, los residuos cumplen con los supuestos necesarios, y cumple con las condiciones de invertibilidad y convergencia. Aunque no presenta estabilidad en los coeficientes, este aspecto es una limitación compartida con los otros modelos evaluados. Pero si lo que mas nos importa es el error el modelo ARIMA(0,1,5) tiene menor error y cumple con los mismo supuestos del modelo ARIMA(1,1,0)*