

Tabla de contenido

Caso 1	3
1 Identificación	3
1. 1 Análisis de la tendencia y la estacionalidad	4
1.1.1 Estacionalidad.....	4
1.1.2 Análisis de tendencia	4
1.2 Análisis de estacionariedad.....	5
1.2.1 Estacionariedad en varianza.....	5
1.2.2 Estacionariedad en media	9
1.3 Identificación del modelo estacionario.....	12
1.3.1 Identificación de las órdenes p y q.....	12
1.3.2 Inclusión del término independiente (δ) o intercepto	12
2 Estimación.....	13
3 Validación	13
3.1 Análisis de los coeficientes estimados	13
3.1.1 Significación de los coeficientes	13
3.1.2 Examen de la matriz de correlaciones entre los coeficientes	14
3.1.3 Condición de convergencia e invertibilidad.....	14
3.1.4 Análisis de la estabilidad.....	15
3.2 Análisis de los residuos	16
3.2.1 Media es igual a cero.....	16
3.2.2 Homocedasticidad o varianza constante	18
3.2.3 Ausencia de correlación serial	20
3.2.4 Contraste de normalidad.....	21
4 Pronostico	23
4.1Pronosticos de cada modelo	23
Modelo 1: ARIMA(2,1,0).....	23
Modelo 2: ARIMA(0,1,1).....	26
Modelo 3: ARIMA(1,1,2).....	29
Métricas basadas en el error	32
Conclusión	33
CASO 2: PRODUCCION DE PAPA.....	34
1 Identificación	34
1. 1 Análisis de la tendencia y la estacionalidad	34
1.1.1 Estacionalidad.....	34
1.1.2 Análisis de tendencia	34
1.2 Análisis de estacionariedad.....	35

1.2.1 Estacionariedad en varianza.....	35
1.2.2 Estacionariedad en media	38
1.3 Identificación del modelo estacionario.....	41
1.3.1 Identificación de las órdenes p y q.....	41
1.3.2 Inclusión del término independiente (δ) o intercepto	41
2 Estimación.....	42
3 Validación.....	42
3.1 Análisis de los coeficientes estimados	42
3.1.1 Significación de los coeficientes	42
3.1.2 Examen de la matriz de correlaciones entre los coeficientes	43
3.1.3 Condición de convergencia e invertibilidad.....	43
3.1.4 Análisis de la estabilidad.....	45
3.2 Análisis de los residuos	45
3.2.1 Media es igual a cero.....	45
3.2.2 Homocedasticidad o varianza constante	47
3.2.3 Ausencia de correlación serial	49
3.2.4 Contraste de normalidad.....	50
4 Pronostico	52
4.1Pronosticos de cada modelo	52
Modelo 1: ARIMA (1,1,0).....	52
Modelo 2: ARIMA (0,1,1).....	56
Modelo 3: ARIMA (1,1,1).....	58
Métricas basadas en el error	61
Conclusión	61

Actividad 6


```
# Librerias necesaria
library(forecast) # Modelo ARIMA
library(tseries) # Para series de tiempo
library(TSA) # Para series de tiempo
library(urca) # Raiz Unitaria
library(ggplot2) # Para hacer gráficos
library(gridExtra)
library(dplyr) # Para la manipulación de datos
library(lmtest) # Inferencia para coeficientes estimados
library(MASS) # Transformacion de Box-Cox
library(nortest) # Pruebas de normalidad
library(strucchange) # Cambio estructural - Test de Chow
library(mFilter)
library(readxl)
library(fitdistrplus)
```

Caso 1

1 Identificación

Grafica inicial de la serie:

```
data <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-06.xlsx",sheet = "01")
View(data)
# Gráfica de la serie
data_ts <- ts(data$Yt, start = c(1872,1), frequency = 1)
plot(data_ts, xlab="Años", ylab="PRODUCCIÓN DE TABACO")
```



En primera instancia podemos visualizar una clara TENDENCIA creciente, la varianza no parece variar mucho, y no es estacionaria en media. Y al ser una serie anual NO haremos un análisis de estacionalidad.

1. 1 Análisis de la tendencia y la estacionalidad

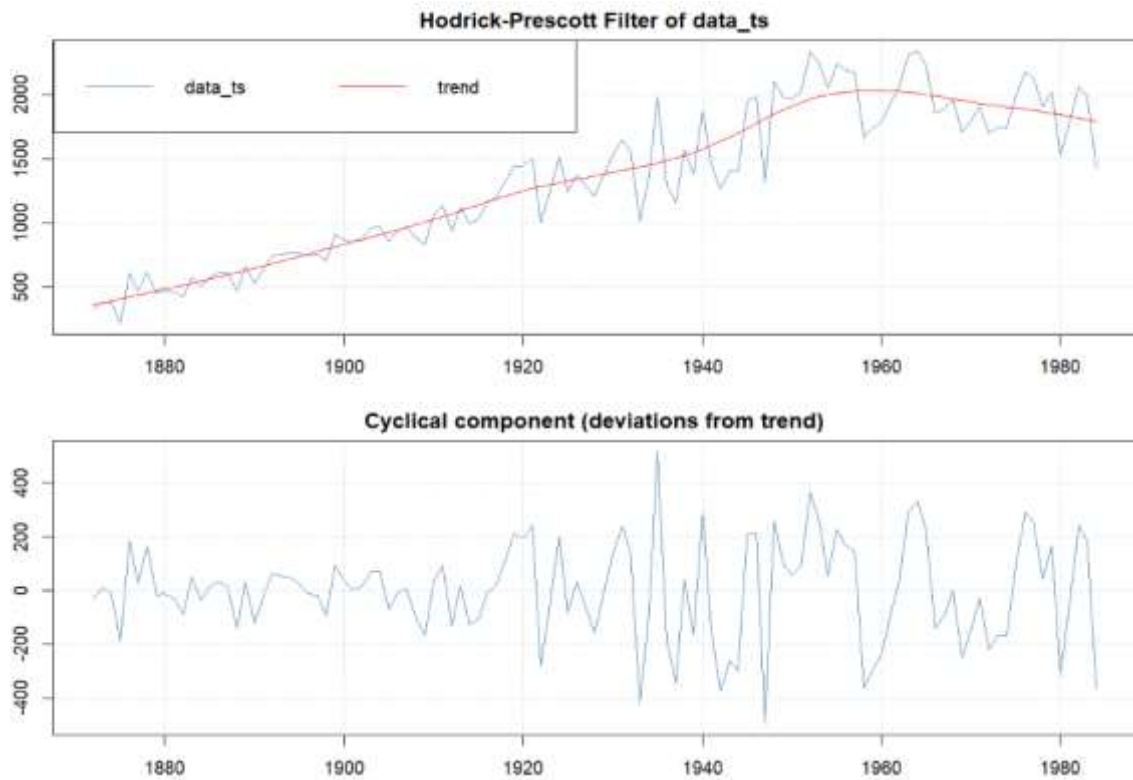
1.1.1 Estacionalidad

Debido a que se trata de un gráfico con un período anual, no se observa estacionalidad.

1.1.2 Análisis de tendencia

```
lambda_hp <- 1000  
data_hp <- hpfilter(data_ts, type="lambda", freq=lambda_hp)  
plot(data_hp)
```

Alumno: Maye Mamani Victor Raul

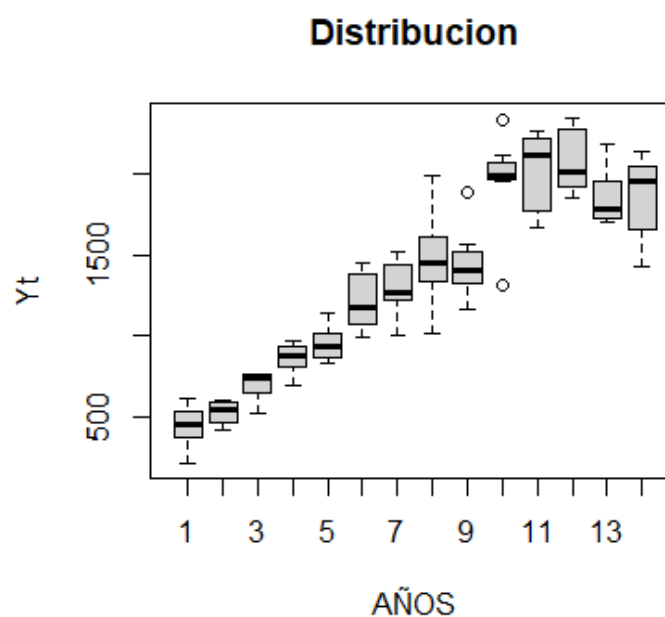


Hay una tendencia creciente hasta el año 1955 aproximadamente tras la cual se muestra un breve descenso en la misma. Y no parece haber algún patrón que se repita cíclicamente

1.2 Análisis de estacionariedad

1.2.1 Estacionariedad en varianza

```
boxplot(data$IPC ~ data$Año, xlab = "AÑOS/MESES", ylab="IPC",  
main="Distribucion" )
```



Tenemos ciertos indicios de estacionariedad en varianza, sin embargo en los últimos años esta presenta un cambio significativo en la serie lo que nos sugiere que no existe estacionariedad en varianza.

```
qqnorm(data_ts, main="lambda = 1")  
qqline(data_ts)
```

```
t1.yt <- data_ts^2  
qqnorm(t1.yt, main="lambda = 2")  
qqline(t1.yt)
```

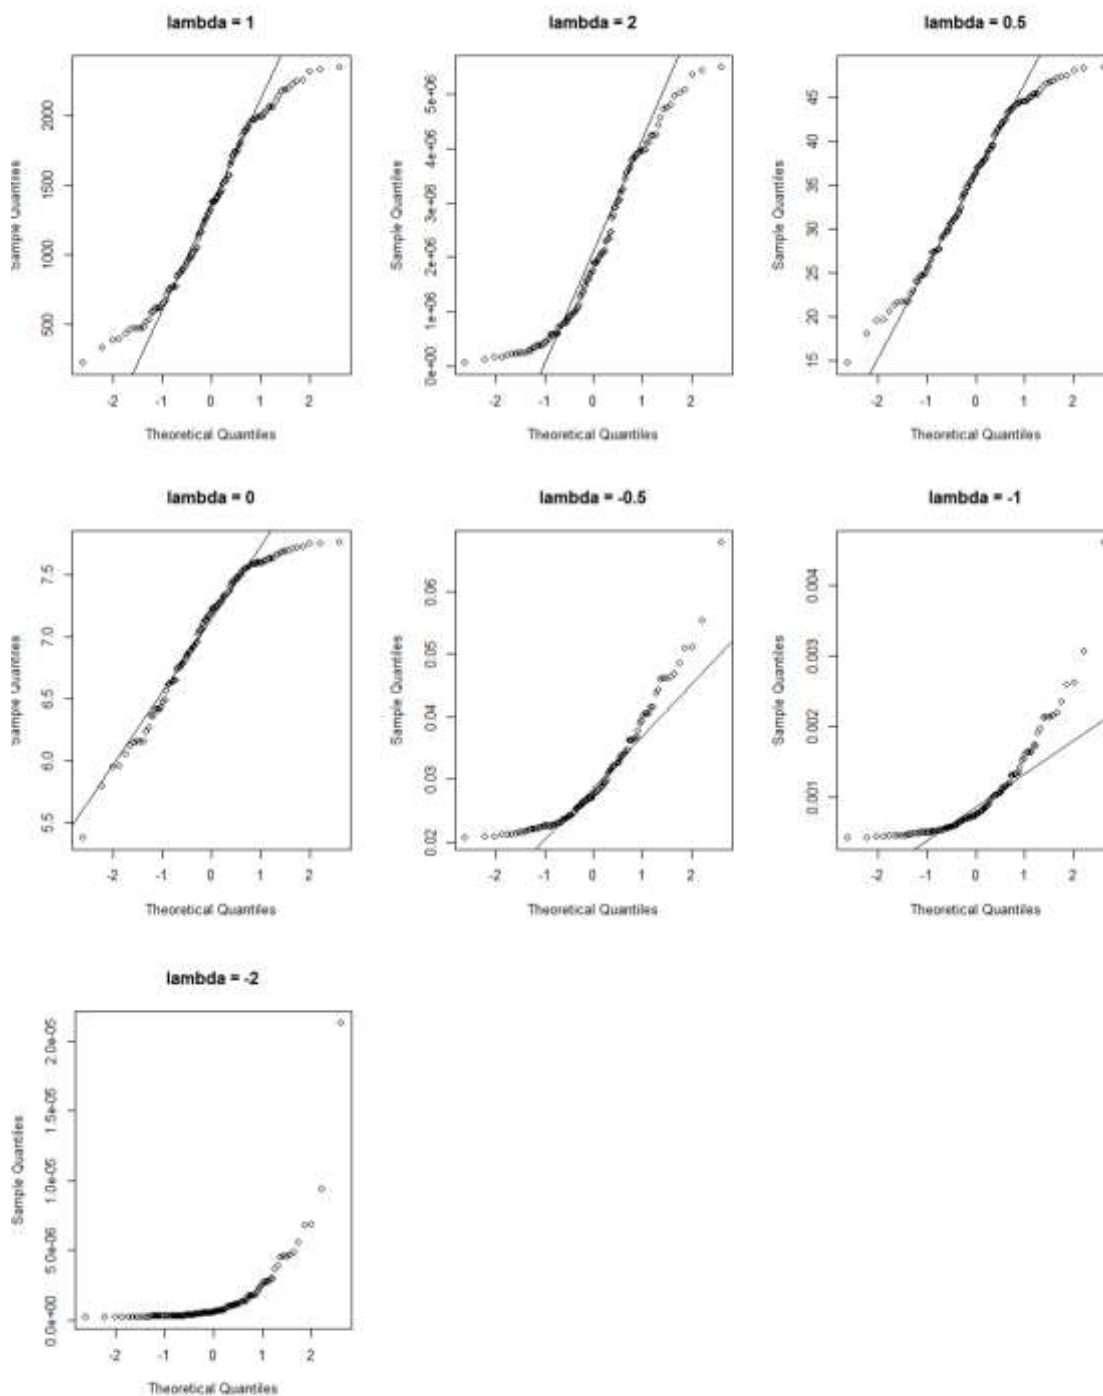
```
t3.yt <- sqrt(data_ts)  
qqnorm(t3.yt, main="lambda = 0.5")  
qqline(t3.yt)
```

```
t4.yt <- log(data_ts)  
qqnorm(t4.yt, main="lambda = 0")  
qqline(t4.yt)
```

```
t5.yt <- 1/sqrt(data_ts)  
qqnorm(t5.yt, main="lambda = -0.5")  
qqline(t5.yt)
```

```
t6.yt <- 1/data_ts  
qqnorm(t6.yt, main="lambda = -1")  
qqline(t6.yt)
```

```
t7.yt <- 1/(Yt^2)  
qqnorm(t7.yt, main="lambda = -2")  
qqline(t7.yt)
```




LAMBDA OPTIMO

```
b <- BoxCox.ar(data_ts)
lambda <- b$ml
round(lambda, 2)
```


```
[1] 0.4
```

Alumno: Maye Mamani Victor Raul



Se observa una mejora en el ajuste a la distribución normal de la serie original al aplicar lambda 0.


```
data_tf <- log(data_ts)
plot(data_tf)
```



Se puede observar una mejora en la estacionariedad en varianza.

1.2.2 Estacionariedad en media

```
par(mfrow = c(1,2))
FAS <- acf(data_ts, lag.max = 15, main="FAS - Yt")
FAP <- pacf(data_ts, lag.max = 15, main="FAP - Yt")
FAP$acf[1]
```



```
[1] 0.9689437
```

El FAS decrece lentamente y el primer FAP es significativo siendo muy cercano a 0.9, por lo que podríamos decir que la serie NO ES ESTACIONARIA, pero de igual forma haremos una prueba confirmatoria.

```
data_adf <- ur.df(data_tf, type="trend", lags = 1)
summary(data_adf)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-0.71596 -0.08100  0.02031  0.09813  0.53372

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  1.885199   0.555697   3.392 0.000972 ***
z.lag.1      -0.294094   0.089150  -3.299 0.001319 **
tt           0.003753   0.001428   2.628 0.009844 **
z.diff.lag   -0.318628   0.093425  -3.411 0.000916 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1752 on 107 degrees of freedom
```

```
Multiple R-squared: 0.286, Adjusted R-squared: 0.266  
F-statistic: 14.29 on 3 and 107 DF, p-value: 6.743e-08
```

```
Value of test-statistic is: -3.2989 4.5669 6.1851
```


```
Critical values for test statistics:
```

	1pct	5pct	10pct
tau3	-3.99	-3.43	-3.13
phi2	6.22	4.75	4.07
phi3	8.43	6.49	5.47

Observamos que el T calculado (-3.2989) es MAYOR que el T crítico (-3.43) por tanto se rechaza la hipótesis nula de la existencia de raíz unitaria, es decir que la serie NO ES ESTACIONARIA

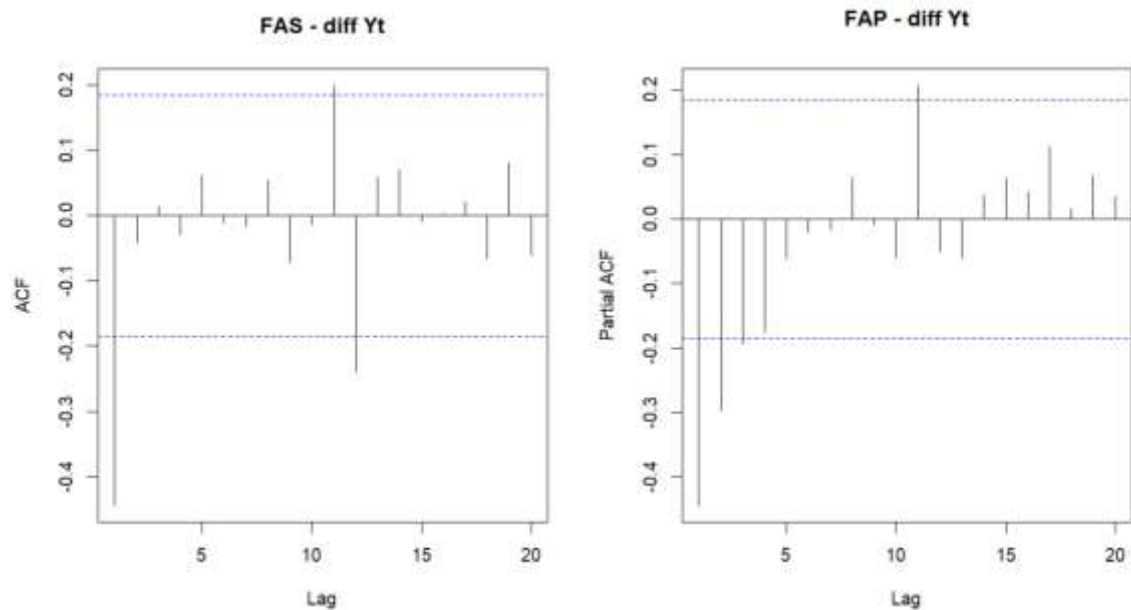
Diferenciamos la serie

```
data_diff = diff(data_mod)  
plot(data_diff, xlab="Meses", ylab="IPC")  
abline(h = mean(data_diff), col = "red")
```



Volvemos a analizar el correlograma

```
par(mfrow = c(1,2))  
FAS <- acf(data_diff, lag.max = 15, main="FAS - diff Yt")  
FAP <- pacf(data_diff, lag.max = 15, main="FAP - diff Yt")  
FAP$acf[1]
```



Hay un decrecimiento rapido en el FAS, y el valor del primer coeficiente de las FAP es menor a 0.9, por lo que existen indicios de que la serie ES ESTACIONARIA

Prueba cofirmatoria

```
data_adf <- ur.df(data_diff, type="trend", lags = 1)
```

```
summary(data_adf)
```

```
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

```
Test regression drift
```

```
Call:
```

```
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

```
Residuals:
```

```
      Min       1Q   Median       3Q      Max  
-0.54422 -0.09446 -0.00272  0.09511  0.66017
```

```
Coefficients:
```

```
            Estimate Std. Error t value Pr(>|t|)  
(Intercept)  0.02644    0.01692   1.562  0.121155  
z.lag.1      -1.92761    0.15958 -12.079 < 2e-16 ***  
z.diff.lag    0.32145    0.09325   3.447  0.000811 ***  
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 0.1755 on 107 degrees of freedom
```

```
Multiple R-squared:  0.7499, Adjusted R-squared:  0.7453
```

```
F-statistic: 160.5 on 2 and 107 DF, p-value: < 2.2e-16
```

```
Value of test-statistic is: -12.0794 72.986
```


```
Critical values for test statistics:
```

```
      1pct      5pct     10pct  
tau2  -3.46  -2.88  -2.57  
phi1   6.52   4.63   3.81
```

Observamos que el T calculado (-12.0767) es MENOR que el T crítico (-3.45) por tanto se acepta la hipótesis nula de la existencia de raíz unitaria, es decir que la serie ES ESTACIONARIA.

1.3 Identificación del modelo estacionario

1.3.1 Identificación de las órdenes p y q



Observando el FAS vemos que decrece rápidamente y tiene 2 coeficientes significativos $MA(1)$. Y el FAP decrecen forma de sinusoidal y tiene 2 coeficientes diferentes de cero por lo que también planteamos un $AR(2)$. Adicionalmente planteamos un $ARIMA(2,1)$.

1.3.2 Inclusión del término independiente (δ) o intercepto

```
Z <- mean(data_diff)
Co <- var(data_diff)
Tn <- length(data_diff)
Ta <- Tn - 1
Sigma <- Co/Ta
t <- Z/Sigma
tt <- qt(1-0.05/2, Ta-1)
pruebaT <- c(t, tt)
names(pruebaT) <- c("t-calculado", "t-critico")
pruebaT
```

t-calculado	t-critico
35.411314	1.981567

Se rechaza la hipótesis nula y se incluye la constante.

Resumiendo, se proponen los siguientes modelos

$ARIMA(2,1,0)$

$ARIMA(0,1,1)$

ARIMA(1,1,2)

2 Estimación

```
mod1 <- Arima(data_tf, order = c(2, 1, 0), include.constant = T)
coeftest(mod1)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
ar1	-0.6018932	0.0912564	-6.5956	4.235e-11	***
ar2	-0.3173850	0.0906412	-3.5016	0.0004626	***
drift	0.0141191	0.0085184	1.6575	0.0974214	.

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\Delta Y_t = 0.0141 + -0.6018\Delta Y_{t-1} - 0.3173\Delta Y_{t-2} + a_t$$

```
mod2 <- Arima(data_tf, order = c(0, 1, 1), include.constant = T)
coeftest(mod2)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
ma1	-0.7242000	0.0614426	-11.7866	< 2.2e-16	***
drift	0.0144458	0.0044053	3.2792	0.001041	**

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\Delta Y_t = 0.01444a_t - 0.7242a_{t-1}$$

```
mod3 <- Arima(data_tf, order = c(1, 1, 2), include.constant = T)
coeftest(mod3)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
ar1	0.977761	0.040107	24.3789	<2e-16	***
ma1	-1.765500	0.074269	-23.7716	<2e-16	***
ma2	0.784000	0.068231	11.4904	<2e-16	***
drift	0.014212	0.010129	1.4032	0.1606	

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

$$\Delta Y_t = 0.0142 + 0.9777\Delta Y_{t-1} + a_t - 1.7655a_{t-1} - 0.7840a_{t-2}$$

3 Validación

3.1 Análisis de los coeficientes estimados

3.1.1 Significación de los coeficientes

Para el modelo 1

AR(1): $\phi_1 = -0.6018 \rightarrow p = 0.0000 < 0.01$, altamente significativo

AR(2): $\phi_2 = -0.3173 \rightarrow p = 0.0004 < 0.01$, altamente significativo

Para el modelo 2

MA(1): $\theta_1 = -0.7242 \rightarrow p = 0.0000 < 0.01$, altamente significativo

Para el modelo 3

AR(1): $\phi_1 = 0.9777 \rightarrow p = 0.0000 < 0.01$, altamente significativo

$MA(1): \theta_1 = -1.7655 \rightarrow p = 0.0000 < 0.01$, es altamente significativo

$MA(2): \phi_1 = 0.7840 \rightarrow p = 0.0000 < 0.01$, es altamente significativo

3.1.2 Examen de la matriz de correlaciones entre los coeficientes

vcov(mod1)

	ar1	ar2	drift
ar1	8.327732e-03	3.808960e-03	-6.492482e-06
ar2	3.808960e-03	8.215831e-03	-7.907764e-06
drift	-6.492482e-06	-7.907764e-06	7.256258e-05

vcov(mod2)

	ma1	drift
ma1	3.775192e-03	-1.116834e-06
drift	-1.116834e-06	1.940628e-05


vcov(mod3)

	ar1	ma1	ma2	drift
ar1	1.608558e-03	-1.610558e-03	1.134299e-03	-1.624084e-05
ma1	-1.610558e-03	5.515904e-03	-4.980805e-03	2.648729e-05
ma2	1.134299e-03	-4.980805e-03	4.655448e-03	-2.125514e-05
drift	-1.624084e-05	2.648729e-05	-2.125514e-05	1.025866e-04

Se observa claramente que ningún coeficiente está próximo ni cercano a 0.9, por tanto, podemos indicar que no hay problema de multicolinealidad en los modelos propuestos.


3.1.3 Condición de convergencia e invertibilidad

autoplot(mod1)




En la figura de raíces inversas de AR, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de estacionariedad para la parte autorregresiva.

autoplot(mod2)



En la figura de raíces inversas de MA, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de invertibilidad para la parte de media móvil.

`autoplot(mod3)`



Al estar los valores dentro de la circunferencia unitaria es un indicativo de que el modelo se ajusta correctamente. Tanto en su parte AR, como en su parte MA.

3.1.4 Análisis de la estabilidad

#Análisis de estabilidad

```
Chow_mod1 <- Fstats(mod1$fitted ~ 1, from = 0.60,to=0.70)
```

```
sctest(Chow_mod1)
```

supF test

data: Chow_mod1

sup.F = 324.15, p-value < 2.2e-16

```
Chow_mod2 <- Fstats(mod2$fitted ~ 1, from = 0.60,to=0.70)
```

```
sctest(Chow_mod2)
```

supF test

data: Chow_mod2

sup.F = 340.91, p-value < 2.2e-16

Alumno: Maye Mamani Victor Raul

```
Chow_mod3 <- Fstats(mod3$fitted ~ 1, from = 0.60, to=0.70)
sctest(Chow_mod3)
supF test
data: Chow_mod3
sup.F = 320.61, p-value < 2.2e-16
```


En las tres pruebas se rechaza la hipótesis nula ($p < \alpha = 0.05$), es decir, NO existe estabilidad de coeficientes

3.2 Análisis de los residuos

3.2.1 Media es igual a cero

Modelo 1

```
plot(mod1$residuals)
abline(h = 0, col = "red")
t.test(mod1$residuals, mu = 0)
```



One Sample t-test


```
data: mod1$residuals
t = 0.048446, df = 112, p-value = 0.9614
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
-0.03127590 0.03284367
sample estimates:
mean of x
0.0007838851
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t:

Como $p = 0.9614 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

Modelo 2

```
plot(mod2$residuals)
abline(h = 0, col = "red")
t.test(mod2$residuals, mu = 0)
```




One Sample t-test

```
data: mod2$residuals
t = 0.138, df = 112, p-value = 0.8905
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.02860809 0.03289153
sample estimates:
mean of x
0.002141719
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t. Como $p = 0.8905 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

Modelo 3

```
plot(mod3$residuals)
abline(h = 0, col = "red")
t.test(mod3$residuals, mu = 0)
```



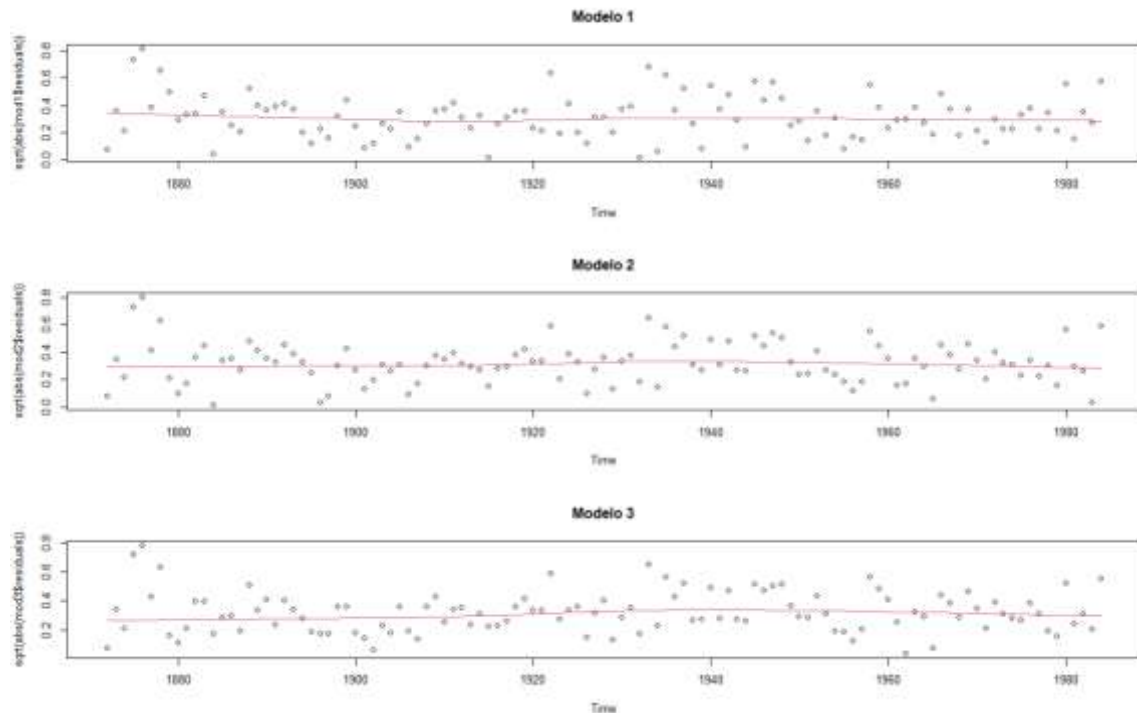
One Sample t-test

```
data: mod3$residuals
t = -0.56544, df = 112, p-value = 0.5729
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.03888680  0.02161961
sample estimates:
mean of x
-0.008633598
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.5729 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

3.2.2 Homocedasticidad o varianza constante

```
par(mfrow = c(3,1))
scatter.smooth(sqrt(abs(mod1$residuals)), lpars=list(col=2), main =
"Modelo 1")
scatter.smooth(sqrt(abs(mod2$residuals)), lpars=list(col=2), main =
"Modelo 2")
scatter.smooth(sqrt(abs(mod3$residuals)), lpars=list(col=2), main =
"Modelo 3")
```



Se observa que los datos parecen presentar una variabilidad considerable, por tanto, será necesario realizar la prueba de Breusch-Pagan para determinar finalmente si las varianzas constantes para los modelos

```
obs=get(mod1$series)
bptest(resid(mod1)~I(obs-resid(mod1)))
studentized Breusch-Pagan test

data: resid(mod1) ~ I(obs - resid(mod1))
BP = 5.5028, df = 1, p-value = 0.01899
```

```
obs=get(mod2$series)
bptest(resid(mod2)~I(obs-resid(mod2)))
studentized Breusch-Pagan test

data: resid(mod2) ~ I(obs - resid(mod2))
BP = 4.1873, df = 1, p-value = 0.04073
```


```
obs=get(mod3$series)
bptest(resid(mod3)~I(obs-resid(mod3)))
studentized Breusch-Pagan test

data: resid(mod3) ~ I(obs - resid(mod3))
BP = 4.3006, df = 1, p-value = 0.0381
```

El valor de probabilidad (p-valor) asociado al estadístico BP asume los valores de probabilidad de 0.01899, 0.04073 y 0.0381 para los modelos 1, 2 y 3 respectivamente, que son menores a $\alpha=0.05$, por lo cual podemos afirmar que los residuales de estos modelos NO son constantes.

3.2.3 Ausencia de correlación serial

```
resid_m1 <- as.vector(mod1$residuals)
resid_m2 <- as.vector(mod2$residuals)
resid_m3 <- as.vector(mod3$residuals)
par(mfrow = c(1,1))
FAS_e.m1 <- acf(resid_m1, lag.max = 25,
                 main="FAS Modelo 1")
FAS_e.m2 <- acf(resid_m2, lag.max = 25,
                 main="FAS Modelo 2")
FAS_e.m3 <- acf(resid_m3, lag.max = 25,
                 main="FAS Modelo 3")
```



Se observa que casi la totalidad de los coeficientes del FAS para los 3 modelos se encuentran dentro de las bandas de no significación. Por tanto, tenemos altos indicios de que los residuos de los modelos 1, 2 y 3 sean ruido blanco

```
Box.test(resid_m1,type = "Ljung-Box")
Box-Ljung test
data: resid_m1
X-squared = 0.48086, df = 1, p-value = 0.488
```

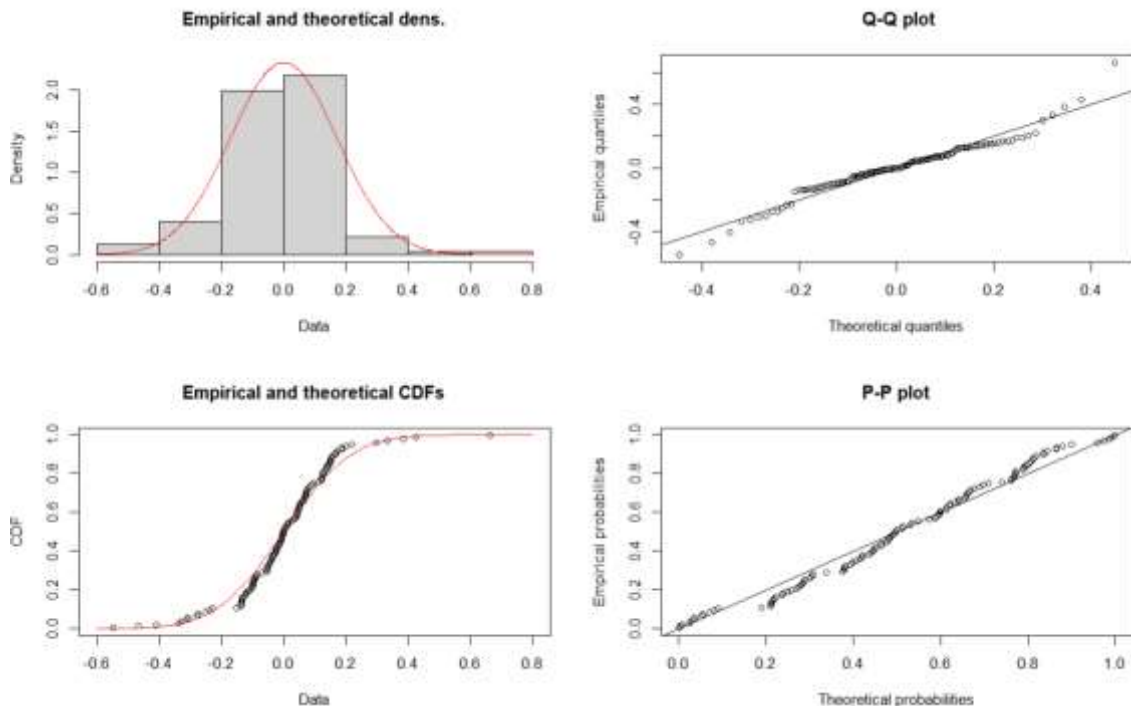
```
Box.test(resid_m2,type = "Ljung-Box")
Box-Ljung test
data: resid_m2
X-squared = 0.0028218, df = 1, p-value = 0.9576
```

```
Box.test(resid_m3,type = "Ljung-Box")
Box-Ljung test
data: resid_m3
X-squared = 0.1021, df = 1, p-value = 0.7493
```

Teniendo los valores 0.488, 0.9576 y 0.7493 en los MODELOS 1, 2 Y 3 respectivamente, los cuales son mayores a $\alpha=0.05$, por lo que se acepta la hipótesis nula de que los coeficientes de autocorrelación son cero; es decir, los residuos son independientes o están incorrelacionados.

3.2.4 Contraste de normalidad

```
ajuste_m1<-fitdist(data = resid_m1, distr="norm")
plot(ajuste_m1)
JB_m1 <- jarque.bera.test(resid_m1)
JB_m1
```

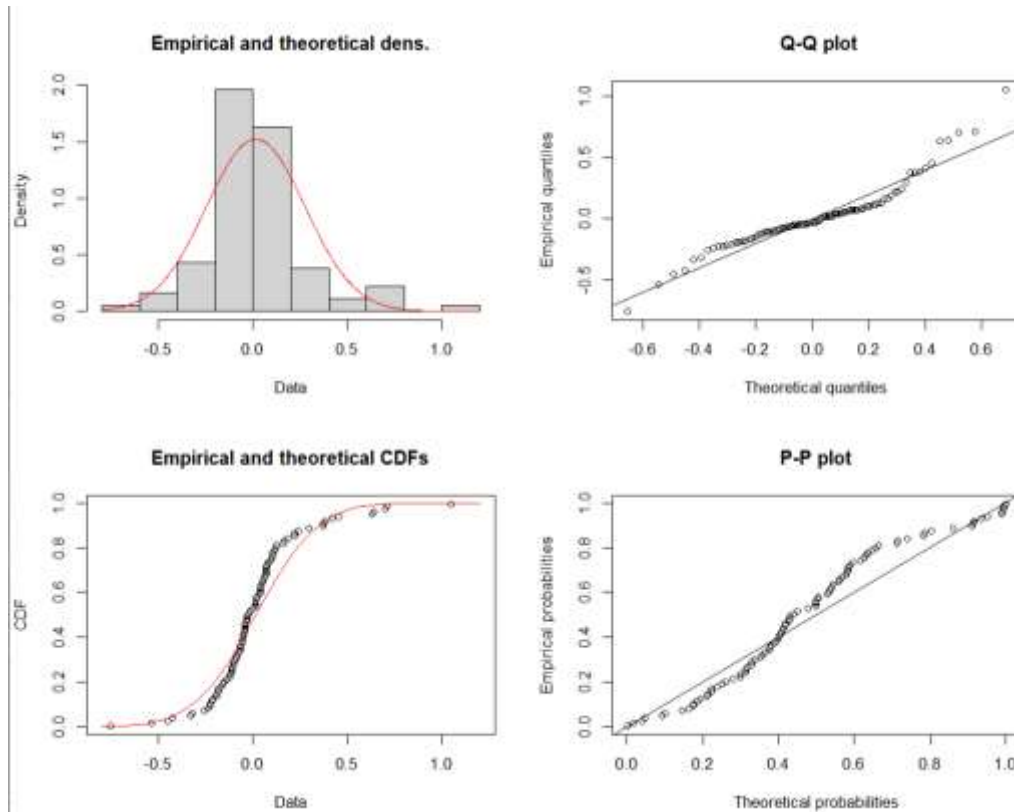


Jarque Bera Test

```
data: resid_m1
X-squared = 24.485, df = 2, p-value = 4.821e-06
```

En las figuras se observa que los residuales del modelo 1 presentan indicios de ajuste hacia la distribución normal. Pero en la prueba JB, como $p = 0.0000 < 0.05$, se rechaza la H_0 , es decir, los residuos NO se aproximan a una distribución normal.

```
ajuste_m2<-fitdist(data = resid_m2, distr="norm")
plot(ajuste_m2)
JB_m2 <- jarque.bera.test(resid_m2)
JB_m2
```

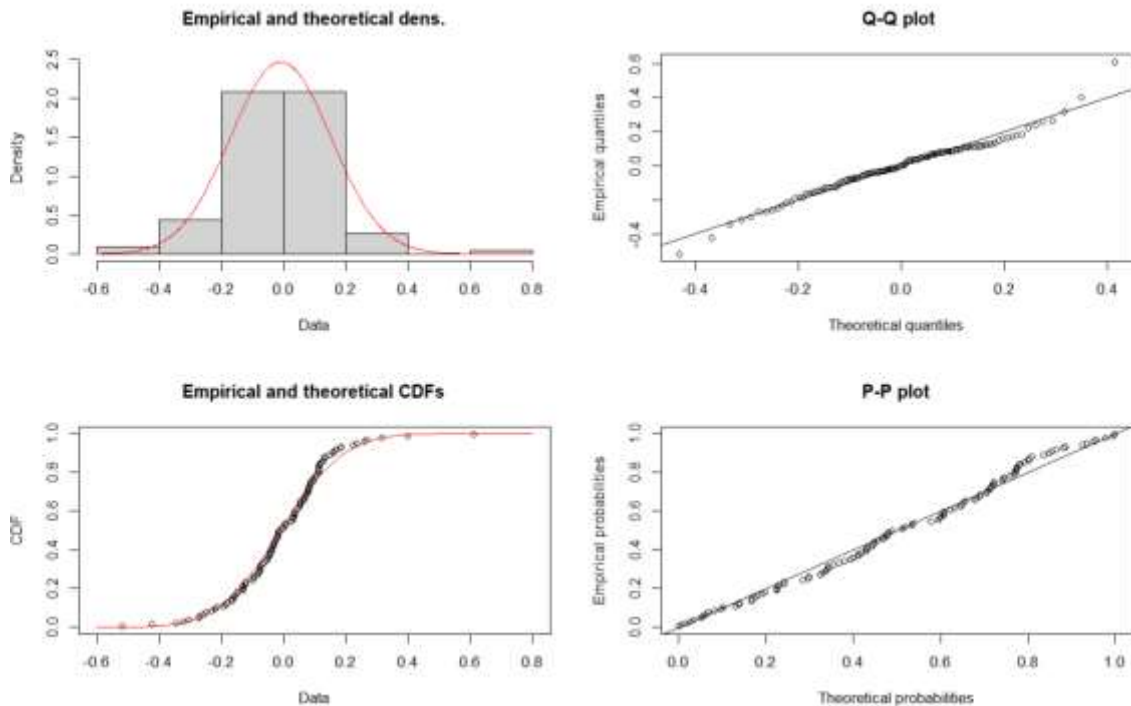


Jarque Bera Test

```
data: resid_m2  
X-squared = 18.485, df = 2, p-value = 9.685e-05
```

En las figuras se observa que los residuales del modelo 2 presentan indicios de ajuste hacia la distribución normal. Pero en la prueba JB, como $p = 0.00000 < 0.05$, se rechaza la H_0 , es decir, los residuos NO se aproximan a una distribución normal.

```
ajuste_m3<-fitdist(data = resid_m3, distr="norm")  
plot(ajuste_m3)  
JB_m3 <- jarque.bera.test(resid_m3)  
JB_m3
```



Jarque Bera Test

```
data: resid_m3  
X-squared = 15.299, df = 2, p-value = 0.0004763
```

En las figuras se observa que los residuales del modelo 3 presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.00047 < 0.05$, se acepta H_0 , es decir, los residuos NO se aproximan a una distribución normal.

4 Pronostico


4.1 Pronosticos de cada modelo

Modelo 1: ARIMA(2,1,0)

```
Pron1 <- forecast(mod1, level=c(95), h=10)
```

```
plot(Pron1)
```

```
summary(Pron1)
```



En la figura se puede observar el comportamiento de la función de predicción por punto y por intervalo.

Los datos proyectados para los siguientes 10 años son:

```
Forecast method: ARIMA(2,1,0) with drift

Model Information:
Series: data_tf
ARIMA(2,1,0) with drift

Coefficients:
      ar1      ar2      drift
    -0.6019  -0.3174   0.0141
s.e.    0.0913   0.0906   0.0085


sigma^2 = 0.0304:  log likelihood = 38
AIC=-68.01  AICC=-67.63  BIC=-57.13

Error measures:
                                ME      RMSE      MAE      MPE      MAPE
MASE                                0.1712412  0.1233828  -0.01076704  1.78273  0.88
Training set 0.0007838851
24134 -0.06437716

Forecasts:
Point Forecast      Lo 95      Hi 95
1985      7.503311  7.161581  7.845040
1986      7.492552  7.124738  7.860366
1987      7.450404  7.052655  7.848153
1988      7.506286  7.057696  7.954876
1989      7.513126  7.033818  7.992435
1990      7.518371  7.008363  8.028380
1991      7.540142  6.998211  8.082072
1992      7.552472  6.982641  8.122303
1993      7.565239  6.968384  8.162094
1994      7.580740  6.957633  8.203846
```


Es importante mencionar que, los valores pronosticados son logaritmos, por tanto, para obtener los verdaderos valores de pronóstico, se tendrán que transformar aplicando la función exp().

```
data_modelo1 <- exp(mod1$fitted)
grafico_comparativo <- cbind(data_ts,data_modelo1)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt", "yest"),lty = c(1,1), lwd = 2,col=c("black",
"red"))
```



PRONÓSTICO DE LA SERIE ORIGINAL

```
Pron1$mean <- exp(Pron1$mean)
Pron1$lower <- exp(Pron1$lower)
Pron1$upper <- exp(Pron1$upper)
Pron1$x <- exp(Pron1$x)
Pron1$fitted <- exp(Pron1$fitted)
Pron1$residuals <- exp(Pron1$residuals)
summary(Pron1)
```

Forecast method: ARIMA(2,1,0) with drift

Model Information:
Series: data_tf
ARIMA(2,1,0) with drift

Coefficients:
 ar1 ar2 drift
 -0.6019 -0.3174 0.0141
s.e. 0.0913 0.0906 0.0085

sigma^2 = 0.0304: log likelihood = 38
AIC=-68.01 AICC=-67.63 BIC=-57.13

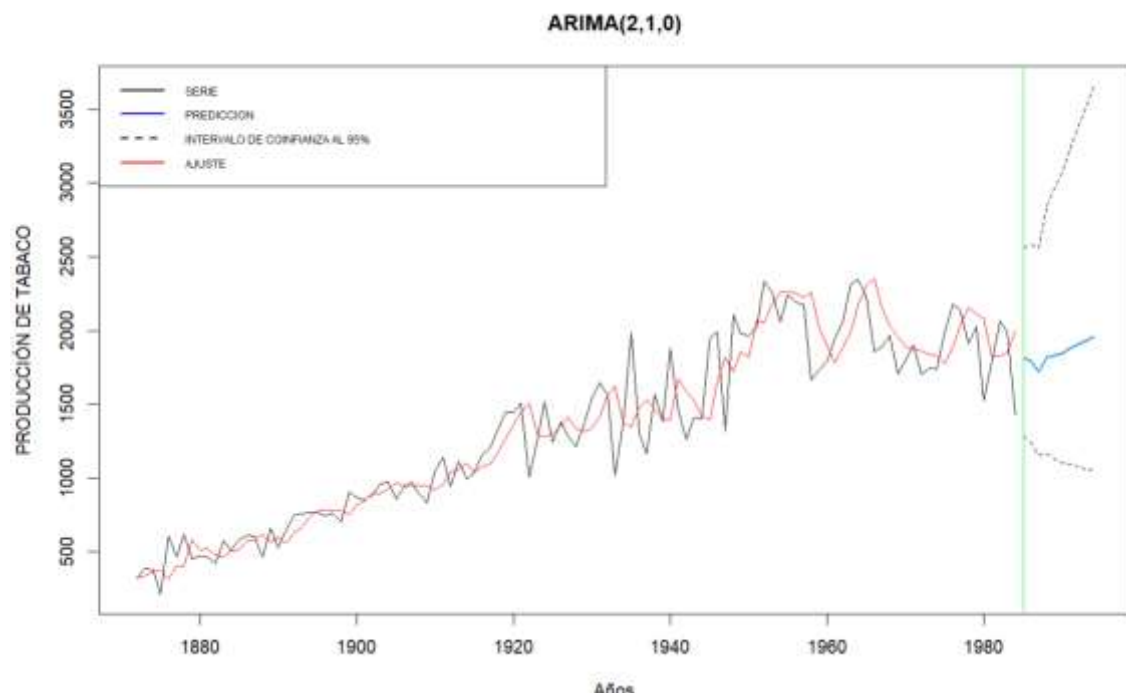
Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-4.832891	216.5697	153.8088	-1.405363	12.55187	0.9204205
	0.0930709					

Forecasts:			
Point	Forecast	Lo 95	Hi 95
1985	1814.038	1288.948	2553.040
1986	1794.625	1242.322	2592.468
1987	1720.558	1155.923	2561.001
1988	1819.443	1161.765	2849.434
1989	1831.932	1134.353	2958.491
1990	1841.566	1105.843	3066.768
1991	1882.097	1094.673	3235.933
1992	1905.447	1077.761	3368.770
1993	1929.931	1062.505	3505.521
1994	1960.078	1051.143	3654.981

GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```
plot(Pron1, shaded = FALSE, xlab = "Años", ylab = "PRODUCCIÓN DE  
TABACO", main = "ARIMA(2,1,0)")  
lines(Pron1$fitted, col = "red")  
legend("topleft", legend=c("SERIE", "PREDICCIÓN", "INTERVALO DE  
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),  
lty=c(1,1,2,1), lwd = 2, cex = 0.6)  
abline(v=1985, lwd = 1, col="green")
```




Modelo 2: ARIMA(0,1,1)

```
Pron2 <- forecast(mod2, level=c(95), h=10)
```

```
plot(Pron2)
```

```
summary(Pron2)
```



Forecast method: ARIMA(0,1,1) with drift

Model Information:

Series: data_tf

ARIMA(0,1,1) with drift

Coefficients:

	ma1	drift
	-0.7242	0.0144
s.e.	0.0614	0.0044

sigma^2 = 0.02772: log likelihood = 42.52

AIC=-79.04 AICC=-78.82 BIC=-70.88

Error measures:

	SE	ACF1	ME	RMSE	MAE	MPE	MAPE	MA
Training set	0.002141719	0.1642564	0.1229315	0.024795	1.767541	0.87918		
64	-0.004931528							


Forecasts:

	Point	Forecast	Lo 95	Hi 95
1985	7.530439	7.204142	7.856736	
1986	7.544885	7.206405	7.883365	
1987	7.559331	7.209092	7.909570	
1988	7.573777	7.212161	7.935392	
1989	7.588222	7.215577	7.960868	
1990	7.602668	7.219310	7.986026	
1991	7.617114	7.223335	8.010893	
1992	7.631560	7.227628	8.035492	
1993	7.646006	7.232171	8.059841	
1994	7.660452	7.236945	8.083959	

PRONÓSTICO DE LA SERIE ORIGINAL Y VALORES ESPERADOS

Como en el anterior modelo para obtener los verdaderos valores de pronóstico, se tendrán que transformar aplicando la función exp().

```
data_modelo2 <- exp(mod2$fitted)
grafico_comparativo <- cbind(data_ts,data_modelo2)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt","yest"),lty = c(1,1), lwd = 2,col=c("black",
"red"))
```



```
Pron2$mean <- exp(Pron2$mean)
Pron2$lower <- exp(Pron2$lower)
Pron2$upper <- exp(Pron2$upper)
Pron2$x <- exp(Pron2$x)
Pron2$fitted <- exp(Pron2$fitted)
Pron2$residuals <- exp(Pron2$residuals)
summary(Pron2)
```

```
Model Information:
Series: data_tf
ARIMA(0,1,1) with drift
```

```
Coefficients:
      ma1      drift
    -0.7242    0.0144
s.e.    0.0614    0.0044
```

```
sigma^2 = 0.02772: log likelihood = 42.52
AIC=-79.04  AICC=-78.82  BIC=-70.88
```


```
Error measures:
```

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-10.17216	212.6267	156.7662	-1.149227	12.4767	0.9381179
	0.1640972					0

```
Forecasts:
Point Forecast    Lo 95    Hi 95
1985      1863.924 1344.990 2583.076
1986      1891.045 1348.037 2652.783
1987      1918.561 1351.664 2723.218
1988      1946.477 1355.819 2794.455
1989      1974.800 1360.458 2866.560
1990      2003.535 1365.547 2939.592
1991      2032.687 1371.054 3013.608
1992      2062.264 1376.953 3088.657
1993      2092.272 1383.222 3164.786
1994      2122.716 1389.841 3242.042
```

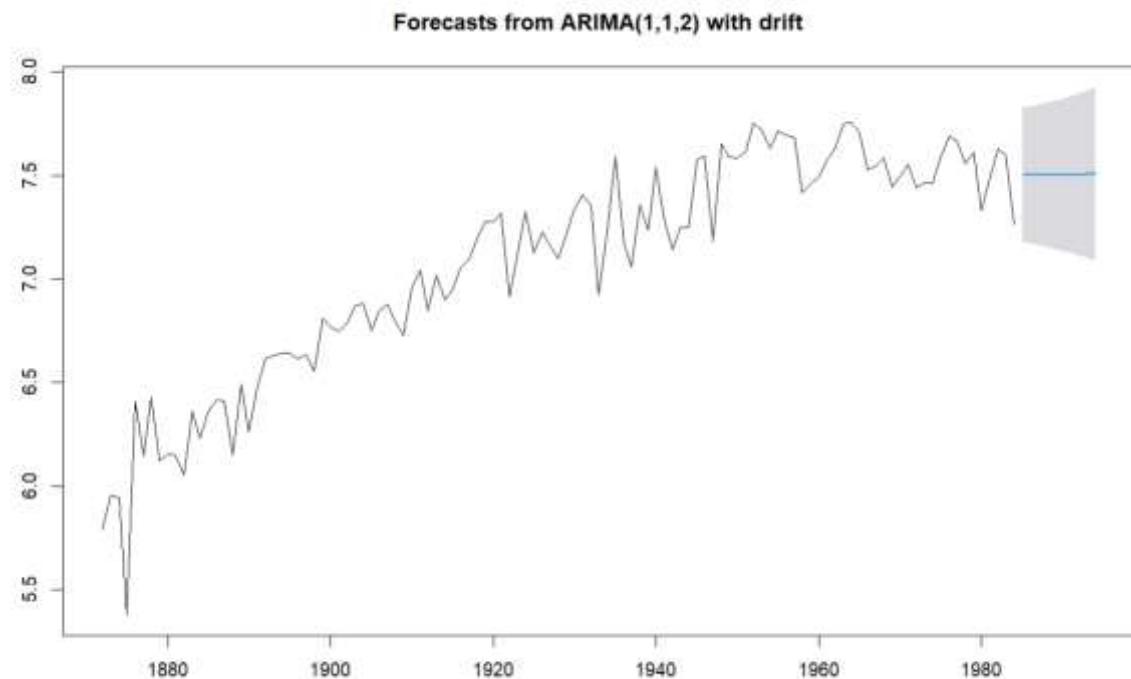
GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```
plot(Pron2, shaded = FALSE, xlab = "Años", ylab = "PRODUCCIÓN DE
TABACO", main = "ARIMA(0,1,1)")
lines(Pron2$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCIÓN", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=2020, lwd = 1, col="green")
```



Modelo 3: ARIMA(1,1,2)

```
Pron3 <- forecast(mod3, level=c(95), h=10)
plot(Pron3)
summary(Pron3)
```



Forecast method: ARIMA(1,1,2) with drift

Model Information:

Series: data_tf

ARIMA(1,1,2) with drift

Coefficients:

	ar1	ma1	ma2	drift
	0.9778	-1.7655	0.7840	0.0142
s.e.	0.0401	0.0743	0.0682	0.0101

sigma² = 0.0274: log likelihood = 43.87

AIC=-77.74 AICC=-77.17 BIC=-64.14

Error measures:

	ME	RMSE	MAE	MPE	MAPE
MASE					
ACF1					
Training set	-0.008633598	0.1618205	0.1223072	-0.1396587	1.755203
47209	0.0296646				0.87

Forecasts:


Point	Forecast	Lo 95	Hi 95
1985	7.505582	7.181161	7.830002
1986	7.504563	7.172914	7.836211
1987	7.503883	7.164223	7.843542
1988	7.503534	7.155099	7.851968
1989	7.503509	7.145560	7.861457
1990	7.503800	7.135629	7.871971
1991	7.504401	7.125332	7.883471
1992	7.505305	7.114697	7.895913
1993	7.506505	7.103756	7.909254
1994	7.507994	7.092538	7.923450

PRONÓSTICO DE SERIE ORIGINAL Y VALORES ESTIMADOS

Como en el anterior modelo para obtener los verdaderos valores de pronóstico, se tendrán que transformar aplicando la función exp().

Alumno: Maye Mamani Victor Raul

```
data_modelo3 <- exp(mod3$fitted)
grafico_comparativo <- cbind(data_ts,data_modelo3)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt", "yest"),lty = c(1,1), lwd = 2,col=c("black",
"red"))
```



```
Pron3$mean <- exp(Pron3$mean)
Pron3$lower <- exp(Pron3$lower)
Pron3$upper <- exp(Pron3$upper)
Pron3$x <- exp(Pron3$x)
Pron3$fitted <- exp(Pron3$fitted)
Pron3$residuals <- exp(Pron3$residuals)
summary(Pron3)
```

Forecast method: ARIMA(1,1,2) with drift

Model Information:

Series: data_tf

ARIMA(1,1,2) with drift

Coefficients:

	ar1	ma1	ma2	drift
	0.9778	-1.7655	0.7840	0.0142
s.e.	0.0401	0.0743	0.0682	0.0101

sigma^2 = 0.0274: log likelihood = 43.87

AIC=-77.74 AICC=-77.17 BIC=-64.14

Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-16.43305	213.2257	158.9872	-2.192223	12.49731	0.9514089
	0.2194535					


Forecasts:

	Point Forecast	Lo 95	Hi 95
1985	1818.162	1314.433	2514.936

1986	1816.311	1303.638	2530.599
1987	1815.076	1292.357	2549.218
1988	1814.443	1280.620	2570.789
1989	1814.397	1268.462	2595.298
1990	1814.926	1255.927	2622.730
1991	1816.017	1243.060	2653.064
1992	1817.659	1229.911	2686.280
1993	1819.842	1216.527	2722.358
1994	1822.554	1202.957	2761.280

GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

```
plot(Pron3, shaded = FALSE, xlab = "Años", ylab = "PRODUCCIÓN DE
TABACO", main = "ARIMA(1,1,1)")
lines(Pron3$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCIÓN", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=2020, lwd = 1, col="green")
```



Métricas basadas en el error

accuracy(Pron1)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-4.832891	216.5697	153.8088	-1.405363	12.55187	0.9204205
0.0930709						

accuracy(Pron2)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-10.17216	212.6267	156.7662	-1.149227	12.4767	0.9381179
0.1640972						

accuracy(Pron3)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-16.43305	213.2257	158.9872	-2.192223	12.49731	0.9514089
0.2194535						

Basado en las métricas MAE y RMSE, el modelo ARIMA(0,1,1) es el mejor entre los tres, ya que tiene los mejores valores (MAE = 156.76 Y RMSE=212.62). Esto indica que sus predicciones son más precisas y con menos variabilidad en los errores grandes.

Conclusión

Se evaluaron tres modelos ARIMA para el conjunto de datos:

1. ARIMA(2,1,0)

- Los coeficientes estimados son significativos para ar1, ar2 y drift.
- Los residuos parecen seguir un comportamiento de ruido blanco según las pruebas de autocorrelación y heterocedasticidad.
- Sin embargo, el p-valor del estadístico BP sugiere que los residuos no son constantes.

2. ARIMA(0,1,1)

- El coeficiente ma1 es significativo.
- Los residuos también muestran comportamiento de ruido blanco según las pruebas realizadas.
- El p-valor del estadístico BP indica que los residuos no son constantes.


3. ARIMA(1,1,2)

- Los coeficientes ar1, ma1 y ma2 son significativos.
- Los residuos muestran comportamiento de ruido blanco, confirmado por las pruebas de autocorrelación y heterocedasticidad.
- El p-valor del estadístico BP indica que los residuos no son constantes.

El modelo seleccionado es ARIMA(1,1,2). Aunque todos los modelos mostraron buenos indicadores de ajuste y comportamiento de los residuos como ruido blanco, ARIMA(1,1,2) presenta coeficientes significativos tanto en los términos autorregresivos como en los de medias móviles. Además, sus métricas de precisión (RMSE, MAE) son comparables con los otros modelos evaluados. Este modelo proporciona un equilibrio adecuado entre complejidad y ajuste, capturando mejor las características de la serie temporal analizada.

CASO 2: PRODUCCION DE PAPA

```
data <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-06.xlsx",sheet = "02")
View(data)
# Gráfica de la serie
data_ts <- ts(data$Producción, start = c(1961,1), frequency = 1)
plot(data_ts, xlab="Años", ylab="Produccion de papa")
```



En primera instancia podemos visualizar una clara TENDENCIA creciente, la varianza no parece variar mucho, y no es estacionaria en media. Y al ser una serie anual NO haremos un análisis de estacionalidad

1 Identificación

1. 1 Análisis de la tendencia y la estacionalidad

1.1.1 Estacionalidad

Debido a que se trata de un gráfico con un período anual, no se observa estacionalidad.

1.1.2 Análisis de tendencia


#Análisis de tendencia

```
lambda_hp <- 1600
```

```
data_hp <- hpfilter(data_ts, type="lambda", freq=lambda_hp)
```

```
plot(data_hp)
```

Alumno: Maye Mamani Victor Raul



Hay una tendencia creciente y no parece haber algún patrón que se repita cíclicamente


1.2 Análisis de estacionariedad

1.2.1 Estacionariedad en varianza

#Estacionariedad en varianza

```
Grupo <- rep(1:7, each = 8)
```

```
boxplot(data$interes ~ Grupo, xlab = "Grupo", ylab="Yt")
```



Se aprecia que la varianza no es constante, por lo que afirmamos que la serie no es estacionaria en varianza.

Transformación de la serie para que sea estacionaria

```
par(mfrow = c(2,3))
```

```
#lambda = 1 <- yt
```

```
qqnorm(data_ts, main="lambda = 1")
```

```
qqline(data_ts)
```

```
#lambda =2 <- yt^2
```

Alumno: Maye Mamani Victor Raul

```
t1.yt <- data_ts^2
qqnorm(t1.yt, main="lambda = 2")
qqline(t1.yt)

#lambda = 0.5 <- aiz(YT)
t3.yt <- sqrt(data_ts)
qqnorm(t3.yt, main="lambda = 0.5")
qqline(t3.yt)

#lambda = 0 <- log(Yt)

t4.yt <- log(data_ts)
qqnorm(t4.yt, main="lambda = 0")
qqline(t4.yt)

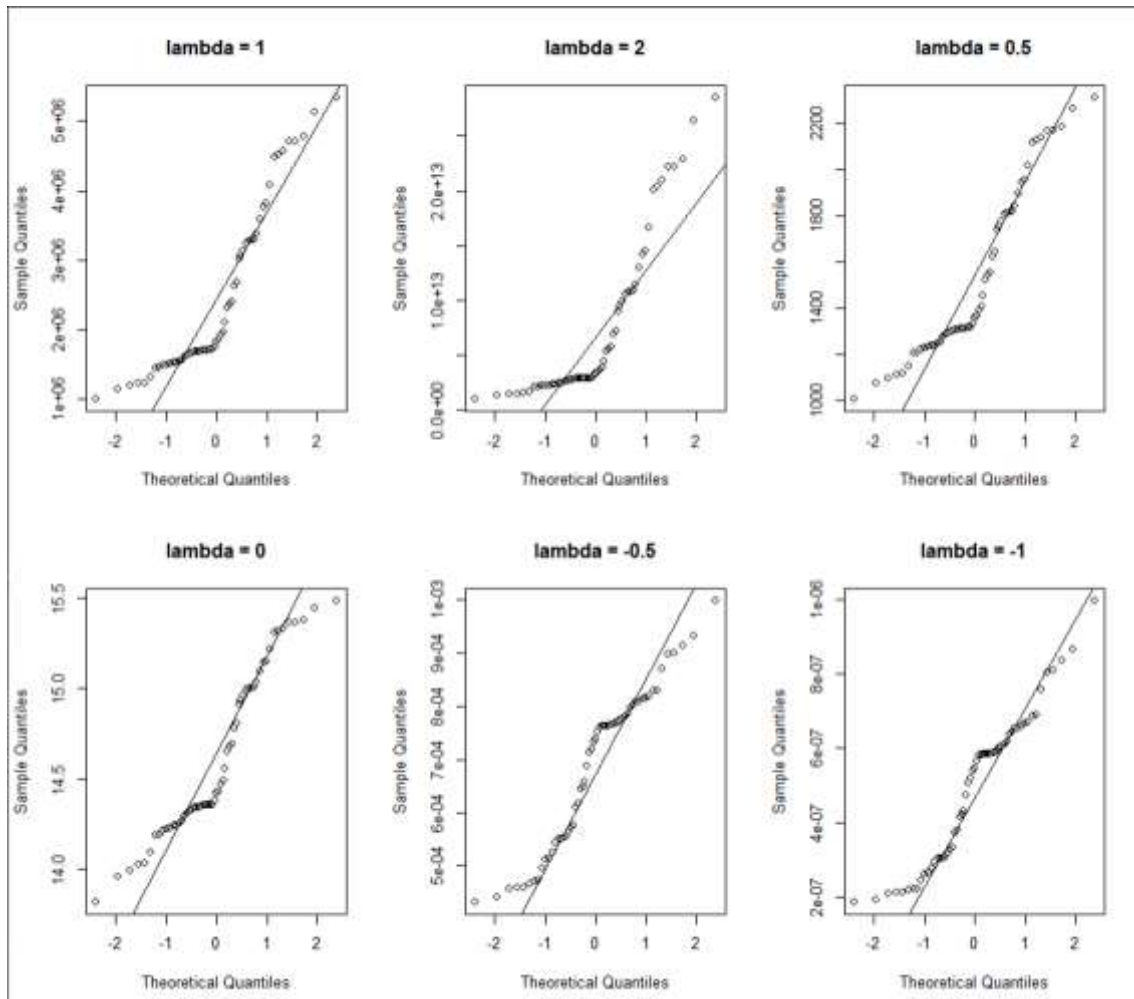
t5.yt <- 1/sqrt(data_ts)
qqnorm(t5.yt, main="lambda = -0.5")
qqline(t5.yt)

#lambda = -1 <- 1/Yt

t6.yt <- 1/data_ts
qqnorm(t6.yt, main="lambda = -1")
qqline(t6.yt)


#lambda = -2 <- 1/(Yt^2)
t7.yt <- 1/(data_ts^2)
qqnorm(t7.yt, main="lambda = -2")
qqline(t7.yt)

b <- BoxCox.ar(data_ts)
lambda <- b$mle
round(lambda,1)
[1] -0.1
```



Elegimos lambda 0

```
data_tf <- log(data_ts)
boxplot(data_mod ~ Grupo, xlab = "Grupo", ylab="log(Yt)")
plot(data_tf)
```






Vemos que hay una leve mejora al transformar la serie, por lo que tomamos la decisión de transformar la serie.

1.2.2 Estacionariedad en media

```
par(mfrow = c(1,2))  
FAS <- acf(data_tf, lag.max = 15, main="FAS - Yt")  
FAP <- pacf(data_tf, lag.max = 15, main="FAP - Yt")  
FAP$acf[1]
```



El FAS decrece lentamente y el primer FAP es significativo siendo 0.917, por lo que podríamos decir que la serie NO ES ESTACIONARIA

Alumno: Maye Mamani Victor Raul

Verificación con la prueba de Raíz unitaria de Dickey-Fuller Aumentada.

```
data_adf <- ur.df(data_ts, type="trend", lags = 1)
summary(data_adf)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression trend

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + tt + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-0.48953 -0.03199  0.01448  0.05906  0.24742

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  2.009477    1.163248   1.727   0.0899 .
z.lag.1      -0.143329    0.083471  -1.717   0.0918 .
tt           0.003831    0.002161   1.773   0.0820 .
z.diff.lag   -0.192866    0.135898  -1.419   0.1617
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1369 on 53 degrees of freedom
Multiple R-squared:  0.1234, Adjusted R-squared:  0.07373
F-statistic: 2.486 on 3 and 53 DF, p-value: 0.07056


Value of test-statistic is: -1.7171 2.1159 1.6428

Critical values for test statistics:
      1pct   5pct  10pct
tau3 -4.04 -3.45 -3.15
phi2  6.50  4.88  4.16
phi3  8.73  6.49  5.47
```

Observamos que el T calculado (-1.7121) es MAYOR que el T crítico (-3.45) por tanto se acepta la hipótesis nula de la existencia de raíz unitaria, es decir que la serie NO ES ESTACIONARIA

Diferenciamos debido a que la serie no es estacionaria

```
data_diff = diff(data_tf)
plot(data_diff, xlab="Años", ylab="Produccion de papa")
abline(h = mean(data_diff), col = "red")
```



Y volvemos a aplicar el test de Dickey Fuller

```
data_adf <- ur.df(data_diff, type="drift", lags = 1)
summary(data_adf)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####

Test regression drift

Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)

Residuals:
    Min       1Q   Median       3Q      Max
-0.47435 -0.04849  0.00947  0.06474  0.30152

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.033224   0.019578   1.697   0.0956 .
z.lag.1      -1.256728   0.218038  -5.764 4.29e-07 ***
z.diff.lag   -0.006175   0.137193  -0.045  0.9643
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 0.1408 on 53 degrees of freedom
Multiple R-squared:  0.6329, Adjusted R-squared:  0.6191
F-statistic: 45.69 on 2 and 53 DF, p-value: 2.926e-12


Value of test-statistic is: -5.7638 16.617

Critical values for test statistics:
      1pct   5pct  10pct
tau2 -3.51 -2.89 -2.58
phi1  6.70  4.71  3.86
```


Ahora vemos que el T calculado (-5.7638) es MENOR que el T crítico (-2.89) por tanto se RECHAZA la hipótesis nula de la existencia de raíz unitaria, es decir que la serie ES ESTACIONARIA

1.3 Identificación del modelo estacionario

1.3.1 Identificación de las órdenes p y q



Observando el FAS vemos que decrece rápidamente y solo tiene un coeficiente ligeramente significativo por lo que proponemos un MA(1). Y el FAP decrece rápidamente a cero con el primer coeficiente diferente de cero por lo que también planteamos un AR(1) aunque no esta muy claro. Adicionalmente planteamos un ARMA(1,1).

1.3.2 Inclusión del término independiente (δ) o intercepto

#incluir el intercepto

```
Z <- mean(data_diff)
```

```
Co <- var(data_diff)
```

```
Tn <- length(data_diff)
```

```
Ta <- Tn - 1
```

```
Sigma <- Co/Ta
```

```
t <- Z/Sigma
```

```
tt <- qt(1-0.05/2,Ta-1)
```

```
pruebaT <- c(t, tt)
```

```
names(pruebaT) <- c("t-calculado", "t-critico")
```

```
pruebaT
```

t-calculado	t-critico
71.848700	2.003241

Al tener un T calculado (71.8487) MAYOR al T crítico (2.003241) se acepta la hipótesis alterna por lo que incluimos la constante en el modelo

2 Estimación

Modelo ARIMA(1,1,0)

```
mod1 <- Arima(data_ts, order = c(1, 1, 0), include.constant = T)
coeftest(mod1)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
ar1	-0.258410	0.125577	-2.0578	0.03961	*
drift	0.025171	0.014133	1.7809	0.07492	.

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'	0.1 ' ' 1

Con los parámetros estimados del modelo tenemos lo siguiente

$$\Delta Z_t = 0.02517 - 0.2584\Delta Z_{t-1} + a_t$$

Modelo ARIMA(0,1,1)

```
mod2 <- Arima(data_tf, order = c(0, 1, 1), include.constant = T)
coeftest(mod2)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
ma1	-0.249715	0.125657	-1.9873	0.04689	*
drift	0.025133	0.013402	1.8753	0.06075	.

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'	0.1 ' ' 1

Con los parámetros estimados del modelo tenemos lo siguiente

$$\Delta Z_t = 0.02513 + a_t - 0.2497a_{t-1}$$

Modelo ARIMA (1,1,1)

```
mod3 <- Arima(data_ts, order = c(1, 1, 1), include.constant = T)
coeftest(mod3)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
ar1	-0.276737	0.446566	-0.6197	0.53545	
ma1	0.019661	0.463039	0.0425	0.96613	
drift	0.025163	0.014202	1.7717	0.07644	.

Signif. codes:	0 '***'	0.001 '**'	0.01 '*'	0.05 '.'	0.1 ' ' 1

Con los parámetros estimados del modelo tenemos lo siguiente

$$\Delta Z_t = 70260 - 0.2767\Delta Z_{t-1} + a_t + 0.0196a_{t-1}$$

3 Validación

3.1 Análisis de los coeficientes estimados

3.1.1 Significación de los coeficientes

Para el modelo ARIMA(1,1,0)

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z)	
ar1	-0.258410	0.125577	-2.0578	0.03961	*
drift	0.025171	0.014133	1.7809	0.07492	.

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

AR(1): $\phi_1 = -0.2584 \rightarrow p = 0.0396 < 0.05$, es significativo

Para el modelo ARIMA (0,1,1)

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ma1  -0.249715   0.125657 -1.9873  0.04689 *
drift  0.025133   0.013402  1.8753  0.06075 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

MA(1): $\theta_1 = -0.2497 \rightarrow p = 0.0468 < 0.05$, es significativo

Para el modelo ARIMA(1,1,1)

test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
ar1  -0.276737   0.446566 -0.6197  0.53545
ma1   0.019661   0.463039  0.0425  0.96613
drift  0.025163   0.014202  1.7717  0.07644 .
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

AR(1): $\phi_1 = -0.2767 \rightarrow p = 0.5354 > 0.05$, NO es significativo

MA(1): $\theta_1 = -0.0196 \rightarrow p = 0.9661 > 0.05$, NO es significativo

3.1.2 Examen de la matriz de correlaciones entre los coeficientes

vcov(mod1)

```
      ar1      drift
ar1  1.576965e-02 -3.699575e-06
drift -3.699575e-06  1.997519e-04
```

vcov(mod2)

```
      ma1      drift
ma1  1.578965e-02  4.544012e-06
drift 4.544012e-06  1.796084e-04
```


vcov(mod3)

```
      ar1      ma1      drift
ar1  1.994215e-01 -1.985281e-01  2.399729e-05
ma1  -1.985281e-01  2.144049e-01 -2.993031e-05
drift 2.399729e-05 -2.993031e-05  2.017064e-04
```

Se observa claramente que NO hay coeficientes que esten cerca o sean superiores a 0.9, por tanto, podemos indicar que NO hay problema de multicolinealidad en los modelos propuestos.


3.1.3 Condición de convergencia e invertibilidad

autoplot(mod1)




En la figura de raíces inversas de AR, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de estacionariedad para la parte autorregresiva.

autoplot(mod2)



En la figura de raíces inversas de MA, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de invertibilidad para la parte de media móvil.

autoplot(mod3)



Al estar los valores dentro de la circunferencia unitaria es un indicativo de que el modelo se ajusta correctamente. Tanto en su parte AR, como en su parte MA.

3.1.4 Análisis de la estabilidad

```
Chow_mod1 <- Fstats(mod1$fitted ~ 1, from = 0.67)
sctest(Chow_mod1)
supF test

data: Chow_mod1
sup.F = 88.171, p-value < 2.2e-16
```

```
Chow_mod2 <- Fstats(mod2$fitted ~ 1, from = 0.67)
sctest(Chow_mod2)
supF test

data: Chow_mod2
sup.F = 87.373, p-value < 2.2e-16
```

```
Chow_mod3 <- Fstats(mod3$fitted ~ 1, from = 0.67)
sctest(Chow_mod3)
supF test


data: Chow_mod3
sup.F = 88.253, p-value < 2.2e-16
```

En las tres pruebas se rechaza la hipótesis nula ($p < \alpha = 0.05$), es decir, NO existe estabilidad de coeficientes.

3.2 Análisis de los residuos

3.2.1 Media es igual a cero

```
plot(mod1$residuals)
abline(h = 0, col = "red")
t.test(mod1$residuals, mu = 0)
```




```
One Sample t-test
data: mod1$residuals
```

Alumno: Maye Mamani Victor Raul

```
t = 0.0060581, df = 58, p-value = 0.9952
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.03506863  0.03528154
sample estimates:
mean of x
0.0001064562
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.9952 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

```
plot(mod2$residuals)
abline(h = 0, col = "red")
t.test(mod2$residuals, mu = 0)
```




One Sample t-test

```
data: mod2$residuals
t = 0.00428, df = 58, p-value = 0.9966
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.03517293  0.03532366
sample estimates:
mean of x
7.536586e-05
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.9966 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

```
plot(mod3$residuals)
```

```
abline(h = 0, col = "red")  
t.test(mod3$residuals, mu = 0)
```




One Sample t-test

```
data: mod3$residuals  
t = 0.0068992, df = 58, p-value = 0.9945  
alternative hypothesis: true mean is not equal to 0  
95 percent confidence interval:  
-0.03505327 0.03529574  
sample estimates:  
mean of x  
0.0001212334
```

Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como $p = 0.9931 > \alpha = 0.05$, se acepta H_0 , es decir la media es igual a cero.

3.2.2 Homocedasticidad o varianza constante

```
par(mfrow = c(3,1))  
scatter.smooth(sqrt(abs(mod1$residuals)), lpars=list(col=2), main =  
"Modelo 1")  
scatter.smooth(sqrt(abs(mod2$residuals)), lpars=list(col=2), main =  
"Modelo 2")  
scatter.smooth(sqrt(abs(mod3$residuals)), lpars=list(col=2), main =  
"Modelo 3")
```



Se observa que los datos parecen no presentar una variabilidad considerable, por tanto, será necesario realizar la prueba de Breusch-Pagan para determinar finalmente si las varianzas constantes para los modelos.

Prueba de Breusch – Pagan

```
obs=get(mod1$series)
bptest(resid(mod1)~I(obs-resid(mod1)))
```

studentized Breusch-Pagan test

```
data: resid(mod1) ~ I(obs - resid(mod1))
BP = 3.7168, df = 1, p-value = 0.05387
```

```
obs=get(mod2$series)
bptest(resid(mod2)~I(obs-resid(mod2)))
```

studentized Breusch-Pagan test

```
data: resid(mod2) ~ I(obs - resid(mod2))
BP = 4.0436, df = 1, p-value = 0.04434
```

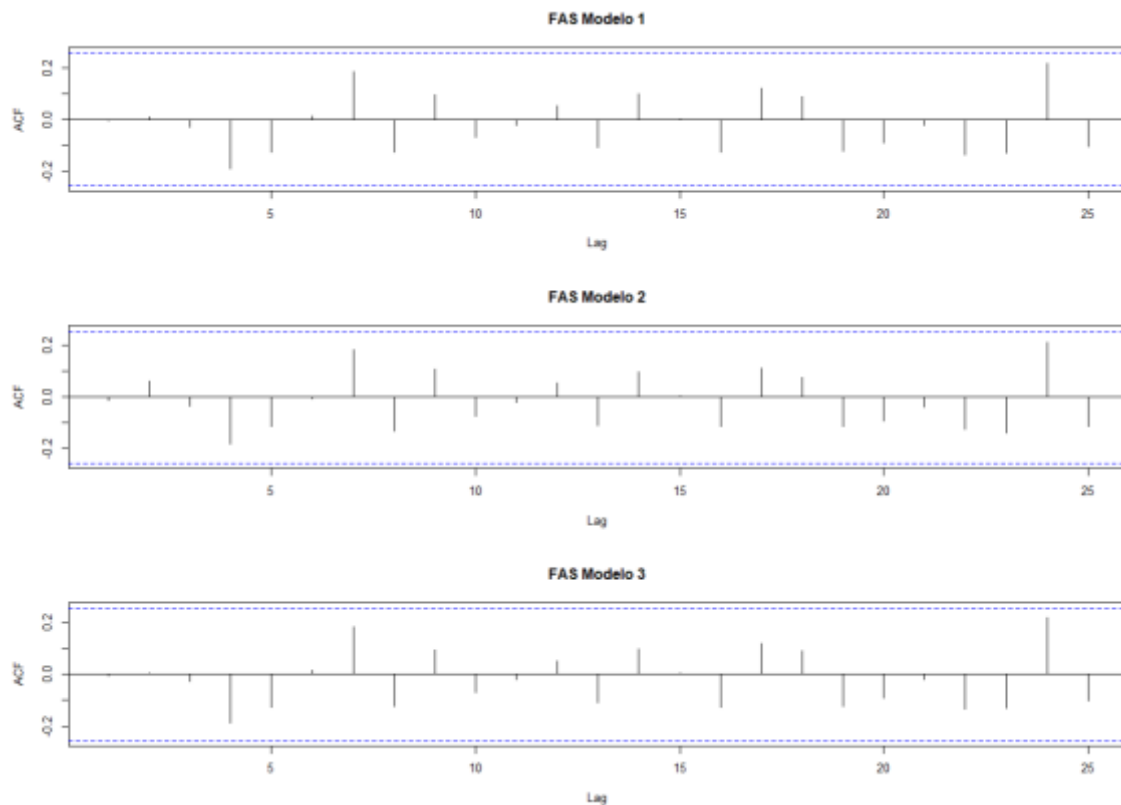
```
obs=get(mod3$series)
bptest(resid(mod3)~I(obs-resid(mod3)))
```

studentized Breusch-Pagan test

```
data: resid(mod3) ~ I(obs - resid(mod3))
BP = 3.6964, df = 1, p-value = 0.05453
```


El valor de probabilidad (p-valor) asociado al estadístico BP asume los valores de probabilidad de 0.0538, 0.04434 y 0.0545 para los modelos 1,2 y 3 respectivamente, que son menores a $\alpha=0.05$, por lo cual podemos afirmar que los residuales de estos modelos NO son constantes.

3.2.3 Ausencia de correlación serial



Se observa que casi la totalidad de los coeficientes del FAS para los modelos 1 , 2 y 3 se encuentran dentro de las bandas de no significación, sobre todo los de los primeros retardos.

Por tanto, tenemos altos indicios de que los residuos de los 3 modelos sean ruido blanco.

```
Box.test(resid_m1,type = "Ljung-Box")
Box-Ljung test

data: resid_m1
X-squared = 0.00054983, df = 1, p-value = 0.9813
```

```
Box.test(resid_m2,type = "Ljung-Box")
Box-Ljung test

data: resid_m2
X-squared = 0.013791, df = 1, p-value = 0.9065
```

```
Box.test(resid_m3,type = "Ljung-Box")
```

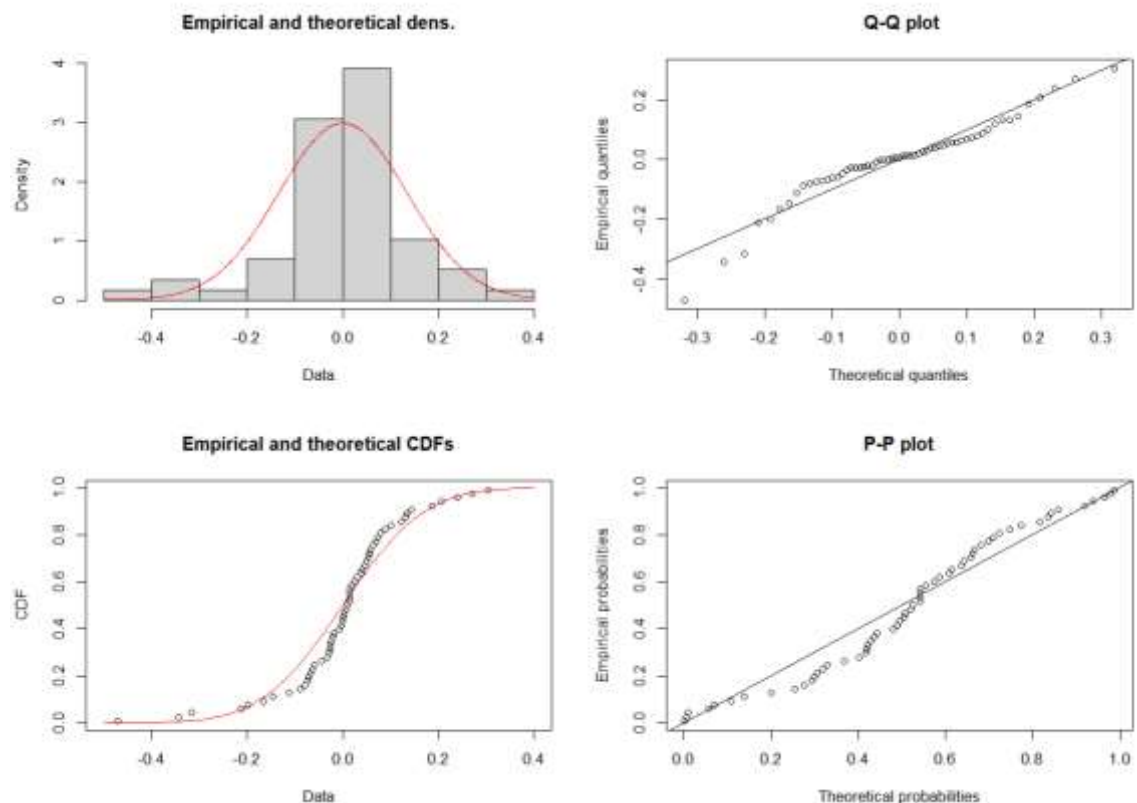
```
Box-Ljung test
```

```
data: resid_m3  
X-squared = 0.0011834, df = 1, p-value = 0.9726
```

Con los valores 0.9813, 0.9065 y 0.9065 son mayores a $\alpha=0.05$, por lo que se acepta la hipótesis nula de que los coeficientes de autocorrelación son cero; es decir, los residuos son independientes o están incorrelacionados.

3.2.4 Contraste de normalidad

```
ajuste_m1<-fitdist(data = resid_m1, distr="norm")  
plot(ajuste_m1)  
JB_m1 <- jarque.bera.test(resid_m1)  
JB_m1
```



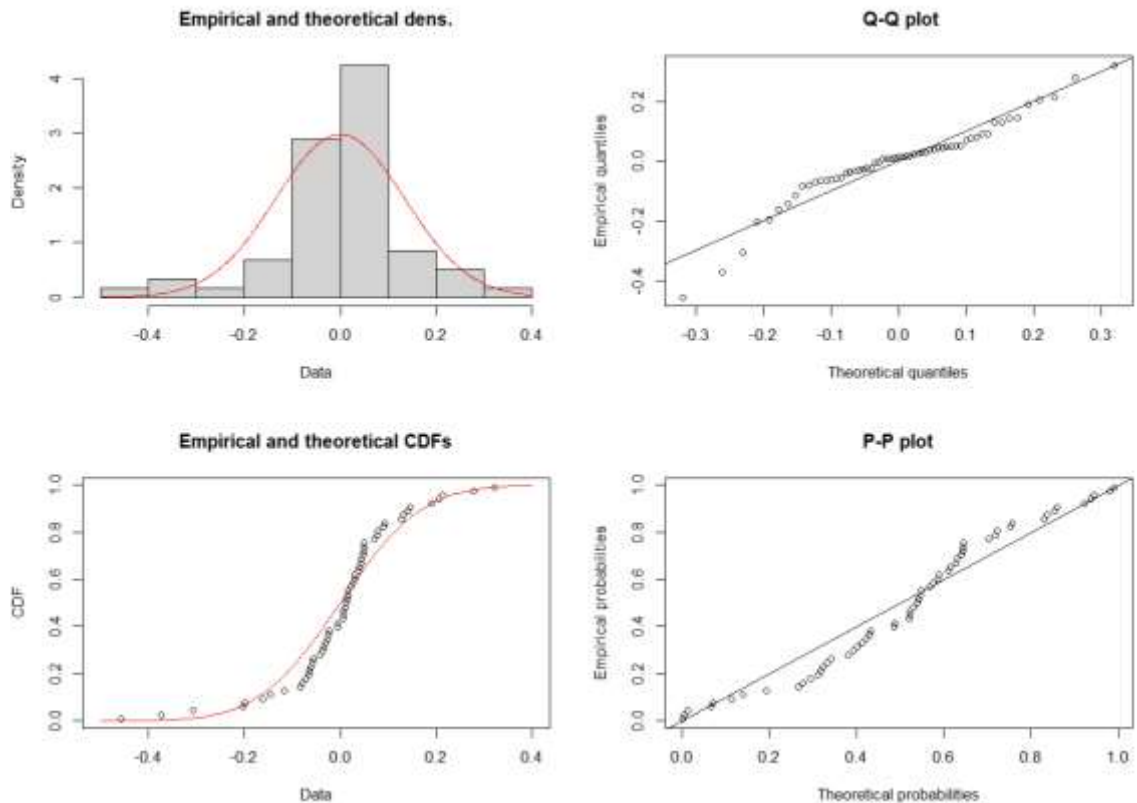
Jarque Bera Test

```
data: resid_m1  
X-squared = 19.141, df = 2, p-value = 6.976e-05
```

En las figuras se observa que los residuales del modelo 1 no presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.0000 < 0.05$, se RECHAZA H_0 , es decir, los residuos NO se aproximan a una distribución normal.

```
ajuste_m2<-fitdist(data = resid_m2, distr="norm")  
plot(ajuste_m2)  
JB_m2 <- jarque.bera.test(resid_m2)  
JB_m2
```

Alumno: Maye Mamani Victor Raul

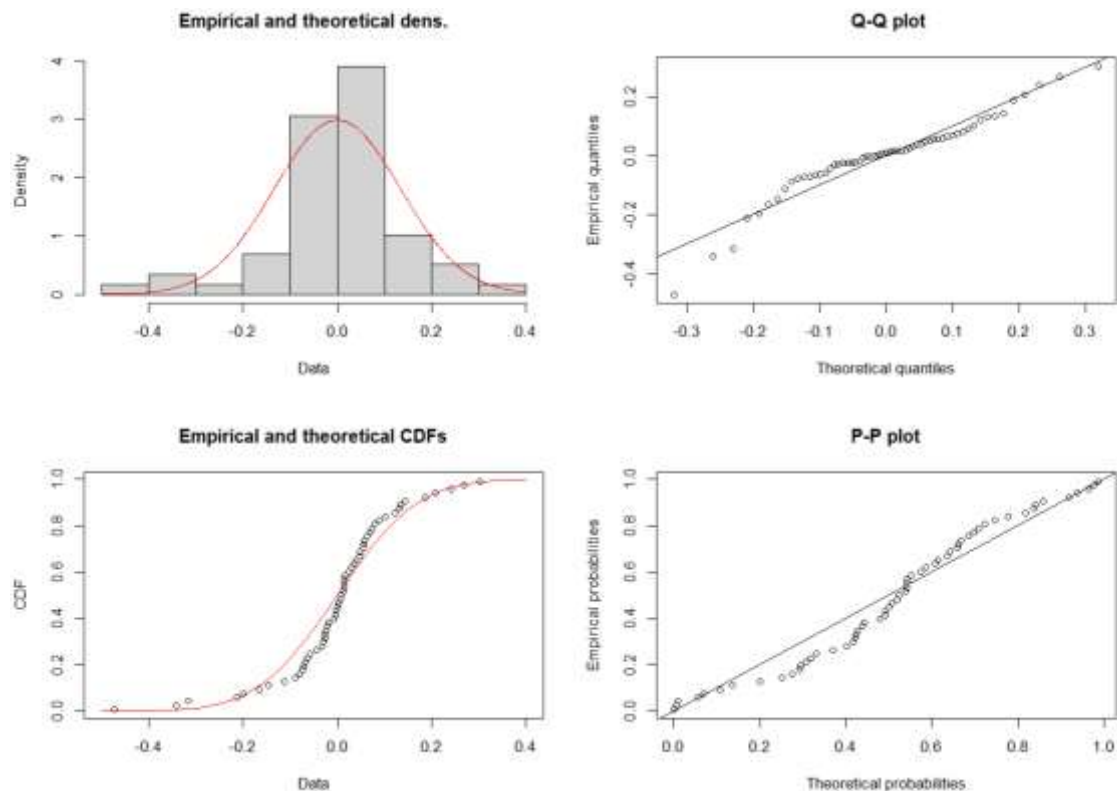


Jarque Bera Test

data: resid_m2
X-squared = 18.168, df = 2, p-value = 0.0001135

En las figuras se observa que los residuales del modelo 2 no presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.00011 < 0.05$, se RECHAZA H_0 , es decir, los residuos NO se aproximan a una distribución normal.

```
ajuste_m3<-fitdist(data = resid_m3, distr="norm")  
plot(ajuste_m3)  
JB_m3 <- jarque.bera.test(resid_m3)  
JB_m3
```



Jarque Bera Test

```
data: resid_m3  
X-squared = 19.16, df = 2, p-value = 6.909e-05
```


En las figuras se observa que los residuales del modelo 3 no presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como $p = 0.00000 < 0.05$, se RECHAZA H_0 , es decir, los residuos NO se aproximan a una distribución normal.

4 Pronostico

4.1 Pronosticos de cada modelo

Modelo 1: ARIMA (1,1,0)

```
Pron1 <- forecast(mod1, level=c(95), h=10)  
plot(Pron1)  
summary(Pron1)
```



En la figura se puede observar el comportamiento de la función de predicción por punto y por intervalo.

Los datos proyectados para los siguientes 10 años son:

```
Forecast method: ARIMA(1,1,0) with drift

Model Information:
Series: data_tf
ARIMA(1,1,0) with drift

Coefficients:
      ar1      drift
      -0.2584  0.0252
s.e.    0.1256  0.0141


sigma^2 = 0.01887: log likelihood = 33.83
AIC=-61.65  AICC=-61.21  BIC=-55.47

Error measures:
MASE      ACF1      ME      RMSE      MAE      MPE      MAPE
Training set 0.0001064562 0.1338278 0.09156039 -0.006624538 0.6352687
0.9057662 -0.002976719

Forecasts:
Point Forecast  Lo 95  Hi 95
2020      15.51088 15.24165 15.78011
2021      15.53692 15.20173 15.87210
2022      15.56186 15.16222 15.96151
2023      15.58709 15.13423 16.03995
2024      15.61225 15.11129 16.11321
2025      15.63742 15.09271 16.18213
2026      15.66259 15.07737 16.24781
2027      15.68776 15.06466 16.31086
2028      15.71293 15.05412 16.37174
2029      15.73810 15.04542 16.43078
```

Es importante mencionar que, los valores pronosticados son logaritmos, por tanto, para obtener los verdaderos valores de pronóstico, se tendrán que transformar aplicando la función exp().

```
data_modelo1 <- exp(mod1$fitted)
grafico_comparativo <- cbind(data_ts,data_modelo1)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt", "yest"),lty = c(1,1), lwd = 2,col=c("black",
"red"))
```



PRONÓSTICO DE LA SERIE ORIGINAL

Deshaciendo la transformación:

```
Pron1$mean <- exp(Pron1$mean)
Pron1$lower <- exp(Pron1$lower)
Pron1$upper <- exp(Pron1$upper)
Pron1$x <- exp(Pron1$x)
Pron1$fitted <- exp(Pron1$fitted)
Pron1$residuals <- exp(Pron1$residuals)
summary(Pron1)
```

Forecast method: ARIMA(1,1,0) with drift

Model Information:

Series: data_tf
ARIMA(1,1,0) with drift

Coefficients:

ar1	drift
-0.2584	0.0252

```
s.e.    0.1256  0.0141


sigma^2 = 0.01887:  log likelihood = 33.83
AIC=-61.65  AICC=-61.21  BIC=-55.47

Error measures:
          ME      RMSE      MAE      MPE      MAPE      MASE
ACF1
Training set 14140.15 248384.4 184763.5 -0.9245591 9.410599 0.8924902
0.0205373

Forecasts:
Point Forecast    Lo 95    Hi 95
2020      5448652 4162585 7132061
2021      5592382 3999699 7819274
2022      5733648 3844744 8550562
2023      5880140 3738636 9248303
2024      6029935 3653833 9951224
2025      6183662 3586595 10661273
2026      6341277 3531975 11385075
2027      6502918 3487371 12126024
2028      6668678 3450819 12887161
2029      6838663 3420935 13670916
```

GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES


```
plot(Pron1, shaded = FALSE, xlab = "Años", ylab = "Produccion de
papa", main = "ARIMA(1,1,0)")
lines(Pron1$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=2020, lwd = 1, col="green")
```



Alumno: Maye Mamani Victor Raul


Modelo 2: ARIMA (0,1,1)

```
Pron2 <- forecast(mod2, level=c(95), h=10)
plot(Pron2)
summary(Pron2)
```



PRONÓSTICO DE LA SERIE ORIGINAL

```
yt_arima2 <- exp(mod2$fitted)
grafico_comparativo <- cbind(Yt,yt_arima2)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt","yest"),lty = c(1,1), lwd = 2)
```

```
Pron2$mean <- exp(Pron2$mean)
Pron2$lower <- exp(Pron2$lower)
Pron2$upper <- exp(Pron2$upper)
Pron2$x <- exp(Pron2$x)
Pron2$fitted <- exp(Pron2$fitted)
Pron2$residuals <- exp(Pron2$residuals)
summary(Pron2)
```

Forecast method: ARIMA(0,1,1) with drift

Model Information:

Series: data_tf
ARIMA(0,1,1) with drift

Coefficients:

	ma1	drift
	-0.2497	0.0251
s.e.	0.1257	0.0134

sigma^2 = 0.01895: log likelihood = 33.71
AIC=-61.42 AICc=-60.97 BIC=-55.23

Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	15276.54	247738.6	186812.5	-0.9300957	9.488785	0.9023876
	0.0161299					


Forecasts:

	Point	Forecast	Lo 95	Hi 95
2020		5432074	4147596	7114346
2021		5570326	3975566	7804809
2022		5712097	3854420	8465099
2023		5857475	3763414	9116726
2024		6006554	3692664	9770368

2025	6159427	3636602	10432414
2026	6316190	3591751	11107191
2027	6476944	3555784	11797906
2028	6641788	3527063	12507107
2029	6810829	3504390	13236936

GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES


```
plot(Pron2, shaded = FALSE, xlab = "Años", ylab = "Produccion de  
papa", main = "ARIMA(0,1,1)")  
lines(Pron2$fitted, col = "red")  
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE  
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),  
lty=c(1,1,2,1), lwd = 2, cex = 0.6)  
abline(v=2020, lwd = 1, col="green")
```



Modelo 3: ARIMA (1,1,1)


```
Pron3 <- forecast(modelo3, level=c(95), h=10)  
plot(Pron3)  
summary(Pron3)
```

Alumno: Maye Mamani Victor Raul



PRONÓSTICO DE LA SERIE ORIGINAL

```
yt_arima3 <- exp(modelo3$fitted)
grafico_comparativo <- cbind(Yt,yt_arima1)
ts.plot(grafico_comparativo, col=c(1,2), lwd = 1)
legend("topleft",c("yt", "yest"),lty = c(1,1), lwd = 2)
```



GRÁFICA DEL AJUSTE Y PRONÓSTICO CON VALORES REALES

Alumno: Maye Mamani Victor Raul

```
Pron3$mean <- exp(Pron3$mean)
Pron3$lower <- exp(Pron3$lower)
Pron3$upper <- exp(Pron3$upper)
Pron3$x <- exp(Pron3$x)
Pron3$fitted <- exp(Pron3$fitted)
Pron3$residuals <- exp(Pron3$residuals)
summary(Pron3)
```

Forecast method: ARIMA(1,1,1) with drift

Model Information:

Series: data_tf

ARIMA(1,1,1) with drift

Coefficients:

	ar1	ma1	drift
	-0.2767	0.0197	0.0252
s.e.	0.4466	0.4630	0.0142

sigma^2 = 0.01921: log likelihood = 33.83

AIC=-59.65 AICc=-58.9 BIC=-51.41


Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	14067.32	248468	184674.9	-0.923185	9.407904	0.8920624
1885228						0.0

Forecasts:

	Point	Forecast	Lo 95	Hi 95
2020		5449957	4153468	7151140
2021		5593637	3987640	7846440
2022		5734810	3827735	8592038
2023		5881330	3719202	9300394
2024		6031088	3631884	10015192
2025		6184802	3562618	10736986
2026		6342393	3506127	11473046
2027		6504012	3459822	12226688
2028		6669746	3421679	13001074
2029		6839703	3390293	13798673

```
plot(Pron3, shaded = FALSE, xlab = "Años", ylab = "Produccion de
papa", main = "ARIMA(1,1,1)")
lines(Pron3$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
abline(v=2020, lwd = 1, col="green")
```



Métricas basadas en el error

accuracy(Pron1)

	MAPE	MASE	ACF1	ME	RMSE	MAE	MPE
Training set	0.0205373	14140.15	248384.4	184763.5	-0.9245591	9.410599	0.8924902

accuracy(Pron2)

	ACF1	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.0161299	15276.54	247738.6	186812.5	-0.9300957	9.488785	0.9023876

accuracy(Pron3)

	ACF1	ME	RMSE	MAE	MPE	MAPE	MASE
Training set	0.1885228	14067.32	248468	184674.9	-0.923185	9.407904	0.8920624

Basado en las métricas MAE y RMSE, el modelo ARIMA(1,1,0) es el mejor entre los tres, ya que tiene los valores más bajos(MAE = 184763.5 Y RMSE=247738.6) en ambas métricas. Esto indica que sus predicciones son más precisas y con menos variabilidad en los errores.

Conclusión

Modelos Evaluados:

1. ARIMA(1,1,0):

- **Significancia:** Coeficiente AR significativo.
 - **Errores:** Muestra mayores errores en comparación con otros modelos.
 - **Estabilidad:** No es estable.
2. **ARIMA(0,1,1):**
- **Significancia:** Coeficiente MA significativo.
 - **Errores:** Mejor ajuste en los residuales, con menores errores.
 - **Estabilidad:** Tampoco es completamente estable.
3. **ARIMA(1,1,1):**
- **Significancia:** Coeficientes no significativos.
 - **Errores:** Menor rendimiento en términos de ajuste y predicción.
 - **Estabilidad:** Similar falta de estabilidad.

Modelo Seleccionado: ARIMA(1,1,0) se selecciona como el más adecuado debido a la significancia del coeficiente AR y el mejor comportamiento en los errores residuales, a pesar de la falta de estabilidad observada en todos los modelos evaluados.