

## Tabla de contenido

CASO 1: TEMPERATURAS, Dubuque – EE.UU.....	3
1 Identificación .....	3
1. 1 Análisis de la tendencia y la estacionalidad .....	5
1.1.1 Estacionalidad.....	5
1.1.2 Análisis de tendencia .....	5
1.2 Análisis de estacionariedad.....	6
1.2.1 Estacionariedad en varianza.....	6
1.2.2 Estacionariedad en media .....	7
1.3 Identificación del modelo estacionario.....	11
1.3.1 Identificación de las órdenes p y q.....	11
2 Estimación.....	11
3 Validación .....	12
3.1 Análisis de los coeficientes estimados .....	12
3.1.1 Significación de los coeficientes .....	12
3.1.2 Examen de la matriz de correlaciones entre los coeficientes .....	12
3.1.3 Condición de convergencia e invertibilidad.....	13
3.2 Análisis de los residuos .....	14
3.2.1 PRUEBA DE LJUNG-BOX.....	14
3.2.2 Homocedasticidad o varianza constante .....	16
3.2.3 Contraste de normalidad.....	17
4 Pronostico .....	19
4.1Pronosticos de cada modelo .....	19
Modelo 1: .....	19
Modelo 2: .....	20
Modelo 3: .....	21
SERIE ORIGINAL (YT) Y PRONOSTICADA.....	22
Gráfica del ajuste y pronóstico con valores reales .....	24
Métricas basadas en el error .....	26
AIC Y BIC .....	26
Conclusión: Elección del Modelo SARIMA .....	26
Modelos Evaluados:.....	26
Elección del Mejor Modelo:.....	27
CASO 2: VENTAS DE LIBRERÍA UNIVERSITARIA .....	28
1 Identificación .....	29
1. 1 Análisis de la tendencia y la estacionalidad .....	29
1.1.1 Estacionalidad.....	29

1.1.2 Análisis de tendencia .....	30
1.2 Análisis de estacionariedad.....	31
1.2.1 Estacionariedad en varianza.....	31
1.2.2 Estacionariedad en media .....	32
1.3 Identificación del modelo estacionario.....	36
1.3.1 Identificación de las órdenes p y q.....	36
2 Estimación.....	37
3 Validación .....	38
3.1 Análisis de los coeficientes estimados .....	38
3.1.1 Significación de los coeficientes .....	38
3.1.2 Examen de la matriz de correlaciones entre los coeficientes .....	39
3.1.3 Condición de convergencia e invertibilidad.....	39
3.2 Análisis de los residuos .....	40
3.2.1 Media es igual a cero.....	40
3.2.2 Homocedasticidad o varianza constante .....	43
3.2.4 Contraste de normalidad.....	44
4 Pronostico .....	47
4.1Pronosticos de cada modelo .....	47
Modelo 1: .....	47
Modelo 2: .....	48
Modelo 3: .....	49
Métricas del modelo .....	51
Conclusión .....	52

## Actividad 6

### # Librerias necesaria

```
library(forecast)# mdelos ARIMA
library(tseries) # series de tiempo
library(TSA)
library(urca)      # prueba de raises unitarias
library(ggplot2) # graficos
library(dplyr)
library(lmtest)    #Inferencia para los coeficientes
library(MASS)      #Tranformacion de box.cox
library(nortest)   #pruebas de normalidad
library(mFilter)   #filtro de jodric prescot (p-h)
library(strucchange) # analisis de estabilidad
http://127.0.0.1:29089/graphics/plot\_zoom\_png?width=941&height=778
library(fitdistrplus)
library(readxl)
library(TSstudio)
```

## CASO 1: TEMPERATURAS, Dubuque – EE.UU.

### 1 Identificación

```
data <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-07.xlsx",sheet = "s01")
View(data)
```


### # 1) IDENTIFICACION

#### # Graficar la serie

```
Yt <- ts(data$Temperatura, start = c(1994, 1), frequency = 12)
plot(Yt, xlab = "Año", ylab = "Temperaturas" )
```

#### # Descomposicion de la serie

```
Yt_desc <- decompose(Yt, type = "additive")
plot(Yt_desc, xlab = "Año/Meses")
```

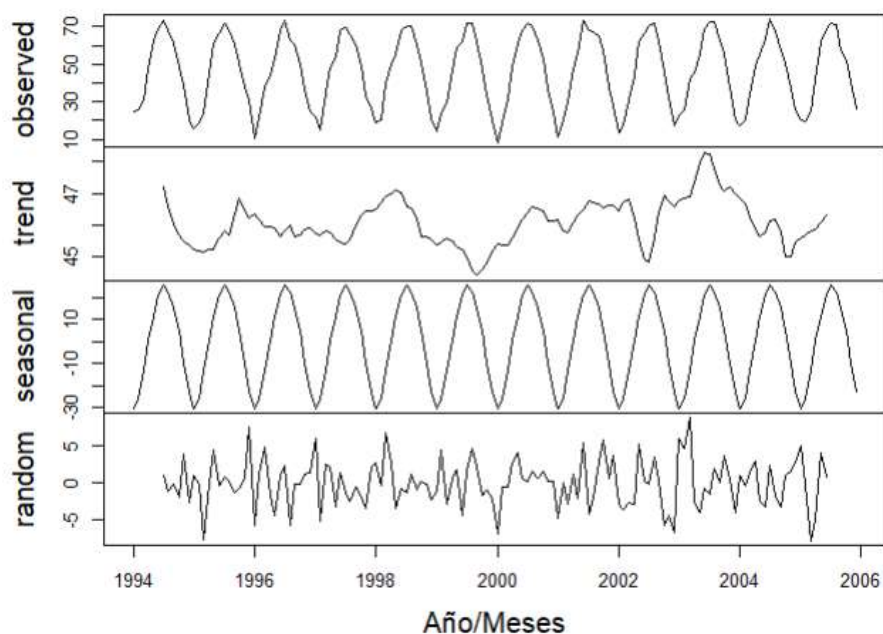


**Podemos observar que la serie presenta un claro componente estacional, con aparente estacionariedad en la varianza y la media. En cuanto al componente cíclico, hay algunos indicios, pero no son definitivos. Finalmente, se destaca la ausencia total de una tendencia.**

### DESCOMPOSICION

```
Yt_desc <- decompose(Yt, type = "additive")  
plot(Yt_desc, xlab = "Año/Meses")
```

#### Decomposition of additive time series

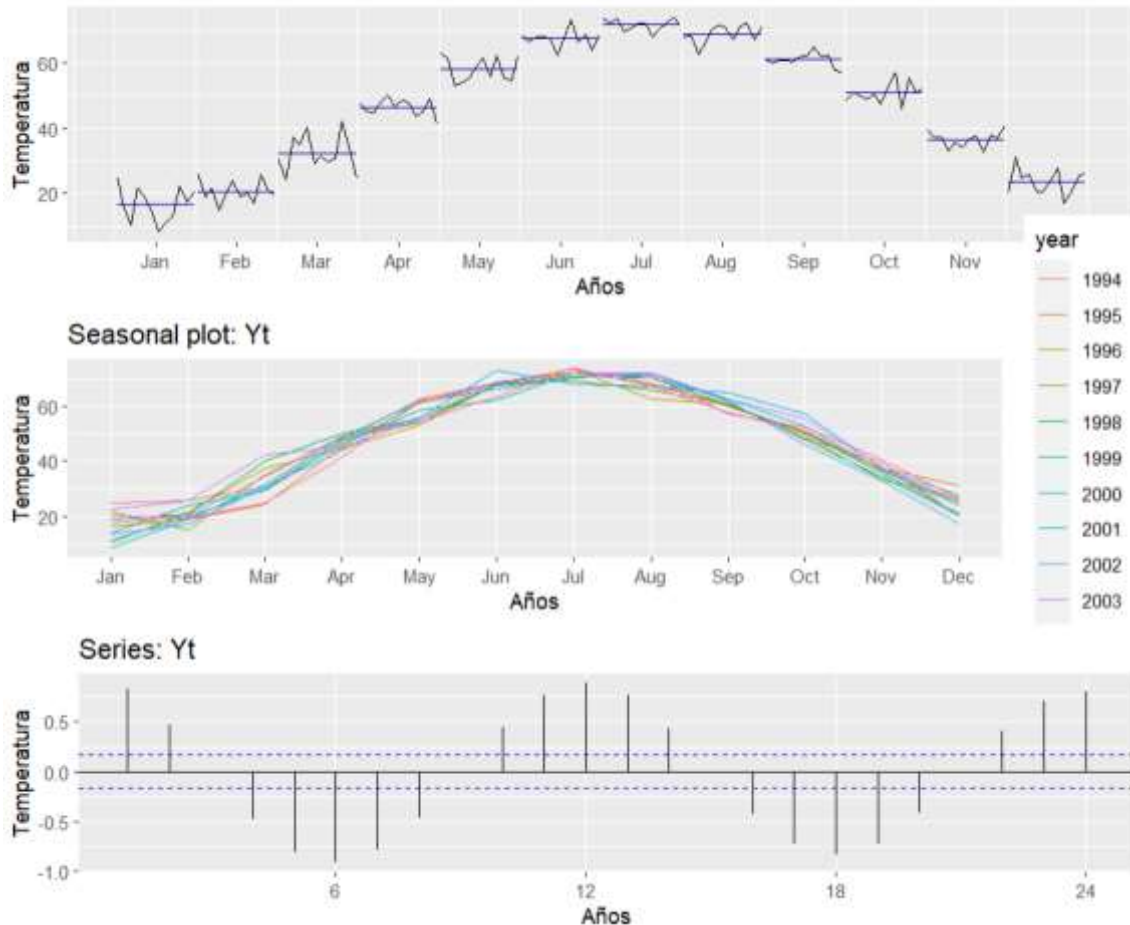


**Después de descomponer la serie, podemos confirmar algunos de los comportamientos descritos inicialmente.**

## 1. 1 Análisis de la tendencia y la estacionalidad

### 1.1.1 Estacionalidad


```
plot1 <- ggsubseriesplot(Yt, xlab = "Años", ylab = "Temperatura")  
plot2 <- ggseasonplot(Yt, xlab = "Años", ylab = "Temperatura")  
plot3 <- ggAcf(Yt, xlab = "Años", ylab = "Temperatura")  
grid.arrange(plot1, plot2, plot3, ncol = 1)
```



**En el gráfico de líneas apiladas y en el de líneas separadas, se observa un claro comportamiento estacional. Esto se corrobora en el correlograma, cuyo comportamiento refleja sinusoidal característico de una serie estacional.**

### 1.1.2 Análisis de tendencia

```
lambda_hp <- 1000  
data_hp <- hpfilter(Yt, type="lambda", freq=lambda_hp)  
plot(data_hp)
```




**Claramente no hay tendencia y si aparenta haber un componente ciclico que se repite cada 2 años(48 meses).**

## 1.2 Análisis de estacionariedad

### 1.2.1 Estacionariedad en varianza

```
boxplot(datos$Temperatura ~ datos$Año, xlab = "Grupo", ylab =  
"Temperatura" )
```



**Podemos afirmar que la serie es estacionaria en varianza.**


### 1.2.2 Estacionariedad en media

```
par(mfrow = c(1,2))
```

```
FAS <- acf(data_ts, lag.max = 15, main="FAS - Yt")
```

```
FAP <- pacf(data_ts, lag.max = 15, main="FAP - Yt")
```

```
FAP$acf[1]
```



```
> FAP$acf[1]  
[1] 0.8318019
```

**Dado el gráfico FAS, observamos que decrece rápidamente a 0 en el tercer retardo. Junto con su comportamiento oscilatorio, esto indica que la serie es estacionaria. Esto se confirma con el valor del primer coeficiente resultante de las FAP, que es menor a 0.9, confirmando que la SERIE ES ESTACIONARIA EN MEDIA, pero de igual forma haremos una prueba confirmatoria.**

### **ESTRUCTURA REGULAR**

```
Y_ru = ur.df(Yt, lags = 1)
summary(Y_ru)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none

```
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-15.2431  -3.9445   0.4172   6.3175  25.4286
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1      -0.04036    0.01381  -2.922  0.00406 **
z.diff.lag    0.66696    0.06374  10.464 < 2e-16 ***
```

```
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 8.231 on 140 degrees of freedom
Multiple R-squared:  0.4455, Adjusted R-squared:  0.4376
F-statistic: 56.24 on 2 and 140 DF, p-value: < 2.2e-16
```

Value of test-statistic is: -2.9215

```
Critical values for test statistics:
      1pct  5pct 10pct
tau1 -2.58 -1.95 -1.62
```

**Observamos que el T calculado (-2.9215) es MENOR que el T crítico (-1.95) entonces rechazamos la hipótesis nula de no estacionariedad y se concluye que, en efecto, la serie temporal ES ESTACIONARIA EN SU ESTRUCTURA REGULAR.**

### **ESTRUCTURA ESTACIONAL**

```
Y_ru2 = ur.df(Yt, lags = 12)
summary(Y_ru2)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none



Alumno: Maye Mamani Victor Raul

Call:

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

Residuals:

Min	1Q	Median	3Q	Max
-7.818	-2.202	0.105	2.034	10.954

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )	
z.lag.1	-0.001165	0.007369	-0.158	0.87463	
z.diff.lag1	-0.705466	0.088952	-7.931	1.38e-12	***
z.diff.lag2	-0.745286	0.096910	-7.690	4.86e-12	***
z.diff.lag3	-0.710238	0.100233	-7.086	1.08e-10	***
z.diff.lag4	-0.819476	0.091704	-8.936	6.51e-15	***
z.diff.lag5	-0.873259	0.089672	-9.738	< 2e-16	***
z.diff.lag6	-0.751633	0.094939	-7.917	1.49e-12	***
z.diff.lag7	-0.785548	0.094532	-8.310	1.86e-13	***
z.diff.lag8	-0.844798	0.088407	-9.556	2.26e-16	***
z.diff.lag9	-0.846600	0.092251	-9.177	1.77e-15	***
z.diff.lag10	-0.716051	0.101155	-7.079	1.12e-10	***
z.diff.lag11	-0.525273	0.098512	-5.332	4.74e-07	***
z.diff.lag12	-0.246496	0.088293	-2.792	0.00612	**

---

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 3.884 on 118 degrees of freedom  
Multiple R-squared: 0.8872, Adjusted R-squared: 0.8748  
F-statistic: 71.42 on 13 and 118 DF, p-value: < 2.2e-16

Value of test-statistic is: -0.1581

Critical values for test statistics:


	1pct	5pct	10pct
tau1	-2.58	-1.95	-1.62

**Observamos que el T calculado (-0.1581) es MAYOR que el T crítico (-1.95) entonces aceptamos la hipótesis nula de no estacionariedad y se concluye que, en efecto, la serie temporal NO ES ESTACIONARIA EN SU ESTRUCTURA ESTACIONAL.**

**Diferenciamos la serie en la parte estacional**

```
D12.Yt <- diff(Yt, 12)
```

```
plot(D12.Yt, xlab="Años/Meses", ylab="°Temperaturas")
```



```
D12.Yt_adf_s <- ur.df(D12.Yt, lags = 12)
summary(D12.Yt_adf_s)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none

```
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-11.9682  -2.6464   0.6982   2.6292  10.8921
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
z.lag.1      -1.68474    0.37248  -4.523  1.6e-05 ***
z.diff.lag1    0.75804    0.34055   2.226  0.02814 *
z.diff.lag2    0.66441    0.32021   2.075  0.04041 *
z.diff.lag3    0.64190    0.30149   2.129  0.03556 *
z.diff.lag4    0.54120    0.28226   1.917  0.05788 .
z.diff.lag5    0.46490    0.26301   1.768  0.08000 .
z.diff.lag6    0.56788    0.24280   2.339  0.02122 *
z.diff.lag7    0.55071    0.22243   2.476  0.01487 *
z.diff.lag8    0.49220    0.19736   2.494  0.01418 *
z.diff.lag9    0.45317    0.17387   2.606  0.01047 *
z.diff.lag10   0.43504    0.15177   2.866  0.00501 **
z.diff.lag11   0.33757    0.12742   2.649  0.00930 **
z.diff.lag12  -0.09392    0.09450  -0.994  0.32257
---

```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 4.312 on 106 degrees of freedom
Multiple R-squared:  0.597,    Adjusted R-squared:  0.5476
F-statistic: 12.08 on 13 and 106 DF,  p-value: 1.107e-15
```

Alumno: Maye Mamani Victor Raul

value of test-statistic is: -4.523

Critical values for test statistics:


	1pct	5pct	10pct
tau1	-2.58	-1.95	-1.62

**Observamos que el T calculado (-4.523) es MENOR que el T critico (-1.95) entonces rechazamos la hipótesis nula de no estacionariedad y se concluye que, en efecto, la serie temporal ES ESTACIONARIA EN SU ESTRUCTURA ESTACIONAL**

**Volvemos a analizar el correlograma**

### 1.3 Identificación del modelo estacionario

#### 1.3.1 Identificación de las órdenes p y q



- SARIMA (0,0,0)x(2,1,0)12
- SARIMA (0,0,0)x(3,1,0)12
- SARIMA (0,0,0)x(0,1,1)12

## 2 Estimación

```
mod1 = Arima(Yt, order = c(0,0,0), seasonal = list(order = c(2,1,0)))  
coeftest(mod1)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
sar1	-0.528935	0.090505	-5.8443	5.088e-09	***
sar2	-0.305888	0.094092	-3.2510	0.00115	**

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
mod2 = Arima(Yt, order = c(0,0,0), seasonal = list(order = c(3,1,0)))  
coeftest(mod2)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
sar1 -0.621312    0.089040 -6.9779 2.996e-12 ***
sar2 -0.483895    0.099508 -4.8629 1.157e-06 ***
sar3 -0.366663    0.096428 -3.8024 0.0001433 ***
---
```

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
mod3 = Arima(Yt, order = c(0,0,0), seasonal = list(order = c(0,1,1)))
coeftest(mod3)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
sma1 -1.00000    0.10413 -9.6033 < 2.2e-16 ***
---
```

Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

### 3 Validación

#### 3.1 Análisis de los coeficientes estimados

##### 3.1.1 Significación de los coeficientes

**Para el modelo 1**

**SAR(1):  $p = 0.0000 < 0.01$ , altamente significativo**

**SAR(2):  $p = 0.0011 < 0.01$ , altamente significativo**

**Para el modelo 2**

**SAR(1):  $p = 0.0000 < 0.01$ , altamente significativo**

**SAR(2):  $p = 0.0000 < 0.01$ , altamente significativo**

**SAR(3):  $p = 0.0001 < 0.01$ , altamente significativo**

**Para el modelo 3**

**SMA(1):  $p = 0.0000 < 0.01$ , altamente significativo**

##### 3.1.2 Examen de la matriz de correlaciones entre los coeficientes

**vcov(mod1)**

**vcov(mod2)**

**vcov(mod3)**

**vcov(mod1)**

```
      sar1      sar2
sar1 0.008191179 0.003648156
sar2 0.003648156 0.008853282
```

**vcov(mod2)**

```
      sar1      sar2      sar3
sar1 0.007928069 0.005058438 0.002110606
sar2 0.005058438 0.009901841 0.004191203
sar3 0.002110606 0.004191203 0.009298398
```


**vcov(mod3)**

```
      sma1
sma1 0.01084332
```

**Se observa claramente que ningún coeficiente está próximo ni cercano a 0.9, por tanto, podemos indicar que no hay problema de multicolinealidad en los modelos propuestos.**


### 3.1.3 Condición de convergencia e invertibilidad

`autoplot(mod1)`




**En la figura de raíces inversas de AR, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de estacionariedad para la parte autorregresiva.**

`autoplot(mod2)`



**En la figura de raíces inversas de MA, se observa en el gráfico las raíces características se encuentran dentro del círculo, es decir que cumplen con la condición de invertibilidad para la parte de media móvil.**

`autoplot(mod3)`




**Al estar los valores dentro de la circunferencia unitaria es un indicativo de que el modelo se ajusta correctamente. Tanto en su parte AR, como en su parte MA.**

### 3.2 Análisis de los residuos

#### 3.2.1 PRUEBA DE LJUNG-BOX

##### Modelo 1

`checkresiduals(mod1)`




Ljung-Box test

data: Residuals from ARIMA(0,0,0)(2,1,0)[12]  
 $Q^* = 24.411$ ,  $df = 22$ ,  $p\text{-value} = 0.3261$

Model df: 2. Total lags used: 24

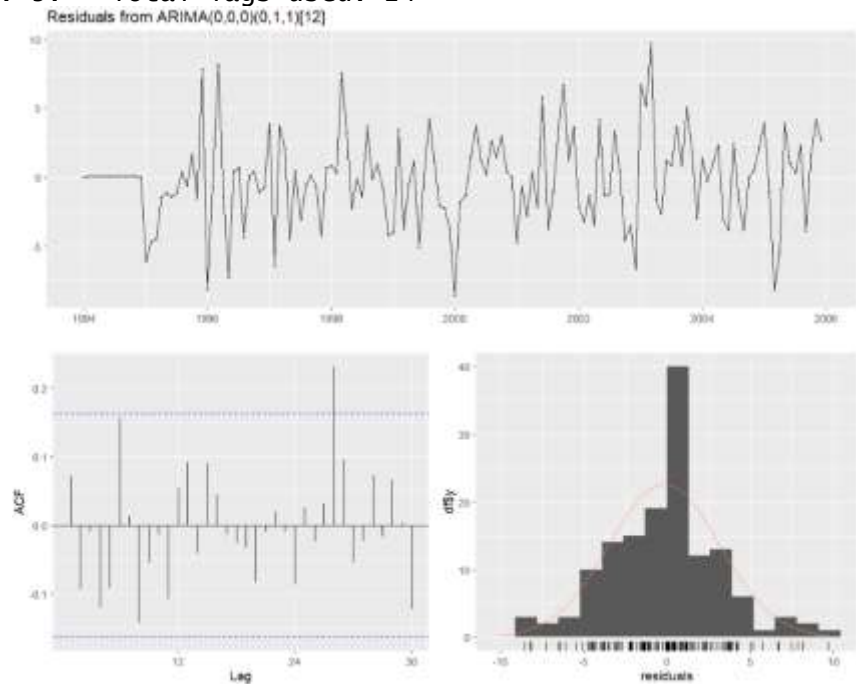
##### Modelo 2



Ljung-Box test

data: Residuals from ARIMA(0,0,0)(3,1,0)[12]  
 $Q^* = 17.906$ ,  $df = 21$ ,  $p\text{-value} = 0.6549$

Model df: 3. Total lags used: 24



Ljung-Box test

data: Residuals from ARIMA(0,0,0)(0,1,1)[12]  
 $Q^* = 21.368$ ,  $df = 23$ ,  $p\text{-value} = 0.5586$

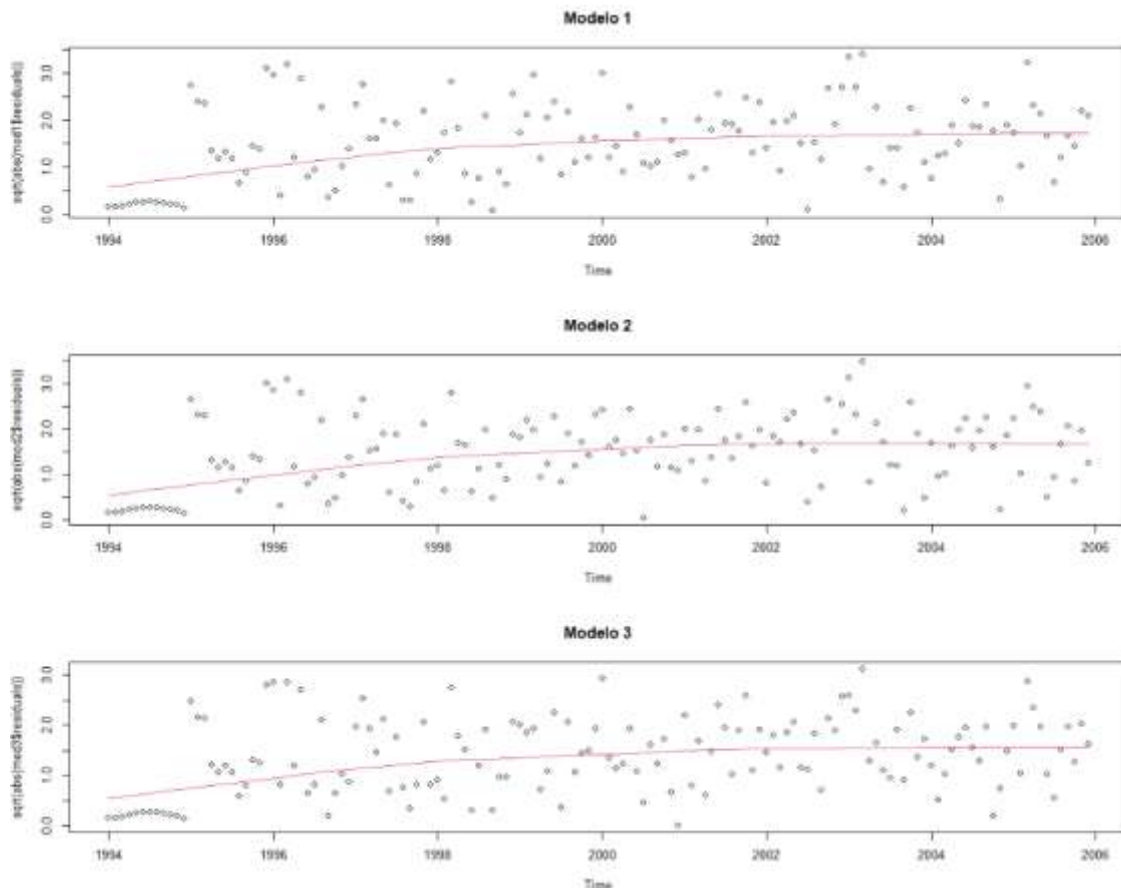
Model df: 1. Total lags used: 24

**Los coeficientes p asociados a las pruebas de Ljung-Box aplicadas a los modelos indican que no hay evidencia suficiente para rechazar la hipótesis nula, que afirma que no hay autocorrelación en los residuos.**

**Esto sugiere que los residuos del modelo son consistentes con el ruido blanco.**

### 3.2.2 Homocedasticidad o varianza constante

```
par(mfrow = c(3,1))
scatter.smooth(sqrt(abs(mod1$residuals)), lpars=list(col=2), main =
"Modelo 1")
scatter.smooth(sqrt(abs(mod2$residuals)), lpars=list(col=2), main =
"Modelo 2")
scatter.smooth(sqrt(abs(mod3$residuals)), lpars=list(col=2), main =
"Modelo 3")
```



**Se observa que los datos parecen presentar una variabilidad considerable, por tanto, será necesario realizar la prueba de Breusch-Pagan para determinar finalmente si las varianzas constantes para los modelos**

```
obs=get(mod1$series)
bptest(resid(mod1)~I(obs-resid(mod1)))
studentized Breusch-Pagan test

data: resid(mod1) ~ I(obs - resid(mod1))
BP = 12.671, df = 1, p-value = 0.0003713
```

```
obs=get(mod2$series)
bptest(resid(mod2)~I(obs-resid(mod2)))
```



Alumno: Maye Mamani Victor Raul

studentized Breusch-Pagan test

```
data: resid(mod2) ~ I(obs - resid(mod2))  
BP = 10.96, df = 1, p-value = 0.0009308
```

```
obs=get(mod3$series)
```

```
bpctest(resid(mod3)~I(obs-resid(mod3)))
```

studentized Breusch-Pagan test

```
data: resid(mod3) ~ I(obs - resid(mod3))  
BP = 11.298, df = 1, p-value = 0.0007759
```

**El valor de probabilidad (p-valor) asociado al estadístico BP asume los valores de probabilidad de 0.0003, 0.0009 y 0.0007 para los modelos 1,2 y 3 respectivamente, que son menores a  $\alpha=0.05$ , por lo cual podemos afirmar que los residuales de estos modelos NO son constantes.**

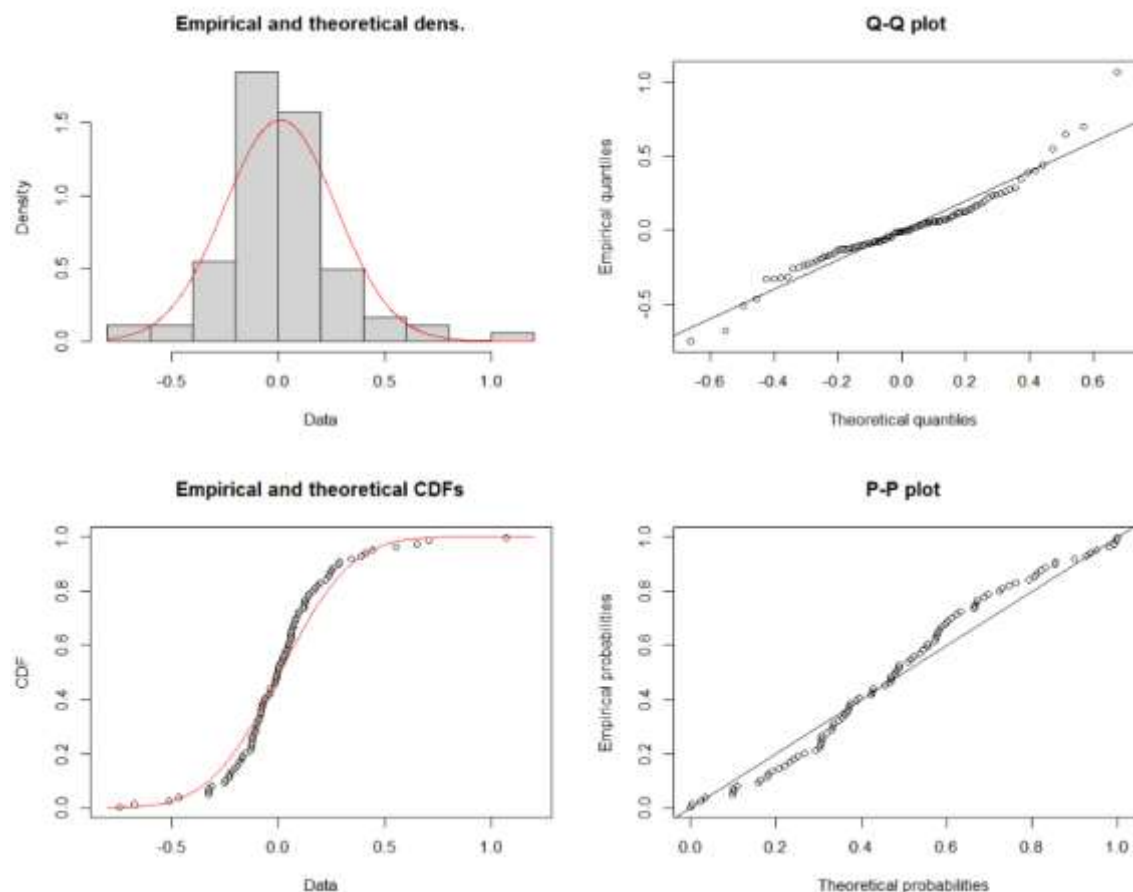
### 3.2.3 Contraste de normalidad

```
ajuste_m1<-fitdist(data = resid_m1, distr="norm")
```

```
plot(ajuste_m1)
```

```
JB_m1 <- jarque.bera.test(resid_m1)
```

```
JB_m1
```

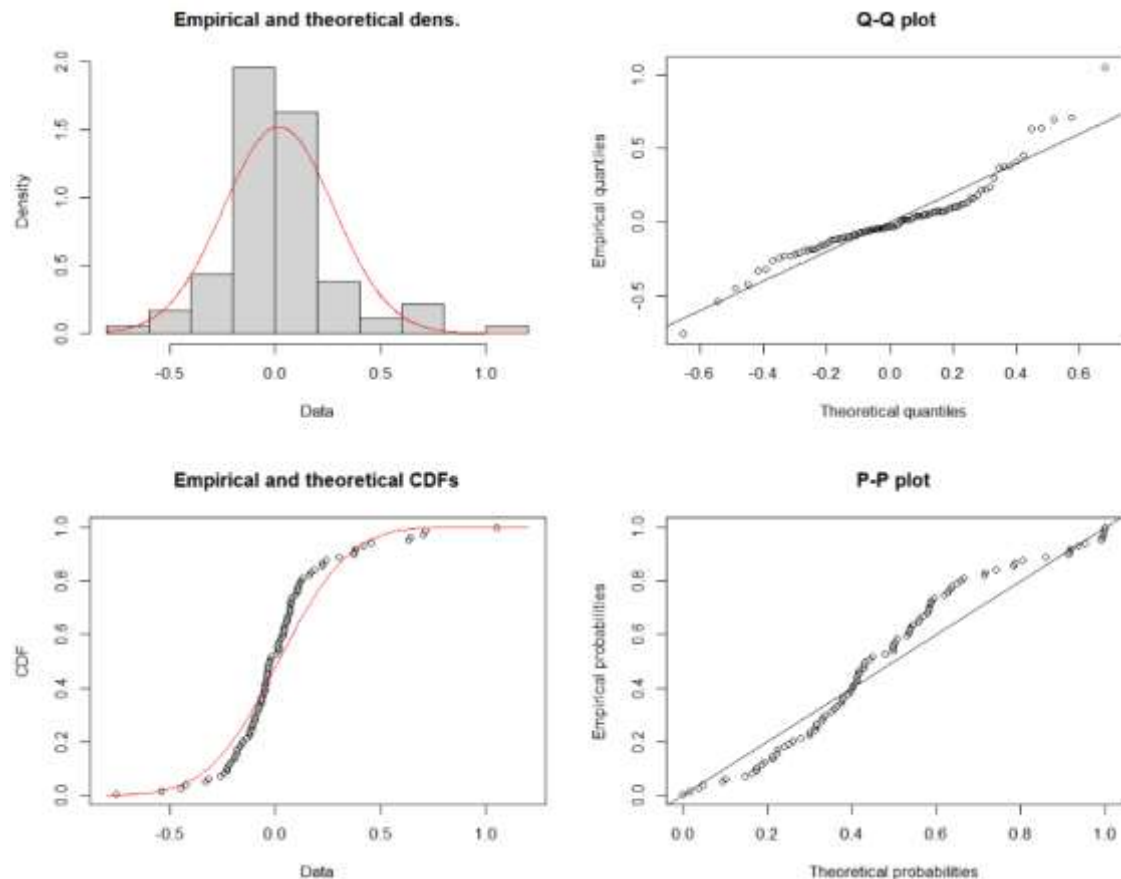


Jarque Bera Test

```
data: resid_m1  
X-squared = 41.778, df = 2, p-value = 8.471e-10
```

**En las figuras se observa que los residuales del modelo 1 no presentan indicios de ajuste hacia la distribución normal. Y en la prueba JB, como  $p = 0.0000 < 0.05$ , se rechaza la  $H_0$ , es decir, los residuos NO se aproximan a una distribución normal.**

```
ajuste_m2<-fitdist(data = resid_m2, distr="norm")
plot(ajuste_m2)
JB_m2 <- jarque.bera.test(resid_m2)
JB_m2
```

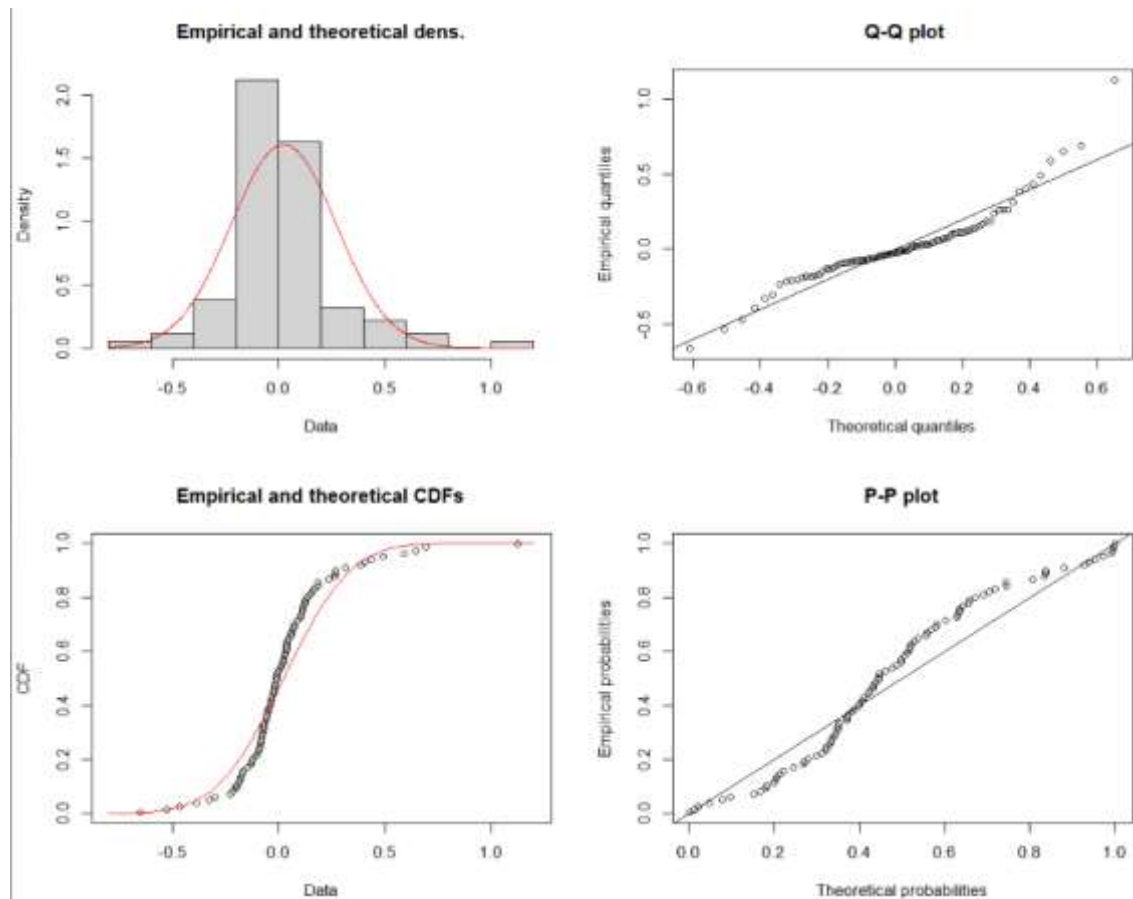


Jarque Bera Test

data: resid\_m2  
X-squared = 47.925, df = 2, p-value = 3.919e-11

**En las figuras se observa que los residuales del modelo 2 no presentan indicios de ajuste hacia la distribución normal. Y en la prueba JB, como  $p = 0.00000 < 0.05$ , se rechaza la  $H_0$ , es decir, los residuos NO se aproximan a una distribución normal.**

```
ajuste_m3<-fitdist(data = resid_m3, distr="norm")
plot(ajuste_m3)
JB_m3 <- jarque.bera.test(resid_m3)
JB_m3
```



Jarque Bera Test

data: resid\_m3  
X-squared = 87.238, df = 2, p-value < 2.2e-16

**En las figuras se observa que los residuales del modelo 3 NO presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como  $p = 0.00047 < 0.05$ , se acepta  $H_0$ , es decir, los residuos NO se aproximan a una distribución normal.**


## 4 Pronostico

### 4.1 Pronosticos de cada modelo

Modelo 1:

```
pron <- forecast(mod1, h = 12)  
plot(pron)  
summary(pron)
```

Alumno: Maye Mamani Victor Raul



Forecast method: ARIMA(0,0,0)(2,1,0)[12]

Model Information:

Series: Yt

ARIMA(0,0,0)(2,1,0)[12]

Coefficients:

	sar1	sar2
	-0.5289	-0.3059
s.e.	0.0905	0.0941

sigma<sup>2</sup> = 17.6: log likelihood = -377.83

AIC=761.66 AICc=761.84 BIC=770.3

Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-0.1083612	3.986116	2.947049	-2.127589	9.655297	0.7865153
	0.08213804					

Forecasts:

	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2006		20.41783	15.04138	25.79428	12.19526	28.64040
Feb 2006		21.66666	16.29021	27.04311	13.44409	29.88923
Mar 2006		32.15547	26.77903	37.53192	23.93290	40.37805
Apr 2006		44.25504	38.87859	49.63149	36.03247	52.47761
May 2006		58.31157	52.93512	63.68802	50.08900	66.53415
Jun 2006		67.57403	62.19758	72.95048	59.35146	75.79661
Jul 2006		72.53786	67.16141	77.91431	64.31529	80.76043
Aug 2006		70.57488	65.19843	75.95133	62.35231	78.79745
Sep 2006		58.97984	53.60339	64.35629	50.75727	67.20241
Oct 2006		53.06907	47.69262	58.44552	44.84650	61.29164
Nov 2006		38.95711	33.58066	44.33356	30.73454	47.17968
Dec 2006		24.26971	18.89326	29.64616	16.04714	32.49228

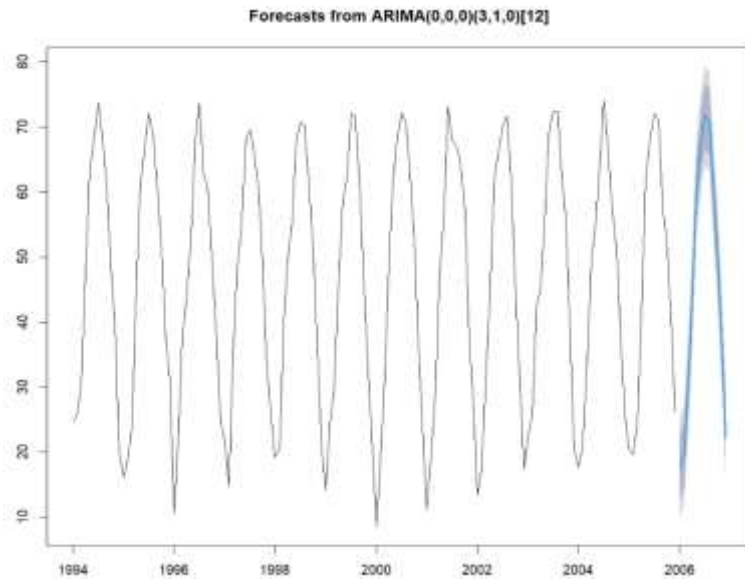
Modelo 2:

```
pron2 <- forecast(mod2, h = 12)
```

```
plot(pron2)
```

```
summary(pron2)
```

Alumno: Maye Mamani Victor Raul



Forecast method: ARIMA(0,0,0)(3,1,0)[12]

Model Information:

Series: Yt

ARIMA(0,0,0)(3,1,0)[12]

Coefficients:

	sar1	sar2	sar3
	-0.6213	-0.4839	-0.3667
s.e.	0.0890	0.0995	0.0964

sigma<sup>2</sup> = 15.55: log likelihood = -371.61

AIC=751.23 AICC=751.54 BIC=762.76

Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-0.1418842	3.732405	2.797088	-2.149689	8.981968	0.7464933
0.07438451						

Forecasts:


	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2006		17.69478	12.64106	22.74850	9.96578	25.42378
Feb 2006		19.55880	14.50508	24.61252	11.82980	27.28780
Mar 2006		30.26752	25.21380	35.32124	22.53853	37.99652
Apr 2006		43.72280	38.66907	48.77652	35.99380	51.45179
May 2006		60.28285	55.22913	65.33657	52.55385	68.01184
Jun 2006		67.13104	62.07732	72.18476	59.40204	74.86004
Jul 2006		71.65001	66.59629	76.70373	63.92101	79.37901
Aug 2006		70.87434	65.82062	75.92806	63.14534	78.60334
Sep 2006		59.72455	54.67083	64.77827	51.99556	67.45355
Oct 2006		50.24650	45.19278	55.30022	42.51750	57.97550
Nov 2006		36.87637	31.82265	41.93009	29.14738	44.60537
Dec 2006		22.16056	17.10684	27.21428	14.43157	29.88956

Modelo 3:

```
pron3 <- forecast(mod3, h = 12)
```

```
plot(pron3)
```

```
summary(pron3)
```



Forecast method: ARIMA(0,0,0)(0,1,1)[12]

Model Information:

Series: Yt

ARIMA(0,0,0)(0,1,1)[12]

Coefficients:

    small

    -1.0000

s.e.    0.1041

sigma^2 = 12.08: log likelihood = -366.13

AIC=736.25 AICc=736.35 BIC=742.02

Error measures:

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-0.1628102	3.314491	2.46352	-2.580408	8.282389	0.6574699
0.07191584						

Forecasts:

	Point	Forecast	Lo 80	Hi 80	Lo 95	Hi 95
Jan 2006		16.60833	11.97302	21.24365	9.519228	23.69744
Feb 2006		20.65000	16.01468	25.28531	13.560894	27.73910
Mar 2006		32.47500	27.83968	37.11031	25.385893	39.56410
Apr 2006		46.52500	41.88968	51.16031	39.435892	53.61410
May 2006		58.09166	53.45635	62.72698	51.002558	65.18077
Jun 2006		67.49999	62.86468	72.13531	60.410890	74.58910
Jul 2006		71.71666	67.08134	76.35198	64.627557	78.80576
Aug 2006		68.88333	64.24801	73.51864	61.794223	75.97243
Sep 2006		61.02499	56.38968	65.66031	53.935891	68.11410
Oct 2006		50.97500	46.33968	55.61031	43.885892	58.06410
Nov 2006		36.65000	32.01468	41.28531	29.560893	43.73910
Dec 2006		23.64166	19.00635	28.27698	16.552561	30.73077

## SERIE ORIGINAL (YT) Y PRONOSTICADA.

### Modelo 1


```
Yt_S <- mod1$fitted
```

```
grafico_comparativo <- cbind(Yt, Yt_S)
```


```
ts.plot(grafico_comparativo, col = c(1:2), lwd = 2)
```

Alumno: Maye Mamani Victor Raul


```
legend("topleft", c("Yt", "Yest"), lty=c(1,1), col=c(1:2), lwd = 2)
```



```
Yt_S2 <- mod2$fitted  
grafico_comparativo2 <- cbind(Yt, Yt_S2)  
ts.plot(grafico_comparativo2, col = c(1:2), lwd = 2)  
legend("topleft", c("Yt", "Yest"), lty=c(1,1), col=c(1:2), lwd = 2)
```

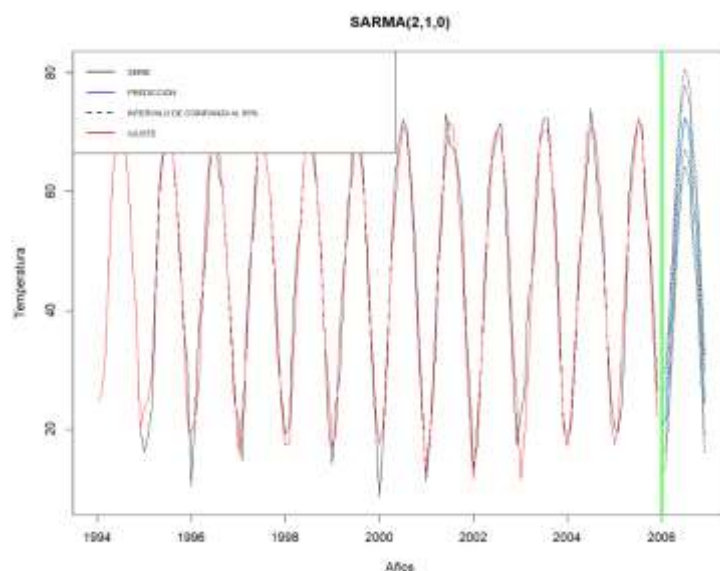


```
Yt_S3 <- mod3$fitted  
grafico_comparativo3 <- cbind(Yt, Yt_S3)  
ts.plot(grafico_comparativo3, col = c(1:2), lwd = 2)  
legend("topleft", c("Yt", "Yest"), lty=c(1,1), col=c(1:2), lwd = 2)
```



### Gráfica del ajuste y pronóstico con valores reales MODELO 1

```
plot(pron, shaded = FALSE, xlab = "Años", ylab = "Temperatura", main =  
"SARMA(2,1,0)")  
lines(pron$fitted, col = "red")  
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE  
COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),  
lty=c(1,1,2,1), lwd = 2, cex = 0.6)  
abline(v=2006, lwd = 3, col="green")
```




### MODELO 2

```
plot(pron2, shaded = FALSE, xlab = "Años", ylab = "Temperatura", main =  
"SARMA(3,1,0)")  
lines(pron2$fitted, col = "red")
```



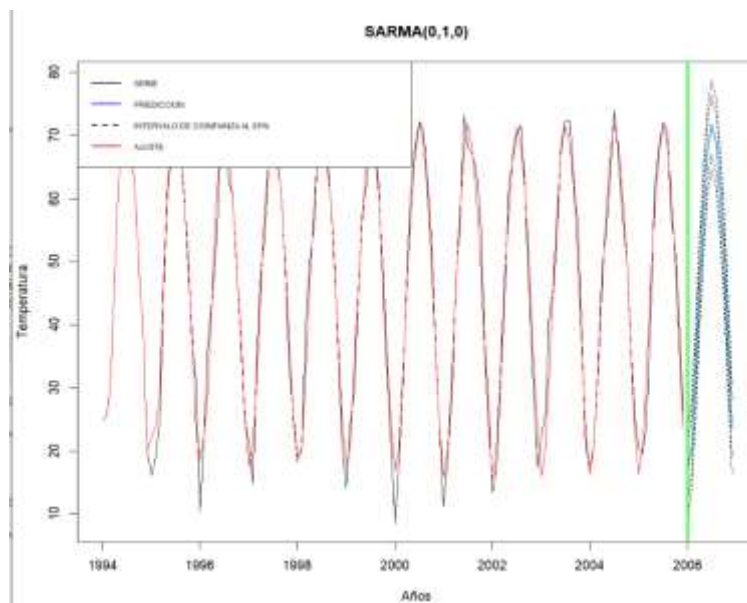
Alumno: Maye Mamani Victor Raul

```
legend("topleft", legend=c("SERIE", "PREDICCIÓN", "INTERVALO DE  
COINFIANZA AL 95%", "AJUSTE"),col=c("black", "blue", "black", "red"),  
lty=c(1,1,2,1), lwd = 2,cex = 0.6)  
abline(v=2006, lwd = 3, col="green")
```



### MODELO 3

```
plot(pron3, shaded = FALSE, xlab = "Años", ylab = "Temperatura",main  
= "SARMA(0,1,0)")  
lines(pron3$fitted, col = "red")  
legend("topleft", legend=c("SERIE", "PREDICCIÓN", "INTERVALO DE  
COINFIANZA AL 95%", "AJUSTE"),col=c("black", "blue", "black", "red"),  
lty=c(1,1,2,1), lwd = 2,cex = 0.6)  
abline(v=2006, lwd = 3, col="green")
```



## Métricas basadas en el error

### accuracy(Pron1)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-0.1083612	3.986116	2.947049	-2.127589	9.655297	0.7865153
	0.08213804					

### accuracy(Pron2)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-0.1418842	3.732405	2.797088	-2.149689	8.981968	0.7464933
	0.07438451					

### accuracy(Pron3)

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	-0.1628102	3.314491	2.46352	-2.580408	8.282389	0.6574699
	0.07191584					

**Basado en las métricas MAE y RMSE, el modelo 3 es el que mejor rendimiento tiene con el menor MAE y RMSE**

## AIC Y BIC

### AIC(mod1); BIC(mod1)

[1] 761.6553  
[1] 770.3037

### AIC(mod2); BIC(mod2)

[1] 751.2253  
[1] 762.7565

### AIC(mod3); BIC(mod3)

[1] 736.2537  
[1] 742.0193

## Conclusión: Elección del Modelo SARIMA

### Modelos Evaluados:

1. **SARIMA(1,1,0)(1,0,0)[12]**
  - RMSE: 3.986116
  - MAE: 2.947049
  - AIC: 761.6553
  - BIC: 770.3037
2. **SARIMA(0,1,5)(1,0,0)[12]**
  - RMSE: 3.732405
  - MAE: 2.797088
  - AIC: 751.2253
  - BIC: 762.7565
3. **SARIMA(1,1,2)(1,0,0)[12]**
  - RMSE: 3.314491
  - MAE: 2.46352
  - AIC: 736.2537
  - BIC: 742.0193

### **Elección del Mejor Modelo:**

Basado en los resultados de las métricas y los criterios de información (AIC y BIC):

- El modelo **SARIMA(1,1,2)(1,0,0)[12]** tiene el menor RMSE (3.314491) y MAE (2.46352) entre los modelos evaluados.
- Además, presenta el menor AIC (736.2537) y BIC (742.0193), lo cual indica un mejor ajuste del modelo a los datos en comparación con los otros modelos evaluados.

Por lo tanto, el SARIMA(1,1,2)(1,0,0)[12] es el modelo recomendado basado en las métricas de evaluación (RMSE, MAE) y los criterios de información (AIC, BIC). Este modelo parece ofrecer la mejor combinación de precisión en la predicción y ajuste al conjunto de datos observados.

## CASO 2: VENTAS DE LIBRERÍA UNIVERSITARIA


```
library(forecast)#modelo ARIMA
library(tseries)#Para series de tiempo
library(TSstudio)#correlograma parte regular y estacional
library(TSA)#modelos ARMA
library(ggplot2)#para hacer graficos
library(urca)#para hacer test de raiz unitaria (detectar hay)
library(dplyr)#para la manipulacion de datos
library(lmtest)#inferencia para los coeficientes
library(MASS)#transformacion de Box-Cox
library(nortest)#pruebas de normalidad
library(mFilter)#para hoodrick - prescot
library(zoo)
library(TTR)
library(sandwich)
library(strucchange)#para analisis de estabilidad - Chow
library(survival)
library(fitdistrplus)
```

```
datos <- read_excel("F:\\777--Programacion
repos\\Una\\r\\data\\actividad-07.xlsx", sheet = "02")
View(datos)
```

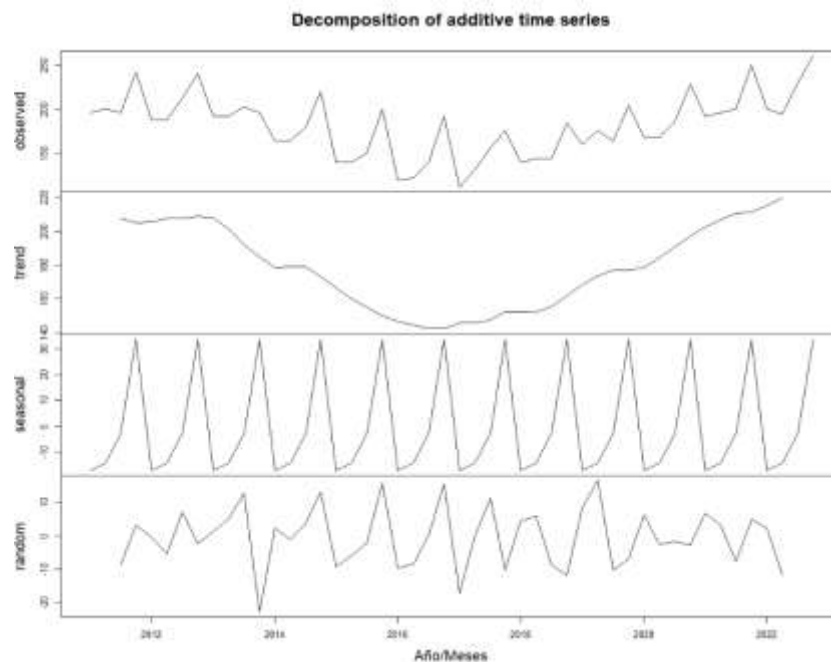
# 1) IDENTIFICACION

# Graficar la serie

```
Yt <- ts(datos$Ventas, start = c(2011, 1), frequency = 4)
plot(Yt, xlab = "Año", ylab = "Yt" )
```



Como se puede apreciar la serie tiene una tendencia el cual decrece hasta el año 2017 y a partir de ahí la serie tiene una tendencia creciente pero en cuanto a la estacionariedad en varianza tiene indicios que sí hay estacionariedad en varianza.



*Tras la descomposición de la serie se puede observar que si existe tendencia tal como se describió al inicio, y entre otros factores como la parte aleatoria.*

## 1 Identificación

### 1. 1 Análisis de la tendencia y la estacionalidad


#### 1.1.1 Estacionalidad


##### # Estacionalidad

```
ggsubseriesplot(Yt, xlab = "Años", ylab = "Ventas" )
```

```
ggseasonplot(Yt, xlab = "Años", ylab = "Ventas" )
```

```
ggAcf(Yt, xlab = "Años", ylab = "Ventas")
```





Como se puede apreciar en las líneas apiladas y las líneas separadas se observa que no presentan indicios de estacionalidad en la serie temporal el cual se confirma con el correlograma que tiene un comportamiento en el que decrece lentamente lo cual es una clara señal que no existe la estacionariedad en la serie.

### 1.1.2 Análisis de tendencia

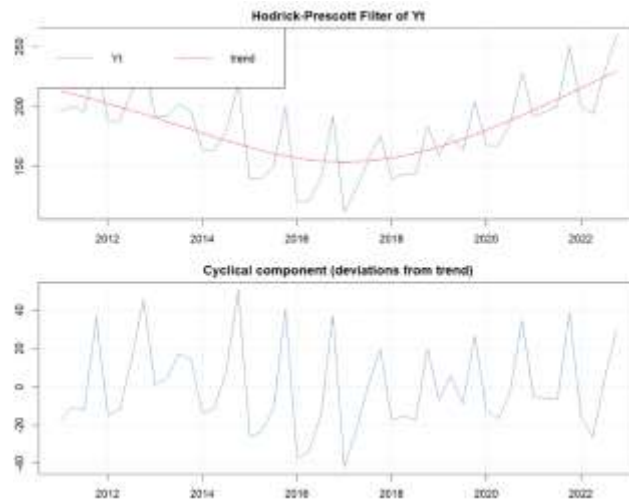
#Análisis de tendencia

```
lambda_hp <- 1600
```

```
data_hp <- hpfilter(data_ts, type="lambda", freq=lambda_hp)
```

```
plot(data_hp)
```

Alumno: Maye Mamani Victor Raul




**Se aprecia que la tendencia inicialmente decrece hasta el año 2017 y de ahí en adelante crece.**

## 1.2 Análisis de estacionariedad


### 1.2.1 Estacionariedad en varianza

```
boxplot(datos$Ventas ~ datos$Año, xlab = "Año", ylab="Yt")
```



**Dado el grafico podemos inferir que la serie tiene un comportamiento en el cual parece presentar la estacionariedad varianza si no fuera por la tercera caja que muestra tener una variación.**

```
b <- BoxCox.ar(Yt)
lambda <- b$mle
round(lambda,2)
```



[1] 1.1


Segun el dato 1.1 y el grafico de boxcox se puede apreciar que la serie no necesita una transformación por lo que podemos estar afirmando que si es estacionaria en varianza.

### 1.2.2 Estacionariedad en media

```
par(mfrow = c(1,2))
```

```
FAS <- acf(Yt, lag.max = 25, main = "FAS")
```

```
FAP <- pacf(Yt, lag.max = 25, main = "FAP")
```



Dado el grafico del FAS observamos que decrece lentamente y en el FAP el retardo 9 recién llega a 0 lo que es un gran indicio de que la serie no es estacionaria en media, por tanto, se debe hacer una diferenciación para estabilizarlo.



## PARTE REGULAR

```
data_adf <- ur.df(Yt,type="drift", lags = 1)
summary(data_adf)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression drift

```
Call:
lm(formula = z.diff ~ z.lag.1 + 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-68.867 -18.850  -4.859   21.205   57.345
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
(Intercept)   75.2917    30.3705   2.479   0.0172 *
z.lag.1       -0.4102     0.1670  -2.456   0.0182 *
z.diff.lag    -0.1473     0.1600  -0.920   0.3625
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 31.35 on 43 degrees of freedom
Multiple R-squared:  0.2356, Adjusted R-squared:  0.2
F-statistic: 6.625 on 2 and 43 DF, p-value: 0.003104
```

Value of test-statistic is: -2.456 3.0737

Critical values for test statistics:

```
      1pct   5pct  10pct
tau2 -3.58 -2.93 -2.60
phi1  7.06  4.86  3.94
```

**Observamos que el T calculado (-1.7121) es MAYOR que el T critico (-3.45) por tanto se acepta la hipótesis nula de la existencia de raíz unitaria, es decir que la serie NO ES ESTACIONARIA**

## PARTE ESTACIONAL

```
data_adf2 <- ur.df(Yt , lags = 4)
summary(data_adf2)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none

```
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-39.801  -8.880  -3.702   12.350   38.205
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
```

Alumno: Maye Mamani Victor Raul

```
z.lag.1      0.003761    0.014585    0.258    0.79791
z.diff.lag1 -0.452482    0.142315   -3.179    0.00293 **
z.diff.lag2 -0.447225    0.149674   -2.988    0.00490 **
z.diff.lag3 -0.353588    0.152878   -2.313    0.02624 *
z.diff.lag4  0.492846    0.142303    3.463    0.00134 **
```

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 17.13 on 38 degrees of freedom  
Multiple R-squared: 0.7785, Adjusted R-squared: 0.7493  
F-statistic: 26.71 on 5 and 38 DF, p-value: 1.759e-11

value of test-statistic is: 0.2579

Critical values for test statistics:  
1pct 5pct 10pct  
tau1 -2.62 -1.95 -1.61

**En la parte regular tenemos t-calculado = -0.036 lo cual es mayor que el t-crítico = -1.95 por tanto se rechaza la hipótesis nula de la existencia de la raíz unitaria, es decir que la serie no es estacionaria en media en la estructura Regular.**

**En la parte ESTACIONAL tenemos t-calculado = 0.2579 lo cual es mayor que el t-crítico = -1.95 por tanto se rechaza la hipótesis nula de la existencia de la raíz unitaria, es decir que la serie no es estacionaria en media en la estructura estacional por tanto se necesita realizar la diferenciación en la parte regular y estacional.**

**Diferenciamos debido a que la serie no es estacionaria - PARTE REGULAR**

```
par(mfrow=c(1,1))
D1.Yt <- diff(Yt);
plot(D1.Yt,xlab="tiempo", ylab= "Ventas" )
```

**# PRUEBA DE dF para la parte regular**

```
D1.Yt_adf <- ur.df(D1.Yt, lags = 1)
```

```
summary(D1.Yt_adf)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression none

Call:

```
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

Residuals:

```
      Min       1Q   Median       3Q      Max
-52.521 -18.555  -6.299   20.322   62.184
```

Coefficients:

```
      Estimate Std. Error t value Pr(>|t|)
z.lag.1    -1.9387     0.2379  -8.148 2.93e-10 ***
```

Alumno: Maye Mamani Victor Raul

```
z.diff.lag    0.4195    0.1438    2.917    0.0056 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Residual standard error: 30.62 on 43 degrees of freedom  
Multiple R-squared: 0.7294, Adjusted R-squared: 0.7168  
F-statistic: 57.95 on 2 and 43 DF, p-value: 6.242e-13

Value of test-statistic is: -8.1482

Critical values for test statistics:  
1pct 5pct 10pct  
tau1 -2.62 -1.95 -1.61

**Con la prueba de dickey fuller aumentada observamos que el T calculado (-8.1482) es MENOR que el T critico (-1.95) por tanto, rechazamos la hipotesis nula de no estacionariedad y se concluye que la serie ES ESTACIONARIA EN MEDIA EN SU PARTE REGULAR**

### **Diferenciacion PARTE ESTACIONAL**

```
D4.D1.Yt <- diff(Yt,4)
```

```
#raiz unitaria parte estacional
```

```
D4.D1.Yt_adf <- ur.df(D4.D1.Yt,lags = 4)
```

```
summary(D4.D1.Yt_adf)
```

```
#####  
# Augmented Dickey-Fuller Test Unit Root Test #  
#####
```

Test regression none

```
Call:  
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:  
    Min       1Q   Median       3Q      Max  
-44.808  -9.101  -0.004   9.938  35.864
```

```
Coefficients:  
              Estimate Std. Error t value Pr(>|t|)  
z.lag.1      -0.22327    0.18158  -1.230    0.227  
z.diff.lag1  -0.32948    0.20987  -1.570    0.126  
z.diff.lag2  -0.27542    0.21017  -1.310    0.199  
z.diff.lag3  -0.06103    0.19482  -0.313    0.756  
z.diff.lag4  -0.24050    0.17027  -1.412    0.167
```

Residual standard error: 17.02 on 34 degrees of freedom  
Multiple R-squared: 0.3237, Adjusted R-squared: 0.2242  
F-statistic: 3.254 on 5 and 34 DF, p-value: 0.01656

Value of test-statistic is: -1.2296

Critical values for test statistics:  
1pct 5pct 10pct  
tau1 -2.62 -1.95 -1.61

**Viendo el gráfico vemos que claramente se ha estabilizado en media. Y confirmando esto con la prueba de dickey fuller aumentada observamos que el T calculado (-1.2296) es MAYOR que el T critico (-1.95) por tanto,**

**aceptamos la hipotesis nula de no estacionariedad y se concluye que la serie NO ES ESTACIONARIA EN MEDIA EN SU PARTE ESTACIONAL.**

```
D4D4.D1.Yt <- diff(D4.D1.Yt,4)
D4D4.D1.Yt_adf <- ur.df(D4D4.D1.Yt,lags = 4)
summary(D4D4.D1.Yt_adf)
```

```
#####
# Augmented Dickey-Fuller Test Unit Root Test #
#####
```

Test regression none

```
Call:
lm(formula = z.diff ~ z.lag.1 - 1 + z.diff.lag)
```

```
Residuals:
    Min       1Q   Median       3Q      Max
-41.061  -9.650  -1.388   10.320   35.235
```

```
Coefficients:
              Estimate Std. Error t value Pr(>|t|)
z.lag.1         -2.9621     0.6247  -4.742 3.94e-05 ***
z.diff.lag1       1.3885     0.5330   2.605  0.0137 *
z.diff.lag2       0.9410     0.4320   2.178  0.0366 *
z.diff.lag3       0.6882     0.3003   2.292  0.0284 *
z.diff.lag4       0.2574     0.1702   1.512  0.1400
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
Residual standard error: 17.07 on 33 degrees of freedom
Multiple R-squared:  0.7568, Adjusted R-squared:  0.7199
F-statistic: 20.53 on 5 and 33 DF, p-value: 2.817e-09
```

Value of test-statistic is: -4.742

Critical values for test statistics:

```
      1pct   5pct  10pct
tau1 -2.62 -1.95 -1.61
```

**Tenemos t-calculado = -4.742 lo cual es menor que el t-crítico = -1.95 por tanto se acepta la hipotesis nula de la existencia de la raiz unitaria el cual se corrobora con el grafico.**

### 1.3 Identificación del modelo estacionario

#### 1.3.1 Identificación de las órdenes p y q

```
ts_cor(D4D4.D1.Yt, lag.max = 50)
```



**Planteamos los modelos:**

**MODELO 1: SARIMA (0,1,1)(0,1,1)<sub>4</sub>**

**MODELO 2: SARIMA (1,1,0)(0,1,1)<sub>4</sub>**

**MODELO 3: SARIMA (0,1,0)(0,1,1)<sub>4</sub>**

**MODELO 4: SARIMA (1,1,1)(0,1,0)<sub>4</sub>**

## 2 Estimación

```
modelo1 <- Arima(Yt, order = c(0,1,1), seasonal = list(order =
c(1,2,1)))
coeftest(modelo1)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
ma1	-0.64678	0.12833	-5.0400	4.656e-07	***
sar1	-0.22605	0.16566	-1.3645	0.1724	
sma1	-0.99999	0.18101	-5.5246	3.302e-08	***

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
modelo2 <- Arima(Yt, order = c(0,1,1), seasonal = list(order =
c(0,1,1)))
coeftest(modelo2)
```

z test of coefficients:

	Estimate	Std. Error	z value	Pr(> z )	
ma1	-0.53259	0.15051	-3.5385	0.0004024	***
sma1	-0.56678	0.27880	-2.0329	0.0420583	*

---  
Signif. codes: 0 '\*\*\*' 0.001 '\*\*' 0.01 '\*' 0.05 '.' 0.1 ' ' 1

```
modelo3 <- Arima(Yt, order = c(0,1,1), seasonal = list(order =  
c(0,1,0)))  
coeftest(modelo3)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)  
ma1 -0.69300    0.11788 -5.8789 4.129e-09 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
modelo4 <- Arima(Yt, order = c(0,1,0), seasonal = list(order =  
c(0,1,1)))  
coeftest(modelo4)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)  
sma1 -1.00000    0.33424 -2.9919 0.002773 **  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

### 3 Validación

#### 3.1 Análisis de los coeficientes estimados

##### 3.1.1 Significación de los coeficientes

```
coeftest(modelo1)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)  
ma1 -0.64678    0.12833 -5.0400 4.656e-07 ***  
sar1 -0.22605    0.16566 -1.3645  0.1724  
sma1 -0.99999    0.18101 -5.5246 3.302e-08 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
coeftest(modelo2)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)  
ma1 -0.53259    0.15051 -3.5385 0.0004024 ***  
sma1 -0.56678    0.27880 -2.0329 0.0420583 *  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
coeftest(modelo3)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)  
ma1 -0.69300    0.11788 -5.8789 4.129e-09 ***  
---  
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
coeftest(modelo4)
```

z test of coefficients:

```
      Estimate Std. Error z value Pr(>|z|)
sma1 -1.00000    0.33424 -2.9919 0.002773 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

### 3.1.2 Examen de la matriz de correlaciones entre los coeficientes

```
vcov(mod1)
      sar1      sar2
sar1 0.008191179 0.003648156
sar2 0.003648156 0.008853282


vcov(mod2)
      sar1      sar2      sar3
sar1 0.007928069 0.005058438 0.002110606
sar2 0.005058438 0.009901841 0.004191203
sar3 0.002110606 0.004191203 0.009298398

vcov(mod3)
      sma1
sma1 0.01084332
```

**Se observa claramente que NO hay coeficientes que esten cerca o sean superiores a 0.9, por tanto, podemos indicar que NO hay problema de multicolinealidad en los modelos propuestos.**


### 3.1.3 Condición de convergencia e invertibilidad

`autoplot(mod1)`




**Dado para el primer modelo dado que los puntos estan dentro del circulo indica que son invertibles y estacionarios.**

`autoplot(mod2)`



**Para el segundo modelo ya que solo presenta la parte de  $ma()$  infiere que la parte autoregresiva ya presenta invertibilidad y estacionariedad. Pero segun el grafico se puede observar que que todo los puntos estan dentro del circulo señal clara de invertibilidad y estacionariedad.**

`autoplot(mod3)`




**Dado que todo los puntos están dentro del circulo lo cual no indica que son invertibles y estacionarios.**

### 3.2 Análisis de los residuos

#### 3.2.1 Media es igual a cero

```
plot(mod1$residuals)
abline(h = 0, col = "red")
t.test(mod1$residuals, mu = 0)
```






One Sample t-test

```
data: mod1$residuals
t = -0.3252, df = 143, p-value = 0.7455
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.7670199  0.5502975
sample estimates:
mean of x
-0.1083612
```

**Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como  $p = 0.7455 > \alpha = 0.05$ , se acepta  $H_0$ , es decir la media es igual a cero.**

```
plot(mod2$residuals)
abline(h = 0, col = "red")
t.test(mod2$residuals, mu = 0)
```




One Sample t-test

```
data: mod2$residuals
t = -0.45491, df = 143, p-value = 0.6499
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.7584022  0.4746337
sample estimates:
mean of x
-0.1418842
```

**Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como  $p = 0.6499 > \alpha = 0.05$ , se acepta  $H_0$ , es decir la media es igual a cero.**

```
plot(mod3$residuals)
abline(h = 0, col = "red")
t.test(mod3$residuals, mu = 0)
```



One Sample t-test

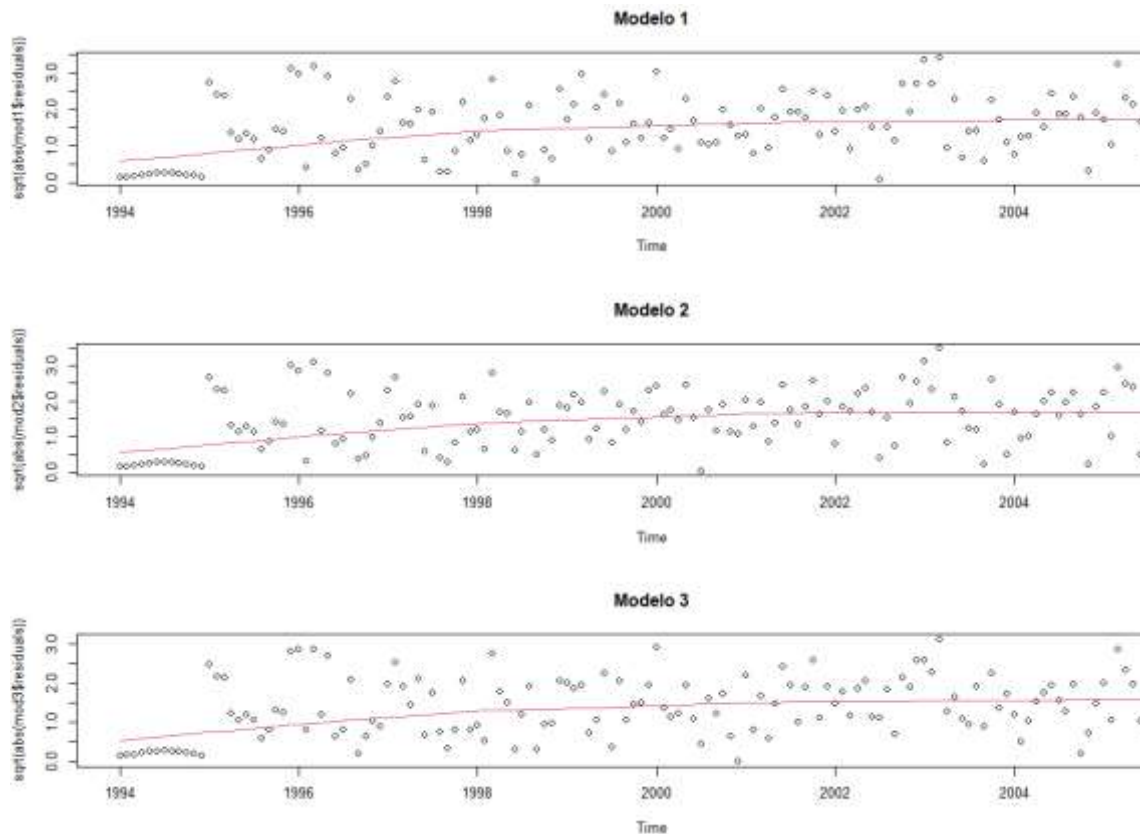
```
data: mod3$residuals
t = -0.58811, df = 143, p-value = 0.5574
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -0.7100319  0.3844116
sample estimates:
mean of x
-0.1628102
```

**Parece indicar que un buen número de residuales están en torno a la media igual a cero. Para confirmar lo mencionado se realiza la prueba t: Como  $p = 0.5574 > \alpha = 0.05$ , se acepta  $H_0$ , es decir la media es igual a cero.**

### 3.2.2 Homocedasticidad o varianza constante

```
par(mfrow = c(3,1))
scatter.smooth(sqrt(abs(mod1$residuals)), lpars=list(col=2), main =
"Modelo 1")
scatter.smooth(sqrt(abs(mod2$residuals)), lpars=list(col=2), main =
"Modelo 2")
scatter.smooth(sqrt(abs(mod3$residuals)), lpars=list(col=2), main =
"Modelo 3")
```

Alumno: Maye Mamani Victor Raul

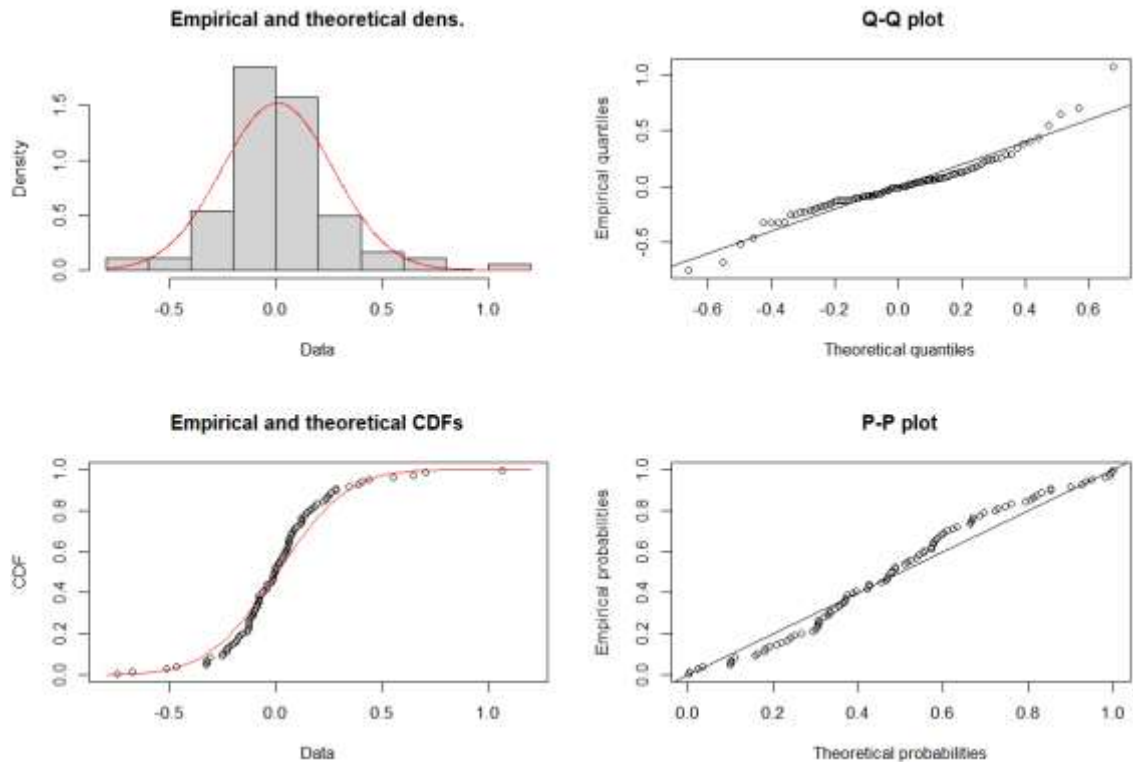


**Se observa que los datos presentan una variabilidad considerable.**

### 3.2.4 Contraste de normalidad

```
ajuste_m1<-fitdistr(data = resid_m1, distr="norm")  
plot(ajuste_m1)  
JB_m1 <- jarque.bera.test(resid_m1)  
JB_m1
```

Alumno: Maye Mamani Victor Raul



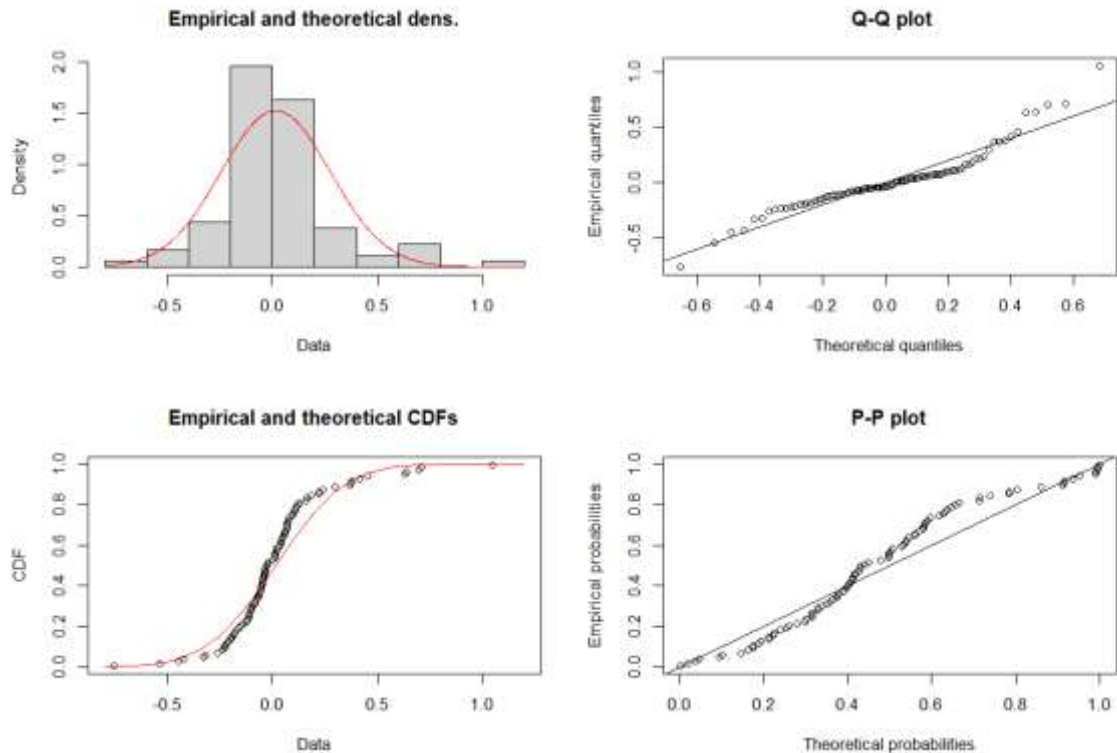
Jarque Bera Test

data: resid\_m1  
X-squared = 41.778, df = 2, p-value = 8.471e-10

**En las figuras se observa que los residuales del modelo 1 no presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como  $p = 0.0000 < 0.05$ , se RECHAZA  $H_0$ , es decir, los residuos NO se aproximan a una distribución normal.**

```
ajuste_m2<-fitdist(data = resid_m2, distr="norm")  
plot(ajuste_m2)  
JB_m2 <- jarque.bera.test(resid_m2)  
JB_m2
```

Alumno: Maye Mamani Victor Raul



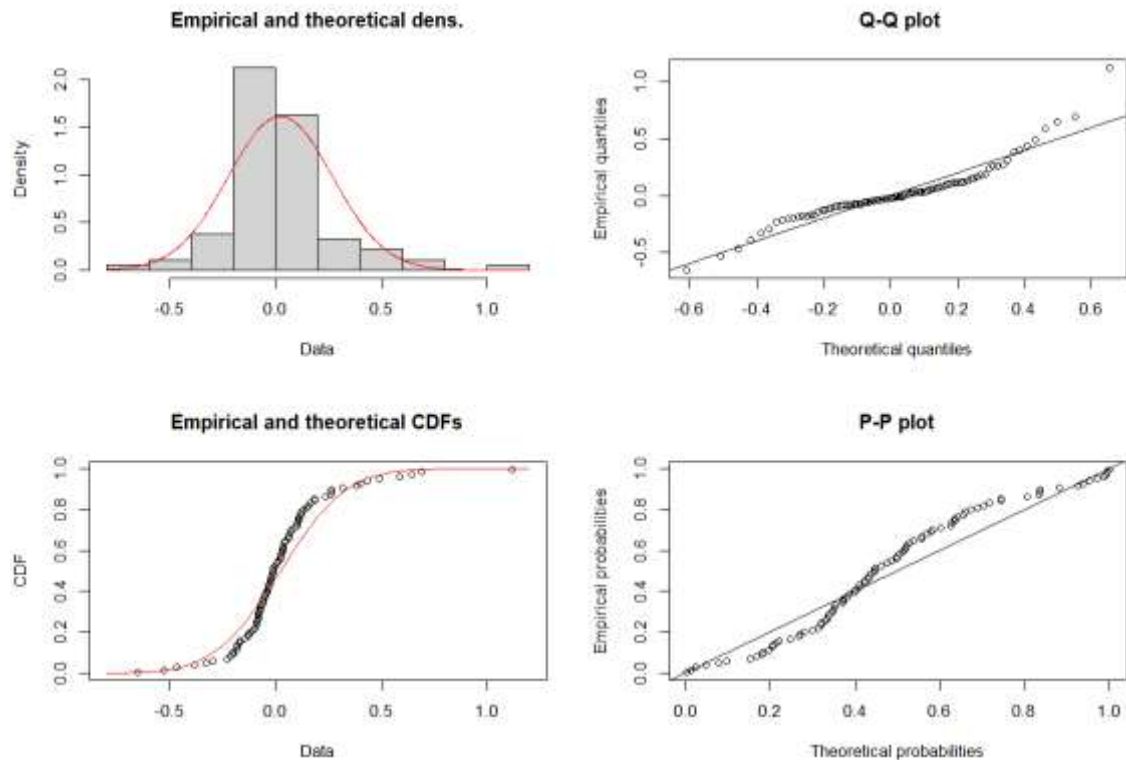
Jarque Bera Test

data: resid\_m2  
X-squared = 47.925, df = 2, p-value = 3.919e-11

**En las figuras se observa que los residuales del modelo 2 no presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como  $p = 0.00011 < 0.05$ , se RECHAZA  $H_0$ , es decir, los residuos NO se aproximan a una distribución normal.**

```
ajuste_m3<-fitdist(data = resid_m3, distr="norm")  
plot(ajuste_m3)  
JB_m3 <- jarque.bera.test(resid_m3)  
JB_m3
```

Alumno: Maye Mamani Victor Raul



Jarque Bera Test

data: resid\_m3  
X-squared = 87.238, df = 2, p-value < 2.2e-16

**En las figuras se observa que los residuales del modelo 3 no presentan indicios de ajuste hacia la distribución normal. En la prueba JB, como  $p = 0.00000 < 0.05$ , se RECHAZA  $H_0$ , es decir, los residuos NO se aproximan a una distribución normal.**


## 4 Pronostico

### 4.1Pronosticos de cada modelo

Modelo 1:


Pronóstico para la serie

```
Pron <- forecast(modelo1,h=12)
plot(Pron)
summary(Pron)
```



### Pronostico vs valores reales

```
plot(Pron, shaded = FALSE, xlab = "Años", ylab = "N° DE ventas", main = "sarima(1,1,0)(0,1,1)")  
lines(Pron$fitted, col = "red")  
legend("topleft", legend=c("SERIE", "PREDICCIÓN", "INTERVALO DE COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"),  
lty=c(1,1,2,1), lwd = 2, cex = 0.6)
```




### Modelo 2: Pronóstico para la serie




Alumno: Maye Mamani Victor Raul

```
Pron2 <- forecast(modelo2,h=12)
plot(Pron2)
summary(Pron2)
```



Pronostico vs valores reales

```
plot(Pron2, shaded = FALSE, xlab = "Años", ylab = "N° DE ventas",
     main = "sarima(0,1,1)(0,1,1)")
lines(Pron2$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE
COINFIANZA AL 95%", "AJUSTE"),col=c("black", "blue", "black", "red"),
lty=c(1,1,2,1), lwd = 2,cex = 0.6)
```




Modelo 3:  
Pronóstico para la serie

```
Pron3 <- forecast(modelo3,h=12)
```


Alumno: Maye Mamani Victor Raul

```
plot(Pron3)
summary(Pron3)
```



Pronostico vs valores reales

```
plot(Pron3, shaded = FALSE, xlab = "Años", ylab = "N° DE ventas", main = "sarima(0,1,1)(0,1,0)")
lines(Pron3$fitted, col = "red")
legend("topleft", legend=c("SERIE", "PREDICCION", "INTERVALO DE COINFIANZA AL 95%", "AJUSTE"), col=c("black", "blue", "black", "red"), lty=c(1,1,2,1), lwd = 2, cex = 0.6)
```



**Métricas del modelo**

**accuracy(modelo1)**

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	1.72136	14.63815	10.3043	1.177992	6.075034	0.5981389
03568487						0.00

**accuracy(modelo2)**

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	2.217023	14.30075	10.39466	1.054772	6.066516	0.6033838
.03435107						-0

**accuracy(modelo3)**

	ME	RMSE	MAE	MPE	MAPE	MASE
ACF1						
Training set	1.409756	15.37879	11.3276	0.7839319	6.51894	0.6575385
6208574						0.0

**AIC(modelo1);BIC(modelo1)**

[1] 348.2515  
[1] 354.9057

**AIC(modelo2);BIC(modelo2)**

[1] 363.5213  
[1] 368.8049

**AIC(modelo3);BIC(modelo3)**

[1] 366.4493  
[1] 369.9717

## Conclusión

1. **Modelo 1:**
  - **RMSE:** 14.63815
  - **MAE:** 10.3043
  - **AIC:** 348.2515
  - **BIC:** 354.9057
2. **Modelo 2:**
  - **RMSE:** 14.30075
  - **MAE:** 10.39466
  - **AIC:** 363.5213
  - **BIC:** 368.8049
3. **Modelo 3:**
  - **RMSE:** 15.37879
  - **MAE:** 11.3276
  - **AIC:** 366.4493
  - **BIC:** 369.9717

Basado en estas métricas y criterios:

- El **Modelo 2** tiene el RMSE más bajo (14.30075) y un MAE comparativamente bajo (10.39466).
- Además, tiene el AIC más bajo (363.5213) y el BIC más bajo (368.8049), lo que indica un mejor ajuste del modelo en comparación con los otros dos.

Por lo tanto, según estas métricas y criterios, el **Modelo 2** sería la elección recomendada debido a su mejor desempeño general en la evaluación de la serie temporal.